EmoLearn — Fiche de synthèse du projet

Type : mémoire de master — prototype de recherche (simulation, OS5)
API : v2.5 — modes simulation / séquence / tuteur
Date : août 2026 (mise à jour 17/08)

---

1. Ce que j'ai développé

J'ai construit un pipeline complet de personnalisation pédagogique adaptative multimodale. Je détecte l'état émotionnel/d'engagement d'un apprenant à partir de deux signaux — visage et voix —, je décide s'il faut intervenir pédagogiquement, puis je génère un contenu adaptatif via un LLM. J'ai également ajouté un tuteur conversationnel, un parcours multi-clips avec règles temporelles, une fusion à pondération continue par incertitude, et plusieurs évaluations instrumentées (fusion, entraînement, forme, similarité, fiabilité).

```
Scénario (clip vidéo + contexte pédagogique)
        |
        v
Perception émotionnelle   Visage (FER, DAiSEE)  +  Voix (SER, IEMOCAP)
        |                 -> fusion 60/40 × confiance (pondération par incertitude)
        v
Décision pédagogique      déclenchement ? + type (A/B/C/D) + template (A1–D5)
        |                 + règles temporelles (urgence sur séquence de clips)
        v
Génération de contenu     LLM (Groq, Llama 3.1) + RAG (ChromaDB) + 20 templates
        |                 + tuteur conversationnel affect-aware (/chat)
        v
Restitution                interface React + export PDF + journal SQLite
```

Deux pipelines (à ne pas confondre)

	Pipeline produit	Banc d'essai (validation)
But	Générer le contenu pédagogique	Valider le moteur de fusion
Visage	Vidéo DAiSEE réelle + FER	Vidéo IEMOCAP
Voix	Audio IEMOCAP apparié par état	Audio IEMOCAP même locuteur, synchronisé
Branché dans l'app	Oui (API + UI)	Non (script hors ligne)

Les deux partagent le même moteur de fusion : ce que je valide au banc d'essai est exactement ce que j'utilise en production.

Contribution que je revendique : une architecture multimodale de bout en bout (perception → décision → génération), avec une évaluation honnête des limites (mapping, appariement, validation humaine partielle).

API principale (v2.5)

Route	Rôle
POST /analyser	Analyse d'un clip (vidéo DAiSEE + audio IEMOCAP)
GET /sequences · POST /analyser/sequence	Parcours multi-clips + règles temporelles
POST /chat	Tuteur conversationnel affect-aware
GET /scenarios · GET /templates · GET /sessions	Référentiels et historique
GET /rag/status · GET /health	Santé RAG / API

---

2. Techniques et algorithmes que j'ai mis en œuvre

2.1 Perception visage — FER

Étape	Ce que j'ai fait
Détection	MediaPipe (BlazeFace ; courte/longue portée + miroir)
Extraction	5 frames réparties sur la vidéo DAiSEE
Classification	HuggingFace dima806/facial_emotions_image_detection (ViT, 7 émotions)
Agrégation	Vote multi-frames (moyenne des probabilités)
Mapping sklearn	Random Forest (GridSearchCV) 7 scores → 4 états, avec échantillon stratifié + oversampling
Fine-tune ViT partiel	Tête 4 classes + couches dégelées (2 ou 4)
Fine-tune ViT complet	Tout le backbone (--unfreeze-all, LR 1e-5) — meilleur F1, modèle runtime models/fer_vit_daisee/

Runtime configurable : EMOLEARN_FER_MAPPING (learned/auto/heuristique) et EMOLEARN_FER_MODE (finetuned/pretrained/auto).

2.2 Perception voix — SER

Étape	Ce que j'ai fait
Signal	Audio réel IEMOCAP (.wav), couverture 100 %
Heuristique	Features librosa (RMS, ZCR, centroïde spectral, pitch pyin) + règles → VAD
Fine-tune tête	superb/wav2vec2-base-superb-er : backbone gelé, tête → 4 états DAiSEE (Confusion via sur/fea)
Fine-tune complet	Tout wav2vec2 dégelé (--unfreeze-all, 1 200 samples, 5 époques, loss class-weighted) → models/ser_wav2vec2_daisee_full/

Runtime : EMOLEARN_SER_METHODE=learned (défaut) ou heuristique.

2.3 Fusion multimodale (+ fiabilité produit)

Composant	Ce que j'ai fait
Prior visage/voix	60 % / 40 % (balayage de sensibilité réalisé)
Pondération continue	Poids effectifs = prior × confiance, puis renormalisation (late fusion)
Repli	Priorité pédagogique seulement si les deux confiances sont nulles
Filtre frames FER	Rejet des frames hésitantes avant moyenne (EMOLEARN_SEUIL_FRAME_FER=0.35)

Plus de seuil dur « gate » : une modalité peu confiante est sous-pondérée, pas forcément ignorée. Éval : scripts/eval_fusion_reliability.py.

2.4 Règles temporelles + parcours séquence

Moteur de règles sur l'historique : déclenchement immédiat, rapide (2–3 clips) ou différé (4–5 clips). Branché dans le pipeline et exposé via /sequences et /analyser/sequence (mode séquence dans l'UI).

2.5 Moteur de décision pédagogique

À partir des 4 scores DAiSEE, je choisis un type puis 1 template parmi 20 :

Type	Rôle	Templates
A	Explication alternative	A1–A5
B	Exemple concret	B1–B5
C	Exercice progressif	C1–C5
D	Encouragement / motivation	D1–D5

Sur 50 scénarios de benchmark, les templates les plus fréquents sont D1, C1, D2/D4, A1, B1 — la

couverture A–D est effective.

2.6 Génération — LLM + RAG + tuteur

Composant	Ce que j'ai fait
LLM	Groq — GPT-OSS 20B (openai/gpt-oss-20b, temp. 0,3), retry/backoff
RAG	ChromaDB (HNSW, cosinus) + embeddings paraphrase-multilingual-MiniLM-L12-v2
Tuteur /chat	Ton, consigne et température adaptés à l'état détecté
Qualité contenu	Métriques de forme + similarité BLEU / ROUGE (cohérence interne par template)

2.7 Stack technique

- Backend : Python 3.11, FastAPI, SQLite
- Frontend : React (interface, export PDF, mode séquence)
- ML/DL : scikit-learn, PyTorch, HuggingFace transformers, OpenCV, MediaPipe (BlazeFace), librosa
- LLM : Groq — openai/gpt-oss-20b (remplace Llama 3.1 8B retiré)
- Tests : pytest (API, fusion, SER, temporel, RAG, entraînement)
- Notebooks : analyses exploratoires OS1–OS4 (DAiSEE, IEMOCAP, FER, décision, RAG)

---

3. Données et mapping

Corpus	Rôle
DAiSEE	Socle : taxonomie d'engagement (4 états × niveaux 0–3), scénarios, déclenchement
IEMOCAP	Voix + banc audiovisuel aligné (même locuteur) pour valider la fusion
Corpus pédagogique	~200 contenus générés + échantillon d'évaluation experts (~60)

Mapping IEMOCAP → DAiSEE (hypothèse documentée)

Émotion IEMOCAP	État DAiSEE
hap, exc	Engagement
neu, sad	Boredom
ang, fru, dis	Frustration
sur, fea	Confusion

Hypothèse de construit, pas une équivalence démontrée. Sensibilité mesurée (§4.7) : jusqu'à 17 % des états changent selon la ré-interprétation.

Audit du corpus : 215/220 contenus OK (97,7 %) ; 5 cas à revoir (templates/ton suspects).

---

4. Résultats d'évaluation

> Origine des métriques (à ne pas confondre)
> - §§4.1–4.3 : entraînement / test des briques (prototype, pas le banc AV aligné)
> - §4.4 et §4.6 : banc d'essai IEMOCAP audiovisuel aligné (même locuteur)
> - §4.5 : proxy produit (pas d'accuracy gold multimodale — visage ≠ voix)
> - §§4.8–4.9 : qualité du contenu LLM
> - §4.10 : fiabilité fusion (pondération par incertitude), cas synthétiques

4.1 Classifieur FER → DAiSEE (Random Forest)

DAiSEE déséquilibré (~75 % Engagement). Variantes sur 1 200 échantillons :

Variante	Accuracy	F1 macro	Rappel Frustration	Note

Baseline déséquilibrée	0,72	0,26	0 %	Collapse
Oversampling seul	0,70	0,30	0 %	Gain F1 léger
Stratifié 300/état (retenu)	0,28	0,27	20 %	test équilibré ; Confusion 41 %

4.2 Fine-tune ViT FER → DAiSEE

Variante	Samples	Époques	Accuracy	F1 macro	Note
Partiel (2	800	3	0,36	0,361	Rappel Frustration 38
Large (4 couches)	~1 566	5	0,378	0,370	N'a pas battu le full
Complet (backbone entier, retenu)	800	5	0,39	0,388	Rappel Frustration 48 %

Le fine-tune complet reste le meilleur compromis ; le runtime garde models/fer_vit_daisee/.

4.3 Fine-tune SER wav2vec2 → DAiSEE

Variante	Samples	Époques	Meilleure Acc.	Meilleur F1 macro
Tête seule (backbone gelé)	600	2	0,300	0,309
Complet (--unfreeze-all, class-weighted)	1 200	5	0,557	0,537

Le fine-tune complet (époque 4) est nettement supérieur à la tête seule. En banc d'essai aligné (§4.4), même la version apprise (tête) passe déjà de 0,263 → 0,487 vs heuristique (+0,224).

4.4 Banc d'essai fusion (n = 80, aligné)

Échantillon = 20 × 4 états (Session 1 IEMOCAP, durée ≥ 1 s, 5 frames, seed 42), même locuteur. Visages détectés : 100 %.

Modalité / approche	Accuracy	Rappel urgents
Visage — FER 1 frame	0,375	0,250
Visage — FER multi-frames	0,412	0,275
Voix — SER heuristique	0,263	0,225
Voix — SER appris (wav2vec2)	0,487	0,200
Fusion — priorité pédagogique	0,338	0,400
Fusion — vote pondéré	0,500	0,125

Gain mesuré	Δ accuracy
SER appris vs heuristique	+0,224
FER multi-frames vs 1 frame	+0,037
Fusion vote vs priorité pédagogique	+0,162
Fusion vote vs meilleure unimodale	+0,013

Arbitrage : vote → accuracy ; priorité pédagogique → rappel des états critiques.

4.5 Proxy pipeline produit (n = 52)

Vérité terrain = état dominant DAiSEE (pas accuracy multimodale gold) :

Métrique	Fusion produit
Accuracy vs état dominant	0,50
Rappel états urgents	1,00

4.6 Sensibilité au poids visage/voix (n = 80)

Poids visage/voix	Accuracy	Rappel urgents
0,5 / 0,5	0,287	0,375
0,6 / 0,4 (retenu)	0,300	0,425
0,7 / 0,3	0,338	0,400
0,8 / 0,2	0,325	0,350
0,9 / 0,1	0,325	0,350

4.7 Sensibilité du mapping (10 039 utterances IEMOCAP)

Variante	% d'états changés
neutre → Engagement	17,0 %
tristesse → Frustration	10,8 %
surprise → Engagement	1,1 %
dégoût → Boredom	0,0 %

4.8 Qualité de forme du corpus LLM (N = 208)

Métrique	Valeur
Longueur moyenne	222 mots (min 113, max 410)
Lisibilité (Kandel-Moles)	95,0
Taux de répétition moyen	0,479
Part dans la cible de longueur	0,832

4.9 Similarité LLM — BLEU / ROUGE (N = 189)

Référence auto = contenu de longueur médiane par template (cohérence interne, pas gold expert) :

Métrique	Moyenne
BLEU-4	0,139
ROUGE-1 F1	0,449
ROUGE-2 F1	0,176
ROUGE-L F1	0,272

Ces scores mesurent la proximité à une référence interne, pas la pertinence pédagogique (réservée à L2).

4.10 Fiabilité fusion — pondération par incertitude (cas synthétiques, n = 6)

Sans prétendre à 100 % de bonnes prédictions en conditions réelles, j'évalue la fusion produit sur 6 cas critiques (modalité bruitée, incertitude totale, etc.) :

Méthode	Accuracy (cas synthétiques)
Pondération continue (w = prior × confiance)	1,000

Exemple : une voix bruitée est sous-pondérée (au lieu de forcer un état urgent erroné).
Repli priorité pédagogique uniquement si les deux confiances sont nulles.

---

5. Validation experte et perspectives

Niveau	Objectif	Statut

L1	Delphi mapping engagement → stratégie	Formulaires prêts (results/forms/) — scores à collecter
L2	Notation enseignante des contenus (≈60)	Formulaires prêts — scores à collecter
L3	Métriques automatiques (forme, fusion, similarité, fiabilité)	Fait
L4	Pilote utilisateurs (n ≈ 30)	À faire

Perspectives prioritaires :
1. Collecter les scores L1/L2 (terrain)
2. Rejouer le banc d'essai aligné avec SER/FER full fine-tune + fusion par incertitude
3. Pilote utilisateurs L4
4. Corpus audiovisuel d'apprentissage vraiment joint (si données)

---

6. Limites que j'assume

#	Tension	Statut
1	Fusion vs unimodal	Compromis mesuré (vote vs priorité pédagogique)
2	Mapping émotions → engagement	Hypothèse + analyse de sensibilité
3	Adaptatif vs simulation	Prototype (pas de captation live MOOC)
4	Appariement visage/voix hétérogène (produit)	Documenté + mitigé via banc aligné
5	Templates non validés par experts	Proposition + protocole prêt
6	Qualité LLM	Forme + similarité mesurées ; fond → L2
7	Déséquilibre DAiSEE	Mitigé (stratifié + fine-tune ViT)
8	Pas d'accuracy gold multimodale produit	Proxy + banc aligné (visage ≠ voix en produit)
9	Confusion peu couverte par la voix (modèle 4 classes d'origine)	Améliorée via fine-tune DAiSEE (sur/fea)
10	Plafond FER (~0,39 F1)	Mitigé par pondération continue selon la confiance
11	Largeur vs profondeur	Contribution = chaîne complète + évaluation critique

---

Message clé : la force du projet n'est pas un score unique élevé, mais une chaîne complète, instrumentée, avec des limites explicites plutôt que dissimulées.