EmoLearn

Extrait pour relecture

Introduction générale — Chapitres 1 et 2

Table des figures — Liste des tableaux — Bibliographie

BRIKI Maram

Version de travail

Note. Cet extrait contient l'Introduction générale, le chapitre 1 (Fondements), le chapitre 2 (État de l'art), la table des figures, la liste des tableaux et la bibliographie citée. Les renvois vers les chapitres ultérieurs peuvent apparaître non résolus.

Table des matières

Table des figures **iv**

Liste des tableaux **v**

Introduction générale **1**

1 Fondements de l'apprentissage adaptatif et de l'engagement **5**

1.1 Introduction 6

1.2 Apprentissage en ligne et MOOC 6

1.2.1 Définition 6

1.2.2 Implication pour l'adaptation 6

1.3 Engagement de l'apprenant 6

1.3.1 Définition 6

1.3.2 Dimensions de l'engagement 7

1.3.3 Mesure de l'engagement 7

1.4 Informatique affective et émotions en apprentissage 7

1.4.1 Rôle des émotions dans l'apprentissage 7

1.4.2 États pertinents pour l'adaptation pédagogique 7

1.4.3 Charge cognitive 8

1.5 Détection multimodale de l'engagement 8

1.5.1 Modalités exploitées 8

1.5.2 Corpus de référence 9

1.5.3 Fusion multimodale 9

1.6 IA générative pour l'éducation 9

1.6.1 Grands modèles de langue 9

1.6.2 Guidage par prompts et patrons 10

1.6.3 Récupération augmentée (RAG) 10

1.7 Conclusion 11

2 État de l'Art **12**
2.1 Introduction 13
2.2 Engagement dans les MOOC : enjeux et cadres théoriques 13
2.2.1 Décrochage massif et rôle de l'engagement 13
2.2.2 Trois dimensions de l'engagement 13
2.2.3 Cadres d'analyse de l'engagement cognitif 14
2.2.4 Émotions d'apprentissage et charge cognitive 15
2.3 Détection automatique de l'engagement 15
2.3.1 Approches textuelles fondées sur les forums 15
2.3.2 Approches visuelles et multimodales 16
2.3.3 Apports et limites des détecteurs 17
2.4 De la détection à l'intervention : IA générative et systèmes adaptatifs . 17
2.4.1 Tuteurs intelligents et adaptation pédagogique 17
2.4.2 Grands modèles de langue, prompts et RAG 18
2.4.3 Génération de contenu conditionnée par le profil psychologique . 19
2.4.4 Outils d'intervention sur les discussions 19
2.4.5 Évaluation de la qualité pédagogique 19
2.5 Synthèse comparative des travaux 20
2.6 Conclusion 22

Bibliographie **24**

Table des figures

1.1 Les trois dimensions classiques de l'engagement. 7
1.2 Taxonomie des quatre états d'engagement retenus (DAiSEE). 8
1.3 Boucle conceptuelle de détection multimodale. 9
1.4 Architecture générale d'un LLM de type Transformer décodeur. 10
1.5 Architecture générale du RAG. 11

Liste des tableaux

2.1 Synthèse comparative des travaux. 20

Introduction générale

L'évolution rapide des technologies numériques et le développement des plateformes éducatives en ligne ont profondément transformé les pratiques d'apprentissage, en particulier à travers la diffusion des cours en ligne ouverts et massifs (MOOC, *Massive Open Online Courses*). Ces dispositifs permettent aujourd'hui de collecter, diffuser et personnaliser des contenus pédagogiques à grande échelle, offrant à des millions d'apprenants un accès élargi à la formation, indépendamment des contraintes géographiques [8, 19]. La crise sanitaire de 2020 a encore accéléré cette dynamique, faisant de l'apprentissage en ligne une composante désormais structurelle des systèmes éducatifs contemporains.

Toutefois, cette évolution s'accompagne d'un constat largement documenté : les MOOC souffrent de taux d'abandon particulièrement élevés. Une part importante des inscrits interrompt son parcours dès les premières semaines, ce qui limite fortement l'efficacité pédagogique réelle de ces dispositifs [42, 61]. Parmi les facteurs explicatifs, la baisse de l'**engagement** de l'apprenant occupe une place centrale [35, 44]. Dans une salle de classe traditionnelle, l'enseignant perçoit en permanence des signaux fins (regard, posture, expression) et adapte spontanément son discours. Cette boucle de régulation disparaît presque entièrement dans les environnements en ligne de masse, où l'apprenant fait face à un contenu figé, identique pour tous et insensible à son état du moment.

Dans ce contexte, plusieurs travaux en informatique affective et en psychologie de l'apprentissage ont établi que les émotions ne sont pas périphériques à la cognition, mais en constituent un rouage essentiel [64, 66]. Des états tels que l'ennui, la confusion ou la frustration influencent directement la profondeur du traitement de l'information, la persévérance et la mémorisation [4, 17]. Une détection inefficace de ces états, combinée à l'absence d'adaptation pédagogique, peut entraîner une dégradation de l'expérience d'apprentissage et favoriser le décrochage. Cette problématique est d'autant plus critique que les décisions pédagogiques doivent idéalement intervenir en temps utile, avant que le désengagement ne s'installe.

Ainsi, ce mémoire s'inscrit dans cette problématique en proposant une approche visant à réunir, au sein d'une même chaîne de traitement, la perception de l'engagement émotionnel et la génération adaptative de contenu pédagogique.

Face à ces enjeux, la question centrale de ce travail est la suivante :

Comment concevoir un dispositif capable d'inférer automatiquement l'état d'engagement d'un apprenant à partir de signaux multimodaux, puis de générer en réponse un contenu pédagogique adapté à cet état, tout en garantissant la cohérence et la traçabilité de la décision pédagogique sous-jacente ?

Cette question se décompose en quatre sous-questions opérationnelles :

— Comment estimer de manière fiable l'état d'engagement à partir de signaux multimodaux hétérogènes (expressions faciales issues de DAiSEE, signal vocal issu de IEMOCAP), et quel gain la fusion apporte-t-elle par rapport à une modalité unique ?
— Comment formaliser une correspondance pédagogiquement justifiable entre les états d'engagement détectés et les stratégies d'intervention, c'est-à-dire un modèle *engagement* $\rightarrow$ *adaptation* ?
— Dans quelle mesure un grand modèle de langue, guidé par des patrons de prompts structurés et ancré par un mécanisme de récupération augmentée (RAG), peut-il produire un contenu pédagogique pertinent et adapté à l'état d'engagement visé ?
— Selon quel protocole peut-on évaluer, de façon honnête et multi-niveaux, la qualité de la perception, la pertinence de la décision et la qualité du contenu généré ?

L'analyse de la littérature montre que, malgré les progrès importants réalisés dans les domaines de la détection de l'engagement et de l'IA générative appliquée à l'éducation, ces deux axes restent majoritairement traités de manière indépendante. D'une part, les modèles de perception multimodale permettent d'inférer l'état affectif d'un apprenant avec une fiabilité croissante [18, 32, 82]. D'autre part, les grands modèles de langue ouvrent la voie à une génération de contenu pédagogique personnalisée à grande échelle [9, 43]. Cependant, ces approches demeurent souvent séquentielles ou fragmentées : la détection n'est pas systématiquement reliée à une décision pédagogique explicite, tandis que la génération n'est pas toujours conditionnée par un état d'engagement mesuré, ce qui limite la capacité des systèmes à restaurer une forme de régulation pédagogique automatique.

Pour répondre à ces limitations, ce mémoire propose un framework hybride nommé EmoLearn, combinant trois briques complémentaires. La couche de **perception** estime l'état d'engagement à partir de signaux visage et voix, en s'appuyant sur les

corpus DAiSEE et IEMOCAP et sur des modèles *fine-tunés* vers la taxonomie des quatre états d'engagement : un Vision Transformer (ViT) pour le visage et un modèle wav2vec2 pour la voix, combinés par un moteur de fusion multimodale. La couche de **décision** formalise un modèle *engagement* → *adaptation* reliant chaque état à un type de contenu et à un patron de génération. Enfin, la couche de **génération** produit un contenu pédagogique adaptatif au moyen d'un grand modèle de langue, guidé par une bibliothèque de vingt patrons structurés et ancré par un module RAG sur une base documentaire pédagogique. Ainsi, EmoLearn vise à passer d'un contenu figé à une adaptation réellement conditionnée par l'état d'engagement détecté.

En résumé, le module de perception anticipe l'état émotionnel de l'apprenant, tandis que les modules de décision et de génération exploitent cette estimation pour produire une intervention pédagogique ciblée, traçable et reproductible.

Les principales contributions de ce travail sont les suivantes :

1. Proposition d'une architecture multimodale de bout en bout reliant perception, décision et génération au sein d'une même chaîne.
2. Formalisation d'un modèle *engagement* → *adaptation* assorti d'une bibliothèque de vingt patrons de génération structurés.
3. Développement d'un module RAG pédagogique ancrant la génération sur une base documentaire vectorisée.
4. Fine-tuning supervisé des modèles de perception (ViT pour le visage et wav2vec2 pour la voix) vers les quatre états d'engagement DAiSEE.
5. Évaluation honnête et instrumentée de la fusion multimodale, incluant l'analyse des compromis entre exactitude globale et sensibilité aux états critiques.
6. Prototype logiciel complet et reproductible, accompagné d'un protocole d'évaluation multi-niveaux.

Méthodologie générale

La démarche adoptée relève de la *recherche orientée conception* (*design science research*), paradigme particulièrement adapté à la conception d'artefacts informatiques répondant à un problème identifié [34]. Elle articule l'analyse d'un problème réel (le décrochage lié à la baisse d'engagement dans les MOOC), la construction d'un artefact (le framework EmoLearn) et son évaluation au regard d'objectifs explicites.

Concrètement, le travail s'organise autour d'une chaîne de traitement en trois étages : un étage de *perception* (FER, SER, fusion), un étage de *décision* (règles temporelles et moteur pédagogique) et un étage de *génération* (RAG et LLM).

Le projet s'appuie sur deux corpus publics de référence. DAiSEE [32] constitue le socle engagement (taxonomie et scénarios), tandis qu'IEMOCAP [10] apporte la modalité vocale et, via un sous-corpus audiovisuel aligné, le support de validation de la fusion. Le prototype repose sur une architecture client-serveur, des modèles de perception fine-tunés (ViT et wav2vec2) vers les quatre états DAiSEE, un LLM accessible par API et un module RAG (ChromaDB).

Structure du mémoire

Le présent mémoire s'ouvre par la présente **introduction générale**, puis s'organise en six chapitres numérotés.

Le **chapitre 1** pose les fondements conceptuels de l'apprentissage adaptatif et de l'engagement (MOOC, émotions, détection multimodale, IA générative).

Le **chapitre 2** propose un état de l'art critique et positionne EmoLearn par rapport aux travaux existants.

Le **chapitre 3** est consacré à la modélisation et à la conception du framework : architecture globale, modèle *engagement* $\rightarrow$ *adaptation*, génération fondée sur des patrons et un module RAG, ainsi que conception du prototype.

Le **chapitre 4** décrit l'implémentation technique de bout en bout.

Le **chapitre 5** expose la validation et les résultats selon un protocole multi-niveaux.

Le **chapitre 6**, enfin, synthétise les contributions, expose les limites et trace des perspectives.

Le mémoire se termine par la bibliographie.

Chapitre 1

Fondements de l'apprentissage adaptatif et de l'engagement

Sommaire

1.1 Introduction 6
1.2 Apprentissage en ligne et MOOC 6
1.2.1 Définition 6
1.2.2 Implication pour l'adaptation 6
1.3 Engagement de l'apprenant 6
1.3.1 Définition 6
1.3.2 Dimensions de l'engagement 7
1.3.3 Mesure de l'engagement 7
1.4 Informatique affective et émotions en apprentissage . . . 7
1.4.1 Rôle des émotions dans l'apprentissage 7
1.4.2 États pertinents pour l'adaptation pédagogique 7
1.4.3 Charge cognitive 8
1.5 Détection multimodale de l'engagement 8
1.5.1 Modalités exploitées 8
1.5.2 Corpus de référence 9
1.5.3 Fusion multimodale 9
1.6 IA générative pour l'éducation 9
1.6.1 Grands modèles de langue 9
1.6.2 Guidage par prompts et patrons 10
1.6.3 Récupération augmentée (RAG) 10
1.7 Conclusion 11

1.1 Introduction

La conception d'un système d'apprentissage adaptatif fondé sur l'engagement émotionnel mobilise un ensemble de notions issues de domaines distincts : sciences de l'éducation, informatique affective, apprentissage multimodal et intelligence artificielle générative. Ces notions sont souvent présentées séparément ; les rassembler permet d'établir un vocabulaire partagé et d'expliciter les hypothèses sur lesquelles repose le pipeline EmoLearn.

Ce chapitre examine les concepts fondamentaux nécessaires à la compréhension de cette architecture. Il aborde successivement l'apprentissage en ligne et les MOOC, la notion d'engagement de l'apprenant, les apports de l'informatique affective, les principes de la détection multimodale, puis les bases de l'intelligence artificielle générative appliquée à l'éducation (LLM, guidage par prompts et RAG).

1.2 Apprentissage en ligne et MOOC

1.2.1 Définition

Les cours en ligne ouverts et massifs (MOOC, *Massive Open Online Courses*) désignent des dispositifs de formation accessibles à distance, le plus souvent sans prérequis d'inscription stricts, et destinés à un public potentiellement très large [8, 19]. Ils reposent typiquement sur des vidéos pédagogiques, des quiz, des forums et un parcours de progression asynchrone.

1.2.2 Implication pour l'adaptation

Dans ce modèle, le contenu est principalement diffusé de manière uniforme. Toute forme d'adaptation automatique suppose donc, en amont, de disposer d'une mesure d'engagement plus fine que les simples proxies de présence (connexion, clics), point développé dans la section suivante.

1.3 Engagement de l'apprenant

1.3.1 Définition

L'engagement désigne la mobilisation cognitive, comportementale et émotionnelle de l'apprenant vis-à-vis de la tâche d'apprentissage [25, 35, 44]. Il ne se réduit pas à la simple présence en ligne (connexion, clics), mais renvoie à une implication active dans le traitement de l'information.

1.3.2 Dimensions de l'engagement

On distingue classiquement :

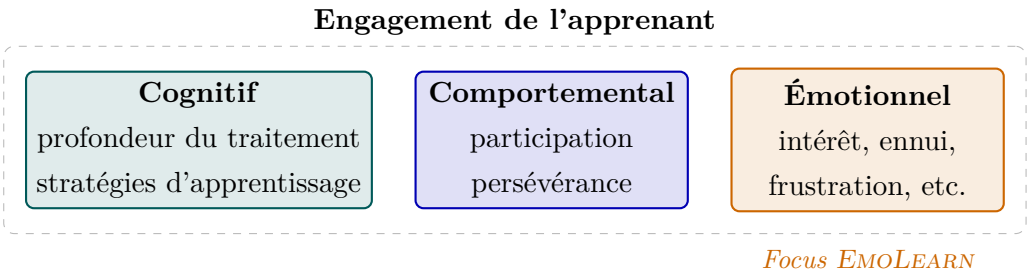


FIGURE 1.1 – Les trois dimensions classiques de l'engagement.

EMOLEARN se concentre principalement sur la dimension émotionnelle / affective, tout en visant un effet sur la persévérance globale.

1.3.3 Mesure de l'engagement

Les indicateurs usuels en e-learning (durée de session, progression, scores) fournissent des *proxies* utiles mais incomplets. Les approches plus récentes mobilisent des signaux multimodaux (visage, voix, posture) pour estimer l'état affectif de manière plus directe [18, 30, 69].

1.4 Informatique affective et émotions en apprentissage

1.4.1 Rôle des émotions dans l'apprentissage

Les travaux en psychologie de l'apprentissage montrent que les émotions modulent l'attention, la mémorisation et la persévérance [4, 17, 31, 57, 64]. Elles ne sont donc pas périphériques à la cognition, mais constitutives du processus d'apprentissage.

1.4.2 États pertinents pour l'adaptation pédagogique

Dans le cadre de ce mémoire, quatre états issus du corpus DAISEE [32] structurent la taxonomie d'engagement :

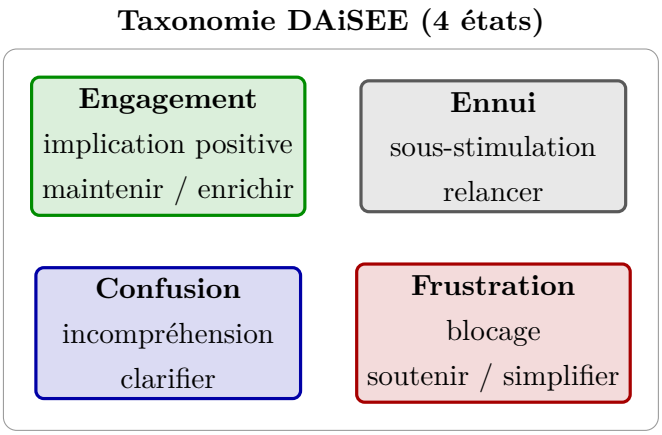


FIGURE 1.2 – Taxonomie des quatre états d'engagement retenus (DAISEE).

Chacun de ces états appelle une stratégie pédagogique distincte.

1.4.3 Charge cognitive

La théorie de la charge cognitive rappelle qu'un contenu trop dense ou mal séquencé favorise la confusion et l'abandon [70, 71]. La théorie de l'apprentissage multimédia complète ce cadre : la conception des messages (texte, image, rythme) conditionne la charge utile [59]. L'adaptation du niveau d'explication, du rythme et du type d'exemple constitue dès lors un levier central des systèmes d'apprentissage adaptatifs.

1.5 Détection multimodale de l'engagement

1.5.1 Modalités exploitées

La détection automatique de l'engagement peut s'appuyer sur :

— le **visage** (expressions faciales, regard) ;
— la **voix** (prosodie, intensité, variations émotionnelles) ;
— éventuellement la posture ou des signaux physiologiques.

EMOLEARN combine les deux premières modalités, à partir de clips vidéo et audio annotés (hors temps réel), plutôt que de traces textuelles de forums ou de capteurs physiologiques.

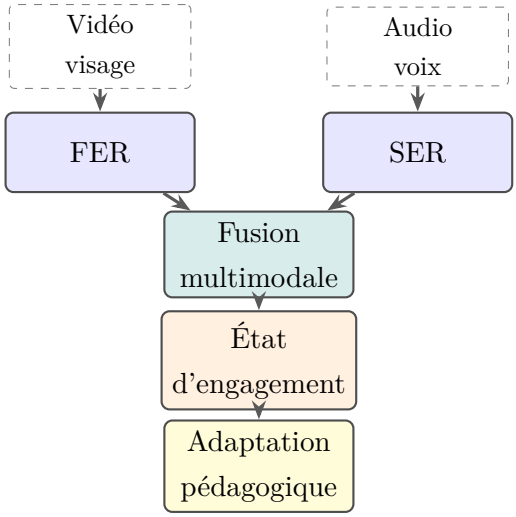


FIGURE 1.3 – Boucle conceptuelle de détection multimodale.

1.5.2 Corpus de référence

Deux corpus publics fondent la chaîne de perception :

— DAiSEE [32] pour l'engagement facial annoté ;

— IEMOCAP [10] pour l'émotion vocale et, via un sous-corpus audiovisuel, la validation de la fusion alignée.

1.5.3 Fusion multimodale

La fusion vise à combiner des sources hétérogènes pour obtenir une décision plus robuste qu'une modalité seule [26, 49]. Elle soulève toutefois des questions de pondération, de désaccord inter-modalités et de déséquilibre des classes, qui seront traités dans la conception et la validation du système.

1.6 IA générative pour l'éducation

1.6.1 Grands modèles de langue

Les grands modèles de langue (LLM, *Large Language Models*) sont des réseaux de neurones entraînés à prédire le prochain token d'une séquence à partir d'un très grand corpus textuel [9, 21, 62, 77, 83]. Architecturée autour du *Transformer* décodeur, cette famille de modèles suit un pipeline strictement séquentiel (figure 1.4) : le texte d'entrée est d'abord *tokenisé* (mots ou sous-mots convertis en identifiants numériques), puis ces identifiants passent dans une couche d'*embeddings* combinée à un encodage de position, avant d'entrer dans une pile de blocs d'*attention* et de couches *feed-forward*.

Une tête de langage produit enfin la distribution sur le vocabulaire. La génération est *auto-régressive* : chaque token prédit est réinjecté pour produire le suivant.

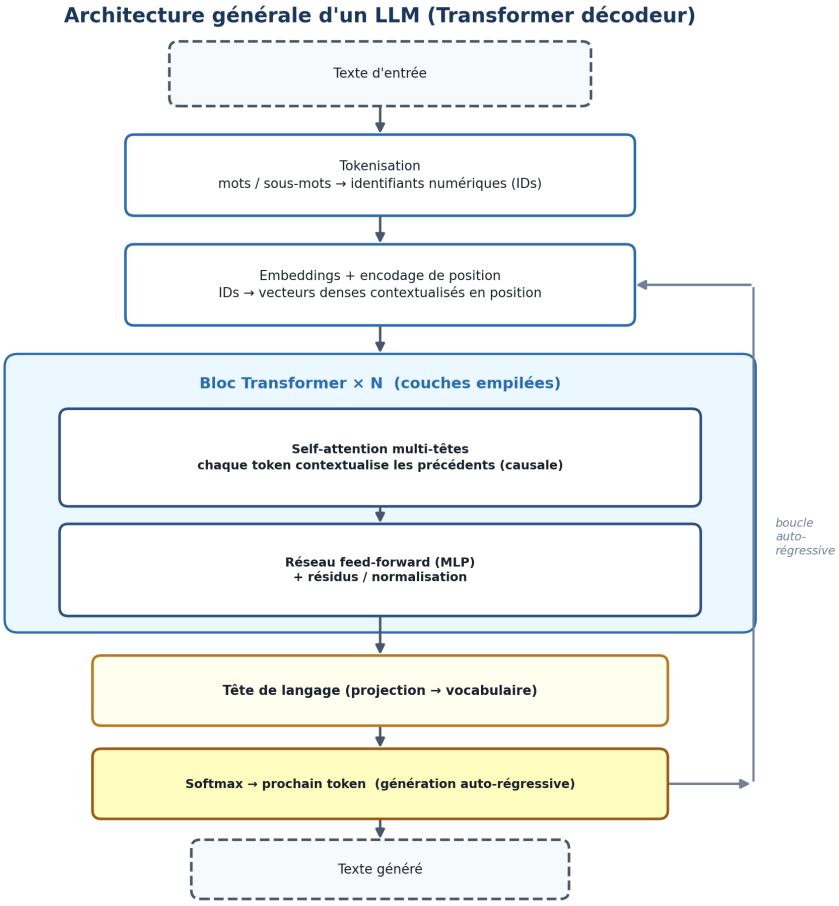


FIGURE 1.4 – Architecture générale d'un LLM de type Transformer décodeur.

En éducation, ces modèles permettent de générer, à la demande, des explications, reformulations, analogies ou encouragements en langage naturel [43, 56, 79, 85]. Ils offrent ainsi une voie crédible pour produire des contenus pédagogiques personnalisés à grande échelle.

1.6.2 Guidage par prompts et patrons

La qualité du contenu généré dépend fortement du guidage [51, 80, 81]. Une bibliothèque de patrons de prompts structurés permet de conditionner la génération selon l'état d'engagement détecté et le type d'intervention pédagogique souhaité.

1.6.3 Récupération augmentée (RAG)

Le mécanisme de *Retrieval-Augmented Generation* (RAG) [23, 27, 47] ancre la génération sur des documents de référence indexés dans une base vectorielle (figure 1.5).

Les documents sont d'abord découpés et vectorisés (indexation hors ligne). À l'exécution, la question est embedée puis confrontée à l'index pour récupérer les passages les plus pertinents ; ces passages enrichissent le prompt transmis au LLM, qui produit une réponse ancrée. Ce dispositif réduit le risque d'hallucinations factuelles et renforce la cohérence pédagogique des contenus produits.

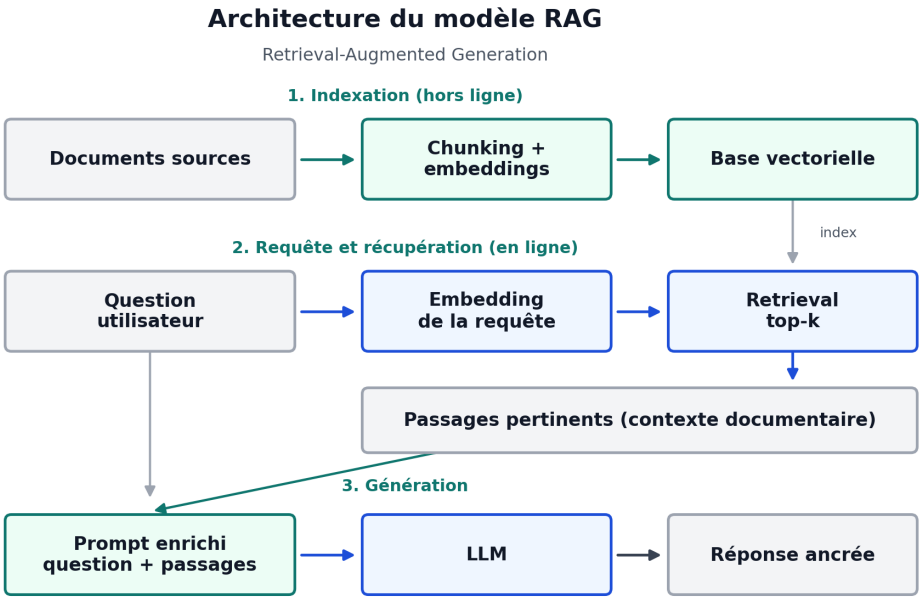


FIGURE 1.5 – Architecture générale du RAG.

1.7 Conclusion

Ce chapitre a rappelé le socle conceptuel sur lequel s'appuie EMOLEARN : la définition des MOOC et l'enjeu d'adaptation, la centralité de l'engagement émotionnel, les bases de la détection multimodale et le potentiel de l'IA générative guidée et ancrée documentairement. Le chapitre suivant examine l'état de l'art correspondant et positionne le présent travail par rapport aux approches existantes.

Chapitre 2

État de l'Art

Sommaire

2.1 Introduction 13

2.2 Engagement dans les MOOC : enjeux et cadres théoriques 13

2.2.1 Décrochage massif et rôle de l'engagement 13

2.2.2 Trois dimensions de l'engagement 13

2.2.3 Cadres d'analyse de l'engagement cognitif 14

2.2.4 Émotions d'apprentissage et charge cognitive 15

2.3 Détection automatique de l'engagement 15

2.3.1 Approches textuelles fondées sur les forums 15

2.3.2 Approches visuelles et multimodales 16

2.3.3 Apports et limites des détecteurs 17

2.4 De la détection à l'intervention : IA générative et systèmes adaptatifs 17

2.4.1 Tuteurs intelligents et adaptation pédagogique 17

2.4.2 Grands modèles de langue, prompts et RAG 18

2.4.3 Génération de contenu conditionnée par le profil psychologique 19

2.4.4 Outils d'intervention sur les discussions 19

2.4.5 Évaluation de la qualité pédagogique 19

2.5 Synthèse comparative des travaux 20

2.6 Conclusion 22

2.1 Introduction

Après les fondements posés au chapitre 1, ce chapitre situe EmoLearn dans la littérature récente. La régulation pédagogique automatique d'un apprenant isolé devant un écran relève de deux axes de recherche complémentaires, encore trop souvent traités séparément.

Le premier axe porte sur la **détection** de l'engagement. Les travaux s'appuient soit sur les traces textuelles des forums (présence cognitive, émotions épistémiques), soit sur des signaux multimodaux (visage, voix, posture). Le second axe porte sur l'**intervention** : systèmes de tutorat intelligent, stratégies d'adaptation, et, plus récemment, génération de contenu par grands modèles de langue. La convergence de ces deux axes (percevoir un état, décider d'une stratégie, produire un contenu) constitue la direction la plus prometteuse, et aussi la moins couverte de bout en bout.

Ce chapitre est organisé en trois niveaux progressifs, selon la logique retenue pour un état de l'art de mémoire. Nous examinons d'abord les enjeux d'engagement dans les MOOC et les cadres théoriques qui permettent de le décrire. Nous analysons ensuite les méthodes de détection automatique, en distinguant les approches textuelles fondées sur les forums et les approches visuelles ou multimodales. Nous présentons enfin les systèmes qui passent de la détection à l'intervention, des tuteurs intelligents historiques aux dispositifs génératifs contemporains. Une synthèse comparative identifie les lacunes que le chapitre **??** vise à combler.

2.2 Engagement dans les MOOC : enjeux et cadres théoriques

2.2.1 Décrochage massif et rôle de l'engagement

Les analyses empiriques confirment que le décrochage n'est pas uniquement dû à des contraintes externes (temps, prérequis) : la baisse d'engagement cognitif, comportemental et émotionnel constitue un facteur central [35, 44], avec des taux de complétion souvent proches de 10 % [52, 67]. Restaurer une adaptation automatique suppose donc, en amont, de mesurer l'engagement autrement que par de simples proxies de présence (clics, durée de session).

2.2.2 Trois dimensions de l'engagement

La définition aujourd'hui la plus partagée distingue trois composantes [25] :

— l'**engagement comportemental** (participation, persévérance, effort observable) ;

— l'**engagement cognitif** (profondeur du traitement, stratégies d'apprentissage, présence cognitive) ;
— l'**engagement émotionnel** (intérêt, ennui, confusion, frustration, sentiment d'affiliation).

Les traces de plateforme capturent surtout la première dimension. Les forums donnent un accès partiel à la seconde. La troisième, pourtant déterminante pour la motivation et la persévérance [17, 64], reste la plus difficile à inférer sans capteurs affectifs. EmoLearn se concentre sur cette dimension émotionnelle, tout en visant un effet sur la persévérance globale.

Liu *et al.* montrent, sur 8 867 apprenants d'un forum MOOC, que engagement émotionnel et engagement cognitif sont liés et prédisent conjointement la réussite : les émotions positives et la confusion contribuent davantage à une cognition de haut niveau que les émotions négatives, et les indicateurs co-occurrents sont plus fiables qu'un facteur isolé [52]. Ce résultat justifie de ne pas réduire l'engagement à un score unique, et d'associer à chaque état (ennui, confusion, frustration, engagement) une stratégie pédagogique distincte.

2.2.3 Cadres d'analyse de l'engagement cognitif

Lorsque le signal disponible est textuel, trois cadres dominent la littérature de détection dans les forums [68].

Le modèle de *Community of Inquiry* (CoI) [28] décompose l'expérience d'apprentissage en ligne en présences sociale, enseignante et cognitive. La présence cognitive s'opérationnalise en quatre phases (événement déclencheur, exploration, intégration, résolution) et sert de référence à de nombreux classifieurs automatiques [38, 54, 68].

Le cadre ICAP (*Interactive, Constructive, Active, Passive*) [12] relie le mode d'engagement à la qualité des apprentissages : plus l'activité est constructive ou interactive, plus le traitement est profond. Il est largement utilisé pour coder les messages de forums [68].

Ces cadres sont précieux pour l'analyse *a posteriori* des discussions. Ils ne couvrent toutefois pas la situation visée par EmoLearn : un apprenant seul, devant une vidéo de cours, sans produire de texte, dont l'état affectif doit être estimé en temps quasi réel pour déclencher une intervention. La taxonomie DAiSEE (engagement, ennui, confusion, frustration) [32] est alors plus opératoire, car elle relie directement un état observable à un besoin pédagogique.

2.2.4 Émotions d'apprentissage et charge cognitive

Les émotions ne sont pas périphériques à la cognition : elles modulent l'attention, la persévérance et la mémorisation [64, 66]. La dynamique confusion–frustration–ennui, documentée par D'Mello et Graesser, montre qu'un épisode de confusion résolu favorise l'apprentissage, tandis qu'une confusion non résolue dérive vers la frustration puis l'ennui [4, 17]. Baker *et al.* concluent qu'il vaut mieux être frustré qu'ennuyé : la frustration signale encore un investissement, l'ennui une désengagement déjà avancé [4].

La théorie de la charge cognitive [70, 71] éclaire le même phénomène sous un autre angle : un contenu trop dense favorise la confusion ; un contenu sous-stimulant favorise l'ennui. La théorie de l'apprentissage multimédia [59] et les méta-analyses sur les émotions en environnements technologiques [31, 57] confirment qu'un système adaptatif doit ajuster la complexité, le rythme et le type d'exemple en fonction de l'état détecté, plutôt que de proposer un unique parcours moyen.

2.3 Détection automatique de l'engagement

La détection automatique vise à substituer, au questionnaire ou à l'observation humaine, un estimateur reproductible. Deux familles de signaux structurent l'état de l'art : le **texte** des forums, abondant dans les MOOC, et les **signaux perceptifs** (visage, voix, posture), plus proches de la régulation en classe.

2.3.1 Approches textuelles fondées sur les forums

Sakeef *et al.* proposent une revue des cadres (CoI, ICAP, KCSA) et des méthodes de TALN / apprentissage profond utilisées pour détecter l'engagement cognitif dans les forums [68]. Ils soulignent que l'annotation manuelle est trop coûteuse pour un suivi en continu, et que l'automatisation devient indispensable. Ils rappellent aussi une limite structurelle : l'absence de indices visuels et auditifs dans le texte rend l'inférence de l'état interne partielle. Cette limite motive, pour EmoLearn, le recours aux modalités visage et voix (corpus annotés) plutôt qu'au seul forum.

Hu, Ferreira Mello et Gašević comparent un CNN à des forêts aléatoires fondées sur des traits linguistiques pour classer la présence cognitive selon le CoI [38]. Le CNN atteint un κ de Cohen de 0,528, comparable aux approches classiques, avec une généralisabilité inter-cours similaire. L'apport principal est l'explicabilité (XAI) au niveau des mots, qui complète l'importance des descripteurs de la forêt aléatoire. Le travail reste toutefois une tâche de *catégorisation* de messages, sans lien avec une intervention pédagogique automatique.

Liu *et al.* (2022) introduisent BERT-CNN pour détecter conjointement l'engagement émotionnel et cognitif dans les discussions MOOC [52]. Par rapport aux modèles antérieurs, le F1 s'améliore d'environ 10 % (émotion) et 8 % (cognition). L'analyse par équations structurelles sur 8 867 apprenants confirme l'effet combiné des deux dimensions sur la réussite. Méthodologiquement, le papier établit qu'un détecteur robuste et interprétable est un prérequis à toute régulation ; opérationnellement, il s'arrête à la prédiction de la réussite, sans générer de contenu adaptatif.

MOOC-BERT pousse plus loin le pré-entraînement : le modèle est pré-entraîné sur des discussions non étiquetées issues de plusieurs MOOC et disciplines, puis utilisé pour identifier la présence cognitive [54]. Il surpasse les algorithmes représentatifs d'apprentissage automatique et de deep learning, y compris en généralisation inter-cours, et permet une analyse longitudinale de l'évolution des phases cognitives. Là encore, la boucle s'arrête à l'aide à l'enseignant : fournir un diagnostic, non produire l'intervention.

Liu *et al.* (2021) articulent analyse de réseaux sociaux et analyse de réseaux épistémiques sur 3 925 participants d'un forum MOOC [55]. Les groupes à haute et basse réussite diffèrent significativement en centralité ; les connexions cognitives sont plus fortes chez les apprenants performants et dans les communautés animées par l'enseignant. Ce résultat éclaire le rôle de l'accompagnement, mais concerne une dynamique *collective* (forum), distincte du scénario *individuel* visé par EmoLearn.

2.3.2 Approches visuelles et multimodales

Lorsque l'apprenant ne produit pas de texte (cas typique du visionnage d'une vidéo de cours), le signal pertinent redevient perceptif. Picard a fondé l'informatique affective [66] ; Whitehill *et al.* ont montré qu'un classifieur d'expressions faciales peut estimer l'engagement d'un étudiant avec une fiabilité comparable à celle d'annotateurs humains [82]. Les revues récentes de reconnaissance d'expressions faciales profondes [48] et les architectures Transformer [20, 87] ont nettement relevé le niveau de ces estimateurs. En salle de classe, des approches par vision estiment l'engagement visible [30, 60] ou le décrochage attentionnel (*mind wandering*) [7, 39]. Sur DAiSEE et des scénarios d'e-learning, des réseaux hybrides CNN/TCN et des descripteurs faciaux multimodaux ont été proposés [1, 5, 33]. La méta-analyse de D'Mello rappelle que les états discrets pertinents en apprentissage médiatisé (ennui, confusion, frustration, engagement) ont des incidences relatives stables, et que la fusion multimodale peut améliorer la robustesse au prix de questions de calibration [18, 26, 49, 69].

Deux corpus publics structurent aujourd'hui cet axe. DAiSEE fournit des vidéos d'apprenants annotées en quatre états d'engagement, avec une intensité de 0 à 3 [32] ; la

classe *Engagement* domine largement, ce qui rend l'accuracy globale insuffisante comme seule métrique. IEMOCAP offre un signal vocal riche et, dans sa version audiovisuelle, un cadre où visage et voix proviennent du même locuteur [10]. EmoLearn s'appuie explicitement sur ces deux ressources complémentaires : le premier pour la taxonomie d'engagement facial, le second pour l'émotion vocale.

Xiong, Guo et Xu proposent un CNN-Transformer qui combine l'information fine des expressions faciales (CNN) et l'information plus grossière de la posture (Transformer), en réduisant le clutter de fond [84]. Sur un jeu de données de classe réelle, annoté par crowdsourcing puis validation experte, le modèle atteint 92,9 % d'accuracy et surpasse plusieurs architectures de deep learning. Ce travail est le plus proche d'EmoLearn du point de vue du *signal* (vision en situation d'apprentissage). Il s'en distingue toutefois sur deux points décisifs : il ne fusionne pas la voix, et il ne relie pas la détection à une génération de contenu. L'identification s'arrête au diagnostic.

Côté voix, le passage des descripteurs acoustiques classiques aux représentations auto-supervisées (wav2vec 2.0, SUPERB) a transformé la reconnaissance d'émotions vocales [46, 65, 86]. Le fine-tuning de wav2vec 2.0 [11] et les architectures Transformer [78] réduisent notamment l'écart de performance sur la valence, longtemps le point faible du SER. Ces avancées justifient le choix d'EmoLearn de fine-tuner un encodeur de parole vers la taxonomie DAiSEE, plutôt que de s'en tenir à des seuils acoustiques.

2.3.3 Apports et limites des détecteurs

Trois constats se dégagent. Premièrement, l'état de l'art textuel (BERT-CNN, MOOC-BERT, CNN+XAI) est mature pour les forums, mais aveugle dès que l'apprenant ne poste pas. Deuxièmement, l'état de l'art visuel (Whitehill, DAiSEE, CNN-Transformer) montre qu'une détection faciale fiable est possible, mais reste rarement multimodale (visage *et* voix) et rarement évaluée au-delà de l'accuracy, malgré le déséquilibre des classes. Troisièmement, presque aucun de ces détecteurs ne ferme la boucle : détecter n'est pas encore intervenir. C'est précisément le passage que la section suivante examine.

2.4 De la détection à l'intervention : IA générative et systèmes adaptatifs

2.4.1 Tuteurs intelligents et adaptation pédagogique

Les systèmes de tutorat intelligent (ITS) combinent historiquement un modèle de l'apprenant, un modèle pédagogique et une interface adaptative [76]. Ils s'appuient sur des

règles explicites ou des modèles cognitifs (traçage bayésien des connaissances, théorie des espaces de connaissances) et sur un contenu *pré-auteuré*. VanLehn montre que les meilleurs ITS approchent l'efficacité d'un tuteur humain, à condition que le domaine soit bien modélisé [76]. Leur limite, dans un MOOC aux contenus ouverts et aux états affectifs fluctuants, est double : le contenu ne peut pas être entièrement pré-écrit pour chaque état, et le modèle de l'apprenant est surtout cognitif, rarement émotionnel, même si des travaux récents visent une explication personnalisée des décisions de tuteurs [14].

Les stratégies d'adaptation classiques distinguent simplification, enrichissement, remédiation et encouragement. EmoLearn les opérationnalise via une matrice *état* → *type de contenu* (explication, exemple, exercice, encouragement) et des règles temporelles sur les séquences de clips. Le moteur reste volontairement interprétable : chaque adaptation doit être justifiable par l'état détecté, la stratégie retenue et le patron mobilisé.

2.4.2 Grands modèles de langue, prompts et RAG

Les LLM [9, 21, 62, 63, 73, 74, 77] permettent de produire, à la demande, des explications, reformulations et exercices en langage naturel. Kasneci *et al.* recensent les opportunités (personnalisation, accessibilité) et les risques (hallucinations, biais, absence de traçabilité) de leur usage éducatif [43]. Les revues 2023–2024 confirment à la fois le potentiel et les tensions éthiques, pédagogiques et d'intégrité académique [6, 13, 15, 16, 22, 24, 29, 36, 41, 50, 56, 58, 72, 75, 79, 85]. Sans guidage, un LLM produit un texte libre dont la forme pédagogique et la fidélité factuelle ne sont pas garanties.

Deux mécanismes d'encadrement s'imposent. Le *prompt engineering* structure la génération par un rôle, un format, un ton et une longueur [51, 80, 81]. La génération augmentée par récupération (RAG) [2, 23, 27, 40, 47] ancre le prompt sur des passages extraits d'une base documentaire, ce qui réduit les inventions factuelles. En contexte pédagogique, le RAG permet d'adosser le contenu à des fiches de cours validées, mécanisme retenu par EmoLearn.

Liu *et al.* (2025) évaluent les LLM non pas comme générateurs de cours, mais comme classifieurs d'engagement textuel [53]. Leur méthode AGKA enrichit le prompt par les définitions extraites des guides d'annotation et par quelques exemples typiques. GPT-4 [62] et LLaMA 3 70B [21] ainsi augmentés rivalisent avec BERT/RoBERTa fine-tunés sur des tâches binaires, mais restent en retrait sur les taxonomies multi-classes sémantiquement proches. Ce résultat est doublement utile : il confirme que le guidage par consignes d'annotation améliore les LLM en éducation, et il rappelle qu'un LLM n'est pas, à lui seul, un détecteur multimodal d'états affectifs. EmoLearn inverse la perspective : le LLM n'y classifie pas l'engagement, il *génère* le contenu une fois l'état

décidé par la couche de perception.

2.4.3 Génération de contenu conditionnée par le profil psychologique

Hu et Shao proposent PAGE (*Psychologically-Aware Generative Education*), un système GenAI qui adapte le style, la difficulté et les mécanismes de soutien au profil Big Five et au feedback émotionnel en temps réel [37]. Sur 200 étudiants, PAGE améliore la satisfaction émotionnelle (4,4/5 contre 3,6/5), le taux de complétion des tâches (87,6 % contre 72,3 %) et la durée d'étude (+34 %) par rapport à un système adaptatif classique ; le bénéfice est particulièrement marqué pour les étudiants à neuroticisme élevé (baisse de 48 % du décrochage). PAGE est le travail le plus proche d'EmoLearn du point de vue de la *génération* : il relie un signal affectif à un contenu produit par LLM.

Trois écarts demeurent. Premièrement, l'émotion y est un feedback (souvent déclaratif ou de surface), et non une estimation multimodale visage–voix fondée sur des corpus publics. Deuxièmement, l'adaptation est pilotée par un profil de personnalité relativement stable, alors qu'EmoLearn vise un état d'engagement *momentané* (confusion de cette minute, ennui de ce clip). Troisièmement, PAGE ne documente pas de moteur de décision explicite ni d'ancrage RAG : la génération n'est pas contrainte par une bibliothèque de patrons traçables ni par un corpus de fiches pédagogiques.

2.4.4 Outils d'intervention sur les discussions

Kong *et al.* évaluent un outil de représentation des discussions assisté par IA (représentations comportementales, cognitives, ou mixtes) auprès de 122 étudiants [45]. L'outil n'améliore pas significativement la motivation, mais augmente la présence cognitive de haut niveau et la performance, et module positivement le lien motivation–présence cognitive–réussite. Il s'agit d'une intervention *sur le forum* (rendre visible le processus collaboratif), non d'une génération de contenu de cours conditionnée par l'état d'un apprenant isolé. Le résultat confirme néanmoins qu'une médiation IA, si elle est bien conçue, peut élever le niveau cognitif, argument en faveur d'une boucle détection–intervention, à condition d'en changer le canal (vidéo de cours plutôt que fil de discussion).

2.4.5 Évaluation de la qualité pédagogique

La qualité du contenu généré se juge sur des critères humains (pertinence, clarté, adéquation à l'état) complétés par des métriques automatiques de forme (longueur, lisibilité, respect du patron). Aucune métrique automatique ne se substitue à une validation

experte ou utilisateur [37, 43]. Les travaux de détection rapportent surtout des F1 et des κ ; les travaux génératifs rapportent des scores de satisfaction. Un protocole multi-niveaux (perception, décision, génération) reste rare. C'est l'un des choix méthodologiques d'EmoLearn, détaillé au chapitre **??**.

2.5 Synthèse comparative des travaux

Les tableaux suivants proposent une synthèse comparative des travaux récents :

Table 2.1: Synthèse comparative des travaux.

Référence	Approche	Contexte	Forces	Limites	Résultats clés
Cadres théoriques, enjeux MOOC et corpus					
Daniel [19] ; Breslow *et al.* [8]	Analyse de plateformes MOOC	Formation en ligne massive	Accès ouvert, données à grande échelle	Pas de détection d'état affectif	Démocratisation de l'accès, pédagogie à l'échelle
Onah *et al.* [61] ; Jordan [42] ; Reich et Ruipérez-Valiente [67]	Statistiques de rétention	Achèvement des MOOC	Diagnostic robuste du décrochage	Constat sans levier d'intervention	Abandon précoce ; taux moyen $\approx 10\,\%$
Kizilcec *et al.* [44] ; Hew [35]	Clustering de trajectoires ; études de cas	Engagement dans les MOOC	Identification de sous-populations et de leviers	Proxies comportementaux (clics, progression)	L'engagement explique une part majeure du décrochage
Fredricks *et al.* [25]	Synthèse conceptuelle	Psychologie de l'éducation	Trois dimensions (comportement, cognition, émotion)	Pas d'estimateur automatique	Cadre de référence encore dominant
Garrison *et al.* [28]	Community of Inquiry (CoI)	Discussions en ligne	Quatre phases de présence cognitive	Conçu pour les forums, pas pour la vidéo	Schéma d'annotation largement repris
Chi et Wylie [12]	Taxonomie ICAP	Engagement cognitif	Lien mode d'activité → apprentissage	Codage d'activités, pas d'affect facial/vocal	Plus l'activité est constructive, plus le traitement est profond
Picard [66]	Informatique affective	Reconnaissance d'émotions	Fondement théorique de la détection	Socle, sans pipeline pédagogique	L'affect est mesurable et actionnable
Pekrun [64]	Théorie contrôle–valeur	Émotions d'accomplissement	Lien valence / activation / performance	Pas d'opérationnalisation logicielle	Les émotions modulent attention et persévérance
D'Mello et Graesser [17] ; Baker *et al.* [4]	Dynamique d'états affectifs	Apprentissage complexe médiatisé	Séquence confusion–frustration–ennui	Pas de génération de contenu	Mieux vaut être frustré qu'ennuyé
D'Mello [18]	Méta-analyse	États affectifs en EIAH	Incidence relative des états ; fusion multimodale	Synthèse, pas de système	Ennui, confusion, engagement et frustration sont les états clés
Sweller [70]	Théorie de la charge cognitive	Conception pédagogique	Explique surcharge et sous-stimulation	Théorie, sans détecteur	Ajuster la complexité au profil de l'apprenant

Suite à la page suivante...

Suite du tableau 2.1

Référence	Approche	Contexte	Forces	Limites	Résultats clés
DAiSEE [32]	Corpus vidéo annoté	Engagement « in the wild »	Quatre états, intensité 0–3	Fort déséquilibre de classes	Taxonomie opératoire pour la détection faciale
IEMOCAP [10]	Corpus audiovisuel	Émotion conversation-nelle	Voix riche, visage et voix alignés	Taxonomie émotionnelle, pas d'engagement MOOC	Référence SER ; cadre de fusion alignée
Détection de l'engagement, ITS et génération adaptative					
Sakeef *et al.* [68]	Revue CoI / ICAP / KCSA + TALN	Forums de cours en ligne	Cartographie des cadres et des méthodes IA	Texte seul ; pas de webcam/micro	L'automatisation du codage est indispensable au suivi continu
Hu *et al.* [38]	CNN + XAI	Présence cognitive (CoI)	Explicabilité au niveau des mots	Texte seul ; généralisabilité limitée	κ de Cohen = 0,528, comparable aux forêts aléatoires
Liu *et al.* [55]	SNA + ENA	Forum MOOC (3 925 apprenants)	Lien réseau social / traitement cognitif / réussite	Analyse collective, hors temps réel	Centralité et connexions cognitives plus fortes chez les performants
Liu *et al.* [52]	BERT-CNN	Forums MOOC (8 867 apprenants)	Détection conjointe émotion + cognition	Pas d'intervention générée	F1 +10 % (émotion) et +8 % (cognition) ; effet combiné sur la réussite
Liu *et al.* [54]	MOOC-BERT (pré-entraînement multi-cours)	Présence cognitive dans les MOOC	Généralisation inter-cours, sans ingénierie de traits	Diagnostic enseignant, sans contenu adaptatif	Surpasse ML et DL représentatifs ; analyse longitudinale des phases
Liu *et al.* [53]	LLM + AGKA (guides d'annotation)	Classification d'engagement textuel	GPT-4 / LLaMA 3 rivalisent avec BERT en binaire	LLM comme détecteur, pas comme générateur ancré	Retrait sur les taxonomies multi-classes sémantiquement proches
Whitehill *et al.* [82]	Classifieur d'expressions faciales	Engagement en classe / e-learning	Fiabilité comparable à l'annotation humaine	Pas de voix, pas de génération	L'engagement facial est mesurable automatiquement
Xiong *et al.* [84]	CNN-Transformer (visage + posture)	Classe réelle annotée	Combine grain fin (visage) et grain large (posture)	Pas de voix, pas de boucle pédagogique	Accuracy 92,9 %, supérieure aux baselines DL
Baevski *et al.* [3]	wav2vec 2.0	Représentations de parole	Encodeur auto-supervisé réutilisable (SER)	Générique, pas d'engagement pédagogique	Socle de fine-tuning vocal largement adopté
VanLehn [76]	ITS, contenu pré-auteuré	Tutorat cognitif	Efficacité proche d'un tuteur humain	Peu d'affect ; contenu figé	Les meilleurs ITS approchent le tutorat humain
Brown *et al.* [9] ; Touvron *et al.* [73]	LLM (GPT-3, LLaMA)	Génération de texte	Production à la demande, few-shot	Hallucinations ; pas d'état d'engagement	Faisabilité d'un contenu pédagogique généré
Kasneci *et al.* [43]	Revue LLM pour l'éducation	Enseignement et apprentissage	Cartographie opportunités / risques	Pas de prototype multimodal	Fiabilité, biais et traçabilité restent ouverts

Suite à la page suivante...

Suite du tableau 2.1

Référence	Approche	Contexte	Forces	Limites	Résultats clés
Lewis *et al.* [47]	RAG (index + générateur)	Tâches NLP intensives en connaissances	Ancrage documentaire, moins d'hallucinations	Non couplé à l'engagement	Le contexte récupéré conditionne la génération
Kong *et al.* [45]	Outil de représentation IA	Apprentissage collaboratif en ligne ($n = 122$)	Hausse de la présence cognitive de haut niveau	Canal forum, pas de contenu de cours	Performance améliorée ; motivation non significativement accrue
Hu et Shao [37]	GenAI PAGE (Big Five + émotion)	Contenu pédagogique personnalisé ($n = 200$)	Adaptation du style, de la difficulté et du soutien	Pas de fusion visage–voix, ni RAG, ni règles explicites	Satisfaction 4,4/5 vs 3,6 ; complétion 87,6 % vs 72,3 %

Quatre lacunes se dégagent, aucune n'étant comblée isolément par les travaux ci-dessus.

1. **Signal.** La majorité des détecteurs récents opèrent sur le texte des forums [52, 54, 68]. Les approches visuelles existent [82, 84] mais fusionnent rarement visage *et* voix, alors que ces deux modalités sont réalistes devant une vidéo de cours.
2. **Décision.** Quand une intervention existe, elle est souvent opaque (réglage de style d'un LLM) ou pédagogique au niveau du groupe (outil de forum). Un moteur de règles *explicites*, journalisé, reliant un état discret à un type de contenu, reste rare.
3. **Génération.** PAGE montre le bénéfice d'un contenu GenAI psychologiquement adapté [37], mais sans ancrage documentaire. Inversement, le RAG [47] n'est presque jamais couplé à un état d'engagement multimodal.
4. **Évaluation.** Les papiers de détection rapportent F1 / κ / accuracy ; les papiers génératifs rapportent satisfaction et complétion. Un protocole unique qui évalue perception, décision et qualité du contenu sur un banc d'essai partagé n'apparaît pas dans les travaux recensés.

EmoLearn se positionne précisément sur ces quatre écarts : chaîne perception (FER + SER + fusion) → décision interprétable → génération par LLM guidée par vingt patrons et ancrée par RAG, évaluée de façon multi-niveaux. Les limites assumées (simulation sur corpus annotés, appariement visage–voix hétérogène en production, mapping émotion → engagement comme hypothèse) sont traitées au chapitre **??** plutôt que dissimulées.

2.6 Conclusion

Ce chapitre a organisé l'état de l'art en trois familles. Les travaux sur l'engagement dans les MOOC établissent le diagnostic : décrochage massif, centralité des dimensions émotionnelle et cognitive, cadres CoI / ICAP opératoires pour les forums mais

insuffisants pour un apprenant silencieux devant une vidéo. Les travaux de détection montrent une maturité réelle du côté textuel (BERT-CNN, MOOC-BERT, AGKA) et des avancées visuelles (CNN-Transformer, DAiSEE), sans fermer la boucle pédagogique. Les travaux d'intervention (ITS, PAGE, outils de discussion) montrent qu'une médiation IA peut élever engagement et performance, mais rarement à partir d'une perception multimodale traçable et d'un contenu ancré.

La lacune scientifique n'est donc pas l'absence de détecteurs, ni l'absence de générateurs : c'est l'absence d'une architecture intégrale, reproductible, qui relie les deux. C'est cette architecture que le chapitre suivant modélise et conçoit.

Bibliographie

[1] Ali Abedi et Shehroz S. Khan. « Improving state-of-the-art in Detecting Student Engagement with ResNet and TCN Hybrid Network ». In : *18th Conference on Robots and Vision (CRV)*. 2021, p. 151-157.

[2] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil et Hannaneh Hajishirzi. « Self-RAG : Learning to Retrieve, Generate, and Critique through Self-Reflection ». In : *International Conference on Learning Representations (ICLR)*. 2024.

[3] Alexei Baevski, Yuhao Zhou, Abdelrahman Mohamed et Michael Auli. « wav2vec 2.0 : A Framework for Self-Supervised Learning of Speech Representations ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33. 2020, p. 12449-12460.

[4] Ryan S. J. d. Baker, Sidney K. D'Mello, Ma. Mercedes T. Rodrigo et Arthur C. Graesser. « Better to Be Frustrated than Bored ». In : *International Journal of Human-Computer Studies* 68.4 (2010), p. 223-241.

[5] Prateek Bhardwaj, P. K. Gupta, Harsh Panwar, Mohammad Khubeb Siddiqui, Ruben Morales-Menendez et Anubha Bhaik. « Application of Deep Learning on Student Engagement in e-learning environments ». In : *Computers & Electrical Engineering* 93 (2021), p. 107273.

[6] Melissa Bond, Hassan Khosravi, Maarten De Laat, Nina Bergdahl, Violeta Negrea, Emily Oxley, Phuong Pham, Sin Wang Chong et George Siemens. « A meta systematic review of artificial intelligence in higher education : a call for increased collaboration, equality, and research ». In : *International Journal of Educational Technology in Higher Education* 21 (2024), p. 4.

[7] Nigel Bosch et Sidney K. D'Mello. « Automatic Detection of Mind Wandering from Video in the Lab and in the Classroom ». In : *IEEE Transactions on Affective Computing* 13.2 (2022), p. 625-638.

[8] Lori Breslow, David E. Pritchard, Jennifer DeBoer, Glenda S. Stump, Andrew D. Ho et Daniel T. Seaton. « Studying Learning in the Worldwide

Classroom : Research into edX's First MOOC ». In : *Research & Practice in Assessment* 8 (2013), p. 13-25.

[9] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah et al. « Language Models are Few-Shot Learners ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33. 2020, p. 1877-1901.

[10] Carlos Busso, Murtaza Bulut, Chi-Chun Lee, Abe Kazemzadeh, Emily Mower, Samuel Kim, Jeannette N. Chang, Sungbok Lee et Shrikanth S. Narayanan. « IEMOCAP : Interactive Emotional Dyadic Motion Capture Database ». In : *Language Resources and Evaluation* 42.4 (2008), p. 335-359.

[11] Li-Wei Chen et Alexander Rudnicky. « Exploring Wav2vec 2.0 Fine Tuning for Improved Speech Emotion Recognition ». In : *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2023.

[12] Michelene T. H. Chi et Ruth Wylie. « The ICAP Framework : Linking Cognitive Engagement to Active Learning Outcomes ». In : *Educational Psychologist* 49.4 (2014), p. 219-243.

[13] Thomas K. F. Chiu, Qi Xia, Xinyan Zhou, Ching Sing Chai et Miaoting Cheng. « Systematic literature review on opportunities, challenges, and future research recommendations of artificial intelligence in education ». In : *Computers and Education : Artificial Intelligence* 4 (2023), p. 100118.

[14] Cristina Conati, Oswald Barral, Vanessa Putnam et Lea Rieger. « Toward personalized XAI : A case study in intelligent tutoring systems ». In : *Artificial Intelligence* 298 (2021), p. 103503.

[15] Debby R. E. Cotton, Peter A. Cotton et J. Reuben Shipway. « Chatting and cheating : Ensuring academic integrity in the era of ChatGPT ». In : *Innovations in Education and Teaching International* 61.2 (2024), p. 228-239.

[16] Helen Crompton et Diane Burke. « Artificial intelligence in higher education : the state of the field ». In : *International Journal of Educational Technology in Higher Education* 20 (2023), p. 22.

[17] Sidney D'Mello et Art Graesser. « Dynamics of Affective States during Complex Learning ». In : *Learning and Instruction* 22.2 (2012), p. 145-157.

[18] Sidney K. D'Mello. « A Selective Meta-Analysis on the Relative Incidence of Discrete Affective States during Learning with Technology ». In : *Journal of Educational Psychology* 105.4 (2013), p. 1082-1099.

[19] John Daniel. « Making Sense of MOOCs : Musings in a Maze of Myth, Paradox and Possibility ». In : *Journal of Interactive Media in Education* 2012.3 (2012), p. 18.

[20] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit et Neil Houlsby. « An

Image is Worth 16x16 Words : Transformers for Image Recognition at Scale ». In : *International Conference on Learning Representations (ICLR)*. 2021.

[21] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan et al. « The Llama 3 Herd of Models ». In : *arXiv preprint arXiv :2407.21783* (2024).

[22] Yogesh K. Dwivedi, Nir Kshetri, Laurie Hughes, Emma Louise Slade, Anand Jeyaraj, Arpan Kumar Kar, Abdullah M. Baabdullah, Alex Koohang, Vishnupriya Raghavan, Manju Ahuja et al. « "So what if ChatGPT wrote it ?" Multidisciplinary perspectives on opportunities, challenges and implications of generative conversational AI for research, practice and policy ». In : *International Journal of Information Management* 71 (2023), p. 102642.

[23] Wenqi Fan, Yujuan Ding, Liangbo Ning, Shijie Wang, Hengyun Li, Dawei Yin, Tat-Seng Chua et Qing Li. « A Survey on RAG Meeting LLMs : Towards Retrieval-Augmented Large Language Models ». In : *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2024, p. 6491-6501.

[24] Mohammadreza Farrokhnia, Seyyed Kazem Banihashem, Omid Noroozi et Arjen Wals. « A SWOT analysis of ChatGPT : Implications for educational practice and research ». In : *Innovations in Education and Teaching International* 61.3 (2024), p. 460-474.

[25] Jennifer A. Fredricks, Phyllis C. Blumenfeld et Alison H. Paris. « School Engagement : Potential of the Concept, State of the Evidence ». In : *Review of Educational Research* 74.1 (2004), p. 59-109.

[26] Ankita Gandhi, Kinjal Adhvaryu, Soujanya Poria, Erik Cambria et Amir Hussain. « Multimodal sentiment analysis : A systematic review of history, datasets, fusion methods, applications, challenges and opportunities ». In : *Information Fusion* 91 (2023), p. 424-444.

[27] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang et Haofen Wang. « Retrieval-Augmented Generation for Large Language Models : A Survey ». In : *arXiv preprint arXiv :2312.10997* (2023).

[28] D. Randy Garrison, Terry Anderson et Walter Archer. « Critical Inquiry in a Text-Based Environment : Computer Conferencing in Higher Education ». In : *The Internet and Higher Education* 2.2–3 (1999), p. 87-105.

[29] Dragan Gašević, George Siemens et Shazia Sadiq. « Empowering learners for the age of artificial intelligence ». In : *Computers and Education : Artificial Intelligence* 4 (2023), p. 100130.

[30] Patricia Goldberg, Ömer Sümer, Kathleen Stürmer, Wolfgang Wagner, Richard Göllner, Peter Gerjets, Enkelejda Kasneci et Ulrich Trautwein. « Attentive or Not ? Toward a Machine Learning Approach to Assessing Students' Visible Engagement in Classroom Instruction ». In : *Educational Psychology Review* 33 (2021), p. 27-49.

[31] Arthur C. Graesser. « Emotions are the experiential glue of learning environments in the 21st century ». In : *Learning and Instruction* 70 (2020), p. 101212.

[32] Abhay Gupta, Arjun D'Cunha, Kamal Awasthi et Vineeth Balasubramanian. « DAiSEE : Towards User Engagement Recognition in the Wild ». In : *arXiv preprint arXiv :1609.01885* (2016).

[33] Shubham Gupta, Parteek Kumar et Rajkumar Tekchandani. « A multimodal facial cues based engagement detection system in e-learning context using deep learning model ». In : *Multimedia Tools and Applications* 82 (2023), p. 28545-28574.

[34] Alan R. Hevner, Salvatore T. March, Jinsoo Park et Sudha Ram. « Design Science in Information Systems Research ». In : *MIS Quarterly* 28.1 (2004), p. 75-105.

[35] Khe Foon Hew. « Promoting Engagement in Online Courses : What Strategies Can We Learn from Three Highly Rated MOOCs ». In : *British Journal of Educational Technology* 47.2 (2016), p. 320-341.

[36] Wayne Holmes et Ilkka Tuomi. « State of the art and practice in AI in education ». In : *European Journal of Education* 57.4 (2022), p. 542-570.

[37] Wentao Hu et Zichen Shao. « Design and Evaluation of a GenAI-based Personalized Educational Content System Tailored to Personality Traits and Emotional Responses for Adaptive Learning ». In : *Computers in Human Behavior Reports* 19 (2025), p. 100735.

[38] Yuanyuan Hu, Rafael Ferreira Mello et Dragan Gašević. « Automatic Analysis of Cognitive Presence in Online Discussions : An Approach Using Deep Learning and Explainable Artificial Intelligence ». In : *Computers and Education : Artificial Intelligence* 2 (2021), p. 100037.

[39] Stephen Hutt, Kristina Krasich, Caitlin Mills, Nigel Bosch, Shelby White, James R. Brockmole et Sidney K. D'Mello. « Automated gaze-based mind wandering detection during computerized learning in classrooms ». In : *User Modeling and User-Adapted Interaction* 31 (2021), p. 821-877.

[40] Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel et Edouard Grave. « Atlas : Few-shot Learning with Retrieval Augmented Language Models ». In : *Journal of Machine Learning Research* 24.251 (2023), p. 1-43.

[41] Jaeho Jeon et Seongyong Lee. « Large language models in education : A focus on the complementary relationship between human teachers and ChatGPT ». In : *Education and Information Technologies* 28 (2023), p. 15873-15892.

[42] Katy Jordan. « Massive Open Online Course Completion Rates Revisited : Assessment, Length and Attrition ». In : *The International Review of Research in Open and Distributed Learning* 16.3 (2015), p. 341-358.

[43] Enkelejda Kasneci, Kathrin Sessler, Stefan Küchemann, Maria Bannert et al. « ChatGPT for Good ? On Opportunities and Challenges of Large Language Models for Education ». In : *Learning and Individual Differences* 103 (2023), p. 102274.

[44] René F. Kizilcec, Chris Piech et Emily Schneider. « Deconstructing Disengagement : Analyzing Learner Subpopulations in Massive Open Online Courses ». In : *Proceedings of LAK '13*. 2013, p. 170-179.

[45] Xi Kong, Zhi Liu, Changsheng Chen, Sannyuya Liu, Zhenguo Xu et Qianhui Tang. « Exploratory Study of an AI-supported Discussion Representational Tool for Online Collaborative Learning in a Chinese University ». In : *The Internet and Higher Education* 64 (2025), p. 100973.

[46] Siddique Latif, Rajib Rana, Sara Khalifa, Raja Jurdak, Junaid Qadir et Björn W. Schuller. « Survey of Deep Representation Learning for Speech Emotion Recognition ». In : *IEEE Transactions on Affective Computing* 14.2 (2023), p. 1634-1654.

[47] Patrick Lewis, Ethan Perez, Aleksandra Piktus et al. « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33. 2020, p. 9459-9474.

[48] Shan Li et Weihong Deng. « Deep Facial Expression Recognition : A Survey ». In : *IEEE Transactions on Affective Computing* 13.3 (2022), p. 1195-1215.

[49] Paul Pu Liang, Amir Zadeh et Louis-Philippe Morency. « Foundations and Trends in Multimodal Machine Learning : Principles, Challenges, and Open Questions ». In : *ACM Computing Surveys* 56.10 (2024), p. 1-42.

[50] Weng Marc Lim, Asanka Gunasekara, Jessica Leigh Pallant, Jason Ian Pallant et Ekaterina Pechenkina. « Generative AI and the future of education : Ragnarök or reformation ? A paradoxical perspective from management educators ». In : *The International Journal of Management Education* 21.2 (2023), p. 100790.

[51] Pengfei Liu, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi et Graham Neubig. « Pre-train, Prompt, and Predict : A Systematic Survey of Prompting Methods in Natural Language Processing ». In : *ACM Computing Surveys* 55.9 (2023), p. 1-35.

[52] Sannyuya Liu, Shiqi Liu, Zhi Liu, Xian Peng et Zongkai Yang. « Automated Detection of Emotional and Cognitive Engagement in MOOC Discussions to Predict Learning Achievement ». In : *Computers & Education* 181 (2022), p. 104461.

[53] Shiqi Liu, Sannyuya Liu, Lele Sha, Zijie Zeng, Dragan Gašević et Zhi Liu. « Annotation Guideline-Based Knowledge Augmentation : Toward Enhancing Large Language Models for Educational Text Classification ». In : *IEEE Transactions on Learning Technologies* 18 (2025), p. 619-634. doi : 10.1109/TLT.2025.3570775.

[54] Zhi Liu, Xi Kong, Hao Chen, Sannyuya Liu et Zongkai Yang. « MOOC-BERT : Automatically Identifying Learner Cognitive Presence From MOOC Discussion Data ». In : *IEEE Transactions on Learning Technologies* 16.4 (2023), p. 528-541.

[55] Zhi Liu, Ning Zhang, Xian Peng, Sannyuya Liu, Zongkai Yang, Jiyi Peng, Zhu Su et Jia Chen. « Exploring the Relationship Between Social Interaction, Cognitive Processing and Learning Achievements in a MOOC Discussion Forum ». In : *Journal of Educational Computing Research* (2021). doi : 10.1177/07356331211027300.

[56] Chung Kwan Lo. « What Is the Impact of ChatGPT on Education ? A Rapid Review of the Literature ». In : *Education Sciences* 13.4 (2023), p. 410.

[57] Kristina Loderer, Reinhard Pekrun et James C. Lester. « Beyond cold technology : A systematic review and meta-analysis on emotions in technology-based learning environments ». In : *Learning and Instruction* 70 (2020), p. 101162.

[58] Rosemary Luckin, Mutlu Cukurova, Carmel Kent et Benedict du Boulay. « Empowering educators to be AI-ready ». In : *Computers and Education : Artificial Intelligence* 3 (2022), p. 100076.

[59] Richard E. Mayer. *Multimedia Learning*. 3e éd. Cambridge : Cambridge University Press, 2021.

[60] Naman K. Mehta, Shyam S. Prasad, Sumeet Saurav, Ravi Saini et Sanjay Singh. « Three-dimensional DenseNet self-attention neural network for automatic detection of student's engagement ». In : *Applied Intelligence* 52 (2022), p. 11270-11287.

[61] Daniel F. O. Onah, Jane Sinclair et Russell Boyatt. « Dropout Rates of Massive Open Online Courses : Behavioural Patterns ». In : *EDULEARN14 Proceedings*. 2014, p. 5825-5834.

[62] OpenAI. « GPT-4 Technical Report ». In : *arXiv preprint arXiv :2303.08774* (2023).

[63] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex

Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike et Ryan Lowe. « Training language models to follow instructions with human feedback ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 35. 2022.

[64] Reinhard Pekrun. « The Control-Value Theory of Achievement Emotions ». In : *Educational Psychology Review* 18.4 (2006), p. 315-341.

[65] Leonardo Pepino, Pablo Riera et Luciana Ferrer. « Emotion Recognition from Speech Using wav2vec 2.0 Embeddings ». In : *Proc. Interspeech*. 2021, p. 3400-3404.

[66] Rosalind W. Picard. *Affective Computing*. Cambridge, MA : MIT Press, 1997.

[67] Justin Reich et José A. Ruipérez-Valiente. « The MOOC Pivot ». In : *Science* 363.6423 (2019), p. 130-131.

[68] Nazmus Sakeef, M. Ali Akber Dewan, Fuhua Lin et Dharamjit Parmar. « Detecting Cognitive Engagement in Online Course Forums : A Review of Frameworks and Methodologies ». In : *Natural Language Processing Journal* 11 (2025), p. 100146.

[69] Kshitij Sharma et Michail Giannakos. « Multimodal data capabilities for learning : What can multimodal data tell us about learning ? » In : *British Journal of Educational Technology* 51.5 (2020), p. 1450-1484.

[70] John Sweller. « Cognitive Load During Problem Solving : Effects on Learning ». In : *Cognitive Science* 12.4 (1988), p. 257-285.

[71] John Sweller, Jeroen J. G. van Merriënboer et Fred Paas. « Cognitive Architecture and Instructional Design : 20 Years Later ». In : *Educational Psychology Review* 31 (2019), p. 261-292.

[72] Ahmed Tlili, Boulus Shehata, Michael Agyemang Adarkwah, Aras Bozkurt, David T. Hickey, Ronghuai Huang et Brighter Agyemang. « What if the devil is my guardian angel : ChatGPT as a case study of using chatbots in education ». In : *Smart Learning Environments* 10 (2023), p. 15.

[73] Hugo Touvron, Thibaut Lavril, Gautier Izacard et al. « LLaMA : Open and Efficient Foundation Language Models ». In : *arXiv preprint arXiv :2302.13971* (2023).

[74] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale et al. « Llama 2 : Open Foundation and Fine-Tuned Chat Models ». In : *arXiv preprint arXiv :2307.09288* (2023).

[75] UNESCO. *Guidance for generative AI in education and research*. Rapp. tech. Paris : UNESCO, 2023.

[76] Kurt VanLehn. « The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems ». In : *Educational Psychologist* 46.4 (2011), p. 197-221.

[77] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser et Illia Polosukhin. « Attention Is All You Need ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 30. 2017, p. 5998-6008.

[78] Johannes Wagner, Andreas Triantafyllopoulos, Hagen Wierstorf, Maximilian Schmitt, Felix Burkhardt, Florian Eyben et Björn W. Schuller. « Dawn of the Transformer Era in Speech Emotion Recognition : Closing the Valence Gap ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 45.9 (2023), p. 10745-10759.

[79] Shen Wang, Tianze Xu, Hang Li, Chaoli Zhang, Joleen Liang, Jiliang Tang, Philip S. Yu et Qingsong Wen. « Large Language Models for Education : A Survey and Outlook ». In : *arXiv preprint arXiv :2403.18105* (2024).

[80] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le et Denny Zhou. « Chain-of-Thought Prompting Elicits Reasoning in Large Language Models ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 35. 2022.

[81] Jules White, Quchen Fu, Sam Hays, Michael Sandborn, Carlos Olea, Henry Gilbert, Ashraf Elnashar, Jesse Spencer-Smith et Douglas C. Schmidt. « A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT ». In : *arXiv preprint arXiv :2302.11382* (2023).

[82] Jacob Whitehill, Zewelanji Serpell, Yi-Ching Lin, Aysha Foster et Javier R. Movellan. « The Faces of Engagement : Automatic Recognition of Student Engagement from Facial Expressions ». In : *IEEE Transactions on Affective Computing* 5.1 (2014), p. 86-98.

[83] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest et Alexander M. Rush. « Transformers : State-of-the-Art Natural Language Processing ». In : *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing : System Demonstrations*. 2020, p. 38-45.

[84] Yan Xiong, Xinya Guo et Junjie Xu. « CNN-Transformer : A Deep Learning Method for Automatically Identifying Learning Engagement ». In : *Education and Information Technologies* 29 (2024), p. 9989-10008.

[85] Lixiang Yan, Lele Sha, Linxuan Zhao, Yuheng Li, Roberto Martinez-Maldonado, Guanliang Chen, Xinyu Li, Yueqiao Jin et Dragan Gašević. « Practical and ethical challenges of large language models in education : A systematic scoping review ». In : *British Journal of Educational Technology* 55.1 (2024), p. 90-112.

[86] Shu-wen Yang, Po-Han Chi, Yung-Sung Chuang, Cheng-I Jeff Lai, Kushal Lakhotia, Yist Y. Lin, Andy T. Liu, Jiatong Shi, Xuankai Chang, Guan-Ting Lin, Tzu-Hsien Huang, Wei-Cheng Tseng, Ko-tik Lee, Da-Rong Liu, Zili Huang, Shun-Po Fu, Kuan-Yu Chen, Shane Arora, Chien-Feng Huang, Wei-Cheng Lin, Chia-Hua Tsai, Chieh-Chi Chen, Chuxin Liu, Hung-yi Lee et Lin-shan Lee. « SUPERB : Speech processing Universal PERformance Benchmark ». In : *Proc. Interspeech*. 2021, p. 1194-1198.

[87] Ce Zheng, Matias Mendieta et Chen Chen. « POSTER : A Pyramid Cross-Fusion Transformer Network for Facial Expression Recognition ». In : *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*. 2023, p. 3146-3155.