République Tunisienne
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université de La Manouba
Ecole Supérieure de Commerce de Tunis

MÉMOIRE DE MASTER DE RECHERCHE

Présenté en vue de l'obtention de la

MÉMOIRE DE MASTER DE RECHERCHE EN INFORMATIQUE DÉCISIONNELLE ET INTELLIGENTE APPLIQUÉE À LA GESTION

Parcours : Aide à la Décision

EmoLearn : personnalisation pédagogique adaptative multimodale fondée sur la détection de l'engagement émotionnel et la génération de contenu par IA générative

---

Par

Briki Maram

Encadrante académique : Dr. REZGUI Kalthom, *ESCT*

Année Universitaire : 2025 – 2026

Dédicaces

À celles et ceux dont le soutien a rendu ce parcours possible,

À mon père, **Dhahbi**, pour l'exemple de droiture et de détermination qu'il m'a transmis, ainsi que pour la confiance qu'il a placée en moi tout au long de mes études.

À ma mère, **Radhia**, pour son dévouement constant, sa patience et l'affection qui ont accompagné chacune des étapes de ce chemin.

À ma tante, **Jalila**, pour sa bienveillance, ses conseils et sa présence attentive durant mon parcours académique.

À mes frères, **Hosni** et **Amara**, pour leur soutien fidèle, leurs encouragements et l'esprit de solidarité qui nous unit.

À mon ami, **Aymen**, pour sa compréhension, sa patience et son appui constant durant les moments les plus exigeants de ce travail.

À l'ensemble de ma famille, pour leur affection et leurs vœux qui m'ont accompagnée jusqu'à l'aboutissement de ce mémoire.

À mes amis, pour leur présence, leur écoute et leurs encouragements tout au long de cette aventure.

Maram Briki
Avec toute ma reconnaissance.

Remerciements

À mon encadrante

Dr. REZGUI Kalthom

Je tiens à exprimer ma profonde gratitude pour avoir accepté d'encadrer ce travail de recherche.

Je vous remercie sincèrement pour le temps que vous y avez consacré ainsi que pour votre soutien tout au long de ce projet.

Je vous suis reconnaissante pour les ressources mises à ma disposition et pour l'encadrement de qualité dont j'ai bénéficié.

Votre patience, votre professionnalisme, vos conseils et vos remarques constructives ont contribué de manière significative à la réussite de ce travail.

Enfin, j'adresse mes sincères remerciements aux membres du jury pour leur temps et leur évaluation attentive.

Table des matières

Dédicaces **i**

Remerciements **ii**

Table des figures **viii**

Liste des tableaux **ix**

Introduction générale **1**

1 Fondements de l'apprentissage adaptatif et de l'engagement **5**

1.1 Introduction 6

1.2 Apprentissage en ligne et MOOC 6

1.2.1 Définition 6

1.2.2 Implication pour l'adaptation 6

1.3 Engagement de l'apprenant 6

1.3.1 Définition 6

1.3.2 Dimensions de l'engagement 7

1.3.3 Mesure de l'engagement 7

1.4 Informatique affective et émotions en apprentissage 7

1.4.1 Rôle des émotions dans l'apprentissage 7

1.4.2 États pertinents pour l'adaptation pédagogique 7

1.4.3 Charge cognitive 8

1.5 Détection multimodale de l'engagement 8

1.5.1 Modalités exploitées 8

1.5.2 Corpus de référence 9

1.5.3 Fusion multimodale 9

1.6 IA générative pour l'éducation 9

1.6.1 Grands modèles de langue 9

1.6.2 Guidage par prompts et patrons 10
1.6.3 Récupération augmentée (RAG) 10
1.7 Conclusion 11

2 État de l'Art 12
2.1 Introduction 13
2.2 Engagement dans les MOOC : enjeux et cadres théoriques 13
2.2.1 Décrochage massif et rôle de l'engagement 13
2.2.2 Trois dimensions de l'engagement 13
2.2.3 Cadres d'analyse de l'engagement cognitif 14
2.2.4 Émotions d'apprentissage et charge cognitive 15
2.3 Détection automatique de l'engagement 15
2.3.1 Approches textuelles fondées sur les forums 15
2.3.2 Approches visuelles et multimodales 16
2.3.3 Apports et limites des détecteurs 17
2.4 De la détection à l'intervention : IA générative et systèmes adaptatifs . 17
2.4.1 Tuteurs intelligents et adaptation pédagogique 17
2.4.2 Grands modèles de langue, prompts et RAG 18
2.4.3 Génération de contenu conditionnée par le profil psychologique . 19
2.4.4 Outils d'intervention sur les discussions 19
2.4.5 Évaluation de la qualité pédagogique 19
2.5 Synthèse comparative des travaux 20
2.6 Conclusion 22

3 Méthodologie proposée et architecture du framework 24
3.1 Introduction 26
3.2 Architecture générale du framework EmoLearn 26
3.2.1 Principes de conception 26
3.2.2 Architecture en trois couches 27
3.2.3 Workflow de génération adaptative 28
3.3 Analyse du dataset DAiSEE 29
3.3.1 Description et caractéristiques 29
3.3.2 Distribution des états d'engagement 30
3.3.3 Analyse exploratoire des données 31
3.3.4 Identification de patterns critiques 31
3.4 Positionnement et usage du corpus IEMOCAP 32
3.4.1 Complémentarité avec DAiSEE 32
3.4.2 Description et caractéristiques 33
3.4.3 Projection des émotions vers la taxonomie DAiSEE 33
3.4.4 Appariement voix–scénarios dans le pipeline produit 33

3.4.5 Sous-corpus audiovisuel aligné (Option A) . . . 34
3.4.6 Analyse de sensibilité du mapping . . . 34
3.5 Couche de perception . . . 35
3.5.1 Taxonomie des états et mapping facial de référence . . . 35
3.5.2 Perception faciale : mapping, classifieur et fine-tuning ViT . . . 35
3.5.3 Perception vocale : heuristique acoustique et fine-tuning wav2vec2 36
3.5.4 Fusion multimodale : formalisation . . . 36
3.5.5 Les deux familles de fusion . . . 37
3.6 Modèle engagement-adaptation . . . 38
3.6.1 Formulation . . . 38
3.6.2 Mapping états vers besoins pédagogiques . . . 38
3.6.3 Règles de déclenchement d'adaptation . . . 39
3.6.4 Stratégies pédagogiques par état . . . 40
3.7 Système de génération . . . 40
3.7.1 Architecture de prompting contextuel . . . 40
3.7.2 Typologie du contenu adaptatif . . . 41
3.7.3 Templates de prompts structurés . . . 41
3.7.4 Mécanismes de contrôle qualité . . . 42
3.8 Conception du prototype de simulation . . . 42
3.8.1 Architecture technique . . . 42
3.8.2 Workflow de simulation . . . 43
3.8.3 Tuteur conversationnel sensible à l'état affectif . . . 43
3.8.4 Interface utilisateur . . . 43
3.9 Pseudo-code de l'algorithme EmoLearn . . . 44
3.10 Conclusion . . . 44

4 Implémentation du prototype 46
4.1 Infrastructure technique . . . 47
4.1.1 Stack technologique . . . 47
4.1.2 Choix d'architecture . . . 49
4.2 Traitement et préparation des données . . . 51
4.2.1 Extraction et nettoyage du dataset DAiSEE . . . 52
4.2.2 Extraction et alignement du corpus IEMOCAP . . . 54
4.2.3 Création de scénarios d'apprentissage . . . 55
4.2.4 Segmentation des sessions . . . 56
4.3 Implémentation du modèle d'adaptation . . . 57
4.3.1 Règles de décision . . . 57
4.3.2 Algorithme de sélection de stratégies . . . 59
4.3.3 Gestion des transitions d'état . . . 60

4.4 Implémentation du module de génération adaptative 61
4.4.1 Configuration du LLM 61
4.4.2 Bibliothèque de 20 templates de prompts 63
4.4.3 Pipeline de génération 63
4.4.4 Post-processing et validation 65
4.5 Développement du prototype de simulation 66
4.5.1 Interface de visualisation 66
4.5.2 Lecteur de parcours d'apprentissage 68
4.5.3 Affichage des adaptations 68
4.6 Génération du corpus de contenu adaptatif 69
4.6.1 Sélection de 50 séquences représentatives 69
4.6.2 Génération de contenus pour chaque scénario 69
4.6.3 Documentation du corpus 70

5 Validation et Résultats 73
5.1 Méthodologie d'évaluation multi-niveaux 75
5.1.1 Approche globale 75
5.1.2 Métriques et critères 75
5.2 Validation de la perception et de la fusion 75
5.2.1 Classifieur FER $\rightarrow$ DAiSEE (Random Forest) 75
5.2.2 Fine-tuning SER (tête wav2vec2) 76
5.2.3 Banc d'essai audiovisuel aligné ($n = 80$) 76
5.2.4 Analyse de sensibilité du mapping IEMOCAP $\rightarrow$ DAiSEE 77
5.3 Validation du modèle d'adaptation 77
5.3.1 Analyse de la pertinence du mapping 77
5.3.2 Couverture des états d'engagement 78
5.3.3 Validation par experts pédagogiques 78
5.4 Validation de la qualité du contenu généré 78
5.4.1 Corpus produit et audit automatique 78
5.4.2 Évaluation experte (protocole) 78
5.4.3 Métriques automatiques complémentaires 78
5.5 Validation utilisateur (étude pilote) 79
5.5.1 Protocole expérimental 79
5.5.2 Simulation de parcours adaptatifs 79
5.6 Résultats et analyses 79
5.6.1 Synthèse quantitative 79
5.6.2 Retours qualitatifs 79
5.7 Discussion approfondie 80
5.7.1 Interprétation des résultats 80

5.7.2 Comparaison avec l'état de l'art 80
5.7.3 Forces et limites identifiées 80

6 Conclusion et Perspectives **81**
6.1 Synthèse des contributions 82
6.2 Réponses aux questions de recherche 82
6.3 Limites de l'étude 83
6.4 Perspectives de recherche 83
6.5 Implications pratiques pour les MOOC 83
6.6 Recommandations 84

Bibliographie **85**

A Templates de prompts **94**

B Protocoles d'évaluation **95**

C Exemple de contenu généré (extrait) **96**

D Résultats détaillés **97**

Table des figures

1.1 Les trois dimensions classiques de l'engagement. 7
1.2 Taxonomie des quatre états d'engagement retenus (DAiSEE). 8
1.3 Boucle conceptuelle de détection multimodale. 9
1.4 Architecture générale d'un LLM de type Transformer décodeur. 10
1.5 Architecture générale du RAG. 11

3.1 Architecture en couches d'EmoLearn. 28
3.2 Distribution des états d'engagement dans DAiSEE (ensemble des partitions annotées du corpus). 31

4.1 Vue technique du prototype : un client web, un processus serveur unique, un service de génération distant et des artefacts persistants locaux (en pointillés). 49
4.2 Chaîne de préparation des données : les deux corpus sources (à gauche) sont transformés hors ligne en trois artefacts versionnés (à droite), qui alimentent ensuite l'entraînement et la simulation. 52
4.3 Composition du prompt de génération : cinq blocs assemblés dans un ordre fixe, précédés d'un message de rôle système interdisant l'invention de faits. 64

Liste des tableaux

2.1 Synthèse comparative des travaux. 20

3.1 Les quatre états affectifs annotés dans DAiSEE (niveaux d'intensité 0 à 3). 30
3.2 Patterns pédagogiques dérivés des scores DAiSEE. 32
3.3 Complémentarité des corpus DAiSEE et IEMOCAP dans EmoLearn. 32
3.4 Projection de référence des émotions IEMOCAP vers la taxonomie DAiSEE (hypothèse de travail). 33
3.5 Sensibilité du mapping IEMOCAP → DAiSEE (sur 10 039 utterances). 34
3.6 Mapping heuristique de référence des émotions faciales (FER) vers les états DAiSEE. 35
3.7 Gestion des conflits dans la fusion multimodale (famille legacy). 37
3.8 Les deux familles de fusion et leurs objectifs respectifs. 37
3.9 Règles de mapping engagement → type de contenu et stratégie. 39
3.10 Règles temporelles de déclenchement de l'adaptation. 40
3.11 Typologie des contenus adaptatifs par famille de patrons. 41
3.12 Bibliothèque des 20 patrons de prompts structurés (A1–D5). 41
3.13 Principaux composants techniques du prototype. 43

4.1 Pile technologique du prototype EmoLearn, par couche fonctionnelle. 48
4.2 Paramètres de la chaîne d'extraction visuelle appliquée aux clips DAiSEE. 53
4.3 Composition du référentiel de scénarios : critère de tirage et effectif par patron pédagogique. 56
4.4 Cascade de décision telle qu'implémentée : la première condition satisfaite détermine la stratégie et le type de contenu. 59
4.5 Configuration du service de génération et du tuteur conversationnel. . . 62
4.6 Critères de l'audit automatique du contenu généré et codes d'anomalie associés. 66
4.7 Composants de l'interface de simulation et fonction de chacun. 67

4.8 Artefacts constituant le corpus de contenu adaptatif et son appareil de validation. 71

5.1 Comparaison mapping heuristique vs classifieur appris (FER → DAiSEE, $n = 300$). 76
5.2 Progression du fine-tuning SER (validation interne). 76
5.3 Validation multimodale sur sous-corpus IEMOCAP aligné ($n = 80$). . . 77
5.4 Balayage des poids de fusion (variante vote pondéré, $n = 80$). 77
5.5 Synthèse des résultats chiffrés disponibles. 79

A.1 Métadonnées des 20 patrons (type, longueur cible, objectif). 94

Introduction générale

L'évolution rapide des technologies numériques et le développement des plateformes éducatives en ligne ont profondément transformé les pratiques d'apprentissage, en particulier à travers la diffusion des cours en ligne ouverts et massifs (MOOC, *Massive Open Online Courses*). Ces dispositifs permettent aujourd'hui de collecter, diffuser et personnaliser des contenus pédagogiques à grande échelle, offrant à des millions d'apprenants un accès élargi à la formation, indépendamment des contraintes géographiques [8, 19]. La crise sanitaire de 2020 a encore accéléré cette dynamique, faisant de l'apprentissage en ligne une composante désormais structurelle des systèmes éducatifs contemporains.

Toutefois, cette évolution s'accompagne d'un constat largement documenté : les MOOC souffrent de taux d'abandon particulièrement élevés. Une part importante des inscrits interrompt son parcours dès les premières semaines, ce qui limite fortement l'efficacité pédagogique réelle de ces dispositifs [42, 61]. Parmi les facteurs explicatifs, la baisse de l'**engagement** de l'apprenant occupe une place centrale [35, 44]. Dans une salle de classe traditionnelle, l'enseignant perçoit en permanence des signaux fins (regard, posture, expression) et adapte spontanément son discours. Cette boucle de régulation disparaît presque entièrement dans les environnements en ligne de masse, où l'apprenant fait face à un contenu figé, identique pour tous et insensible à son état du moment.

Dans ce contexte, plusieurs travaux en informatique affective et en psychologie de l'apprentissage ont établi que les émotions ne sont pas périphériques à la cognition, mais en constituent un rouage essentiel [65, 67]. Des états tels que l'ennui, la confusion ou la frustration influencent directement la profondeur du traitement de l'information, la persévérance et la mémorisation [4, 17]. Une détection inefficace de ces états, combinée à l'absence d'adaptation pédagogique, peut entraîner une dégradation de l'expérience d'apprentissage et favoriser le décrochage. Cette problématique est d'autant plus critique que les décisions pédagogiques doivent idéalement intervenir en temps utile, avant que le désengagement ne s'installe.

Ainsi, ce mémoire s'inscrit dans cette problématique en proposant une approche visant à réunir, au sein d'une même chaîne de traitement, la perception de l'engagement émotionnel et la génération adaptative de contenu pédagogique.

Face à ces enjeux, la question centrale de ce travail est la suivante :

Comment concevoir un dispositif capable d'inférer automatiquement l'état d'engagement d'un apprenant à partir de signaux multimodaux, puis de générer en réponse un contenu pédagogique adapté à cet état, tout en garantissant la cohérence et la traçabilité de la décision pédagogique sous-jacente ?

Cette question se décompose en quatre sous-questions opérationnelles :

— Comment estimer de manière fiable l'état d'engagement à partir de signaux multimodaux hétérogènes (expressions faciales issues de DAiSEE, signal vocal issu de IEMOCAP), et quel gain la fusion apporte-t-elle par rapport à une modalité unique ?
— Comment formaliser une correspondance pédagogiquement justifiable entre les états d'engagement détectés et les stratégies d'intervention, c'est-à-dire un modèle *engagement* → *adaptation* ?
— Dans quelle mesure un grand modèle de langue, guidé par des patrons de prompts structurés et ancré par un mécanisme de récupération augmentée (RAG), peut-il produire un contenu pédagogique pertinent et adapté à l'état d'engagement visé ?
— Selon quel protocole peut-on évaluer, de façon honnête et multi-niveaux, la qualité de la perception, la pertinence de la décision et la qualité du contenu généré ?

L'analyse de la littérature montre que, malgré les progrès importants réalisés dans les domaines de la détection de l'engagement et de l'IA générative appliquée à l'éducation, ces deux axes restent majoritairement traités de manière indépendante. D'une part, les modèles de perception multimodale permettent d'inférer l'état affectif d'un apprenant avec une fiabilité croissante [18, 32, 84]. D'autre part, les grands modèles de langue ouvrent la voie à une génération de contenu pédagogique personnalisée à grande échelle [9, 43]. Cependant, ces approches demeurent souvent séquentielles ou fragmentées : la détection n'est pas systématiquement reliée à une décision pédagogique explicite, tandis que la génération n'est pas toujours conditionnée par un état d'engagement mesuré, ce qui limite la capacité des systèmes à restaurer une forme de régulation pédagogique automatique.

Pour répondre à ces limitations, ce mémoire propose un framework hybride nommé EmoLearn, combinant trois briques complémentaires. La couche de **perception** estime l'état d'engagement à partir de signaux visage et voix, en s'appuyant sur les corpus DAiSEE et IEMOCAP et sur des modèles *fine-tunés* vers la taxonomie des

quatre états d'engagement : un Vision Transformer (ViT) pour le visage et un modèle wav2vec2 pour la voix, combinés par un moteur de fusion multimodale. La couche de **décision** formalise un modèle *engagement* → *adaptation* reliant chaque état à un type de contenu et à un patron de génération. Enfin, la couche de **génération** produit un contenu pédagogique adaptatif au moyen d'un grand modèle de langue, guidé par une bibliothèque de vingt patrons structurés et ancré par un module RAG sur une base documentaire pédagogique. Ainsi, EmoLearn vise à passer d'un contenu figé à une adaptation réellement conditionnée par l'état d'engagement détecté.

En résumé, le module de perception anticipe l'état émotionnel de l'apprenant, tandis que les modules de décision et de génération exploitent cette estimation pour produire une intervention pédagogique ciblée, traçable et reproductible.

Les principales contributions de ce travail sont les suivantes :

1. Proposition d'une architecture multimodale de bout en bout reliant perception, décision et génération au sein d'une même chaîne.
2. Formalisation d'un modèle *engagement* → *adaptation* assorti d'une bibliothèque de vingt patrons de génération structurés.
3. Développement d'un module RAG pédagogique ancrant la génération sur une base documentaire vectorisée.
4. Fine-tuning supervisé des modèles de perception (ViT pour le visage et wav2vec2 pour la voix) vers les quatre états d'engagement DAiSEE.
5. Évaluation honnête et instrumentée de la fusion multimodale, incluant l'analyse des compromis entre exactitude globale et sensibilité aux états critiques.
6. Prototype logiciel complet et reproductible, accompagné d'un protocole d'évaluation multi-niveaux.

Méthodologie générale

La démarche adoptée relève de la *recherche orientée conception* (*design science research*), paradigme particulièrement adapté à la conception d'artefacts informatiques répondant à un problème identifié [34]. Elle articule l'analyse d'un problème réel (le décrochage lié à la baisse d'engagement dans les MOOC), la construction d'un artefact (le framework EmoLearn) et son évaluation au regard d'objectifs explicites.

Concrètement, le travail s'organise autour d'une chaîne de traitement en trois étages : un étage de *perception* (FER, SER, fusion), un étage de *décision* (règles temporelles et moteur pédagogique) et un étage de *génération* (RAG et LLM).

Le projet s'appuie sur deux corpus publics de référence. DAiSEE [32] constitue le socle engagement (taxonomie et scénarios), tandis qu'IEMOCAP [10] apporte la modalité

vocale et, via un sous-corpus audiovisuel aligné, le support de validation de la fusion. Le prototype repose sur une architecture client-serveur, des modèles de perception fine-tunés (ViT et wav2vec2) vers les quatre états DAiSEE, un LLM accessible par API et un module RAG (ChromaDB).

Structure du mémoire

Le présent mémoire s'ouvre par la présente **introduction générale**, puis s'organise en six chapitres numérotés.

Le **chapitre 1** pose les fondements conceptuels de l'apprentissage adaptatif et de l'engagement (MOOC, émotions, détection multimodale, IA générative).

Le **chapitre 2** propose un état de l'art critique et positionne EmoLearn par rapport aux travaux existants.

Le **chapitre 3** est consacré à la modélisation et à la conception du framework : architecture globale, modèle *engagement* $\rightarrow$ *adaptation*, génération fondée sur des patrons et un module RAG, ainsi que conception du prototype.

Le **chapitre 4** décrit l'implémentation technique de bout en bout.

Le **chapitre 5** expose la validation et les résultats selon un protocole multi-niveaux.

Le **chapitre 6**, enfin, synthétise les contributions, expose les limites et trace des perspectives.

Le mémoire se termine par la bibliographie.

Chapitre 1

Fondements de l'apprentissage adaptatif et de l'engagement

Sommaire

1.1 Introduction 6
1.2 Apprentissage en ligne et MOOC 6
1.2.1 Définition 6
1.2.2 Implication pour l'adaptation 6
1.3 Engagement de l'apprenant 6
1.3.1 Définition 6
1.3.2 Dimensions de l'engagement 7
1.3.3 Mesure de l'engagement 7
1.4 Informatique affective et émotions en apprentissage . . . 7
1.4.1 Rôle des émotions dans l'apprentissage 7
1.4.2 États pertinents pour l'adaptation pédagogique 7
1.4.3 Charge cognitive 8
1.5 Détection multimodale de l'engagement 8
1.5.1 Modalités exploitées 8
1.5.2 Corpus de référence 9
1.5.3 Fusion multimodale 9
1.6 IA générative pour l'éducation 9
1.6.1 Grands modèles de langue 9
1.6.2 Guidage par prompts et patrons 10
1.6.3 Récupération augmentée (RAG) 10
1.7 Conclusion 11

1.1 Introduction

La conception d'un système d'apprentissage adaptatif fondé sur l'engagement émotionnel mobilise un ensemble de notions issues de domaines distincts : sciences de l'éducation, informatique affective, apprentissage multimodal et intelligence artificielle générative. Ces notions sont souvent présentées séparément ; les rassembler permet d'établir un vocabulaire partagé et d'expliciter les hypothèses sur lesquelles repose le pipeline EmoLearn.

Ce chapitre examine les concepts fondamentaux nécessaires à la compréhension de cette architecture. Il aborde successivement l'apprentissage en ligne et les MOOC, la notion d'engagement de l'apprenant, les apports de l'informatique affective, les principes de la détection multimodale, puis les bases de l'intelligence artificielle générative appliquée à l'éducation (LLM, guidage par prompts et RAG).

1.2 Apprentissage en ligne et MOOC

1.2.1 Définition

Les cours en ligne ouverts et massifs (MOOC, *Massive Open Online Courses*) désignent des dispositifs de formation accessibles à distance, le plus souvent sans prérequis d'inscription stricts, et destinés à un public potentiellement très large [8, 19]. Ils reposent typiquement sur des vidéos pédagogiques, des quiz, des forums et un parcours de progression asynchrone.

1.2.2 Implication pour l'adaptation

Dans ce modèle, le contenu est principalement diffusé de manière uniforme. Toute forme d'adaptation automatique suppose donc, en amont, de disposer d'une mesure d'engagement plus fine que les simples proxies de présence (connexion, clics), point développé dans la section suivante.

1.3 Engagement de l'apprenant

1.3.1 Définition

L'engagement désigne la mobilisation cognitive, comportementale et émotionnelle de l'apprenant vis-à-vis de la tâche d'apprentissage [25, 35, 44]. Il ne se réduit pas à la simple présence en ligne (connexion, clics), mais renvoie à une implication active dans le traitement de l'information.

1.3.2 Dimensions de l'engagement

On distingue classiquement :

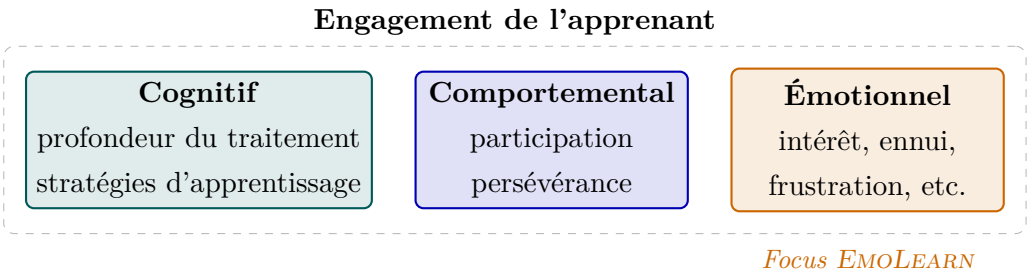


FIGURE 1.1 – Les trois dimensions classiques de l'engagement.

EMOLEARN se concentre principalement sur la dimension émotionnelle / affective, tout en visant un effet sur la persévérance globale.

1.3.3 Mesure de l'engagement

Les indicateurs usuels en e-learning (durée de session, progression, scores) fournissent des *proxies* utiles mais incomplets. Les approches plus récentes mobilisent des signaux multimodaux (visage, voix, posture) pour estimer l'état affectif de manière plus directe [18, 30, 70].

1.4 Informatique affective et émotions en apprentissage

1.4.1 Rôle des émotions dans l'apprentissage

Les travaux en psychologie de l'apprentissage montrent que les émotions modulent l'attention, la mémorisation et la persévérance [4, 17, 31, 57, 65]. Elles ne sont donc pas périphériques à la cognition, mais constitutives du processus d'apprentissage.

1.4.2 États pertinents pour l'adaptation pédagogique

Dans le cadre de ce mémoire, quatre états issus du corpus DAISEE [32] structurent la taxonomie d'engagement :

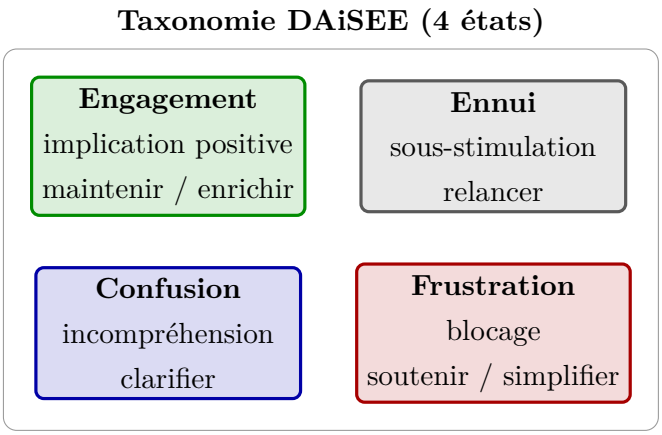


FIGURE 1.2 – Taxonomie des quatre états d'engagement retenus (DAISEE).

Chacun de ces états appelle une stratégie pédagogique distincte.

1.4.3 Charge cognitive

La théorie de la charge cognitive rappelle qu'un contenu trop dense ou mal séquencé favorise la confusion et l'abandon [71, 72]. La théorie de l'apprentissage multimédia complète ce cadre : la conception des messages (texte, image, rythme) conditionne la charge utile [59]. L'adaptation du niveau d'explication, du rythme et du type d'exemple constitue dès lors un levier central des systèmes d'apprentissage adaptatifs.

1.5 Détection multimodale de l'engagement

1.5.1 Modalités exploitées

La détection automatique de l'engagement peut s'appuyer sur :

- le **visage** (expressions faciales, regard) ;
- la **voix** (prosodie, intensité, variations émotionnelles) ;
- éventuellement la posture ou des signaux physiologiques.

EMOLEARN combine les deux premières modalités, à partir de clips vidéo et audio annotés (hors temps réel), plutôt que de traces textuelles de forums ou de capteurs physiologiques.

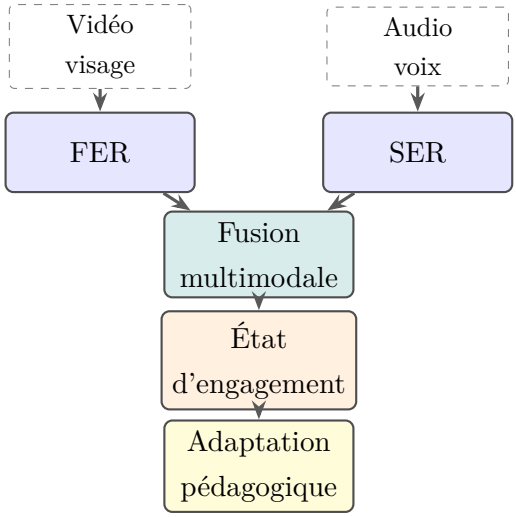


FIGURE 1.3 – Boucle conceptuelle de détection multimodale.

1.5.2 Corpus de référence

Deux corpus publics fondent la chaîne de perception :

— DAiSEE [32] pour l'engagement facial annoté ;

— IEMOCAP [10] pour l'émotion vocale et, via un sous-corpus audiovisuel, la validation de la fusion alignée.

1.5.3 Fusion multimodale

La fusion vise à combiner des sources hétérogènes pour obtenir une décision plus robuste qu'une modalité seule [26, 49]. Elle soulève toutefois des questions de pondération, de désaccord inter-modalités et de déséquilibre des classes, qui seront traités dans la conception et la validation du système.

1.6 IA générative pour l'éducation

1.6.1 Grands modèles de langue

Les grands modèles de langue (LLM, *Large Language Models*) sont des réseaux de neurones entraînés à prédire le prochain token d'une séquence à partir d'un très grand corpus textuel [9, 21, 62, 78, 85]. Architecturée autour du *Transformer* décodeur, cette famille de modèles suit un pipeline strictement séquentiel (figure 1.4) : le texte d'entrée est d'abord *tokenisé* (mots ou sous-mots convertis en identifiants numériques), puis ces identifiants passent dans une couche d'*embeddings* combinée à un encodage de position, avant d'entrer dans une pile de blocs d'*attention* et de couches *feed-forward*.

Une tête de langage produit enfin la distribution sur le vocabulaire. La génération est *auto-régressive* : chaque token prédit est réinjecté pour produire le suivant.

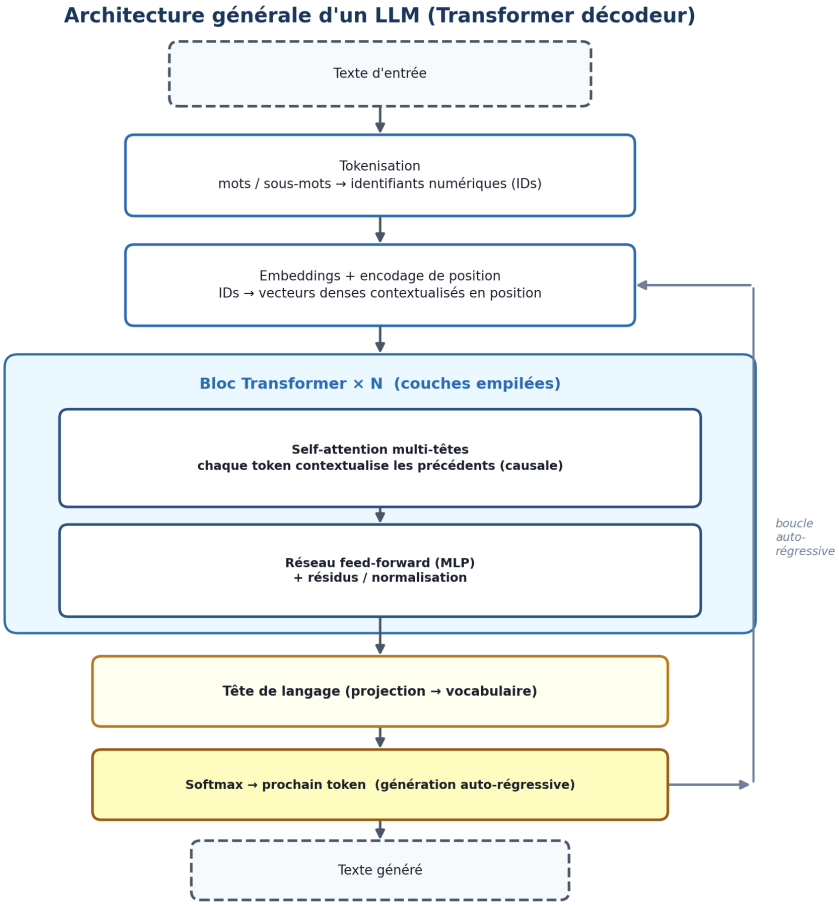


FIGURE 1.4 – Architecture générale d'un LLM de type Transformer décodeur.

En éducation, ces modèles permettent de générer, à la demande, des explications, reformulations, analogies ou encouragements en langage naturel [43, 56, 80, 87]. Ils offrent ainsi une voie crédible pour produire des contenus pédagogiques personnalisés à grande échelle.

1.6.2 Guidage par prompts et patrons

La qualité du contenu généré dépend fortement du guidage [51, 82, 83]. Une bibliothèque de patrons de prompts structurés permet de conditionner la génération selon l'état d'engagement détecté et le type d'intervention pédagogique souhaité.

1.6.3 Récupération augmentée (RAG)

Le mécanisme de *Retrieval-Augmented Generation* (RAG) [23, 27, 47] ancre la génération sur des documents de référence indexés dans une base vectorielle (figure 1.5).

Les documents sont d'abord découpés et vectorisés (indexation hors ligne). À l'exécution, la question est embedée puis confrontée à l'index pour récupérer les passages les plus pertinents ; ces passages enrichissent le prompt transmis au LLM, qui produit une réponse ancrée. Ce dispositif réduit le risque d'hallucinations factuelles et renforce la cohérence pédagogique des contenus produits.

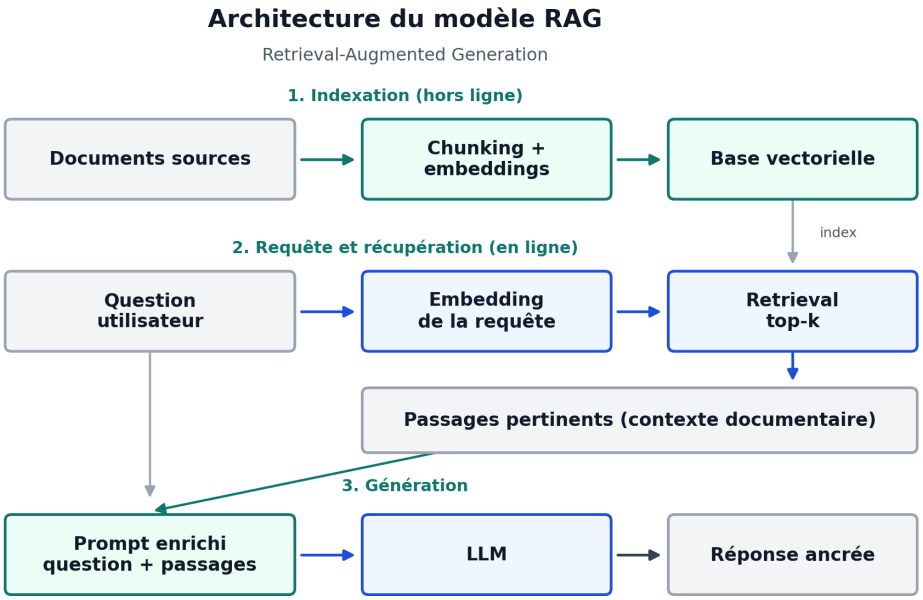


FIGURE 1.5 – Architecture générale du RAG.

1.7 Conclusion

Ce chapitre a rappelé le socle conceptuel sur lequel s'appuie EMOLEARN : la définition des MOOC et l'enjeu d'adaptation, la centralité de l'engagement émotionnel, les bases de la détection multimodale et le potentiel de l'IA générative guidée et ancrée documentairement. Le chapitre suivant examine l'état de l'art correspondant et positionne le présent travail par rapport aux approches existantes.

Chapitre 2

État de l'Art

Sommaire

2.1 Introduction 13

2.2 Engagement dans les MOOC : enjeux et cadres théoriques 13

2.2.1 Décrochage massif et rôle de l'engagement 13

2.2.2 Trois dimensions de l'engagement 13

2.2.3 Cadres d'analyse de l'engagement cognitif 14

2.2.4 Émotions d'apprentissage et charge cognitive 15

2.3 Détection automatique de l'engagement 15

2.3.1 Approches textuelles fondées sur les forums 15

2.3.2 Approches visuelles et multimodales 16

2.3.3 Apports et limites des détecteurs 17

2.4 De la détection à l'intervention : IA générative et systèmes adaptatifs 17

2.4.1 Tuteurs intelligents et adaptation pédagogique 17

2.4.2 Grands modèles de langue, prompts et RAG 18

2.4.3 Génération de contenu conditionnée par le profil psychologique 19

2.4.4 Outils d'intervention sur les discussions 19

2.4.5 Évaluation de la qualité pédagogique 19

2.5 Synthèse comparative des travaux 20

2.6 Conclusion 22

2.1 Introduction

Après les fondements posés au chapitre 1, ce chapitre situe EmoLearn dans la littérature récente. La régulation pédagogique automatique d'un apprenant isolé devant un écran relève de deux axes de recherche complémentaires, encore trop souvent traités séparément.

Le premier axe porte sur la **détection** de l'engagement. Les travaux s'appuient soit sur les traces textuelles des forums (présence cognitive, émotions épistémiques), soit sur des signaux multimodaux (visage, voix, posture). Le second axe porte sur l'**intervention** : systèmes de tutorat intelligent, stratégies d'adaptation, et, plus récemment, génération de contenu par grands modèles de langue. La convergence de ces deux axes (percevoir un état, décider d'une stratégie, produire un contenu) constitue la direction la plus prometteuse, et aussi la moins couverte de bout en bout.

Ce chapitre est organisé en trois niveaux progressifs, selon la logique retenue pour un état de l'art de mémoire. Nous examinons d'abord les enjeux d'engagement dans les MOOC et les cadres théoriques qui permettent de le décrire. Nous analysons ensuite les méthodes de détection automatique, en distinguant les approches textuelles fondées sur les forums et les approches visuelles ou multimodales. Nous présentons enfin les systèmes qui passent de la détection à l'intervention, des tuteurs intelligents historiques aux dispositifs génératifs contemporains. Une synthèse comparative identifie les lacunes que le chapitre 3 vise à combler.

2.2 Engagement dans les MOOC : enjeux et cadres théoriques

2.2.1 Décrochage massif et rôle de l'engagement

Les analyses empiriques confirment que le décrochage n'est pas uniquement dû à des contraintes externes (temps, prérequis) : la baisse d'engagement cognitif, comportemental et émotionnel constitue un facteur central [35, 44], avec des taux de complétion souvent proches de 10 % [52, 68]. Restaurer une adaptation automatique suppose donc, en amont, de mesurer l'engagement autrement que par de simples proxies de présence (clics, durée de session).

2.2.2 Trois dimensions de l'engagement

La définition aujourd'hui la plus partagée distingue trois composantes [25] :

— l'**engagement comportemental** (participation, persévérance, effort observable) ;

— l'**engagement cognitif** (profondeur du traitement, stratégies d'apprentissage, présence cognitive) ;
— l'**engagement émotionnel** (intérêt, ennui, confusion, frustration, sentiment d'affiliation).

Les traces de plateforme capturent surtout la première dimension. Les forums donnent un accès partiel à la seconde. La troisième, pourtant déterminante pour la motivation et la persévérance [17, 65], reste la plus difficile à inférer sans capteurs affectifs. EmoLearn se concentre sur cette dimension émotionnelle, tout en visant un effet sur la persévérance globale.

Liu *et al.* montrent, sur 8 867 apprenants d'un forum MOOC, que engagement émotionnel et engagement cognitif sont liés et prédisent conjointement la réussite : les émotions positives et la confusion contribuent davantage à une cognition de haut niveau que les émotions négatives, et les indicateurs co-occurrents sont plus fiables qu'un facteur isolé [52]. Ce résultat justifie de ne pas réduire l'engagement à un score unique, et d'associer à chaque état (ennui, confusion, frustration, engagement) une stratégie pédagogique distincte.

2.2.3 Cadres d'analyse de l'engagement cognitif

Lorsque le signal disponible est textuel, trois cadres dominent la littérature de détection dans les forums [69].

Le modèle de *Community of Inquiry* (CoI) [28] décompose l'expérience d'apprentissage en ligne en présences sociale, enseignante et cognitive. La présence cognitive s'opérationnalise en quatre phases (événement déclencheur, exploration, intégration, résolution) et sert de référence à de nombreux classifieurs automatiques [38, 54, 69].

Le cadre ICAP (*Interactive, Constructive, Active, Passive*) [12] relie le mode d'engagement à la qualité des apprentissages : plus l'activité est constructive ou interactive, plus le traitement est profond. Il est largement utilisé pour coder les messages de forums [69].

Ces cadres sont précieux pour l'analyse *a posteriori* des discussions. Ils ne couvrent toutefois pas la situation visée par EmoLearn : un apprenant seul, devant une vidéo de cours, sans produire de texte, dont l'état affectif doit être estimé en temps quasi réel pour déclencher une intervention. La taxonomie DAiSEE (engagement, ennui, confusion, frustration) [32] est alors plus opératoire, car elle relie directement un état observable à un besoin pédagogique.

2.2.4 Émotions d'apprentissage et charge cognitive

Les émotions ne sont pas périphériques à la cognition : elles modulent l'attention, la persévérance et la mémorisation [65, 67]. La dynamique confusion–frustration–ennui, documentée par D'Mello et Graesser, montre qu'un épisode de confusion résolu favorise l'apprentissage, tandis qu'une confusion non résolue dérive vers la frustration puis l'ennui [4, 17]. Baker *et al.* concluent qu'il vaut mieux être frustré qu'ennuyé : la frustration signale encore un investissement, l'ennui une désengagement déjà avancé [4].

La théorie de la charge cognitive [71, 72] éclaire le même phénomène sous un autre angle : un contenu trop dense favorise la confusion ; un contenu sous-stimulant favorise l'ennui. La théorie de l'apprentissage multimédia [59] et les méta-analyses sur les émotions en environnements technologiques [31, 57] confirment qu'un système adaptatif doit ajuster la complexité, le rythme et le type d'exemple en fonction de l'état détecté, plutôt que de proposer un unique parcours moyen.

2.3 Détection automatique de l'engagement

La détection automatique vise à substituer, au questionnaire ou à l'observation humaine, un estimateur reproductible. Deux familles de signaux structurent l'état de l'art : le **texte** des forums, abondant dans les MOOC, et les **signaux perceptifs** (visage, voix, posture), plus proches de la régulation en classe.

2.3.1 Approches textuelles fondées sur les forums

Sakeef *et al.* proposent une revue des cadres (CoI, ICAP, KCSA) et des méthodes de TALN / apprentissage profond utilisées pour détecter l'engagement cognitif dans les forums [69]. Ils soulignent que l'annotation manuelle est trop coûteuse pour un suivi en continu, et que l'automatisation devient indispensable. Ils rappellent aussi une limite structurelle : l'absence de indices visuels et auditifs dans le texte rend l'inférence de l'état interne partielle. Cette limite motive, pour EmoLearn, le recours aux modalités visage et voix (corpus annotés) plutôt qu'au seul forum.

Hu, Ferreira Mello et Gašević comparent un CNN à des forêts aléatoires fondées sur des traits linguistiques pour classer la présence cognitive selon le CoI [38]. Le CNN atteint un κ de Cohen de 0,528, comparable aux approches classiques, avec une généralisabilité inter-cours similaire. L'apport principal est l'explicabilité (XAI) au niveau des mots, qui complète l'importance des descripteurs de la forêt aléatoire. Le travail reste toutefois une tâche de *catégorisation* de messages, sans lien avec une intervention pédagogique automatique.

Liu *et al.* (2022) introduisent BERT-CNN pour détecter conjointement l'engagement émotionnel et cognitif dans les discussions MOOC [52]. Par rapport aux modèles antérieurs, le F1 s'améliore d'environ 10 % (émotion) et 8 % (cognition). L'analyse par équations structurelles sur 8 867 apprenants confirme l'effet combiné des deux dimensions sur la réussite. Méthodologiquement, le papier établit qu'un détecteur robuste et interprétable est un prérequis à toute régulation ; opérationnellement, il s'arrête à la prédiction de la réussite, sans générer de contenu adaptatif.

MOOC-BERT pousse plus loin le pré-entraînement : le modèle est pré-entraîné sur des discussions non étiquetées issues de plusieurs MOOC et disciplines, puis utilisé pour identifier la présence cognitive [54]. Il surpasse les algorithmes représentatifs d'apprentissage automatique et de deep learning, y compris en généralisation inter-cours, et permet une analyse longitudinale de l'évolution des phases cognitives. Là encore, la boucle s'arrête à l'aide à l'enseignant : fournir un diagnostic, non produire l'intervention.

Liu *et al.* (2021) articulent analyse de réseaux sociaux et analyse de réseaux épistémiques sur 3 925 participants d'un forum MOOC [55]. Les groupes à haute et basse réussite diffèrent significativement en centralité ; les connexions cognitives sont plus fortes chez les apprenants performants et dans les communautés animées par l'enseignant. Ce résultat éclaire le rôle de l'accompagnement, mais concerne une dynamique *collective* (forum), distincte du scénario *individuel* visé par EmoLearn.

2.3.2 Approches visuelles et multimodales

Lorsque l'apprenant ne produit pas de texte (cas typique du visionnage d'une vidéo de cours), le signal pertinent redevient perceptif. Picard a fondé l'informatique affective [67] ; Whitehill *et al.* ont montré qu'un classifieur d'expressions faciales peut estimer l'engagement d'un étudiant avec une fiabilité comparable à celle d'annotateurs humains [84]. Les revues récentes de reconnaissance d'expressions faciales profondes [48] et les architectures Transformer [20, 89] ont nettement relevé le niveau de ces estimateurs. En salle de classe, des approches par vision estiment l'engagement visible [30, 60] ou le décrochage attentionnel (*mind wandering*) [7, 39]. Sur DAiSEE et des scénarios d'e-learning, des réseaux hybrides CNN/TCN et des descripteurs faciaux multimodaux ont été proposés [1, 5, 33]. La méta-analyse de D'Mello rappelle que les états discrets pertinents en apprentissage médiatisé (ennui, confusion, frustration, engagement) ont des incidences relatives stables, et que la fusion multimodale peut améliorer la robustesse au prix de questions de calibration [18, 26, 49, 70].

Deux corpus publics structurent aujourd'hui cet axe. DAiSEE fournit des vidéos d'apprenants annotées en quatre états d'engagement, avec une intensité de 0 à 3 [32] ; la classe *Engagement* domine largement, ce qui rend l'accuracy globale insuffisante comme

seule métrique. IEMOCAP offre un signal vocal riche et, dans sa version audiovisuelle, un cadre où visage et voix proviennent du même locuteur [10]. EmoLearn s'appuie explicitement sur ces deux ressources complémentaires : le premier pour la taxonomie d'engagement facial, le second pour l'émotion vocale.

Xiong, Guo et Xu proposent un CNN-Transformer qui combine l'information fine des expressions faciales (CNN) et l'information plus grossière de la posture (Transformer), en réduisant le clutter de fond [86]. Sur un jeu de données de classe réelle, annoté par crowdsourcing puis validation experte, le modèle atteint 92,9 % d'accuracy et surpasse plusieurs architectures de deep learning. Ce travail est le plus proche d'EmoLearn du point de vue du *signal* (vision en situation d'apprentissage). Il s'en distingue toutefois sur deux points décisifs : il ne fusionne pas la voix, et il ne relie pas la détection à une génération de contenu. L'identification s'arrête au diagnostic.

Côté voix, le passage des descripteurs acoustiques classiques aux représentations auto-supervisées (wav2vec 2.0, SUPERB) a transformé la reconnaissance d'émotions vocales [46, 66, 88]. Le fine-tuning de wav2vec 2.0 [11] et les architectures Transformer [79] réduisent notamment l'écart de performance sur la valence, longtemps le point faible du SER. Ces avancées justifient le choix d'EmoLearn de fine-tuner un encodeur de parole vers la taxonomie DAiSEE, plutôt que de s'en tenir à des seuils acoustiques.

2.3.3 Apports et limites des détecteurs

Trois constats se dégagent. Premièrement, l'état de l'art textuel (BERT-CNN, MOOC-BERT, CNN+XAI) est mature pour les forums, mais aveugle dès que l'apprenant ne poste pas. Deuxièmement, l'état de l'art visuel (Whitehill, DAiSEE, CNN-Transformer) montre qu'une détection faciale fiable est possible, mais reste rarement multimodale (visage *et* voix) et rarement évaluée au-delà de l'accuracy, malgré le déséquilibre des classes. Troisièmement, presque aucun de ces détecteurs ne ferme la boucle : détecter n'est pas encore intervenir. C'est précisément le passage que la section suivante examine.

2.4 De la détection à l'intervention : IA générative et systèmes adaptatifs

2.4.1 Tuteurs intelligents et adaptation pédagogique

Les systèmes de tutorat intelligent (ITS) combinent historiquement un modèle de l'apprenant, un modèle pédagogique et une interface adaptative [77]. Ils s'appuient sur des règles explicites ou des modèles cognitifs (traçage bayésien des connaissances, théorie

des espaces de connaissances) et sur un contenu *pré-auteuré*. VanLehn montre que les meilleurs ITS approchent l'efficacité d'un tuteur humain, à condition que le domaine soit bien modélisé [77]. Leur limite, dans un MOOC aux contenus ouverts et aux états affectifs fluctuants, est double : le contenu ne peut pas être entièrement pré-écrit pour chaque état, et le modèle de l'apprenant est surtout cognitif, rarement émotionnel, même si des travaux récents visent une explication personnalisée des décisions de tuteurs [14].

Les stratégies d'adaptation classiques distinguent simplification, enrichissement, remédiation et encouragement. EmoLearn les opérationnalise via une matrice *état* → *type de contenu* (explication, exemple, exercice, encouragement) et des règles temporelles sur les séquences de clips. Le moteur reste volontairement interprétable : chaque adaptation doit être justifiable par l'état détecté, la stratégie retenue et le patron mobilisé.

2.4.2 Grands modèles de langue, prompts et RAG

Les LLM [9, 21, 62, 63, 74, 75, 78] permettent de produire, à la demande, des explications, reformulations et exercices en langage naturel. Kasneci *et al.* recensent les opportunités (personnalisation, accessibilité) et les risques (hallucinations, biais, absence de traçabilité) de leur usage éducatif [43]. Les revues 2023–2024 confirment à la fois le potentiel et les tensions éthiques, pédagogiques et d'intégrité académique [6, 13, 15, 16, 22, 24, 29, 36, 41, 50, 56, 58, 73, 76, 80, 87]. Sans guidage, un LLM produit un texte libre dont la forme pédagogique et la fidélité factuelle ne sont pas garanties.

Deux mécanismes d'encadrement s'imposent. Le *prompt engineering* structure la génération par un rôle, un format, un ton et une longueur [51, 82, 83]. La génération augmentée par récupération (RAG) [2, 23, 27, 40, 47] ancre le prompt sur des passages extraits d'une base documentaire, ce qui réduit les inventions factuelles. En contexte pédagogique, le RAG permet d'adosser le contenu à des fiches de cours validées, mécanisme retenu par EmoLearn.

Liu *et al.* (2025) évaluent les LLM non pas comme générateurs de cours, mais comme classifieurs d'engagement textuel [53]. Leur méthode AGKA enrichit le prompt par les définitions extraites des guides d'annotation et par quelques exemples typiques. GPT-4 [62] et LLaMA 3 70B [21] ainsi augmentés rivalisent avec BERT/RoBERTa fine-tunés sur des tâches binaires, mais restent en retrait sur les taxonomies multi-classes sémantiquement proches. Ce résultat est doublement utile : il confirme que le guidage par consignes d'annotation améliore les LLM en éducation, et il rappelle qu'un LLM n'est pas, à lui seul, un détecteur multimodal d'états affectifs. EmoLearn inverse la perspective : le LLM n'y classifie pas l'engagement, il *génère* le contenu une fois l'état décidé par la couche de perception.

2.4.3 Génération de contenu conditionnée par le profil psychologique

Hu et Shao proposent PAGE (*Psychologically-Aware Generative Education*), un système GenAI qui adapte le style, la difficulté et les mécanismes de soutien au profil Big Five et au feedback émotionnel en temps réel [37]. Sur 200 étudiants, PAGE améliore la satisfaction émotionnelle (4,4/5 contre 3,6/5), le taux de complétion des tâches (87,6 % contre 72,3 %) et la durée d'étude (+34 %) par rapport à un système adaptatif classique ; le bénéfice est particulièrement marqué pour les étudiants à neuroticisme élevé (baisse de 48 % du décrochage). PAGE est le travail le plus proche d'EmoLearn du point de vue de la *génération* : il relie un signal affectif à un contenu produit par LLM.

Trois écarts demeurent. Premièrement, l'émotion y est un feedback (souvent déclaratif ou de surface), et non une estimation multimodale visage–voix fondée sur des corpus publics. Deuxièmement, l'adaptation est pilotée par un profil de personnalité relativement stable, alors qu'EmoLearn vise un état d'engagement *momentané* (confusion de cette minute, ennui de ce clip). Troisièmement, PAGE ne documente pas de moteur de décision explicite ni d'ancrage RAG : la génération n'est pas contrainte par une bibliothèque de patrons traçables ni par un corpus de fiches pédagogiques.

2.4.4 Outils d'intervention sur les discussions

Kong *et al.* évaluent un outil de représentation des discussions assisté par IA (représentations comportementales, cognitives, ou mixtes) auprès de 122 étudiants [45]. L'outil n'améliore pas significativement la motivation, mais augmente la présence cognitive de haut niveau et la performance, et module positivement le lien motivation–présence cognitive–réussite. Il s'agit d'une intervention *sur le forum* (rendre visible le processus collaboratif), non d'une génération de contenu de cours conditionnée par l'état d'un apprenant isolé. Le résultat confirme néanmoins qu'une médiation IA, si elle est bien conçue, peut élever le niveau cognitif, argument en faveur d'une boucle détection–intervention, à condition d'en changer le canal (vidéo de cours plutôt que fil de discussion).

2.4.5 Évaluation de la qualité pédagogique

La qualité du contenu généré se juge sur des critères humains (pertinence, clarté, adéquation à l'état) complétés par des métriques automatiques de forme (longueur, lisibilité, respect du patron). Aucune métrique automatique ne se substitue à une validation experte ou utilisateur [37, 43]. Les travaux de détection rapportent surtout des F1 et des κ ; les travaux génératifs rapportent des scores de satisfaction. Un protocole multi-niveaux (perception, décision, génération) reste rare. C'est l'un des choix métho-

dologiques d'EmoLearn, détaillé au chapitre 5.

2.5 Synthèse comparative des travaux

Les tableaux suivants proposent une synthèse comparative des travaux récents :

Table 2.1: Synthèse comparative des travaux.

Référence	Approche	Contexte	Forces	Limites	Résultats clés
Cadres théoriques, enjeux MOOC et corpus					
Daniel [19] ; Breslow *et al.* [8]	Analyse de plateformes MOOC	Formation en ligne massive	Accès ouvert, données à grande échelle	Pas de détection d'état affectif	Démocratisation de l'accès, pédagogie à l'échelle
Onah *et al.* [61] ; Jordan [42] ; Reich et Ruipérez-Valiente [68]	Statistiques de rétention	Achèvement des MOOC	Diagnostic robuste du décrochage	Constat sans levier d'intervention	Abandon précoce ; taux moyen ≈ 10 %
Kizilcec *et al.* [44] ; Hew [35]	Clustering de trajectoires ; études de cas	Engagement dans les MOOC	Identification de sous-populations et de leviers	Proxies comportementaux (clics, progression)	L'engagement explique une part majeure du décrochage
Fredricks *et al.* [25]	Synthèse conceptuelle	Psychologie de l'éducation	Trois dimensions (comportement, cognition, émotion)	Pas d'estimateur automatique	Cadre de référence encore dominant
Garrison *et al.* [28]	Community of Inquiry (CoI)	Discussions en ligne	Quatre phases de présence cognitive	Conçu pour les forums, pas pour la vidéo	Schéma d'annotation largement repris
Chi et Wylie [12]	Taxonomie ICAP	Engagement cognitif	Lien mode d'activité → apprentissage	Codage d'activités, pas d'affect facial/vocal	Plus l'activité est constructive, plus le traitement est profond
Picard [67]	Informatique affective	Reconnaissance d'émotions	Fondement théorique de la détection	Socle, sans pipeline pédagogique	L'affect est mesurable et actionnable
Pekrun [65]	Théorie contrôle–valeur	Émotions d'accomplissement	Lien valence / activation / performance	Pas d'opérationnalisation logicielle	Les émotions modulent attention et persévérance
D'Mello et Graesser [17] ; Baker *et al.* [4]	Dynamique d'états affectifs	Apprentissage complexe médiatisé	Séquence confusion–frustration–ennui	Pas de génération de contenu	Mieux vaut être frustré qu'ennuyé
D'Mello [18]	Méta-analyse	États affectifs en EIAH	Incidence relative des états ; fusion multimodale	Synthèse, pas de système	Ennui, confusion, engagement et frustration sont les états clés
Sweller [71]	Théorie de la charge cognitive	Conception pédagogique	Explique surcharge et sous-stimulation	Théorie, sans détecteur	Ajuster la complexité au profil de l'apprenant
DAiSEE [32]	Corpus vidéo annoté	Engagement « in the wild »	Quatre états, intensité 0–3	Fort déséquilibre de classes	Taxonomie opératoire pour la détection faciale

Suite à la page suivante...

Suite du tableau 2.1

Référence	Approche	Contexte	Forces	Limites	Résultats clés
IEMOCAP [10]	Corpus audiovisuel	Émotion conversationnelle	Voix riche, visage et voix alignés	Taxonomie émotionnelle, pas d'engagement MOOC	Référence SER ; cadre de fusion alignée
Détection de l'engagement, ITS et génération adaptative					
Sakeef *et al.* [69]	Revue CoI / ICAP / KCSA + TALN	Forums de cours en ligne	Cartographie des cadres et des méthodes IA	Texte seul ; pas de webcam/micro	L'automatisation du codage est indispensable au suivi continu
Hu *et al.* [38]	CNN + XAI	Présence cognitive (CoI)	Explicabilité au niveau des mots	Texte seul ; généralisabilité limitée	κ de Cohen = 0,528, comparable aux forêts aléatoires
Liu *et al.* [55]	SNA + ENA	Forum MOOC (3 925 apprenants)	Lien réseau social / traitement cognitif / réussite	Analyse collective, hors temps réel	Centralité et connexions cognitives plus fortes chez les performants
Liu *et al.* [52]	BERT-CNN	Forums MOOC (8 867 apprenants)	Détection conjointe émotion + cognition	Pas d'intervention générée	F1 +10 % (émotion) et +8 % (cognition) ; effet combiné sur la réussite
Liu *et al.* [54]	MOOC-BERT (pré-entraînement multi-cours)	Présence cognitive dans les MOOC	Généralisation inter-cours, sans ingénierie de traits	Diagnostic enseignant, sans contenu adaptatif	Surpasse ML et DL représentatifs ; analyse longitudinale des phases
Liu *et al.* [53]	LLM + AGKA (guides d'annotation)	Classification d'engagement textuel	GPT-4 / LLaMA 3 rivalisent avec BERT en binaire	LLM comme détecteur, pas comme générateur ancré	Retrait sur les taxonomies multi-classes sémantiquement proches
Whitehill *et al.* [84]	Classifieur d'expressions faciales	Engagement en classe / e-learning	Fiabilité comparable à l'annotation humaine	Pas de voix, pas de génération	L'engagement facial est mesurable automatiquement
Xiong *et al.* [86]	CNN-Transformer (visage + posture)	Classe réelle annotée	Combine grain fin (visage) et grain large (posture)	Pas de voix, pas de boucle pédagogique	Accuracy 92,9 %, supérieure aux baselines DL
Baevski *et al.* [3]	wav2vec 2.0	Représentations de parole	Encodeur auto-supervisé réutilisable (SER)	Générique, pas d'engagement pédagogique	Socle de fine-tuning vocal largement adopté
VanLehn [77]	ITS, contenu pré-auteuré	Tutorat cognitif	Efficacité proche d'un tuteur humain	Peu d'affect ; contenu figé	Les meilleurs ITS approchent le tutorat humain
Brown *et al.* [9] ; Touvron *et al.* [74]	LLM (GPT-3, LLaMA)	Génération de texte	Production à la demande, few-shot	Hallucinations ; pas d'état d'engagement	Faisabilité d'un contenu pédagogique généré
Kasneci *et al.* [43]	Revue LLM pour l'éducation	Enseignement et apprentissage	Cartographie opportunités / risques	Pas de prototype multimodal	Fiabilité, biais et traçabilité restent ouverts

Suite à la page suivante...

Suite du tableau 2.1

Référence	Approche	Contexte	Forces	Limites	Résultats clés
Lewis *et al.* [47]	RAG (index + générateur)	Tâches NLP intensives en connaissances	Ancrage documentaire, moins d'hallucinations	Non couplé à l'engagement	Le contexte récupéré conditionne la génération
Kong *et al.* [45]	Outil de représentation IA	Apprentissage collaboratif en ligne ($n = 122$)	Hausse de la présence cognitive de haut niveau	Canal forum, pas de contenu de cours	Performance améliorée ; motivation non significativement accrue
Hu et Shao [37]	GenAI PAGE (Big Five + émotion)	Contenu pédagogique personnalisé ($n = 200$)	Adaptation du style, de la difficulté et du soutien	Pas de fusion visage–voix, ni RAG, ni règles explicites	Satisfaction 4,4/5 vs 3,6 ; complétion 87,6 % vs 72,3 %

Quatre lacunes se dégagent, aucune n'étant comblée isolément par les travaux ci-dessus.

1. **Signal.** La majorité des détecteurs récents opèrent sur le texte des forums [52, 54, 69]. Les approches visuelles existent [84, 86] mais fusionnent rarement visage *et* voix, alors que ces deux modalités sont réalistes devant une vidéo de cours.
2. **Décision.** Quand une intervention existe, elle est souvent opaque (réglage de style d'un LLM) ou pédagogique au niveau du groupe (outil de forum). Un moteur de règles *explicites*, journalisé, reliant un état discret à un type de contenu, reste rare.
3. **Génération.** PAGE montre le bénéfice d'un contenu GenAI psychologiquement adapté [37], mais sans ancrage documentaire. Inversement, le RAG [47] n'est presque jamais couplé à un état d'engagement multimodal.
4. **Évaluation.** Les papiers de détection rapportent F1 / κ / accuracy ; les papiers génératifs rapportent satisfaction et complétion. Un protocole unique qui évalue perception, décision et qualité du contenu sur un banc d'essai partagé n'apparaît pas dans les travaux recensés.

EmoLearn se positionne précisément sur ces quatre écarts : chaîne perception (FER + SER + fusion) → décision interprétable → génération par LLM guidée par vingt patrons et ancrée par RAG, évaluée de façon multi-niveaux. Les limites assumées (simulation sur corpus annotés, appariement visage–voix hétérogène en production, mapping émotion → engagement comme hypothèse) sont traitées au chapitre 6 plutôt que dissimulées.

2.6 Conclusion

Ce chapitre a organisé l'état de l'art en trois familles. Les travaux sur l'engagement dans les MOOC établissent le diagnostic : décrochage massif, centralité des dimensions émotionnelle et cognitive, cadres CoI / ICAP opératoires pour les forums mais

insuffisants pour un apprenant silencieux devant une vidéo. Les travaux de détection montrent une maturité réelle du côté textuel (BERT-CNN, MOOC-BERT, AGKA) et des avancées visuelles (CNN-Transformer, DAiSEE), sans fermer la boucle pédagogique. Les travaux d'intervention (ITS, PAGE, outils de discussion) montrent qu'une médiation IA peut élever engagement et performance, mais rarement à partir d'une perception multimodale traçable et d'un contenu ancré.

La lacune scientifique n'est donc pas l'absence de détecteurs, ni l'absence de générateurs : c'est l'absence d'une architecture intégrale, reproductible, qui relie les deux. C'est cette architecture que le chapitre suivant modélise et conçoit.

Chapitre 3

Méthodologie proposée et architecture du framework

Sommaire

3.1 Introduction 26
3.2 Architecture générale du framework EmoLearn 26
3.2.1 Principes de conception 26
3.2.2 Architecture en trois couches 27
3.2.3 Workflow de génération adaptative 28
3.3 Analyse du dataset DAiSEE 29
3.3.1 Description et caractéristiques 29
3.3.2 Distribution des états d'engagement 30
3.3.3 Analyse exploratoire des données 31
3.3.4 Identification de patterns critiques 31
3.4 Positionnement et usage du corpus IEMOCAP 32
3.4.1 Complémentarité avec DAiSEE 32
3.4.2 Description et caractéristiques 33
3.4.3 Projection des émotions vers la taxonomie DAiSEE 33
3.4.4 Appariement voix–scénarios dans le pipeline produit 33
3.4.5 Sous-corpus audiovisuel aligné (Option A) 34
3.4.6 Analyse de sensibilité du mapping 34
3.5 Couche de perception 35
3.5.1 Taxonomie des états et mapping facial de référence 35
3.5.2 Perception faciale : mapping, classifieur et fine-tuning ViT . . 35
3.5.3 Perception vocale : heuristique acoustique et fine-tuning wav2vec2 36
3.5.4 Fusion multimodale : formalisation 36
3.5.5 Les deux familles de fusion 37

3.6 Modèle engagement-adaptation 38
3.6.1 Formulation 38
3.6.2 Mapping états vers besoins pédagogiques 38
3.6.3 Règles de déclenchement d'adaptation 39
3.6.4 Stratégies pédagogiques par état 40
3.7 Système de génération 40
3.7.1 Architecture de prompting contextuel 40
3.7.2 Typologie du contenu adaptatif 41
3.7.3 Templates de prompts structurés 41
3.7.4 Mécanismes de contrôle qualité 42
3.8 Conception du prototype de simulation 42
3.8.1 Architecture technique 42
3.8.2 Workflow de simulation 43
3.8.3 Tuteur conversationnel sensible à l'état affectif 43
3.8.4 Interface utilisateur 43
3.9 Pseudo-code de l'algorithme EmoLearn 44
3.10 Conclusion 44

3.1 Introduction

Le chapitre 2 a identifié quatre lacunes que les travaux existants ne comblent pas conjointement : un signal encore trop souvent textuel (forums) là où l'apprenant est silencieux devant une vidéo ; une décision pédagogique rarement explicite ; une génération de contenu rarement ancrée documentairement *et* conditionnée par un état affectif ; enfin l'absence d'un protocole d'évaluation unique couvrant perception, décision et qualité du contenu. Ce chapitre propose l'architecture qui vise à fermer cette boucle.

La démarche relève de la recherche orientée conception [34] : le problème (décrochage lié à la baisse d'engagement dans les MOOC) oriente la construction d'un artefact (le framework EmoLearn) dont les propriétés seront évaluées au chapitre 5. Conformément à ce paradigme, nous distinguons ici *ce que* le système doit faire (modélisation) de *comment* il le fait (implémentation, chapitre 4).

Le chapitre est organisé comme suit. La section 3.2 présente l'architecture générale et le workflow. La section 3.3 analyse le corpus DAiSEE qui fournit la taxonomie d'engagement ; la section 3.4 positionne IEMOCAP comme modalité vocale complémentaire. La section 3.5 formalise la couche de perception (FER, SER, fusion). La section 3.6 décrit le modèle engagement $\rightarrow$ adaptation. La section 3.7 détaille le système de génération, la section 3.8 la conception du prototype, et la section 3.9 rassemble le pseudo-code de la chaîne complète.

3.2 Architecture générale du framework EmoLearn

3.2.1 Principes de conception

Trois principes structurent l'artefact, en réponse directe aux lacunes du chapitre 2.

1. **Chaîne complète.** Perception, décision et génération appartiennent au même pipeline. Un détecteur sans intervention, ou un LLM sans état d'engagement, ne suffisent pas (chapitre 2).
2. **Décision explicable.** Chaque adaptation doit être justifiable par un état, une règle et un patron nommé (A1–D5). Le moteur n'est pas une boîte noire : il journalise ses choix.
3. **Moteurs uniques.** Le module de fusion et le moteur de décision sont *partagés* entre la production (génération de contenu) et le banc d'essai. Ce qui est évalué est exactement ce qui est utilisé.

3.2.2 Architecture en trois couches

EmoLearn est une chaîne organisée en trois couches successives. Chaque couche répond à une question distincte.

Couche de perception : « Que ressent l'apprenant ? » Elle estime l'état d'engagement à partir de deux modalités : le **visage**, via un module FER appliqué aux clips DAiSEE, et la **voix**, via un module SER s'appuyant sur IEMOCAP. Un module de fusion combine les deux estimations et gère les conflits.

Couche de décision : « Faut-il intervenir, et comment ? » Elle applique, sur l'état fusionné et son historique temporel, un ensemble de règles qui déterminent (i) s'il convient de déclencher une adaptation, (ii) le type de contenu (A/B/C/D) et (iii) le patron précis à mobiliser.

Couche de génération : « Quel contenu produire ? » Elle construit un prompt contextuel à partir du patron retenu, éventuellement enrichi par RAG, puis sollicite un grand modèle de langue pour produire le contenu adaptatif.

La figure 3.1 présente cette architecture. Un apprenant isolé devant une vidéo de cours constitue le scénario cible, distinct des forums sur lesquels opèrent la majorité des détecteurs recensés au chapitre 2.

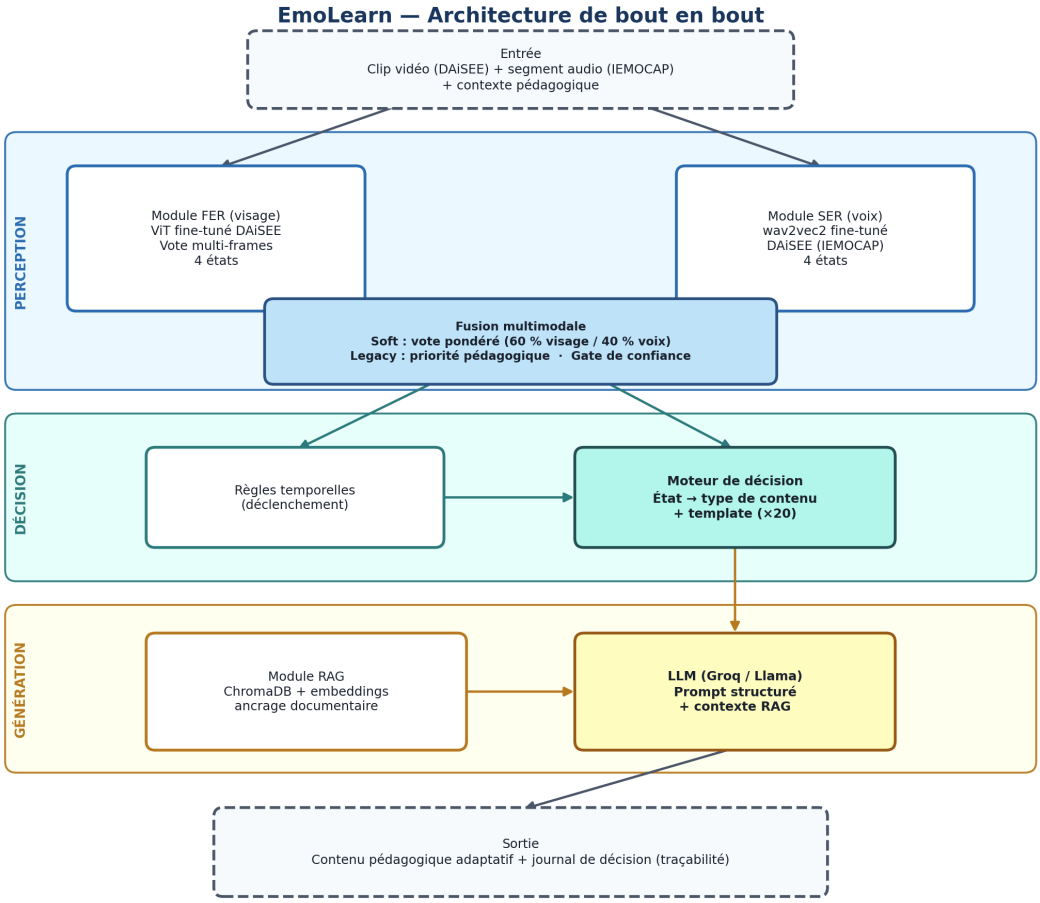


FIGURE 3.1 – Architecture en couches d'EMOLEARN.

3.2.3 Workflow de génération adaptative

Le traitement d'un clip suit un enchaînement déterministe de sept étapes.

1. **Acquisition.** Le fichier vidéo du clip DAISEE est résolu sur disque, puis associé au segment audio apparié et à un contexte pédagogique (concept, module, niveau, moment du cours).
2. **Perception par modalité.** Le module FER traite *uniquement* le visage : il détecte le visage sur plusieurs images du clip, agrège les distributions par vote multi-frames, et estime l'état facial. En parallèle, le module SER traite *uniquement* la voix et estime l'état vocal. Chaque module reste donc séparé (une modalité = un estimateur) ; ce n'est qu'à l'étape suivante que les deux sorties sont combinées.
3. **Fusion.** Les deux estimations sont combinées (pondération $w_v = 0{,}6$ / $w_a = 0{,}4$) et les conflits sont résolus (section 3.5).
4. **Analyse temporelle.** L'historique récent des clips décide de l'urgence et du déclenchement.

5. **Décision.** Si une intervention est requise, le moteur détermine la stratégie, le type de contenu et le patron (A1–D5).
6. **Génération.** Un prompt structuré est construit, éventuellement enrichi par le RAG, puis soumis au LLM.
7. **Restitution et traçabilité.** Le contenu est renvoyé à l'interface ; chaque décision est journalisée (état, stratégie, patron, paramètres de fusion).

Lorsque l'analyse temporelle conclut à un engagement stable, aucune génération n'est déclenchée : le système signale une *non-intervention*. Ce choix évite de sur-solliciter l'apprenant et documente le choix de ne rien faire.

Perception sur le signal, annotations réservées à la vérité terrain. La couche de perception opère sur le **signal brut** et non sur les annotations du corpus. Le module FER ouvre le fichier vidéo, y détecte le visage et produit ses propres distributions ; le module SER analyse la forme d'onde. Les niveaux annotés dans DAiSEE tiennent exclusivement le rôle d'**étiquettes de référence**, pour l'entraînement des mappings appris (section 3.5) et pour la validation. Un système qui lirait les annotations pour *estimer* l'état n'évaluerait que lui-même.

3.3 Analyse du dataset DAiSEE

3.3.1 Description et caractéristiques

Le corpus DAiSEE (*Dataset for Affective States in E-Environments*) [32] est un jeu de données vidéo de référence pour la reconnaissance de l'engagement « dans la nature » (*in the wild*). Il rassemble environ 9 000 clips d'une dizaine de secondes, capturés auprès d'étudiants en situation réelle d'apprentissage en ligne, dans des conditions variées d'éclairage et d'arrière-plan. Chaque clip est annoté selon **quatre états affectifs** (l'ennui (*boredom*), la confusion, l'engagement et la frustration), chacun exprimé sur une échelle ordinale à **quatre niveaux d'intensité** (0 : très faible, 1 : faible, 2 : élevé, 3 : très élevé). Le tableau 3.1 synthétise cette taxonomie, qui constitue le référentiel de tout le projet. Elle est plus opératoire, pour un apprenant silencieux devant une vidéo, que les cadres CoI ou ICAP discutés au chapitre 2, conçus pour le codage de forums.

État	Signification dans le contexte d'apprentissage
Engagement	Attention active et implication dans la tâche d'apprentissage.
Boredom	Ennui, désengagement passif, baisse de la stimulation.
Confusion	Incompréhension d'un concept, difficulté de traitement.
Frustration	Blocage émotionnel, tension liée à une difficulté persistante.

TABLE 3.1 – Les quatre états affectifs annotés dans DAiSEE (niveaux d'intensité 0 à 3).

Chaque enregistrement est identifié par un `ClipID` et associé à un quadruplet de scores $s = (s_{\mathrm{B}}, s_{\mathrm{C}}, s_{\mathrm{E}}, s_{\mathrm{F}}) \in \{0,1,2,3\}^4$. L'**état dominant** d'un clip est

$$e^{\star} \;=\; \arg\max_{e \in E} s_e, \tag{3.1}$$

où $E = \{\mathrm{Boredom}, \mathrm{Confusion}, \mathrm{Engagement}, \mathrm{Frustration}\}$. En cas d'égalité, un départage pédagogique s'applique : Frustration > Confusion > Boredom > Engagement. Cette règle garantit qu'un apprenant en difficulté n'est jamais classé « engagé » par simple ex-æquo : mieux vaut signaler une frustration que la masquer derrière un engagement concurrent.

3.3.2 Distribution des états d'engagement

L'analyse des annotations révèle un **déséquilibre de classes marqué**, caractéristique documentée de DAiSEE. L'engagement est largement dominant (niveaux 2 ou 3), tandis que la confusion et surtout la frustration intenses sont rares. Deux conséquences en découlent pour la conception :

— les états *critiques* (confusion et frustration élevées), pourtant les plus importants pédagogiquement, sont **sous-représentés** ;
— maximiser l'exactitude globale tendrait à privilégier la classe majoritaire au détriment des états à risque.

Ce constat justifie d'accorder une **priorité pédagogique** aux états négatifs dans la fusion et la décision (section 3.6). La figure 3.2 restitue la distribution observée.

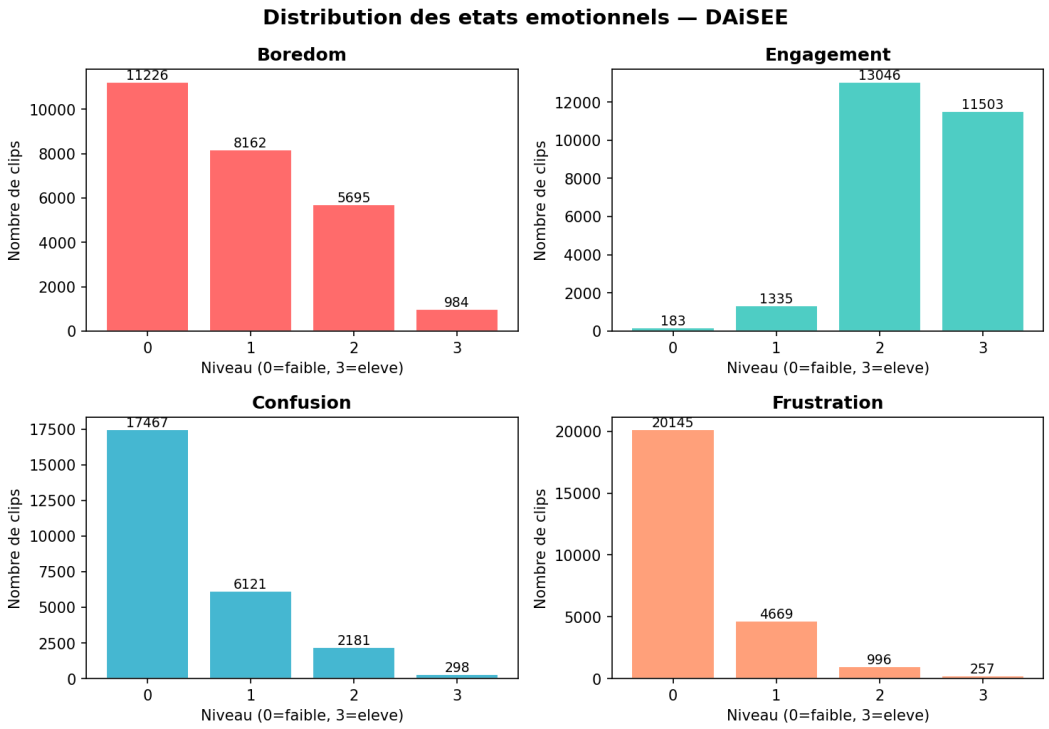


FIGURE 3.2 – Distribution des états d'engagement dans DAISEE (ensemble des partitions annotées du corpus).

3.3.3 Analyse exploratoire des données

L'analyse exploratoire poursuit trois objectifs. Premièrement, **caractériser les co-occurrences** : l'engagement varie en sens inverse de l'ennui, tandis que confusion et frustration tendent à coexister. Deuxièmement, **déterminer l'état dominant** de chaque clip via l'équation (3.1). Troisièmement, **constituer un sous-ensemble représentatif** : une sélection de scénarios (clips isolés) et de parcours (séquences) alimente la simulation.

3.3.4 Identification de patterns critiques

Au-delà de l'état instantané, la conception introduit un **pattern pédagogique** qui qualifie la situation globale d'un clip ou d'une séquence et oriente le choix du patron de génération (tableau 3.2).

Pattern	Condition (scores DAiSEE)
critique	Au moins trois états simultanément ≥ 2 (situation cumulée).
engagement_faible	Engagement ≤ 1, sans confusion ni frustration marquées.
confusion	État dominant = Confusion.
ennui_eleve	État dominant = Boredom.
frustration	État dominant = Frustration.
stable	Engagement dominant, situation acceptable.

TABLE 3.2 – Patterns pédagogiques dérivés des scores DAiSEE.

3.4 Positionnement et usage du corpus IEMOCAP

IEMOCAP (*Interactive Emotional Dyadic Motion Capture*) [10] constitue le **second jeu de données** mobilisé. Contrairement à DAiSEE, il ne fonde pas la taxonomie pédagogique : il apporte la **modalité vocale** et, dans un cadre distinct, un **sous-corpus audiovisuel aligné** pour valider la fusion.

3.4.1 Complémentarité avec DAiSEE

Les deux corpus couvrent des contextes distincts, mais convergent vers la même taxonomie à quatre états (tableau 3.3). Cette complémentarité répond à la lacune « signal » du chapitre 2 : fusionner visage *et* voix, plutôt que le seul canal visuel.

Aspect	DAiSEE	IEMOCAP
Contexte	Apprenants en e-learning (*in the wild*)	Dialogues actés, dyades (sessions 1–5)
Modalité principale	Visage / engagement annoté	Voix (+ vidéo pour le banc d'essai)
Étiquettes natives	4 états × niveaux 0–3	Émotions discrètes + dimensions VAD
Rôle dans EmoLearn	Socle : scénarios, patterns, décision	Voix en production ; validation AV alignée

TABLE 3.3 – Complémentarité des corpus DAiSEE et IEMOCAP dans EMOLEARN.

3.4.2 Description et caractéristiques

IEMOCAP rassemble des enregistrements audiovisuels de dialogues entre deux acteurs, annotés au niveau de l'*utterance* par des émotions discrètes et par des scores valence–activation–dominance (VAD). Le corpus parsé du projet compte 10 039 utterances, chacune associée à un fichier audio réel. Les annotations sont consommées par le module SER (section 3.5.3).

3.4.3 Projection des émotions vers la taxonomie DAiSEE

Les émotions conversationnelles d'IEMOCAP ne coïncident pas naturellement avec les états d'engagement de DAiSEE. La conception retient donc une **table de projection** (tableau 3.4). Cette correspondance est une **hypothèse de construit**, et non une équivalence psychologique démontrée : elle rend le pipeline cohérent en ramenant visage et voix dans un espace commun, mais elle doit être mesurée (section 3.4.6).

Code IEMOCAP	État DAiSEE	Niv.	Justification pédagogique
hap, exc	Engagement	3	Valence positive, activation forte
neu	Boredom	1	Neutre prolongé ≈ faible stimulation
sad	Boredom	2	Faible engagement
ang, fru	Frustration	3	Blocage, tension
dis	Frustration	2	Rejet, gêne modérée
sur, fea	Confusion	2–3	Incertitude, surprise cognitive
xxx	Boredom	1	Non classifié → défaut prudent

TABLE 3.4 – Projection de référence des émotions IEMOCAP vers la taxonomie DAiSEE (hypothèse de travail).

3.4.4 Appariement voix–scénarios dans le pipeline produit

Dans la chaîne de **production** (simulation sur clips DAiSEE), le visage et la voix ne proviennent pas du même individu : le FER analyse un clip DAiSEE, le SER sélectionne une utterance IEMOCAP *émotionnellement cohérente* avec l'état dominant du scénario. La règle est la suivante :

1. calcul de l'état dominant du scénario DAiSEE (équation (3.1)) ;
2. filtrage des utterances projetées sur le *même* état ;

3. sélection reproductible via l'identifiant du scénario (`scenario_id` modulo la taille du pool) ;
4. analyse du segment audio réel sur l'intervalle annoté.

Cet appariement améliore la cohérence émotionnelle par rapport à un tirage aléatoire, mais conserve une limite assumée : **absence de synchronisation temporelle** entre l'apprenant filmé et le locuteur enregistré. Cette tension n'est levée que dans le banc d'essai ci-dessous.

3.4.5 Sous-corpus audiovisuel aligné (Option A)

Pour **valider la fusion** sans l'appariement hétérogène, un sous-corpus IEMOCAP **audiovisuel aligné** est construit hors ligne : pour chaque utterance, le visage et la voix proviennent du **même locuteur**, synchronisés sur le segment annoté. Les vidéos dyadiques imposent un crop (moitié gauche ou droite selon les marqueurs mocap). Ce banc d'essai partage le **même moteur de fusion** que la production ; seules les entrées changent. Les métriques comparatives sont présentées au chapitre 5.

3.4.6 Analyse de sensibilité du mapping

La robustesse de la projection émotion → engagement est évaluée par une **analyse de sensibilité** sur les 10 039 utterances (tableau 3.5). Les variantes affectant `neu` (neutre → Engagement) ou `sad` (tristesse → Frustration) modifient jusqu'à 17 % et 10,8 % des étiquettes projetées, confirmant que l'hypothèse n'est pas anodine. Le protocole et la discussion sont détaillés au chapitre 5.

Variante testée	Modification du mapping	Utterances
neu_engagement	`neu` → Engagement (au lieu de Boredom)	17,0 %
sad_frustration	`sad` → Frustration (au lieu de Boredom)	10,8 %
surprise_engagement	`sur` → Engagement (au lieu de Confusion)	1,1 %
disgust_boredom	`dis` → Boredom (au lieu de Frustration)	0,0 %

TABLE 3.5 – Sensibilité du mapping IEMOCAP → DAiSEE (sur 10 039 utterances).

3.5 Couche de perception

La perception transforme un couple (vidéo, audio) en une distribution sur E et en un couple $(\hat{e}, \hat{n})$ (état et niveau). Chaque modalité dispose d'une *référence explicable* et d'une *variante fine-tunée* ; la fusion existe en deux familles aux objectifs distincts.

3.5.1 Taxonomie des états et mapping facial de référence

Les émotions produites par les modules FER (sept classes) et SER sont d'abord ramenées dans l'espace DAiSEE. Cette mise en correspondance est conçue à **deux niveaux** : une table fixe, justifiable *a priori* (tableau 3.6) ; et un modèle *appris* qui la remplace lorsqu'il apporte un gain mesuré.

Émotion faciale	État DAiSEE	Niveau associé
happy	Engagement	3
neutral	Boredom	1
sad	Boredom	2
angry	Frustration	3
fear	Confusion	3
surprise	Confusion	2
disgust	Frustration	2

Table 3.6 – Mapping heuristique de référence des émotions faciales (FER) vers les états DAiSEE.

3.5.2 Perception faciale : mapping, classifieur et fine-tuning ViT

La table 3.6 traduit un raisonnement pédagogique (un visage en colère signale une frustration, un visage neutre l'amorce d'un désengagement) mais elle n'est calibrée sur aucune donnée. La conception prévoit donc plusieurs niveaux, du plus transparent au plus performant.

Le premier niveau appris, volontairement *léger*, laisse le réseau de reconnaissance faciale pré-entraîné inchangé et n'apprend que le lien entre ses sept scores d'émotion et la taxonomie d'engagement. Un **Random Forest** est entraîné sur ce couple (étiquettes DAiSEE), avec sélection d'hyperparamètres par validation croisée stratifiée. Un garde-fou peut conditionner l'usage de ce mapping à un gain simultané d'exactitude et de F-score macro, afin d'éviter un classifieur biaisé vers Engagement.

Le mode retenu **par défaut en production** va plus loin : un **Vision Transformer**

(ViT) [20] est **fine-tuné** de bout en bout vers les quatre états DAiSEE, à partir d'un modèle pré-entraîné d'émotions faciales. Le runtime agrège plusieurs frames du clip (moyenne des probabilités, avec rejet des frames peu confiantes). Ce choix élimine le détour par les sept émotions génériques et produit directement une distribution $P_{\text{visage}}(e)$ sur E.

Les modes demeurent interchangeables par configuration : mapping heuristique, Random Forest, ou ViT fine-tuné (défaut). La table 3.6 conserve le statut de **baseline**.

3.5.3 Perception vocale : heuristique acoustique et fine-tuning wav2vec2

Le module vocal suit la même logique. La **méthode heuristique** sert de référence : elle extrait des descripteurs acoustiques classiques (énergie, taux de passage par zéro, centroïde spectral, F_0) puis applique des seuils dans l'espace valence–activation–dominance, avant projection vers DAiSEE. Entièrement transparente, elle reste grossière.

La **méthode apprise**, retenue par défaut, part d'un encodeur wav2vec2 [3] déjà spécialisé pour la reconnaissance d'émotions, **fine-tuné** vers les quatre états DAiSEE (*full fine-tuning*). Ce choix répond à une contrainte précise : le modèle de base ne possède aucune classe **Confusion**. Le fine-tuning sur des étiquettes projetées (surprise et peur alimentant Confusion) fait émerger cette classe absente. Une pondération de classes compense le déséquilibre. L'heuristique sert de repli lorsque le modèle n'est pas disponible.

3.5.4 Fusion multimodale : formalisation

Soit $P_v(e)$ et $P_a(e)$ les distributions produites par le visage et la voix, et $w_v \in [0,1]$ le poids du visage ($w_a = 1 - w_v$). Deux familles de fusion sont conservées.

Famille *weighted vote* (défaut produit). La pondération porte sur l'état lui-même :

$$\hat{P}(e) \;=\; w_v\, P_v(e) \;+\; (1 - w_v)\, P_a(e), \qquad \hat{e} \;=\; \arg\max_{e \in E} \hat{P}(e). \tag{3.2}$$

Un *gate* de fiabilité annule le poids d'une modalité dont le score de confiance est inférieur à un seuil θ (défaut 0,40). Si les deux modalités sont sous le seuil, un repli de priorité pédagogique s'applique. Si la voix est absente, (3.2) se réduit à P_v.

Famille *pedagogical priority* (legacy). Chaque modalité décide d'abord un état (e_v, n_v) et (e_a, n_a). Si $e_v = e_a$, le niveau fusionné est la moyenne pondérée

$$\hat{n} \;=\; \text{round}\Big(w_v\, n_v + (1 - w_v)\, n_a\Big). \tag{3.3}$$

Si $e_v \neq e_a$, l'état retenu est celui de priorité maximale

$$\pi(\text{Frustration}) > \pi(\text{Confusion}) > \pi(\text{Boredom}) > \pi(\text{Engagement}), \tag{3.4}$$

indépendamment de w_v. Dans cette formulation, **le poids des modalités n'influence pas l'état** : il ne pondère que le niveau. C'est précisément ce que la famille par vote corrige.

Le tableau 3.7 résume la gestion des conflits dans la famille legacy ; le tableau 3.8 compare les deux objectifs.

Type de conflit	Résolution
Accord parfait / partiel	Fusion pondérée normale ($w_v = 0{,}6$).
Conflit de niveau	Moyenne pondérée des niveaux (même état).
Conflit mineur	Modalité au score de confiance le plus élevé.
Conflit modéré / majeur	*Pedagogical priority* (défaut) ou *confidence*.

TABLE 3.7 – Gestion des conflits dans la fusion multimodale (famille legacy).

3.5.5 Les deux familles de fusion

Les deux familles ne poursuivent pas le même objectif et sont donc conservées, sélectionnables par configuration. La fusion par priorité pédagogique est volontairement asymétrique : elle accepte de se tromper au profit de l'état le plus grave. La fusion par vote est symétrique et vise l'exactitude. Le chapitre 5 mesure l'arbitrage.

Famille	Ce que pondère w_v	Objectif optimisé
Pedagogical priority	Le niveau d'intensité ; l'état suit (3.4)	Rappel des états critiques (sécurité pédagogique)
Weighted vote	L'état lui-même, via (3.2)	Exactitude de la décision

TABLE 3.8 – Les deux familles de fusion et leurs objectifs respectifs.

Choix des poids. La valeur $w_v = 0{,}6$ traduit d'abord une hypothèse (le visage est la modalité native de DAiSEE), puis fait l'objet d'un balayage empirique de 0,5 à 0,9 (chapitre 5). Le poids n'a d'effet sur l'état que dans la variante par vote ; 0,6/0,4 maximise le rappel des états urgents, conformément à la priorité posée en section 3.3.

3.6 Modèle engagement-adaptation

Le modèle engagement → adaptation constitue le cœur scientifique du framework. Il transforme l'état perçu $(\hat{e}, \hat{n})$ et l'historique H en une décision pédagogique traçable : un type de contenu, un patron et un déclenchement. C'est la réponse à la lacune « décision » du chapitre 2 : des règles *explicites*, journalisées, plutôt qu'un réglage opaque de style.

3.6.1 Formulation

Soit $H = (s^{(t-k)}, \ldots, s^{(t)})$ l'historique des k derniers quadruplet de scores dérivés de la fusion. Le moteur calcule

$$\big(\tau,\, \gamma,\, u\big) \;=\; \Delta\big(\hat{e},\, \hat{n},\, s^{(t)},\, H\big), \tag{3.5}$$

où $\tau \in \{A, B, C, D, A{+}D, D{+}A, \varnothing\}$ est le type de contenu, $\gamma \in \{A1, \ldots, D5\}$ le patron, et $u \in \{\text{immédiate}, \text{rapide}, \text{différée}, \text{aucune}\}$ l'urgence. La fonction Δ est une cascade de règles, non un réseau : chaque sortie est inspectable.

Les scores $s^{(t)}$ utilisés par Δ sont **dérivés de la fusion**, et non lus dans les annotations DAiSEE. Si la fusion expose $\hat{P}$, chaque dimension est projetée sur $\{0, 1, 2, 3\}$ par $s_e = \text{round}(3\,\hat{P}(e))$; sinon, l'état retenu reçoit le niveau fusionné et les autres dimensions valent 0.

3.6.2 Mapping états vers besoins pédagogiques

Quatre types fondamentaux sont définis, plus deux composites :

Type A : Explication. Reformuler un concept mal compris.

Type B : Exemple. Ancrer le concept dans une application concrète.

Type C : Exercice. Approfondir par un défi adapté au niveau.

Type D : Encouragement. Apporter un soutien émotionnel.

Type A+D / D+A : Composites. Combiner explication et soutien lorsque confusion et frustration coexistent.

Le mapping est un ensemble de règles ordonnées, appliquées par priorité décroissante d'urgence (tableau 3.9). La première règle satisfaite l'emporte.

Ordre	Condition (scores DAiSEE)	**Type**	Stratégie
1	Confusion ≥ 3 **et** Frustration ≥ 2	**A+D**	Aide de déblocage immédiate
2	Engagement $= 0$	**B**	Réengagement urgent
3	Frustration ≥ 2	**D+A**	Encouragement + simplification
4	Confusion ≥ 2	**A**	Explication alternative
5	Boredom ≥ 2	**C**	Exercice avancé
6	Engagement ≤ 1	**B**	Exemple concret stimulant
7	Boredom $= 1$	**B**	Application pratique
8	Engagement ≥ 2	**D**	Renforcement positif
9	Sinon	–	Continuation normale (pas d'adaptation)

TABLE 3.9 – Règles de mapping engagement → type de contenu et stratégie.

Cette ordonnance suit une logique pédagogique simple : un contenu trop dense (confusion) appelle une simplification ; un contenu sous-stimulant (ennui) appelle un défi ; un blocage (frustration) appelle d'abord un soutien, non un exercice supplémentaire. Les fondements théoriques correspondants (charge cognitive, dynamique affect–apprentissage) sont exposés aux chapitres 1 et 2.

3.6.3 Règles de déclenchement d'adaptation

La décision d'intervenir ne repose pas uniquement sur le clip courant mais sur sa **dynamique temporelle**. Un module dédié classe la situation selon quatre niveaux d'urgence (tableau 3.10). Cette temporalisation évite deux écueils : réagir à un signal isolé, et laisser s'installer un état négatif durable.

Urgence	Règle de déclenchement
Immédiate	Confusion ≥ 3 et Frustration ≥ 2 sur le clip courant ; ou Engagement $= 0$.
Rapide	Boredom, Confusion ou Frustration ≥ 2 sur 2 clips consécutifs.
Différée	Engagement ≤ 1 (ou Boredom $= 1$) stable sur 4 clips.
Aucune	Engagement ≥ 2 stable sur 2 clips $\rightarrow$ pas d'intervention.

TABLE 3.10 – Règles temporelles de déclenchement de l'adaptation.

Si $u =$ aucune, alors $\tau = \varnothing$: le système n'appelle pas le LLM.

3.6.4 Stratégies pédagogiques par état

En synthèse, chaque état dominant est associé à une famille de stratégies : à la *confusion* répond l'explication (A) ; à l'*ennui* l'exemple (B) ou l'exercice (C) selon que l'engagement est faible ou que la maîtrise est déjà installée ; à la *frustration* le soutien (D), combiné à une simplification en cas de confusion associée ; un *bon engagement* appelle un renforcement positif (D) destiné à entretenir la dynamique.

3.7 Système de génération

3.7.1 Architecture de prompting contextuel

Une fois le patron γ sélectionné, la génération repose sur une **ingénierie de prompt** structurée. Le prompt est organisé en blocs explicites : un contexte de référence issu du RAG (optionnel), un bloc [**Contexte pédagogique**] (sujet, module, concept, niveau, objectif), un bloc [**État d'engagement**] (état, intensité, durée, pattern, moment du cours), un bloc [**Tâche**] (patron et objectif), un bloc [**Contraintes**] (longueur, format, ton) et un bloc [**Instructions spécifiques**] propre au patron. Un *message système* fixe le rôle (expert en pédagogie) et impose de s'appuyer uniquement sur le contexte fourni, afin de limiter les hallucinations. La génération est assurée par un LLM de la famille LLAMA 3.1 [21] servi via API, avec une température basse (0,3) privilégiant la stabilité.

3.7.2 Typologie du contenu adaptatif

Les patrons se répartissent selon les quatre types, chaque type portant un objectif et un registre de ton distincts (tableau 3.11).

Type	Objectif dominant	Registre / ton
A	Clarifier, débloquer	Rassurant, patient, pédagogue
B	Stimuler, contextualiser	Dynamique, concret, motivant
C	Approfondir, consolider	Challengeant, structurant
D	Encourager, renforcer	Empathique, valorisant

TABLE 3.11 – Typologie des contenus adaptatifs par famille de patrons.

3.7.3 Templates de prompts structurés

Le système propose une bibliothèque de **vingt patrons** (A1–A5, B1–B5, C1–C5, D1–D5). Chaque patron définit un format, un ton, une longueur cible et un jeu d'instructions. Cette bibliothèque constitue une contribution centrale de la conception : elle conditionne la génération par l'état, plutôt que par un simple réglage de style ou de difficulté.

TABLE 3.12: Bibliothèque des 20 patrons de prompts structurés (A1–D5).

ID	Description	Format / ton	Long.
A1	Explication alternative : confusion modérée	Étapes / rassurant	200
A2	Micro-explication : confusion intense	Décomposé / patient	150
A3	Aide de déblocage : confusion + frustration	Déblocage / empathique	200
A4	Explication de fond : confusion récurrente	Fond / stratégique	250
A5	Explication narrative : concept abstrait	Narratif / créatif	200
B1	Exemple concret : ennui modéré	Engageant / dynamique	200
B2	Cas pratique : engagement faible	Cas / curiosité	250
B3	Mise en pratique : ennui après théorie	Action / pratique	200
B4	Application réelle : contextualisation	Pro / carrière	250
B5	Exemple interdisciplinaire	Transversal / créatif	200
C1	Exercice avancé : ennui élevé (maîtrise)	Structuré / challengeant	250
C2	Exercice de consolidation	Progressif / encourageant	200
C3	Exercice créatif	Ouvert / valorisant	200
C4	Mini-projet	Projet / ambitieux	250
C5	Exercice comparatif	Analytique / critique	200
D1	Encouragement : frustration modérée	Motivant / empathique	150

Suite du tableau 3.12

ID	Description	Format / ton	Long.
D2	Soutien : frustration élevée	Soutien / déstressant	180
D3	Remotivation : découragement	Remotivant / recentrant	200
D4	Renforcement positif : bon engagement	Positif / valorisant	150
D5	Félicitation : après déblocage	Félicitation / confiant	150

3.7.4 Mécanismes de contrôle qualité

La qualité du contenu est encadrée par plusieurs mécanismes complémentaires, qui répondent à la lacune « génération » (RAG couplé à l'état d'engagement) :

— **Ancrage documentaire (RAG).** Le RAG [47] fournit un contexte de référence indexé, réduisant les inventions factuelles.

— **Consigne anti-hallucination.** Le message système interdit d'inventer des faits absents du contexte.

— **Contraintes de forme.** Chaque patron impose longueur, format et ton.

— **Robustesse d'exécution.** Une politique de nouvelle tentative gère les limites de débit de l'API.

— **Traçabilité.** Chaque génération est journalisée ; des métriques de forme (longueur, lisibilité, répétition) sont calculées *a posteriori*.

3.8 Conception du prototype de simulation

3.8.1 Architecture technique

Le prototype est conçu selon une architecture **client–serveur**. Le serveur expose une API qui orchestre la chaîne perception–décision–génération. Le client est une interface web qui permet de sélectionner un parcours, de le dérouler clip par clip et de visualiser les adaptations. Un magasin de sessions assure la persistance ; la génération s'appuie sur le service LLM distant et, optionnellement, sur une base vectorielle. Le tableau 3.13 résume le rôle de chaque composant. Les choix d'outils (langages, bibliothèques, contraintes matérielles) relèvent du chapitre 4.

Composant	Rôle
API applicative	Orchestration de la chaîne et exposition des endpoints.
Interface web	Sélection des parcours, déroulé, visualisation des adaptations.
Magasin de sessions	Persistance des parcours et de l'historique des décisions.
Service LLM	Génération du contenu adaptatif.
Base vectorielle	Récupération documentaire (RAG) optionnelle.
Tuteur conversationnel	Dialogue libre, paramétré par l'état détecté.

TABLE 3.13 – Principaux composants techniques du prototype.

3.8.2 Workflow de simulation

La simulation reproduit un parcours d'apprentissage : l'utilisateur choisit un scénario (clip isolé) ou une séquence (plusieurs clips), puis avance pas à pas. Pour chaque clip, le prototype exécute la chaîne de la section 3.2.3 et met à jour l'état de session. Les règles temporelles s'appuient sur cet historique, ce qui permet d'observer la réaction du système à l'évolution de l'engagement.

3.8.3 Tuteur conversationnel sensible à l'état affectif

Le contenu adaptatif est produit à l'initiative du système ; il ne couvre pas le cas où l'apprenant pose une question. La conception prévoit un **tuteur conversationnel** qui prolonge le même principe : l'état détecté n'y sélectionne pas un patron, mais paramètre la *manière* de répondre : décomposition en micro-étapes pour la confusion, action unique de déblocage pour la frustration, mise en situation pour l'ennui, approfondissement pour un engagement soutenu. Le module réutilise la même base documentaire que la génération de contenu.

3.8.4 Interface utilisateur

L'interface a été pensée pour rendre la décision **lisible**. Elle affiche, pour chaque clip : les scores et l'état fusionné (avec l'indication d'un conflit éventuel), la décision (type, patron, ou non-intervention), et le contenu généré. Un journal consultable et une fonction d'export complètent le dispositif. Cette exigence de transparence prolonge, au niveau de l'outil, le principe de traçabilité qui guide la conception.

3.9 Pseudo-code de l'algorithme EmoLearn

L'algorithme 1 rassemble la chaîne complète. Il ne présente pas l'implémentation (fichiers, API, entraînement) mais la logique de conception : percevoir, fusionner, décider, éventuellement générer.

Algorithme 1 Chaîne perception – décision – génération d'EmoLearn.

Entrée : clip vidéo x_v, segment audio x_a, historique H, contexte pédagogique C

Sortie : contenu y (éventuellement vide) et journal de décision J

$P_v \leftarrow \text{FER}(x_v)$ ▷ ViT fine-tuné, vote multi-frames

$P_a \leftarrow \text{SER}(x_a)$ ▷ wav2vec2 fine-tuné, ou abstention

$(\hat{e}, \hat{n}, \hat{P}) \leftarrow \text{Fusion}(P_v, P_a, w_v)$ ▷ éq. (3.2) ou (3.4)

$s^{(t)} \leftarrow$ scores dérivés de $\hat{P}$ (ou de $(\hat{e}, \hat{n})$)

$H \leftarrow H \cup \{s^{(t)}\}$

$u \leftarrow \text{Urgence}(H)$ ▷ tableau 3.10

si $u =$ aucune **alors**

    $J \leftarrow (\hat{e}, \hat{n}, \varnothing, \text{non-intervention})$

    retourner $\emptyset$, J

fin si

$(\tau, \text{stratégie}) \leftarrow \text{Mapping}(s^{(t)})$ ▷ tableau 3.9

$\gamma \leftarrow \text{Patron}(\tau, \hat{e}, \hat{n}, s^{(t)})$ ▷ A1–D5

$d \leftarrow \text{RAG}(C)$ ▷ optionnel

$y \leftarrow \text{LLM}(\gamma, C, \hat{e}, d)$

$J \leftarrow (\hat{e}, \hat{n}, \tau, \gamma, u)$

retourner y, J

Trois propriétés méritent d'être soulignées. Premièrement, les annotations DAiSEE n'apparaissent pas en entrée : seules x_v et x_a alimentent la perception. Deuxièmement, la non-intervention est une sortie légitime, pas un échec. Troisièmement, le journal J rend chaque étape rejouable, ce qui conditionne l'évaluation multi-niveaux du chapitre 5.

3.10 Conclusion

Ce chapitre a proposé la méthodologie et l'architecture d'EmoLearn, en réponse aux quatre lacunes de l'état de l'art. L'artefact relie, au sein d'une même chaîne, une perception multimodale (FER + SER + fusion), une décision explicite (cascade A/B/C/D, vingt patrons, règles temporelles) et une génération guidée et ancrée (LLM + RAG). Deux principes structurent la perception : chaque modalité dispose d'une référence explicable et d'une variante fine-tunée ; la fusion existe en deux familles, l'une orientée

vers la sécurité pédagogique, l'autre vers l'exactitude. Les limites assumées (appariement visage–voix hétérogène en production, mapping émotion → engagement comme hypothèse, simulation sur corpus annotés) sont posées ici plutôt que dissimulées ; elles seront mesurées au chapitre 5.

Le chapitre suivant traduit ces choix en un prototype exécutable : infrastructure, traitement des données, implémentation des modules et génération du corpus de contenu adaptatif.

Chapitre 4

Implémentation du prototype

Sommaire

4.1 Infrastructure technique 47
4.1.1 Stack technologique 47
4.1.2 Choix d'architecture 49
4.2 Traitement et préparation des données 51
4.2.1 Extraction et nettoyage du dataset DAiSEE 52
4.2.2 Extraction et alignement du corpus IEMOCAP 54
4.2.3 Création de scénarios d'apprentissage 55
4.2.4 Segmentation des sessions 56
4.3 Implémentation du modèle d'adaptation 57
4.3.1 Règles de décision 57
4.3.2 Algorithme de sélection de stratégies 59
4.3.3 Gestion des transitions d'état 60
4.4 Implémentation du module de génération adaptative . . . 61
4.4.1 Configuration du LLM 61
4.4.2 Bibliothèque de 20 templates de prompts 63
4.4.3 Pipeline de génération 63
4.4.4 Post-processing et validation 65
4.5 Développement du prototype de simulation 66
4.5.1 Interface de visualisation 66
4.5.2 Lecteur de parcours d'apprentissage 68
4.5.3 Affichage des adaptations 68
4.6 Génération du corpus de contenu adaptatif 69
4.6.1 Sélection de 50 séquences représentatives 69
4.6.2 Génération de contenus pour chaque scénario 69
4.6.3 Documentation du corpus 70

Le chapitre précédent a défini *ce que* le système doit faire : percevoir un état d'engagement à partir du visage et de la voix, décider s'il faut intervenir, puis générer un contenu pédagogique adapté. Ce chapitre expose *comment* ces choix de conception ont été réalisés, sous les contraintes concrètes d'un travail de master. Nous présentons d'abord l'infrastructure technique et les principes d'architecture qui structurent le code (section 4.1), puis le traitement des données (section 4.2), l'implémentation du modèle d'adaptation (section 4.3) et celle du module de génération (section 4.4). Nous décrivons enfin le prototype de simulation qui rend le dispositif observable (section 4.5) et la génération du corpus de contenu adaptatif qui en constitue le livrable (section 4.6). Conformément à la démarche de recherche orientée conception [34], l'artefact logiciel n'est pas ici un simple support de démonstration : il est l'objet même dont les propriétés seront évaluées au chapitre 5.

4.1 Infrastructure technique

Quatre contraintes ont orienté les choix techniques exposés dans cette section. Le système a été développé et exécuté sur une machine de travail ordinaire, **sans accélérateur graphique dédié** : toute inférence s'effectue sur processeur, ce qui exclut l'entraînement de réseaux profonds de bout en bout. Le prototype devait fonctionner **sans budget d'infrastructure**, d'où le recours à des bibliothèques libres exécutées localement et à l'offre gratuite d'un service de génération distant. Les résultats du chapitre 5 devant être **reproductibles**, les modèles entraînés, corpus dérivés et métriques sont des fichiers déposés à des emplacements fixes et tout tirage aléatoire est initialisé par une graine explicite. Enfin, l'exigence de **transparence** posée au chapitre 3 impose que chaque étape laisse une trace lisible plutôt qu'un simple résultat final.

4.1.1 Stack technologique

Le prototype n'emploie que deux langages. Python 3.11 couvre l'intégralité du serveur applicatif *et* des scripts hors ligne (entraînement, évaluation, construction de corpus) : ce choix garantit que les modules de perception, de fusion et de décision utilisés par l'interface sont littéralement les mêmes objets que ceux exécutés par les scripts de validation, et non des réimplémentations. JavaScript (React) couvre l'interface cliente. Le tableau 4.1 récapitule la pile retenue, couche par couche.

Couche	Technologies	Rôle dans le prototype
Exécution	Python 3.11	Langage unique du serveur et des scripts hors ligne.
Service web	FastAPI, Uvicorn, Pydantic	Exposition de l'API REST/JSON et validation des requêtes.
Vision	OpenCV, Transformers, PyTorch	Décodage des clips, détection du visage, classification des expressions.
Audio	librosa, soundfile, Transformers	Lecture du signal, extraction du segment annoté, reconnaissance vocale.
Apprentissage	scikit-learn [64], joblib	Mapping appris visage → engagement et sérialisation des modèles.
Génération	SDK Groq, LLaMA 3.1 [21, 74]	Production du contenu pédagogique adaptatif.
Récupération	ChromaDB, sentence-transformers (MiniLM) [81]	Base vectorielle et encodage des documents pour le RAG [27, 47].
Persistance	SQLite, fichiers JSONL et CSV	Sessions, journal des décisions, référentiels de scénarios.
Client et tests	React 19, jsPDF, pytest, React Testing Library	Interface de simulation, export du contenu, tests unitaires et d'API.

Table 4.1 – Pile technologique du prototype EmoLearn, par couche fonctionnelle.

Réutilisation de modèles pré-entraînés. La contrainte matérielle a une conséquence directe sur la perception : aucun réseau profond n'est entraîné depuis l'initialisation. Des modèles publics sont mobilisés tels quels et seule la *dernière articulation* est apprise localement — celle qui relie leurs sorties à la taxonomie d'engagement de DAiSEE [32]. Le visage est traité par une cascade de détection OpenCV puis par un classifieur d'expressions Hugging Face [85] à sept émotions, tous deux **gelés**, dont le vecteur de scores alimente le mapping appris (section 4.3) ; la voix repose sur un modèle *wav2vec2* spécialisé en émotions [3] dont l'encodeur est gelé et la seule tête de classification **ré-entraînée** vers les quatre états DAiSEE à partir d'IEMOCAP [10] ; le RAG vectorise ses documents avec un encodeur multilingue de phrases ; la génération est confiée à un modèle de langue distant, sans réglage fin, avec une température basse et un budget de sortie borné.

Conséquences de l'exécution sur processeur. Travailler sans accélérateur impose des arbitrages explicites. L'analyse faciale d'un clip n'examine pas toutes ses images mais un **échantillon de cinq images** réparties sur sa durée : en deçà, l'estimation devient sensible à une image mal cadrée ; au-delà, le coût croît linéairement sans gain observé. La génération de texte est déportée vers un service distant, ce qui évite d'héberger localement un modèle de plusieurs milliards de paramètres, et les modèles lourds ne sont chargés qu'à leur première sollicitation effective. Les dépendances sont figées dans un fichier de spécification unique, l'unique secret — la clé d'accès au service de génération — est lu depuis un fichier d'environnement non versionné, et les emplacements sont normalisés : `data/` (corpus et référentiels), `models/` (modèles entraînés), `results/` (métriques), `logs/` (journaux).

4.1.2 Choix d'architecture

L'architecture fonctionnelle en trois couches a été posée au chapitre 3. Il s'agit ici de la traduire en une organisation logicielle, c'est-à-dire de répondre à des questions d'un autre ordre : quels processus s'exécutent, comment le code est découpé, où sont stockés les artefacts, et que se passe-t-il lorsqu'un composant est indisponible (figure 4.1).

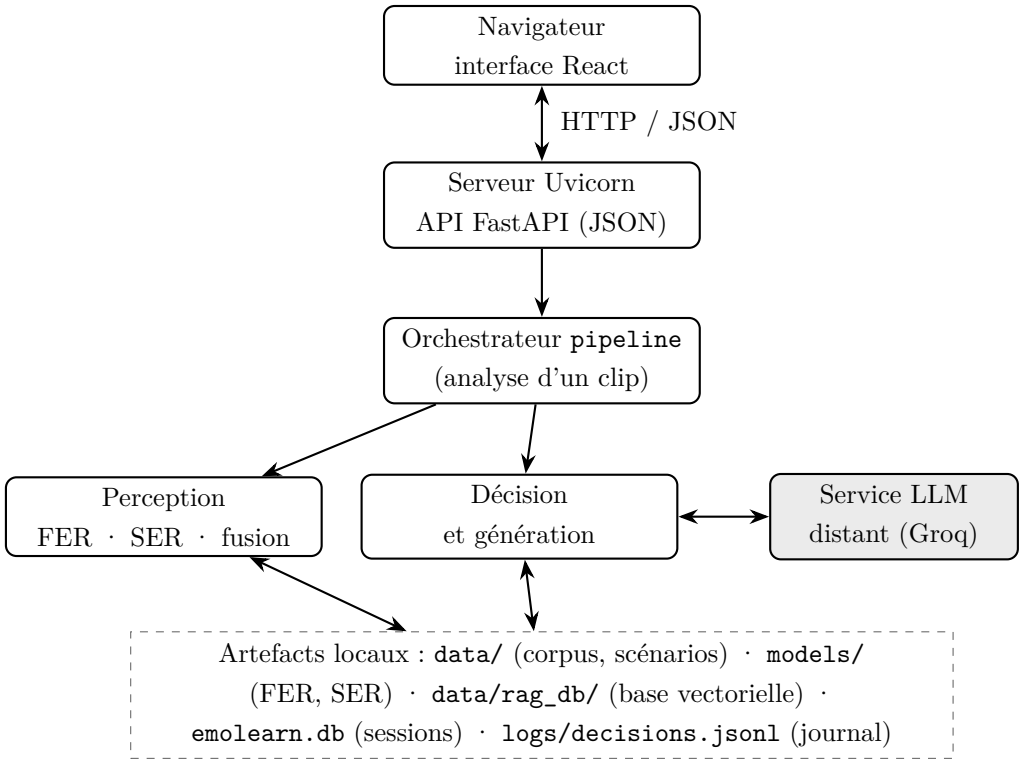


FIGURE 4.1 – Vue technique du prototype : un client web, un processus serveur unique, un service de génération distant et des artefacts persistants locaux (en pointillés).

Client–serveur et découpage par responsabilité. Le client et le serveur sont deux applications distinctes communiquant par des échanges JSON sur HTTP, et l'API ne conserve **aucune session en mémoire** : chaque requête porte son contexte complet (scénario, concept, module, niveau de l'apprenant, moment du cours) et l'historique nécessaire aux règles temporelles est relu depuis la couche de persistance. Le serveur peut ainsi être redémarré sans perdre les parcours simulés, et une analyse peut être rejouée depuis un script sans passer par l'interface. Le code lui-même n'est pas organisé par couche technique mais par *responsabilité scientifique*, chaque module étant autonome, testable isolément et substituable : la perception réunit la résolution et le décodage des clips (`daisee_video`), la chaîne faciale (`fer_offline`, `fer_classifier`, `fer_module`), la chaîne vocale (`iemocap_parser`, `iemocap_audio`, `ser_module`) et la combinaison des modalités (`fusion_module`) ; la décision repose sur `temporal_rules` et `decision_engine` ; la génération sur `prompts/templates`, `rag_module`, `llm_module` et `chat_module` ; l'infrastructure sur `pipeline` (orchestration et journalisation), `database` (sessions) et `main` (points d'entrée de l'API).

Un orchestrateur unique, partagé avec le banc d'essai. La séquence complète d'analyse d'un clip est écrite *une seule fois*, dans le module d'orchestration : l'API n'y ajoute que la validation de la requête et la mise en forme de la réponse. Les scripts hors ligne — évaluation de la perception faciale, construction du sous-corpus audiovisuel aligné, analyse de sensibilité — importent les *mêmes* modules de perception et de fusion. Ce point conditionne la validité du chapitre 5 : aucun écart de code ne peut s'installer entre le système mesuré et le système utilisé.

Commutation des variantes par configuration. Le chapitre 3 a conservé, pour chaque modalité, une référence explicable et une variante apprise, ainsi que deux stratégies de résolution de conflit. Pour que ces alternatives restent comparables, elles sont sélectionnables par variables d'environnement, sans modification du code : `EMOLEARN_FER_MAPPING` (*auto* par défaut, *learned* ou *heuristique*, le mode *auto* ne retenant le modèle appris que s'il dépasse la référence sur les deux métriques de contrôle), `EMOLEARN_SER_METHODE` (*learned* ou *heuristique*) et `EMOLEARN_FUSION_STRATEGIE` (*priorité pédagogique* ou *confiance*). Les conditions expérimentales du chapitre 5 sont donc des combinaisons de ces variables, et chaque mesure est rejouable par une commande explicite.

Robustesse d'exécution. Plusieurs ressources de la chaîne peuvent faire défaut au moment de l'exécution. Plutôt que d'interrompre le traitement, l'implémentation prévoit un repli à chaque point de fragilité : un modèle appris absent ramène au mapping heuristique de référence, un échec de la récupération documentaire laisse la généra-

tion se poursuivre sans ancrage, une limite de débit du service distant déclenche des tentatives espacées et l'absence de modalité vocale conduit à une décision unimodale. Le principe commun est qu'une dégradation n'est jamais silencieuse : elle est déclarée dans la réponse et dans le journal, faute de quoi une performance mesurée pourrait être attribuée à une configuration qui n'était pas celle réellement exécutée.

Traçabilité, apprentissage hors ligne et périmètre assumé. La persistance distingue deux besoins : un **journal de décision**, en ajout seul, enregistre pour chaque clip l'état fusionné, le type de conflit, le patron retenu et les indicateurs de génération — c'est la matière première des analyses du chapitre 5 — tandis qu'une **base de sessions** conserve le déroulé pédagogique consultable dans l'interface. L'entraînement, lui, reste **hors du serveur** : les scripts d'apprentissage produisent des artefacts sur disque que les modules de perception se contentent de charger, si bien qu'un modèle ne peut pas changer silencieusement entre deux exécutions. Cette infrastructure demeure toutefois celle d'un **prototype de simulation** : base mono-fichier adaptée à un utilisateur unique, absence d'authentification et de cloisonnement des accès, aucune conteneurisation. Ces limites correspondent au périmètre de recherche défini au chapitre et sont discutées au chapitre 6 ; ce qui devait être solide ici n'est pas l'exploitabilité industrielle, mais la reproductibilité et la traçabilité de la chaîne scientifique.

4.2 Traitement et préparation des données

Le chapitre 3 a justifié le recours à deux corpus complémentaires : DAiSEE [32] fournit le signal facial annoté en états d'engagement, IEMOCAP [10] fournit le signal vocal annoté en émotions. Aucun des deux n'est utilisable en l'état par le système : le premier est distribué comme une arborescence de clips vidéo accompagnée de fichiers d'annotation, le second comme une collection de dialogues continus dont les segments pertinents doivent être localisés. Cette section décrit les traitements qui transforment ces deux ressources brutes en artefacts exploitables — un référentiel de scénarios, un index d'énoncés vocaux et des jeux de données d'entraînement — ainsi que le découpage temporel retenu pour la simulation (figure 4.2).

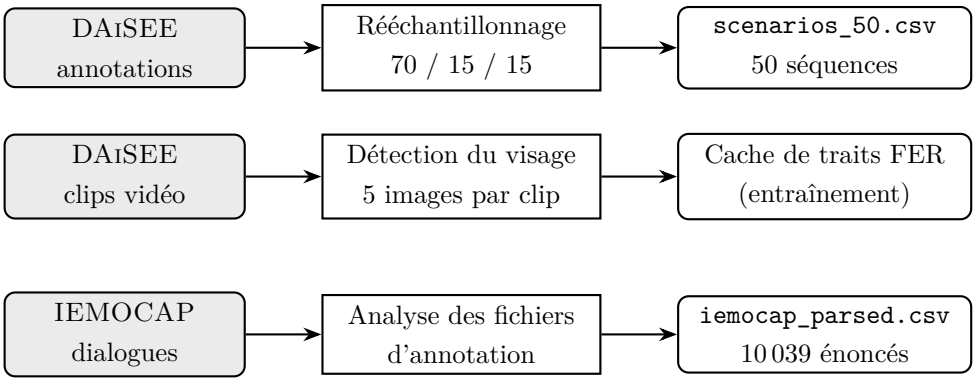


FIGURE 4.2 – Chaîne de préparation des données : les deux corpus sources (à gauche) sont transformés hors ligne en trois artefacts versionnés (à droite), qui alimentent ensuite l'entraînement et la simulation.

4.2.1 Extraction et nettoyage du dataset DAiSEE

Reconstitution d'un référentiel unique. Les annotations de DAiSEE sont fournies en trois fichiers correspondant au découpage d'origine des auteurs (5 358 clips d'apprentissage, 1 429 de validation et 1 784 de test, soit 8 571 clips annotés). Chaque ligne associe un identifiant de clip à quatre entiers compris entre 0 et 3 pour l'ennui, l'engagement, la confusion et la frustration. Les trois fichiers ont été concaténés puis redécoupés en un partage **70 / 15 / 15** — 5 999 clips de conception, 1 285 de validation et 1 287 de test — après un mélange initialisé par la graine 42. Ce redécoupage répond à une exigence méthodologique : le sous-ensemble servant à concevoir les règles et à choisir les scénarios doit être disjoint de celui qui servira à mesurer les performances au chapitre 5. Les noms de colonnes sont normalisés à la lecture, car les fichiers d'origine contiennent des espaces parasites qui font échouer un accès direct par nom.

Résolution des clips vers les fichiers vidéo. L'arborescence des vidéos suit une structure à trois niveaux (partition, sujet, clip) et mélange deux formats de conteneur. Plutôt que de reconstruire un chemin à chaque appel, le module de résolution construit *une seule fois* un index en mémoire associant chaque nom de fichier à son chemin absolu, puis tolère l'absence d'extension dans l'identifiant en essayant successivement les deux formats connus. Cette indexation initiale rend le coût de résolution négligeable et, surtout, rend explicite le cas d'un clip annoté dont la vidéo est absente du disque : la situation est retournée comme un état d'erreur nommé plutôt que comme une exception.

Extraction des régions de visage. La perception faciale ne travaille pas sur l'image entière mais sur la région du visage, isolée par une cascade de détection. L'implémentation enchaîne trois tentatives — vue de face, puis profil, puis profil sur l'image miroir

— et retient la boîte de plus grande aire, la méthode effectivement employée étant conservée dans la trace. Ce dispositif répond à une caractéristique du corpus : les apprenants filmés en situation d'ennui ou de distraction détournent fréquemment la tête, et une détection frontale seule échouerait précisément sur les cas pédagogiquement les plus intéressants. Le tableau 4.2 rassemble les paramètres retenus.

Opération	**Valeur**	**Motif du réglage**
Images analysées par clip	5	Compromis entre robustesse et coût sur processeur (section 4.1.1).
Position des images	régulière, hors bords	Évite les premières et dernières images, souvent floues ou en transition.
Égalisation d'histogramme	activée	Réduit l'effet des conditions d'éclairage très inégales du corpus.
Facteur d'échelle de la cascade	1,1	Recherche fine, au prix d'un temps de détection accru.
Voisins minimaux	4	Diminue les fausses détections sans perdre les visages de profil.
Taille minimale de visage	40 × 40 pixels	Écarte les régions trop petites pour porter une expression exploitable.
Marge autour de la boîte	30 %	Conserve le front et le menton, informatifs pour l'ennui et la confusion.

TABLE 4.2 – Paramètres de la chaîne d'extraction visuelle appliquée aux clips DAISEE.

Nettoyage et politique d'exclusion. Le nettoyage retenu est *déclaratif* plutôt que silencieux. Un clip est écarté du jeu d'entraînement dans quatre cas seulement : vidéo introuvable, vidéo illisible, vidéo sans image décodable, ou échec du classifieur d'expressions ; chacun de ces cas porte un code distinct. Aucune suppression de doublons ni filtrage sur la durée n'a été appliqué, les clips de DAISEE étant tous calibrés à dix secondes. Aucun rééquilibrage artificiel des classes n'a été effectué non plus : le déséquilibre massif du corpus, déjà documenté au chapitre 3 (figure 3.2), est traité en aval par une pondération inverse des classes lors de l'apprentissage et par le choix d'une métrique moyennée par classe, ce qui préserve la distribution réelle du phénomène observé.

Mise en cache des traits. L'extraction des traits faciaux est l'opération la plus coûteuse de la chaîne : elle suppose de décoder la vidéo, de détecter le visage sur cinq images et d'appeler le réseau de classification. Pour que l'apprentissage du mapping puis les analyses de sensibilité puissent être relancés sans repayer ce coût, les vecteurs de sept probabilités sont écrits une fois pour toutes dans un fichier de cache accompagnant chaque clip de son état annoté. Le cache constitué compte 1 200 clips ; il reproduit la distribution déséquilibrée du corpus (885 clips d'engagement contre 42 de frustration), ce qui en fait aussi un artefact de documentation du problème d'apprentissage traité.

4.2.2 Extraction et alignement du corpus IEMOCAP

Analyse des fichiers d'annotation. IEMOCAP distribue ses annotations sous forme de fichiers textuels par dialogue, où chaque énoncé occupe une ligne mêlant bornes temporelles, identifiant, étiquette émotionnelle et coordonnées d'activation, de valence et de dominance. Une expression régulière unique extrait ces sept champs et alimente une table homogène. Le résultat, matérialisé dans un fichier unique de **10 039 énoncés** couvrant les cinq sessions, remplace définitivement la lecture des fichiers d'origine : tous les traitements ultérieurs — projection vers la taxonomie d'engagement, analyse de sensibilité, entraînement de la tête vocale — partent de cette table. La projection des étiquettes vers les quatre états DAiSEE suit la correspondance de référence définie au chapitre 3 (tableau 3.4) ; elle est implémentée comme un dictionnaire isolé, ce qui a permis l'analyse de sensibilité présentée en section 3.4.6 par simple substitution d'une entrée.

Localisation du signal vocal. Le corpus ne fournit pas un fichier audio par énoncé mais un fichier par dialogue. Le chemin du dialogue est reconstruit à partir de l'identifiant de l'énoncé, dont le suffixe de locuteur est retiré par expression régulière, puis le segment annoté est chargé à la position et pour la durée indiquées, en monophonie et à 16 kHz — la fréquence attendue par l'encodeur vocal pré-entraîné. Une étape d'enrichissement a ajouté à la table le chemin résolu et un indicateur d'existence pour chaque énoncé, ce qui permet de vérifier en une lecture que la couverture audio est complète avant tout entraînement.

Appariement voix–scénario. DAiSEE et IEMOCAP ne partageant aucun sujet, l'appariement ne peut être qu'une simulation, dont le principe a été posé au chapitre 3 (section 3.4.4). Son implémentation est volontairement minimale et déterministe : les énoncés dont l'état projeté correspond à l'état dominant du scénario sont regroupés, puis l'énoncé retenu est désigné par le reste de la division de l'identifiant du scénario par la taille du groupe. Le même scénario reçoit donc toujours le même énoncé, propriété indispensable pour que deux exécutions du banc d'essai soient comparables, et

l'appariement est signalé comme tel dans la réponse de l'API afin qu'il ne puisse jamais être confondu avec une captation réellement synchrone.

Sous-corpus audiovisuel réellement aligné. Pour disposer malgré tout d'une mesure où visage et voix proviennent de la même personne au même instant, un second artefact a été construit à l'intérieur d'IEMOCAP lui-même (section 3.4.5). Seule la première session dispose des enregistrements vidéo ; ceux-ci filment deux locuteurs côte à côte dans une image de 720 × 480 pixels, ce qui impose de déterminer quel côté correspond au locuteur de l'énoncé. Le genre du locuteur, lisible dans l'identifiant, est comparé au genre annoncé dans le nom du dialogue, et la moitié d'image correspondante est découpée avant application de la même chaîne de détection de visage que pour DAiSEE. Après filtrage des énoncés trop courts et des étiquettes indéterminées, un échantillon équilibré de vingt énoncés par état constitue un sous-corpus de **80 paires audiovisuelles** sur lequel les deux modalités et leurs fusions seront comparées au chapitre 5.

Constitution du jeu d'entraînement vocal. La tête de classification vocale est apprise sur ce même référentiel, filtré selon trois critères explicites : exclusion des étiquettes indéterminées, durée minimale d'une seconde et présence effective du fichier audio. Un tirage par classe ramène ensuite les quatre états à des effectifs voisins, ce qui compense la rareté de la confusion dans le corpus. Les segments sont recadrés ou complétés à une longueur fixe de quatre secondes, l'encodeur est gelé et seul le classifieur final est optimisé, sur deux époques et avec un partage stratifié à 80 / 20. Tous les tirages dépendent d'une graine unique, consignée dans le fichier de métriques produit à côté du modèle.

4.2.3 Création de scénarios d'apprentissage

Du clip annoté au scénario pédagogique. Un clip de DAiSEE est un objet perceptif : dix secondes de vidéo et quatre scores. Un *scénario d'apprentissage* est un objet pédagogique : un état d'engagement situé dans un contexte de cours, auquel le système doit répondre. Le passage de l'un à l'autre est opéré par deux fonctions volontairement séparées. La première détermine l'état dominant du clip, en levant les égalités par un ordre de priorité pédagogique qui place la frustration avant la confusion, puis l'ennui, puis l'engagement : à scores égaux, c'est le besoin le plus urgent qui est retenu, jamais l'état le plus favorable. La seconde attribue au clip un *patron*, c'est-à-dire une des six configurations pédagogiques définies au chapitre 3 (tableau 3.2), en traitant d'abord les deux cas composites — la situation critique où au moins trois dimensions dépassent le seuil, et l'engagement faible — avant de retomber sur le patron associé à l'état dominant.

Sélection des cinquante scénarios. Un échantillon de cinquante clips a été constitué à partir du seul sous-ensemble de conception, par tirages indépendants et reproductibles pour chaque patron (tableau 4.3). Les effectifs ne sont pas proportionnels à la fréquence des patrons dans le corpus : ils sont *délibérément déséquilibrés en faveur des états problématiques*. Un tirage proportionnel aurait produit un échantillon composé presque exclusivement de clips engagés, sur lesquels le système n'a par construction rien à décider ; le sur-échantillonnage des situations de frustration, de confusion et d'état critique est ce qui rend l'échantillon informatif pour évaluer la chaîne de décision. Ce choix est aussi une limite d'interprétation, rappelée au chapitre 5 : les taux mesurés sur ces cinquante scénarios ne sont pas des taux attendus en population.

Patron	**Critère de tirage**	**Effectif**
Stable	engagement ≥ 2	15
Ennui élevé	ennui ≥ 2	10
Frustration	frustration ≥ 2	8
Confusion	confusion ≥ 2	7
Engagement faible	engagement ≤ 1	6
État critique	confusion ≥ 2 *et* frustration ≥ 2	4
Total		**50**

TABLE 4.3 – Composition du référentiel de scénarios : critère de tirage et effectif par patron pédagogique.

Un référentiel recalculé plutôt que figé. Le fichier de scénarios conserve, outre l'identifiant du clip et ses quatre scores, le patron obtenu au moment du tirage. Ce patron est néanmoins **recalculé au chargement** par le serveur à partir des scores. Cette redondance apparente est un garde-fou : elle garantit qu'une modification ultérieure des règles de catégorisation se propage immédiatement au référentiel, au lieu de laisser cohabiter des étiquettes héritées d'une version antérieure du code. Un jeu de tests dédié vérifie d'ailleurs que, pour chacune des cinquante lignes, le patron stocké reste cohérent avec l'état dominant. Un second fichier dérivé associe à chaque scénario la stratégie et le type de contenu retenus, servant de table de référence lisible pour la discussion des résultats.

4.2.4 Segmentation des sessions

Trois granularités emboîtées. La simulation manipule trois niveaux de découpage temporel. Le **clip** de dix secondes est l'unité de perception et de décision : c'est le grain auquel l'API répond et auquel une adaptation est éventuellement produite. La **fenêtre**

glissante est l'unité d'analyse dynamique : les règles de déclenchement examinent les deux ou quatre derniers clips selon la règle considérée (section 4.3.3). La **séquence** est l'unité de parcours : dix séquences de quatre à sept clips ont été assemblées hors ligne à partir du référentiel, chacune portant un titre et un patron dominant — engagement stable, ennui progressif, frustration montante, confusion avec blocage, état critique multi-états. Ces séquences ne sont pas tirées au hasard : elles sont construites pour exposer des *trajectoires* plutôt que des états isolés, seule manière d'observer le comportement des règles temporelles.

Persistance des sessions. Chaque adaptation effectivement produite est enregistrée dans la base de sessions avec l'identifiant du scénario, l'état détecté, son intensité, la stratégie, le type de contenu, le texte généré et un horodatage. Le choix d'une table plate, sans identifiant de parcours, mérite d'être assumé explicitement : la reconstitution d'une trajectoire s'effectue par lecture ordonnée des enregistrements, ce qui suffit à un prototype mono-utilisateur mais ne permettrait pas de distinguer plusieurs apprenants simultanés. Le journal de décision, lui, conserve pour chaque clip analysé les éléments nécessaires à l'analyse scientifique — état fusionné, type de conflit entre modalités, patron retenu, indicateurs de génération — sous une forme en ajout seul qui interdit la réécriture rétrospective d'une décision.

4.3 Implémentation du modèle d'adaptation

Le modèle d'adaptation transforme un état perçu en une intention pédagogique. Sa formulation conceptuelle occupe les sections 3.5 et 3.6 du chapitre 3 ; il s'agit ici d'exposer sa traduction en code, c'est-à-dire l'ordre exact d'évaluation des règles, les seuils effectivement programmés et le traitement des cas où deux règles pourraient s'appliquer. Trois composants sont concernés : la fusion des modalités, la sélection de la stratégie et le patron de prompt, et la prise en compte de la dynamique temporelle.

4.3.1 Règles de décision

Fusion des deux modalités. La fusion est implémentée en deux temps séparés : *qualifier* la relation entre les deux perceptions, puis *résoudre* le désaccord éventuel. La qualification distingue six situations, selon que les deux modalités désignent le même état ou non. Lorsqu'elles s'accordent, l'écart d'intensité est comparé à un seuil de tolérance d'un niveau : en deçà, l'accord est jugé suffisant et l'intensité finale est la moyenne pondérée des deux, avec un poids de 0,60 pour le visage et de 0,40 pour la voix ; au-delà, un conflit d'intensité est déclaré. Lorsqu'elles désignent des états différents, la sévérité du conflit est mesurée par l'écart entre les priorités pédagogiques des deux

états, ce qui distingue un désaccord mineur — par exemple entre ennui et confusion — d'un désaccord majeur entre frustration et engagement. La résolution applique alors la stratégie sélectionnée par configuration (section 4.1.2) : la priorité pédagogique retient l'état le plus urgent, la stratégie de confiance retient celui dont le score est le plus élevé. Un point important pour l'interprétation des résultats : quelle que soit la stratégie, la sortie conserve le type de conflit et la règle appliquée, si bien qu'une décision peut toujours être rejouée et expliquée.

Deux familles de fusion, deux usages. La distinction établie au chapitre 3 entre fusion par résolution de conflit et fusion par vote pondéré (section 3.5.5) se traduit par deux fonctions coexistantes. La première, employée par le serveur, décide d'abord de l'état puis pondère l'intensité : le poids n'influence donc pas le choix de l'état. La seconde combine les distributions de probabilité des quatre états avant d'en prendre l'argument maximal, de sorte que le poids agit cette fois sur l'état retenu ; elle est mobilisée par le banc d'essai sur le sous-corpus audiovisuel aligné, où elle permet le balayage des poids de modalité rapporté au chapitre 5. Faire cohabiter les deux implémentations, plutôt que d'en généraliser une, était la seule manière de comparer les deux familles sur les mêmes données sans modifier le comportement du prototype.

Cascade de sélection de la stratégie. La décision proprement pédagogique est une cascade de conditions évaluées dans un ordre fixe, la première satisfaite l'emportant (tableau 4.4). Cet ordre *est* la règle : il encode une hiérarchie de besoins où le blocage combinant confusion et frustration passe avant le désengagement total, lui-même avant la frustration seule, la confusion, l'ennui, puis l'engagement. Écrire la même logique comme une suite de conditions indépendantes aurait laissé indéterminé le cas — fréquent dans le corpus — d'un clip présentant simultanément plusieurs scores élevés.

Rang	Condition	Stratégie retenue	Type
1	confusion ≥ 3 et frustration ≥ 2	Aide de déblocage immédiate	A+D
2	engagement $= 0$	Réengagement urgent	B
3	frustration ≥ 2	Encouragement et simplification	D+A
4	confusion ≥ 2	Explication alternative	A
5	ennui ≥ 2	Exercice avancé	C
6	engagement ≤ 1	Exemple concret stimulant	B
7	ennui $= 1$	Application pratique	B
8	engagement ≥ 2	Renforcement positif	D
9	aucun des cas précédents	Continuation normale	aucune

TABLE 4.4 – Cascade de décision telle qu'implémentée : la première condition satisfaite détermine la stratégie et le type de contenu.

4.3.2 Algorithme de sélection de stratégies

Une sélection en deux étages. Le type de contenu issu de la cascade ne suffit pas à lancer une génération : il désigne une famille d'intervention, non un patron de prompt. Un second étage traduit le couple formé par ce type et le contexte du clip en l'un des vingt patrons de la bibliothèque (tableau 3.12). Ce découplage a une raison précise : il permet de faire évoluer la bibliothèque de patrons — en ajouter, en reformuler — sans toucher aux règles pédagogiques, et réciproquement de modifier un seuil de décision sans réécrire de prompt. L'algorithme complet se déroule ainsi :

1. les quatre scores sont lus dans l'état fusionné ;
2. la cascade du tableau 4.4 désigne un type de contenu et une stratégie ;
3. si la dynamique temporelle conclut à l'absence de besoin d'intervention, la décision est court-circuitée (section 4.3.3) ;
4. sinon, le type est raffiné en un patron précis à l'aide de l'intensité de l'état, du patron du clip et des scores individuels ;
5. les métadonnées du patron — objectif, longueur cible, format, ton — sont lues dans la bibliothèque et jointes à la décision ;
6. l'objet de décision, qui porte à la fois le résultat et ses déterminants, est transmis au module de génération.

Règles de raffinement. Le raffinement obéit à des règles courtes et lisibles. Le type composite associant explication et soutien conduit directement au patron d'aide au déblocage. Le soutien guidé se scinde selon l'intensité de la frustration, un niveau maximal appelant un patron de soutien plus enveloppant qu'un patron d'encouragement standard. L'explication alternative se décline en trois variantes : une micro-explication décomposée lorsque la confusion est maximale, une explication reformulée lorsque le patron du clip confirme la confusion, une explication narrative dans les autres cas. L'exemple concret distingue le réengagement d'un apprenant totalement décroché de la simple stimulation d'un apprenant peu engagé. Enfin, un cas par défaut garantit qu'aucune combinaison de scores ne peut laisser la sélection sans patron.

Ce que produit la cascade sur le référentiel. Appliquée aux cinquante scénarios, la chaîne complète ne mobilise **que onze des vingt patrons**, la distribution étant fortement concentrée sur l'encouragement en cas de frustration modérée et sur l'exercice avancé en cas d'ennui élevé. Ce résultat, obtenu et consigné par le banc d'essai, n'est pas un défaut d'implémentation mais la conséquence conjointe de la composition du référentiel et de l'ordre de la cascade : les patrons dédiés aux situations rares ne peuvent être atteints que par des configurations de scores que l'échantillon contient peu ou pas. Il constitue à ce titre une observation de premier plan pour la discussion du chapitre 5, et une justification du corpus complémentaire généré en section 4.6, qui couvre dix-neuf patrons.

4.3.3 Gestion des transitions d'état

Quatre degrés d'urgence. La dynamique temporelle est implémentée dans un module distinct, qui reçoit l'historique récent et retourne quatre éléments : faut-il intervenir, avec quel degré d'urgence, en vertu de quelle règle nommée, et depuis combien de clips l'état persiste. Les degrés — immédiate, rapide, différée, aucune — sont évalués dans cet ordre, si bien qu'une situation de blocage aigu ne peut jamais être ramenée à une intervention différée par une règle de rang inférieur. La détection immédiate ne considère que le clip courant, dans deux cas seulement : confusion maximale accompagnée de frustration, ou désengagement total. L'urgence rapide exige la persistance d'un seuil sur **deux clips consécutifs**, ce qui filtre les fluctuations d'une seule fenêtre de dix secondes. L'urgence différée observe **quatre clips**, pour capter les états faibles mais durables — engagement bas prolongé, ennui de faible intensité qui s'installe — que la règle rapide laisserait passer.

Le cas de la non-intervention. La règle la plus importante pour la crédibilité pédagogique du système est celle qui conclut à *ne rien faire* : lorsque l'engagement se maintient à un niveau satisfaisant sur les deux derniers clips, aucune adaptation

n'est déclenchée. Son implémentation traverse toute la chaîne. Le moteur de décision force alors le type de contenu à « aucune », remplace la stratégie par une continuation normale et marque explicitement la décision comme non déclenchée ; l'orchestrateur n'appelle pas le service de génération et substitue au contenu un objet portant un indicateur de saut ; enfin, ni le journal de décision ni la base de sessions ne reçoivent d'enregistrement. Une non-intervention ne consomme donc aucun appel au modèle de langue et reste distinguable, dans les traces, d'une intervention qui aurait échoué.

Ce qui est implémenté, ce qui ne l'est pas. Deux limites doivent être énoncées ici plutôt que découvertes au chapitre 5. D'une part, le module temporel est complètement implémenté et couvert par des tests unitaires qui vérifient chacun de ses cas — déclenchement immédiat sur blocage, déclenchement immédiat sur désengagement, non-intervention sur engagement stable, déclenchement rapide sur ennui consécutif, court-circuitage de la décision — mais le point d'entrée exposé par l'API analyse un clip isolé : la dynamique n'est mobilisée que lorsqu'une trajectoire est rejouée à partir des séquences reconstituées, et non lors d'une analyse ponctuelle depuis l'interface. D'autre part, le moteur de décision est **sans mémoire d'une décision à la suivante** : il n'implémente ni hystérésis, ni délai de garde entre deux interventions, ni mécanisme évitant la répétition d'un même patron sur des clips voisins. Sur un parcours réel, ces absences produiraient un risque d'oscillation et de saturation de l'apprenant ; elles constituent la première piste d'amélioration formulée au chapitre 6.

4.4 Implémentation du module de génération adaptative

La décision étant prise, il reste à produire le contenu. Cette section décrit la configuration du service de génération, la bibliothèque de patrons qui structure les demandes, l'assemblage du prompt effectivement envoyé, et les dispositifs de contrôle appliqués aux textes obtenus.

4.4.1 Configuration du LLM

Choix du service et du modèle. La génération est confiée à un modèle LLaMA 3.1 de huit milliards de paramètres [74], interrogé à distance via l'interface de programmation de Groq. Ce choix résulte des contraintes énoncées en section 4.1 : un modèle propriétaire de très grande taille aurait supposé un budget d'appels incompatible avec la génération d'un corpus de plusieurs centaines de contenus, et un modèle hébergé localement était exclu par l'absence d'accélérateur. Le modèle est utilisé **sans réglage fin** : toute l'adaptation passe par le prompt, ce qui rend chaque contenu explicable par

la conjonction d'un état détecté, d'un patron et d'un contexte documentaire, et rend le dispositif transposable à un autre fournisseur sans réapprentissage.

Paramètres de décodage. Les paramètres retenus (tableau 4.5) traduisent une exigence de sobriété plutôt que de créativité. Une température basse limite la variabilité entre deux générations comparables, ce qui est indispensable pour que le corpus produit soit interprétable. Un budget de sortie borné empêche les productions interminables et maintient les contenus dans l'ordre de grandeur attendu par les patrons. Le message de rôle système, enfin, formule trois interdits : produire en français, n'utiliser que les informations du contexte de référence fourni, et déclarer explicitement l'absence d'information plutôt que de l'inventer — première ligne de défense contre les hallucinations, complétée par le module RAG (ancrage documentaire) décrit en section 4.4.3.

Paramètre	**Valeur**	**Effet recherché**
Modèle	`llama-3.1-8b-instant`	Coût nul et latence faible, au prix d'une capacité inférieure aux très grands modèles.
Température (contenu)	0,3	Contenus reproductibles à contexte constant.
Température (tuteur)	0,25 à 0,55	Modulée selon l'état : basse en confusion, plus haute en situation d'ennui.
Budget de sortie	600 unités	Borne la longueur des contenus adaptatifs.
Budget de sortie (tuteur)	400 à 650 unités	Ajusté selon la demande de l'apprenant (exemple, exercice, détail).
Tentatives	4, espacées de 2, 5 puis 8 s	Absorbe les limitations de débit du service gratuit.
Fenêtre de dialogue	10 derniers messages	Borne le contexte conversationnel et le coût par échange.
Clé d'accès	variable d'environnement	Aucun secret dans le dépôt.

TABLE 4.5 – Configuration du service de génération et du tuteur conversationnel.

Comportement en cas d'indisponibilité. La gestion des défaillances est partielle et il importe de le dire. Les dépassements de quota sont explicitement rattrapés par des tentatives espacées, mécanisme qui a rendu possible la génération du corpus décrite en

section 4.6. En revanche, aucun délai d'expiration n'est fixé sur l'appel distant et les autres erreurs de service ne sont pas retentées : elles remontent jusqu'au point d'entrée de l'API, qui répond par un message d'erreur explicite. Le prototype ne propose donc pas de contenu de repli hors ligne — un choix assumé, puisqu'un contenu produit sans le modèle n'aurait pas la même nature et fausserait l'analyse du corpus.

4.4.2 Bibliothèque de 20 templates de prompts

Séparation des métadonnées et des instructions. La bibliothèque des vingt patrons introduite au chapitre 3 (tableau 3.12) est implémentée en deux structures distinctes. La première est une table de **métadonnées** : pour chaque patron, sa famille, sa longueur cible en mots, son format attendu, son ton et son objectif pédagogique. Ces attributs ne servent pas seulement à documenter : ils sont injectés dans la section des contraintes du prompt, exposés par l'API et réutilisés par l'audit automatique comme référence de longueur (section 4.4.4). La seconde est une table de **constructeurs d'instructions**, une fonction par patron, qui produit le corps de la demande en y insérant les variables de contexte : concept visé, intensité de l'état, intensité spécifique de la frustration, durée de persistance et module en cours. Un patron inconnu retombe sur un patron de référence, de sorte qu'une faute de frappe dans un identifiant ne provoque jamais d'interruption.

Anatomie d'un patron. Les instructions ne demandent pas un texte libre mais une structure. Le patron d'aide au déblocage, mobilisé lorsque confusion et frustration se combinent, demande ainsi quatre éléments dans un ordre imposé : une phrase rassurante qui normalise la difficulté, l'identification du point de blocage probable, une approche radicalement différente de l'explication initiale, puis un micro-exercice guidé très simple — le tout sur environ deux cents mots et sur un ton déculpabilisant. Le patron de félicitation, à l'autre extrémité de la bibliothèque, demande de célébrer la réussite, d'expliciter la compétence acquise, de faire le lien avec la suite du parcours et de renforcer la confiance, en cent cinquante mots. Cette forme numérotée n'est pas un détail stylistique : elle rend le contenu généré *vérifiable*, puisqu'un auditeur — automatique ou humain — peut constater la présence ou l'absence de chaque élément attendu.

4.4.3 Pipeline de génération

Ancrage documentaire (RAG). Avant toute génération, un contexte de référence est constitué par **récupération augmentée** (*Retrieval-Augmented Generation*, RAG) [47]. Neuf fiches documentaires — définitions, exemples, exercices sur les algorithmes de tri, les réseaux de neurones et les structures de données, auxquelles s'ajoutent deux

fiches sur l'encouragement et les méthodes d'apprentissage — sont encodées par un modèle de phrases multilingue et indexées dans une base vectorielle persistante utilisant la similarité cosinus. Les documents étant courts, aucun découpage en fragments n'a été nécessaire. La requête n'est pas le concept seul : elle est enrichie de l'état détecté, de sorte qu'un apprenant frustré et un apprenant curieux sur le même concept ne reçoivent pas nécessairement le même appui documentaire. Les trois documents les plus proches sont retenus, à condition de dépasser un seuil de similarité ; en deçà, ils sont écartés et un contexte générique est fourni, ce qui évite d'ancrer un contenu sur une source hors sujet.

Assemblage du prompt. Le prompt transmis au modèle est une composition de cinq blocs ordonnés (figure 4.3). Cet ordre suit une progression délibérée : la référence factuelle d'abord, la situation pédagogique ensuite, l'état affectif et sa durée, puis seulement la tâche et ses contraintes. La durée de persistance de l'état est convertie en secondes dans le prompt, afin que le modèle raisonne sur une réalité temporelle et non sur un compteur abstrait de clips.

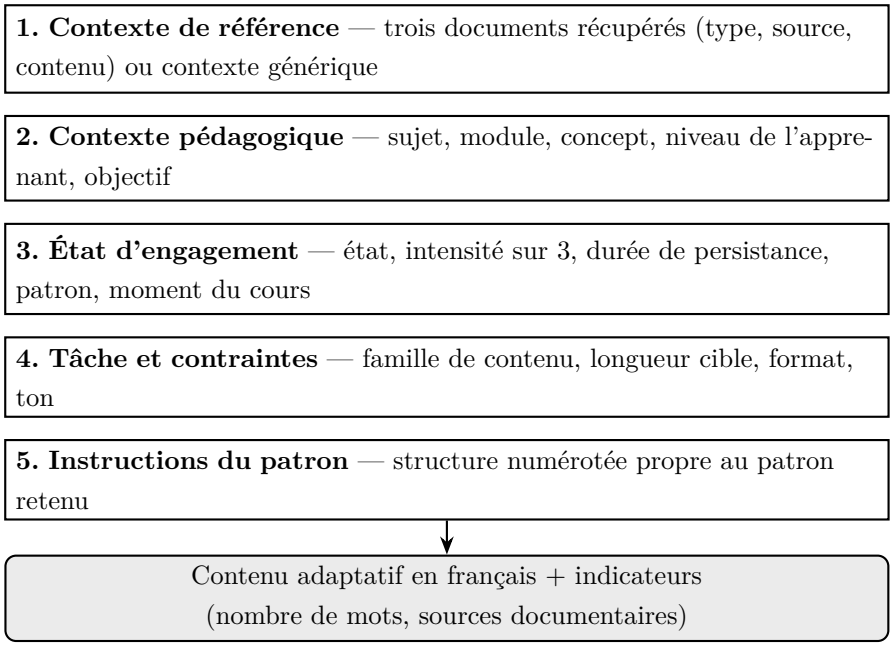


FIGURE 4.3 – Composition du prompt de génération : cinq blocs assemblés dans un ordre fixe, précédés d'un message de rôle système interdisant l'invention de faits.

Sortie et traçabilité. La réponse retournée par le module de génération ne contient pas seulement le texte. Elle porte l'état et l'intensité qui l'ont motivée, le patron employé, l'objectif visé, le nombre de mots produits, un indicateur d'utilisation effective de la récupération documentaire, le nombre et les sources des documents injectés, et le cas échéant le message d'erreur de la récupération. L'interface expose ces éléments à

l'utilisateur et le journal en conserve les principaux : un contenu du corpus peut ainsi être rattaché, après coup, à la décision et aux sources qui l'ont produit.

Tuteur conversationnel. Le même dispositif alimente un second mode d'interaction. Le tuteur reçoit l'état détecté et adapte trois éléments : le ton et la consigne pédagogique, propres à chaque état ; la température de décodage, plus basse en situation de confusion pour privilégier la précision, plus haute en situation d'ennui pour autoriser la variété ; et le budget de réponse, étendu lorsque la question de l'apprenant appelle un exemple, un exercice ou un approfondissement. Le contenu adaptatif initial est réinjecté comme premier tour de parole, de sorte que le dialogue prolonge l'adaptation au lieu de repartir de zéro.

4.4.4 Post-processing et validation

Un contrôle a posteriori, hors de la boucle de génération. Le module de génération n'applique aucune transformation au texte reçu, hormis le comptage des mots : ni troncature, ni réécriture, ni nouvelle tentative en cas de sortie jugée insatisfaisante. Ce choix est méthodologique. Un post-traitement corrigeant silencieusement les productions rendrait impossible la mesure de la qualité intrinsèque du dispositif : on n'évaluerait plus la génération adaptative, mais la génération augmentée d'un correcteur. Le contrôle est donc reporté sur un **audit hors ligne** appliqué à l'ensemble du corpus, dont les verdicts alimentent une régénération ciblée (section 4.6).

Critères de l'audit automatique. L'audit vérifie trois familles de propriétés (tableau 4.6) : la conformité de longueur, évaluée par rapport à une plage tolérée autour de la longueur cible du patron ; la cohérence entre l'émotion enregistrée et la famille du patron ; et la présence de marqueurs lexicaux attendus, détectés par expressions régulières — marqueurs d'explication pour la famille A, de consigne d'exercice pour la famille C, de soutien pour les patrons de frustration. Chaque anomalie détectée porte un code nommé et retire vingt-cinq points à un score de qualité initialisé à cent, un contenu sans anomalie étant déclaré conforme. Cette granularité rend l'audit actionnable : le rapport indique non pas qu'un contenu est mauvais, mais quel critère précis il enfreint.

Code d'anomalie	Propriété vérifiée
`trop_court` · `trop_long`	Longueur du contenu au regard de la cible déclarée par le patron.
`emotion_template_suspect`	Compatibilité entre l'émotion enregistrée et la famille du patron.
`manque_marqueurs_explication`	Présence de marqueurs de reformulation dans un contenu de famille A.
`manque_marqueurs_exercice`	Présence d'une consigne d'exercice dans un contenu de famille C.
`ton_trop_positif_pour_frustration`	Absence de registre de félicitation dans un contenu de soutien.
`confusion_sans_ton_rassurant`	Présence d'un registre rassurant dans un contenu de déblocage.
`template_inconnu`	Existence du patron déclaré dans la bibliothèque.

TABLE 4.6 – Critères de l'audit automatique du contenu généré et codes d'anomalie associés.

Indicateurs de lisibilité. Un second script calcule, indépendamment de l'audit de cohérence, des indicateurs de forme : nombre de mots et de phrases, longueur moyenne des phrases, indice de lisibilité approché par comptage syllabique, et taux de répétition défini comme le complément du rapport entre mots distincts et mots totaux. Ces indicateurs ne portent aucun jugement pédagogique ; ils fournissent une caractérisation objective du corpus, exploitée au chapitre 5 en complément de l'appréciation humaine, dont ils ne peuvent tenir lieu.

4.5 Développement du prototype de simulation

Le prototype n'a pas pour fonction de démontrer une faisabilité technique déjà établie par le serveur : il a pour fonction de rendre la chaîne *observable*. Ce qui doit être visible, c'est moins le contenu produit que le raisonnement qui y conduit — quel état a été perçu par chaque modalité, comment le désaccord a été tranché, quel patron a été retenu, quelles sources ont ancré la génération.

4.5.1 Interface de visualisation

Une application d'une seule page. L'interface est une application REACT en page unique, sans routeur : la configuration, l'attente et les résultats occupent des sections

successives d'une même vue, ce qui maintient sous les yeux le lien entre le profil choisi et l'adaptation obtenue. L'adresse du serveur est lue dans une variable d'environnement, avec repli sur l'hôte local, et la disponibilité de l'API est vérifiée toutes les trente secondes puis signalée par un indicateur d'état : un prototype de recherche est fréquemment utilisé pendant que le serveur redémarre, et distinguer une panne d'API d'une absence de résultat évite de fausses conclusions lors des démonstrations. Le tableau 4.7 récapitule les composants et leur rôle.

Composant	**Rôle dans l'observation de la chaîne**
Sélecteur de scénario	Liste filtrable des cinquante scénarios, avec repère coloré de l'état dominant et raccourcis vers un scénario type de chaque patron.
Diagramme en barres	Intensité des quatre dimensions du scénario sélectionné, avec mise en évidence de la dimension dominante.
Diagramme radial	Même information sous forme de profil, plus lisible pour comparer deux scénarios de mémoire.
Flux de pipeline	Progression en quatre étapes : engagement, décision, récupération documentaire, contenu.
Panneau d'attente	Messages d'étape pendant l'analyse, dont la durée dépend du service distant.
Pastille d'état	Codage couleur et symbole constants pour chaque état d'engagement, réutilisés dans tout l'écran.
Tuteur conversationnel	Dialogue prolongeant l'adaptation, avec activation ou désactivation de l'ancrage documentaire.
Historique latéral	Dix dernières adaptations, rechargées depuis le serveur au démarrage.

TABLE 4.7 – Composants de l'interface de simulation et fonction de chacun.

Des visualisations écrites à la main. Les deux représentations graphiques ne reposent sur aucune bibliothèque de tracé : le diagramme en barres est construit en éléments de mise en page et le diagramme radial est un dessin vectoriel direct. Pour quatre dimensions bornées à quatre niveaux, une bibliothèque générique aurait ajouté une dépendance volumineuse sans apporter de fonction utile, et aurait rendu moins direct le contrôle du codage couleur, lequel doit rester strictement identique entre les pastilles d'état, les graphiques et les cartes de fusion.

4.5.2 Lecteur de parcours d'apprentissage

Le parcours comme enchaînement de clips. Un parcours est, dans le prototype, une suite ordonnée de clips appartenant à une même séquence (section 4.2.4). Sa lecture s'effectue en enchaînant les analyses : l'utilisateur sélectionne successivement les clips de la séquence, chaque analyse produisant une décision et, le cas échéant, un contenu. L'interface matérialise le parcours par un historique latéral qui conserve les dix dernières adaptations avec leur état et leur horodatage, et qui est rechargé depuis la base de sessions au démarrage : une trajectoire simulée survit donc au rafraîchissement de la page et peut être reprise ou présentée après coup.

Ce que le lecteur ne fait pas. La lecture est **pilotée par l'utilisateur** et non automatisée : l'interface ne comporte ni commande de lecture continue, ni boutons de clip suivant et précédent, et le référentiel de séquences n'est pas exposé par le serveur — il reste un artefact hors ligne exploité par les scripts d'évaluation. Cette limite est cohérente avec le choix, assumé en section 4.3.3, d'un point d'entrée au grain du clip ; elle implique en retour que l'évaluation des trajectoires du chapitre 5 s'appuie sur les séquences rejouées hors ligne, non sur des captures d'écran de l'interface. L'ajout d'un véritable lecteur de parcours, doté d'une notion de session identifiée, figure parmi les développements proposés au chapitre 6.

4.5.3 Affichage des adaptations

Rendre la décision lisible avant le contenu. L'écran de résultats place la décision avant le texte produit. Un bandeau annonce l'état détecté et son intensité ; une grille de quatre indicateurs donne le patron retenu, sa famille, le fait qu'une intervention a bien été déclenchée et le nombre de documents injectés ; une carte reprend en clair la description de la décision. Ce n'est qu'ensuite qu'apparaît le contenu, accompagné de son patron, de son objectif et de son nombre de mots. L'ordre est intentionnel : il empêche de lire le contenu comme un texte autonome et rappelle qu'il est la conséquence d'une décision documentée.

Montrer la fusion et ses désaccords. Lorsque l'analyse est effectivement multimodale, trois cartes juxtaposent l'état perçu par le visage, l'état perçu par la voix et l'état fusionné. C'est l'élément d'interface le plus directement lié à la contribution scientifique du travail : il rend visible, cas par cas, le désaccord entre modalités et la manière dont il a été tranché, là où un affichage du seul état final laisserait croire à une perception univoque. La liste des sources documentaires injectées joue le même rôle pour la génération, en rattachant le texte produit à des références identifiables.

Exploitation du contenu produit. Deux fonctions closent l'écran : la copie du contenu dans le presse-papiers et son export en document PDF titré, portant le concept, l'état, l'intensité et le patron employé. Cette seconde fonction n'est pas un ornement : elle a servi à constituer les pièces soumises aux évaluateurs humains du chapitre 5, en garantissant que le contenu évalué est bien celui produit par le système et qu'il reste accompagné des métadonnées qui en conditionnent l'appréciation.

4.6 Génération du corpus de contenu adaptatif

L'artefact final du travail n'est pas seulement un logiciel : c'est un *corpus* de contenus pédagogiques adaptatifs, produit par le système et soumis à évaluation. Cette section décrit sa constitution, depuis le choix des situations couvertes jusqu'à sa documentation.

4.6.1 Sélection de 50 séquences représentatives

Cinquante situations, six patrons. Les cinquante séquences retenues sont les clips de dix secondes du référentiel constitué en section 4.2.3. Leur sélection répond à un critère de couverture et non de représentativité statistique : chacun des six patrons pédagogiques est présent, les situations problématiques étant sur-représentées pour que la chaîne de décision soit sollicitée sur l'ensemble de son domaine. Le passage complet du banc d'essai sur ces cinquante séquences — perception faciale réelle, perception vocale appariée, fusion, décision — produit une table de décisions consignant pour chaque scénario l'état retenu, la stratégie et le patron, qui constitue la base de référence des analyses du chapitre 5.

Des séquences aux trajectoires. Ces cinquante situations sont en outre regroupées en dix trajectoires de quatre à sept clips, chacune illustrant une évolution typique. Une trajectoire n'ajoute aucune donnée : elle ordonne des scénarios existants pour qu'une dynamique devienne observable. C'est sur ces trajectoires que les règles temporelles peuvent être exercées, une situation isolée ne permettant par construction de tester que les règles instantanées.

4.6.2 Génération de contenus pour chaque scénario

Volume et couverture. Le corpus a été produit en appliquant la chaîne complète à chaque scénario, pour plusieurs patrons compatibles avec son état, de manière à couvrir la bibliothèque au-delà des seuls patrons que la cascade sélectionne spontanément. Il compte environ **220 contenus**, chacun enregistré avec l'identifiant du clip, son patron

pédagogique, le patron de prompt employé, l'émotion et son intensité, le texte produit et son nombre de mots. Dix-neuf des vingt patrons de prompts sont représentés, contre onze lors du seul passage automatique sur les cinquante scénarios : le corpus documente donc davantage de situations pédagogiques que le référentiel n'en produit spontanément. Le patron manquant, dédié à un exercice comparatif, n'a été atteint par aucune combinaison de scores présente dans l'échantillon — observation cohérente avec la concentration de la cascade relevée en section 4.3.2.

Caractéristiques mesurées. Les indicateurs de forme calculés sur l'ensemble du corpus situent les contenus autour de **225 mots** en moyenne, dans une plage allant de 115 à 434 mots, avec un taux de répétition lexicale moyen proche de 0,49. La dispersion des longueurs suit les longueurs cibles des patrons : les patrons d'encouragement produisent les textes les plus courts, ceux d'exercice et d'application les plus longs. Cette conformité relative n'est pas garantie par construction — aucun mécanisme ne tronque les sorties (section 4.4.4) — et constitue donc un résultat en soi, discuté au chapitre 5.

Régénération ciblée plutôt que globale. Le corpus n'a pas été produit en une passe. Un premier audit a signalé un nombre important de contenus incohérents, principalement des associations douteuses entre émotion enregistrée et famille de patron. Une passe de correction des seules métadonnées, recalculant la décision sans rappeler le modèle, a ramené la proportion de contenus conformes à plus de neuf sur dix ; une passe de régénération, limitée aux lignes encore signalées et sauvegardant le corpus avant écriture, a porté cette proportion à **97,7 %**, les anomalies résiduelles ne concernant plus que cinq contenus. Deux propriétés de l'outillage ont rendu cette progression possible : la régénération est *sélective*, elle ne retouche que les entrées signalées par l'audit et laisse les autres intactes ; et elle est *temporisée*, un délai séparant deux appels au service distant, sans quoi la limitation de débit interromprait le traitement. Cette traçabilité du corpus — état initial, correction appliquée, état final — fait partie du livrable au même titre que les contenus.

4.6.3 Documentation du corpus

Artefacts livrés. Le corpus n'est pas un fichier isolé mais un ensemble d'artefacts articulés (tableau 4.8) : les contenus eux-mêmes, le rapport d'audit ligne par ligne, les indicateurs de forme, l'échantillon stratifié soumis aux évaluateurs et les fiches d'évaluation vierges. Chaque fichier est produit par un script identifié, à un emplacement fixe, ce qui permet de reconstituer la chaîne complète depuis les scénarios jusqu'aux fiches.

Artefact	**Contenu**	**Volume**
Corpus de contenus	Texte généré, patron, émotion, intensité, nombre de mots	≈ 220
Rapport d'audit	Anomalies détectées et score de qualité par contenu	≈ 220
Indicateurs de forme	Longueur, phrases, lisibilité approchée, répétition	≈ 220
Échantillon d'évaluation	Tirage stratifié par famille de patron	58
Fiches d'évaluation	Extrait de contenu et grille de notation à remplir	58
Table de décisions	État, stratégie et patron retenus par scénario	50

TABLE 4.8 – Artefacts constituant le corpus de contenu adaptatif et son appareil de validation.

Documentation méthodologique. Deux documents accompagnent ces fichiers. Le premier décrit la procédure de régénération : commandes exactes de l'audit, de la simulation à blanc, de la correction des métadonnées puis de la régénération complète, prérequis d'accès au service de génération, et proportions de conformité obtenues à chaque étape. Le second fixe le protocole d'évaluation : constitution de l'échantillon à quinze contenus par famille de patron, maintien d'un concept identique pour rendre les contenus comparables, critères de notation soumis aux enseignants et articulation avec les indicateurs automatiques. Ce protocole est détaillé et mis en œuvre au chapitre 5.

Reproductibilité de la chaîne. Le tirage de l'échantillon d'évaluation est lui-même initialisé par une graine fixe, et les fiches soumises aux évaluateurs sont générées par script à partir du corpus, non recopiées manuellement. L'écart entre l'effectif visé — soixante contenus, quinze par famille — et l'effectif obtenu de cinquante-huit provient de la couverture inégale des familles de patrons dans le corpus ; il est mentionné ici pour que les effectifs rapportés au chapitre 5 soient interprétés à leur juste valeur.

Bilan de l'implémentation. Au terme de ce chapitre, l'artefact est complet : deux corpus préparés et documentés, une chaîne de perception dont les variantes sont commutables par configuration, un moteur de décision dont chaque règle est nommée et testée, un module de génération ancré documentairement, une interface qui expose le raisonnement autant que son résultat, et un corpus de contenus accompagné de son appareil de validation. Trois limites ont été énoncées en chemin plutôt que dissimulées : l'absence de mémoire entre décisions successives, la lecture de parcours pilotée manuel-

lement et l'absence de post-traitement des contenus générés. Le chapitre 5 soumet cet artefact à l'épreuve des faits, en mesurant successivement la perception, la décision et la qualité pédagogique du corpus produit.

Chapitre 5

Validation et Résultats

Sommaire

5.1 Méthodologie d'évaluation multi-niveaux 75
5.1.1 Approche globale 75
5.1.2 Métriques et critères 75
5.2 Validation de la perception et de la fusion 75
5.2.1 Classifieur FER → DAiSEE (Random Forest) 75
5.2.2 Fine-tuning SER (tête wav2vec2) 76
5.2.3 Banc d'essai audiovisuel aligné ($n = 80$) 76
5.2.4 Analyse de sensibilité du mapping IEMOCAP → DAiSEE . . 77
5.3 Validation du modèle d'adaptation 77
5.3.1 Analyse de la pertinence du mapping 77
5.3.2 Couverture des états d'engagement 78
5.3.3 Validation par experts pédagogiques 78
5.4 Validation de la qualité du contenu généré 78
5.4.1 Corpus produit et audit automatique 78
5.4.2 Évaluation experte (protocole) 78
5.4.3 Métriques automatiques complémentaires 78
5.5 Validation utilisateur (étude pilote) 79
5.5.1 Protocole expérimental 79
5.5.2 Simulation de parcours adaptatifs 79
5.6 Résultats et analyses 79
5.6.1 Synthèse quantitative 79
5.6.2 Retours qualitatifs 79
5.7 Discussion approfondie 80
5.7.1 Interprétation des résultats 80
5.7.2 Comparaison avec l'état de l'art 80

5.7.3 Forces et limites identifiées 80

Ce chapitre présente l'évaluation multi-niveaux du prototype EmoLearn, conformément à l'OS6. Il distingue les validations **techniques** (conduites et chiffrées) des validations **expertes et utilisateurs** (instrumentées mais non finalisées dans le cadre de ce mémoire).

5.1 Méthodologie d'évaluation multi-niveaux

5.1.1 Approche globale

L'évaluation s'organise en quatre niveaux complémentaires :

1. **Niveau technique — perception.** Exactitude des modules visage (FER → DAiSEE), voix (SER) et fusion multimodale sur jeux de test documentés.
2. **Niveau décision.** Cohérence du mapping engagement → stratégie et couverture des cinquante scénarios simulés.
3. **Niveau contenu.** Métriques automatiques de forme sur le corpus généré ; protocole d'évaluation experte préparé (60 fiches).
4. **Niveau utilisateur.** Protocole d'étude pilote ($n = 30$) documenté, non exécuté dans la version actuelle du mémoire.

Cette hiérarchie privilégie la *mesure honnête* des compromis observés plutôt qu'une démonstration de performance maximale.

5.1.2 Métriques et critères

Les métriques retenues varient selon le niveau :

— **Classification** : accuracy, F1 macro, matrices de confusion ; pour la fusion, rappel des états « urgents » (confusion, frustration).
— **Corpus généré** : longueur en mots, indice de lisibilité (Kandel–Moles), taux de répétition, taux de conformité à l'audit automatique.
— **Évaluation experte** (protocole) : Likert 1–5 sur pertinence, clarté, adéquation émotionnelle, qualité pédagogique, utilisabilité MOOC et absence d'erreurs factuelles (avec RAG).

5.2 Validation de la perception et de la fusion

5.2.1 Classifieur FER → DAiSEE (Random Forest)

Un échantillon de **1 200** clips DAiSEE a servi à l'entraînement d'un Random Forest (GridSearchCV, $n_estimators = 200$) sur les sept scores de probabilité du modèle

FER pré-entraîné [48, 85]. Le jeu de test ($n = 300$) est fortement déséquilibré (≈75 % Engagement).

Approche	**Accuracy**	**F1 macro**
Mapping heuristique (baseline)	0,193	0,141
Random Forest appris	**0,723**	**0,264**
Gain absolu	+0,530	+0,123

TABLE 5.1 – Comparaison mapping heuristique vs classifieur appris (FER → DAiSEE, $n = 300$).

Le classifieur appris améliore nettement l'accuracy mais le F1 macro reste modeste : le modèle prédit surtout *Engagement*, avec un rappel nul sur *Confusion* et *Frustration* sur ce split. Le gain justifie néanmoins le déploiement du modèle appris en production, sous réserve de compléter l'évaluation par le rappel des classes minoritaires.

5.2.2 Fine-tuning SER (tête wav2vec2)

La tête de classification d'un modèle *wav2vec2* pré-entraîné [3] a été fine-tunée sur 600 segments IEMOCAP (150 par état DAiSEE, oversampling des classes rares), avec validation interne $n = 120$ sur deux époques (CPU) :

Époque	**Accuracy**	**F1 macro**
1	0,275	0,279
2	0,300	**0,309**

TABLE 5.2 – Progression du fine-tuning SER (validation interne).

Ces chiffres mesurent la progression d'entraînement ; la performance en usage réel est évaluée ci-dessous sur le banc d'essai audiovisuel aligné.

5.2.3 Banc d'essai audiovisuel aligné ($n = 80$)

Un sous-corpus IEMOCAP **aligné** (même locuteur, visage et voix synchronisés, 20 segments par état) permet de comparer modalités uniques et fusion sans biais d'appariement. Le tableau 5.3 synthétise les résultats.

Variante	**Accuracy**	**Rappel urgents**
Visage — FER 1 frame	0,375	0,250
Visage — FER multi-frames	0,412	0,275
Voix — SER heuristique	0,263	0,225
Voix — **SER appris (wav2vec2)**	**0,487**	0,200
Fusion — priorité pédagogique	0,338	**0,400**
Fusion — **vote pondéré**	**0,500**	0,125

TABLE 5.3 – Validation multimodale sur sous-corpus IEMOCAP aligné ($n = 80$).

Lecture. Le SER appris double quasi l'accuracy de la voix (+0,224 vs heuristique). La fusion par *weighted vote* atteint la meilleure accuracy (0,500) ; la stratégie *pedagogical priority* maximise le rappel des états urgents (0,400) au prix d'une accuracy plus faible. Ce compromiss est assumé : le prototype retient 60 %/40 % (visage/voix) pour équilibrer les deux objectifs (tableau 5.4).

Poids visage / voix	**Accuracy**	**Rappel urgents**
0,5 / 0,5	0,287	0,375
0,6 / 0,4 (retenu)	0,300	**0,425**
0,7 / 0,3	0,338	0,400
0,8 / 0,2	0,325	0,350

TABLE 5.4 – Balayage des poids de fusion (variante vote pondéré, $n = 80$).

5.2.4 Analyse de sensibilité du mapping IEMOCAP → DAiSEE

Sur 10 039 utterances IEMOCAP, des variantes plausibles du mapping émotion → engagement modifient jusqu'à **17 %** des étiquettes (neutre → Engagement au lieu d'Ennui). La sensibilité confirme que cette hypothèse n'est pas anodine et justifie une validation experte prioritaire sur les correspondances neutre/tristesse.

5.3 Validation du modèle d'adaptation

5.3.1 Analyse de la pertinence du mapping

La cascade engagement → type de contenu (A/B/C/D) + patron (A1–D5) a été appliquée aux cinquante scénarios du référentiel. La distribution des patrons est concentrée sur l'encouragement (type D) en cas de frustration élevée, conforme à la conception (section 4.6 du chapitre 4).

5.3.2 Couverture des états d'engagement

Les cinquante séquences couvrent les quatre états DAiSEE avec un échantillonnage stratifié favorisant les états problématiques (confusion, frustration). Six patrons de séquence (stable, dégradation, récupération, etc.) sont représentés.

5.3.3 Validation par experts pédagogiques

Un protocole Delphi simplifié (deux tours, trois experts, 15 cas tests + 20 fiches de patrons) a été préparé. Les fiches d'évaluation (`results/validation_expert_fiches.csv`, 58 contenus stratifiés) sont prêtes ; les scores Likert restent à compléter. Le livrable final visé est documenté dans `docs/PROTOCOLE_EVALUATION.md`.

5.4 Validation de la qualité du contenu généré

5.4.1 Corpus produit et audit automatique

La chaîne complète (perception simulée, décision, LLM + RAG) a produit **220** contenus (`corpus_200.csv`). Les métriques automatiques donnent :

— Longueur moyenne : **225** mots (min 115, max 434).
— Indice Kandel–Moles moyen : 94,2 (textes accessibles).
— Taux de répétition moyen : 0,485.
— Conformité à l'audit heuristique : **97,7 %** (215/220 sans anomalie majeure ; 5 contenus avec alertes mineures).

Les patrons d'encouragement (D1–D5) produisent les textes les plus courts (≈130–190 mots) ; les exercices (C1–C2) les plus longs (≈320–350 mots), en cohérence avec les contraintes des patrons.

5.4.2 Évaluation experte (protocole)

Un échantillon de 60 contenus stratifiés par type (A/B/C/D) a été extrait (`corpus_evaluation_60.cs`
La grille comprend six critères Likert, dont l'absence d'erreurs factuelles *avec RAG*. Cette évaluation humaine n'a pas été menée à terme dans le délai du mémoire ; elle constitue la perspective immédiate de validation du fond pédagogique.

5.4.3 Métriques automatiques complémentaires

Le script `scripts/metrics_contenu.py` calcule longueur, lisibilité et présence heuristique des éléments structurants des patrons. Ces métriques contrôlent la *forme* mais ne garantissent pas la pertinence sémantique.

5.5 Validation utilisateur (étude pilote)

5.5.1 Protocole expérimental

Un protocole *within-subject* ($n = 30$, deux conditions : contenu statique vs contenu adaptatif EmoLearn) est documenté (durée ≈45 min, SUS, Likert utilité/adéquation émotionnelle). Les hypothèses exploratoires (C2 > C1 sur utilité ; SUS ≥ 68) n'ont pas été testées empiriquement dans cette version du travail.

5.5.2 Simulation de parcours adaptatifs

Le prototype React permet néanmoins une démonstration qualitative : lecture de séquences vidéo, affichage de l'état détecté, de la décision et du contenu généré (avec sources RAG), export PDF et journal SQLite.

5.6 Résultats et analyses

5.6.1 Synthèse quantitative

Composant	**Métrique clé**	**Valeur**
FER → DAiSEE (appris)	Accuracy test	0,723
SER wav2vec2 (banc aligné)	Accuracy	0,487
Fusion vote pondéré	Accuracy	0,500
Fusion priorité pédagogique	Rappel urgents	0,400
Corpus généré (LLM + RAG)	Audit OK	97,7 %

Table 5.5 – Synthèse des résultats chiffrés disponibles.

5.6.2 Retours qualitatifs

Les démonstrations internes du prototype mettent en évidence la *lisibilité* de la chaîne de décision (journal complet) et l'apport visible du RAG (sources documentaires affichées dans l'interface). Les limites perceptives sur les classes minoritaires et le compromis fusion accuracy/rappel urgent sont explicitement documentées plutôt que masquées.

5.7 Discussion approfondie

5.7.1 Interprétation des résultats

Les validations techniques confirment que (i) l'apprentissage léger améliore fortement le mapping FER → DAiSEE, (ii) le SER appris surpasse l'heuristique vocale, (iii) la fusion apporte un gain mesurable mais impose un arbitrage entre exactitude globale et sensibilité aux états critiques. Le module RAG et les patrons structurés maintiennent la forme du corpus à un niveau acceptable (97,7 % d'audit OK), sans préjuger de la qualité pédagogique profonde, qui requiert l'évaluation experte prévue.

5.7.2 Comparaison avec l'état de l'art

Peu de travaux publient une chaîne comparable (multimodal + règles + RAG + LLM) avec métriques de fusion *et* corpus généré audité. La contribution distinctive réside dans l'architecture reproductible et l'honnêteté sur les compromis, plus que dans des scores de référence établis sur MOOC réels.

5.7.3 Forces et limites identifiées

— **Forces** : pipeline bout-en-bout, traçabilité, RAG intégré, banc d'essai aligné, protocoles d'évaluation documentés.

— **Limites** : simulation (pas de captation live), appariement visage–voix hétérogène en production, évaluations experte et utilisateur non finalisées, déséquilibre DAiSEE pénalisant le F1 macro.

Chapitre 6

Conclusion et Perspectives

Sommaire

6.1 Synthèse des contributions 82
6.2 Réponses aux questions de recherche 82
6.3 Limites de l'étude 83
6.4 Perspectives de recherche 83
6.5 Implications pratiques pour les MOOC 83
6.6 Recommandations 84

6.1 Synthèse des contributions

Ce mémoire a conçu, implémenté et évalué partiellement EmoLearn, un prototype de recherche qui relie la **perception multimodale** de l'engagement, une **décision pédagogique explicite** et la **génération adaptative** de contenu par LLM, complétée par un module **RAG** d'ancrage documentaire.

Les contributions concrètes sont les suivantes :

1. Une architecture client–serveur reproductible (FastAPI, React, SQLite) partageant un unique moteur de fusion et de décision entre le pipeline produit et le banc d'essai.
2. Un modèle engagement → adaptation formalisé (20 patrons A1–D5, règles temporelles, journal de traçabilité).
3. Un apprentissage léger des correspondances modalité → état (Random Forest sur FER ; fine-tuning de tête wav2vec2 pour le SER).
4. Un module RAG (ChromaDB, embeddings multilingues, neuf fiches pédagogiques, top-3 avec seuil de similarité) réduisant le risque d'hallucinations [2, 27, 47].
5. Une évaluation instrumentée et transparente : gains mesurés sur FER (+0,53 accuracy), SER (+0,224), fusion (0,500 accuracy en vote pondéré), sensibilité du mapping IEMOCAP, audit automatique du corpus (97,7 % OK).
6. Un protocole d'évaluation multi-niveaux (experts, contenu, utilisateurs) prêt à être exécuté.

6.2 Réponses aux questions de recherche

QR1 — Perception. La fusion multimodale améliore l'exactitude dans le cadre aligné ($n = 80$) lorsque l'on retient le vote pondéré (0,500), au prix d'un rappel faible sur les états urgents. L'apprentissage supervisé améliore nettement chaque modalité par rapport aux mappings heuristiques. Le compromis accuracy/rappel urgent est quantifié et documenté.

QR2 — Décision. Le modèle engagement → adaptation est implémenté, testé sur cinquante scénarios stratifiés et exposé de manière interprétable dans l'interface. La validation experte Delphi est préparée mais non finalisée.

QR3 — Génération. Le pipeline LLM + RAG + patrons produit un corpus de 220 contenus dont 97,7 % passent l'audit automatique de forme. La pertinence pédagogique profonde reste à confirmer par évaluation humaine.

QR4 — Validation. Un protocole multi-niveaux a été appliqué aux composants techniques ; les niveaux expert et utilisateur sont instrumentés pour une exécution ultérieure.

6.3 Limites de l'étude

1. **Prototype de simulation** : pas de déploiement live sur MOOC réels ; les états proviennent de corpus annotés a posteriori.
2. **Appariement visage–voix** : hétérogène en production (DAiSEE + IEMOCAP) ; aligné uniquement pour le banc d'essai.
3. **Mapping émotion → engagement** : hypothèse de construit, sensible jusqu'à 17 % des utterances selon la variante.
4. **Déséquilibre DAiSEE** : F1 macro modeste malgré une accuracy élevée sur le classifieur FER.
5. **Évaluations humaines** : protocoles prêts, exécution incomplète (experts, $n = 30$ utilisateurs).
6. **RAG** : base documentaire réduite (neuf fiches) ; généralisation à d'autres disciplines non démontrée.

6.4 Perspectives de recherche

— **Captation live** : intégrer webcam/micro en temps réel avec consentement et anonymisation.

— **Enrichissement RAG** : indexer les ressources MOOC complètes, évaluer l'impact du RAG sur les erreurs factuelles (critère Q6).

— **Fusion end-to-end** : apprendre la fusion plutôt que des règles fixes, tout en préservant l'interprétabilité pédagogique.

— **Validation experte et utilisateur** : exécuter les protocoles documentés ; analyser statistiquement les Likert et verbatims.

— **Fine-tuning LLM** : adapter un modèle open-weight [21, 63] à la pédagogie française sous contrainte des patrons, en tenant compte des recommandations éthiques [36, 76, 87].

6.5 Implications pratiques pour les MOOC

EmoLearn suggère qu'une régulation pédagogique automatique — détecter un état dégradé, choisir une stratégie explicite, générer une réponse ancrée — est techniquement réalisable comme couche *additionnelle* aux plateformes existantes. Le journal de

décision faciliterait l'audit pédagogique et l'amélioration itérative des règles. Le RAG offre une piste concrète pour limiter les erreurs de contenu généré, à condition d'investir dans une base documentaire curatée.

6.6 Recommandations

Pour un passage au-delà du prototype de recherche, nous recommandons :

1. Prioriser le **rappel des états urgents** dans le choix de la stratégie de fusion, même au détriment de l'accuracy globale.
2. Conduire la **validation experte** du mapping et des patrons avant tout déploiement.
3. Étendre la **base RAG** et mesurer son effet sur la factualité.
4. Documenter et publier les **artefacts reproductibles** (code, jeux de scénarios, métriques) pour permettre la comparaison avec l'état de l'art.

En conclusion, ce travail démontre la faisabilité d'une chaîne perception – décision – génération (LLM + RAG) pour l'adaptation émotionnelle en contexte MOOC, tout en assumant et en mesurant ses limites — condition, à notre sens, d'une recherche crédible en informatique affective appliquée à l'éducation.

Bibliographie

[1] Ali Abedi et Shehroz S. Khan. « Improving state-of-the-art in Detecting Student Engagement with ResNet and TCN Hybrid Network ». In : *18th Conference on Robots and Vision (CRV)*. 2021, p. 151-157.

[2] Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil et Hannaneh Hajishirzi. « Self-RAG : Learning to Retrieve, Generate, and Critique through Self-Reflection ». In : *International Conference on Learning Representations (ICLR)*. 2024.

[3] Alexei Baevski, Yuhao Zhou, Abdelrahman Mohamed et Michael Auli. « wav2vec 2.0 : A Framework for Self-Supervised Learning of Speech Representations ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33. 2020, p. 12449-12460.

[4] Ryan S. J. d. Baker, Sidney K. D'Mello, Ma. Mercedes T. Rodrigo et Arthur C. Graesser. « Better to Be Frustrated than Bored ». In : *International Journal of Human-Computer Studies* 68.4 (2010), p. 223-241.

[5] Prateek Bhardwaj, P. K. Gupta, Harsh Panwar, Mohammad Khubeb Siddiqui, Ruben Morales-Menendez et Anubha Bhaik. « Application of Deep Learning on Student Engagement in e-learning environments ». In : *Computers & Electrical Engineering* 93 (2021), p. 107273.

[6] Melissa Bond, Hassan Khosravi, Maarten De Laat, Nina Bergdahl, Violeta Negrea, Emily Oxley, Phuong Pham, Sin Wang Chong et George Siemens. « A meta systematic review of artificial intelligence in higher education : a call for increased collaboration, equality, and research ». In : *International Journal of Educational Technology in Higher Education* 21 (2024), p. 4.

[7] Nigel Bosch et Sidney K. D'Mello. « Automatic Detection of Mind Wandering from Video in the Lab and in the Classroom ». In : *IEEE Transactions on Affective Computing* 13.2 (2022), p. 625-638.

[8] Lori Breslow, David E. Pritchard, Jennifer DeBoer, Glenda S. Stump, Andrew D. Ho et Daniel T. Seaton. « Studying Learning in the Worldwide

Classroom : Research into edX's First MOOC ». In : *Research & Practice in Assessment* 8 (2013), p. 13-25.

[9] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah et al. « Language Models are Few-Shot Learners ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33. 2020, p. 1877-1901.

[10] Carlos Busso, Murtaza Bulut, Chi-Chun Lee, Abe Kazemzadeh, Emily Mower, Samuel Kim, Jeannette N. Chang, Sungbok Lee et Shrikanth S. Narayanan. « IEMOCAP : Interactive Emotional Dyadic Motion Capture Database ». In : *Language Resources and Evaluation* 42.4 (2008), p. 335-359.

[11] Li-Wei Chen et Alexander Rudnicky. « Exploring Wav2vec 2.0 Fine Tuning for Improved Speech Emotion Recognition ». In : *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2023.

[12] Michelene T. H. Chi et Ruth Wylie. « The ICAP Framework : Linking Cognitive Engagement to Active Learning Outcomes ». In : *Educational Psychologist* 49.4 (2014), p. 219-243.

[13] Thomas K. F. Chiu, Qi Xia, Xinyan Zhou, Ching Sing Chai et Miaoting Cheng. « Systematic literature review on opportunities, challenges, and future research recommendations of artificial intelligence in education ». In : *Computers and Education : Artificial Intelligence* 4 (2023), p. 100118.

[14] Cristina Conati, Oswald Barral, Vanessa Putnam et Lea Rieger. « Toward personalized XAI : A case study in intelligent tutoring systems ». In : *Artificial Intelligence* 298 (2021), p. 103503.

[15] Debby R. E. Cotton, Peter A. Cotton et J. Reuben Shipway. « Chatting and cheating : Ensuring academic integrity in the era of ChatGPT ». In : *Innovations in Education and Teaching International* 61.2 (2024), p. 228-239.

[16] Helen Crompton et Diane Burke. « Artificial intelligence in higher education : the state of the field ». In : *International Journal of Educational Technology in Higher Education* 20 (2023), p. 22.

[17] Sidney D'Mello et Art Graesser. « Dynamics of Affective States during Complex Learning ». In : *Learning and Instruction* 22.2 (2012), p. 145-157.

[18] Sidney K. D'Mello. « A Selective Meta-Analysis on the Relative Incidence of Discrete Affective States during Learning with Technology ». In : *Journal of Educational Psychology* 105.4 (2013), p. 1082-1099.

[19] John Daniel. « Making Sense of MOOCs : Musings in a Maze of Myth, Paradox and Possibility ». In : *Journal of Interactive Media in Education* 2012.3 (2012), p. 18.

[20] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit et Neil Houlsby. « An

Image is Worth 16x16 Words : Transformers for Image Recognition at Scale ». In : *International Conference on Learning Representations (ICLR)*. 2021.

[21] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan et al. « The Llama 3 Herd of Models ». In : *arXiv preprint arXiv :2407.21783* (2024).

[22] Yogesh K. Dwivedi, Nir Kshetri, Laurie Hughes, Emma Louise Slade, Anand Jeyaraj, Arpan Kumar Kar, Abdullah M. Baabdullah, Alex Koohang, Vishnupriya Raghavan, Manju Ahuja et al. « "So what if ChatGPT wrote it ?" Multidisciplinary perspectives on opportunities, challenges and implications of generative conversational AI for research, practice and policy ». In : *International Journal of Information Management* 71 (2023), p. 102642.

[23] Wenqi Fan, Yujuan Ding, Liangbo Ning, Shijie Wang, Hengyun Li, Dawei Yin, Tat-Seng Chua et Qing Li. « A Survey on RAG Meeting LLMs : Towards Retrieval-Augmented Large Language Models ». In : *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2024, p. 6491-6501.

[24] Mohammadreza Farrokhnia, Seyyed Kazem Banihashem, Omid Noroozi et Arjen Wals. « A SWOT analysis of ChatGPT : Implications for educational practice and research ». In : *Innovations in Education and Teaching International* 61.3 (2024), p. 460-474.

[25] Jennifer A. Fredricks, Phyllis C. Blumenfeld et Alison H. Paris. « School Engagement : Potential of the Concept, State of the Evidence ». In : *Review of Educational Research* 74.1 (2004), p. 59-109.

[26] Ankita Gandhi, Kinjal Adhvaryu, Soujanya Poria, Erik Cambria et Amir Hussain. « Multimodal sentiment analysis : A systematic review of history, datasets, fusion methods, applications, challenges and opportunities ». In : *Information Fusion* 91 (2023), p. 424-444.

[27] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang et Haofen Wang. « Retrieval-Augmented Generation for Large Language Models : A Survey ». In : *arXiv preprint arXiv :2312.10997* (2023).

[28] D. Randy Garrison, Terry Anderson et Walter Archer. « Critical Inquiry in a Text-Based Environment : Computer Conferencing in Higher Education ». In : *The Internet and Higher Education* 2.2–3 (1999), p. 87-105.

[29] Dragan Gašević, George Siemens et Shazia Sadiq. « Empowering learners for the age of artificial intelligence ». In : *Computers and Education : Artificial Intelligence* 4 (2023), p. 100130.

[30] Patricia Goldberg, Ömer Sümer, Kathleen Stürmer, Wolfgang Wagner, Richard Göllner, Peter Gerjets, Enkelejda Kasneci et Ulrich Trautwein. « Attentive or Not ? Toward a Machine Learning Approach to Assessing Students' Visible Engagement in Classroom Instruction ». In : *Educational Psychology Review* 33 (2021), p. 27-49.

[31] Arthur C. Graesser. « Emotions are the experiential glue of learning environments in the 21st century ». In : *Learning and Instruction* 70 (2020), p. 101212.

[32] Abhay Gupta, Arjun D'Cunha, Kamal Awasthi et Vineeth Balasubramanian. « DAiSEE : Towards User Engagement Recognition in the Wild ». In : *arXiv preprint arXiv :1609.01885* (2016).

[33] Shubham Gupta, Parteek Kumar et Rajkumar Tekchandani. « A multimodal facial cues based engagement detection system in e-learning context using deep learning model ». In : *Multimedia Tools and Applications* 82 (2023), p. 28545-28574.

[34] Alan R. Hevner, Salvatore T. March, Jinsoo Park et Sudha Ram. « Design Science in Information Systems Research ». In : *MIS Quarterly* 28.1 (2004), p. 75-105.

[35] Khe Foon Hew. « Promoting Engagement in Online Courses : What Strategies Can We Learn from Three Highly Rated MOOCs ». In : *British Journal of Educational Technology* 47.2 (2016), p. 320-341.

[36] Wayne Holmes et Ilkka Tuomi. « State of the art and practice in AI in education ». In : *European Journal of Education* 57.4 (2022), p. 542-570.

[37] Wentao Hu et Zichen Shao. « Design and Evaluation of a GenAI-based Personalized Educational Content System Tailored to Personality Traits and Emotional Responses for Adaptive Learning ». In : *Computers in Human Behavior Reports* 19 (2025), p. 100735.

[38] Yuanyuan Hu, Rafael Ferreira Mello et Dragan Gašević. « Automatic Analysis of Cognitive Presence in Online Discussions : An Approach Using Deep Learning and Explainable Artificial Intelligence ». In : *Computers and Education : Artificial Intelligence* 2 (2021), p. 100037.

[39] Stephen Hutt, Kristina Krasich, Caitlin Mills, Nigel Bosch, Shelby White, James R. Brockmole et Sidney K. D'Mello. « Automated gaze-based mind wandering detection during computerized learning in classrooms ». In : *User Modeling and User-Adapted Interaction* 31 (2021), p. 821-877.

[40] Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel et Edouard Grave. « Atlas : Few-shot Learning with Retrieval Augmented Language Models ». In : *Journal of Machine Learning Research* 24.251 (2023), p. 1-43.

[41] Jaeho Jeon et Seongyong Lee. « Large language models in education : A focus on the complementary relationship between human teachers and ChatGPT ». In : *Education and Information Technologies* 28 (2023), p. 15873-15892.

[42] Katy Jordan. « Massive Open Online Course Completion Rates Revisited : Assessment, Length and Attrition ». In : *The International Review of Research in Open and Distributed Learning* 16.3 (2015), p. 341-358.

[43] Enkelejda Kasneci, Kathrin Sessler, Stefan Küchemann, Maria Bannert et al. « ChatGPT for Good ? On Opportunities and Challenges of Large Language Models for Education ». In : *Learning and Individual Differences* 103 (2023), p. 102274.

[44] René F. Kizilcec, Chris Piech et Emily Schneider. « Deconstructing Disengagement : Analyzing Learner Subpopulations in Massive Open Online Courses ». In : *Proceedings of LAK '13*. 2013, p. 170-179.

[45] Xi Kong, Zhi Liu, Changsheng Chen, Sannyuya Liu, Zhenguo Xu et Qianhui Tang. « Exploratory Study of an AI-supported Discussion Representational Tool for Online Collaborative Learning in a Chinese University ». In : *The Internet and Higher Education* 64 (2025), p. 100973.

[46] Siddique Latif, Rajib Rana, Sara Khalifa, Raja Jurdak, Junaid Qadir et Björn W. Schuller. « Survey of Deep Representation Learning for Speech Emotion Recognition ». In : *IEEE Transactions on Affective Computing* 14.2 (2023), p. 1634-1654.

[47] Patrick Lewis, Ethan Perez, Aleksandra Piktus et al. « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33. 2020, p. 9459-9474.

[48] Shan Li et Weihong Deng. « Deep Facial Expression Recognition : A Survey ». In : *IEEE Transactions on Affective Computing* 13.3 (2022), p. 1195-1215.

[49] Paul Pu Liang, Amir Zadeh et Louis-Philippe Morency. « Foundations and Trends in Multimodal Machine Learning : Principles, Challenges, and Open Questions ». In : *ACM Computing Surveys* 56.10 (2024), p. 1-42.

[50] Weng Marc Lim, Asanka Gunasekara, Jessica Leigh Pallant, Jason Ian Pallant et Ekaterina Pechenkina. « Generative AI and the future of education : Ragnarök or reformation ? A paradoxical perspective from management educators ». In : *The International Journal of Management Education* 21.2 (2023), p. 100790.

[51] Pengfei Liu, Weizhe Yuan, Jinlan Fu, Zhengbao Jiang, Hiroaki Hayashi et Graham Neubig. « Pre-train, Prompt, and Predict : A Systematic Survey of Prompting Methods in Natural Language Processing ». In : *ACM Computing Surveys* 55.9 (2023), p. 1-35.

[52] Sannyuya Liu, Shiqi Liu, Zhi Liu, Xian Peng et Zongkai Yang. « Automated Detection of Emotional and Cognitive Engagement in MOOC Discussions to Predict Learning Achievement ». In : *Computers & Education* 181 (2022), p. 104461.

[53] Shiqi Liu, Sannyuya Liu, Lele Sha, Zijie Zeng, Dragan Gašević et Zhi Liu. « Annotation Guideline-Based Knowledge Augmentation : Toward Enhancing Large Language Models for Educational Text Classification ». In : *IEEE Transactions on Learning Technologies* 18 (2025), p. 619-634. doi : 10.1109/TLT.2025.3570775.

[54] Zhi Liu, Xi Kong, Hao Chen, Sannyuya Liu et Zongkai Yang. « MOOC-BERT : Automatically Identifying Learner Cognitive Presence From MOOC Discussion Data ». In : *IEEE Transactions on Learning Technologies* 16.4 (2023), p. 528-541.

[55] Zhi Liu, Ning Zhang, Xian Peng, Sannyuya Liu, Zongkai Yang, Jiyi Peng, Zhu Su et Jia Chen. « Exploring the Relationship Between Social Interaction, Cognitive Processing and Learning Achievements in a MOOC Discussion Forum ». In : *Journal of Educational Computing Research* (2021). doi : 10.1177/07356331211027300.

[56] Chung Kwan Lo. « What Is the Impact of ChatGPT on Education ? A Rapid Review of the Literature ». In : *Education Sciences* 13.4 (2023), p. 410.

[57] Kristina Loderer, Reinhard Pekrun et James C. Lester. « Beyond cold technology : A systematic review and meta-analysis on emotions in technology-based learning environments ». In : *Learning and Instruction* 70 (2020), p. 101162.

[58] Rosemary Luckin, Mutlu Cukurova, Carmel Kent et Benedict du Boulay. « Empowering educators to be AI-ready ». In : *Computers and Education : Artificial Intelligence* 3 (2022), p. 100076.

[59] Richard E. Mayer. *Multimedia Learning*. 3e éd. Cambridge : Cambridge University Press, 2021.

[60] Naman K. Mehta, Shyam S. Prasad, Sumeet Saurav, Ravi Saini et Sanjay Singh. « Three-dimensional DenseNet self-attention neural network for automatic detection of student's engagement ». In : *Applied Intelligence* 52 (2022), p. 11270-11287.

[61] Daniel F. O. Onah, Jane Sinclair et Russell Boyatt. « Dropout Rates of Massive Open Online Courses : Behavioural Patterns ». In : *EDULEARN14 Proceedings*. 2014, p. 5825-5834.

[62] OpenAI. « GPT-4 Technical Report ». In : *arXiv preprint arXiv :2303.08774* (2023).

[63] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll L. Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex

Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike et Ryan Lowe. « Training language models to follow instructions with human feedback ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 35. 2022.

[64] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel et al. « Scikit-learn : Machine Learning in Python ». In : *Journal of Machine Learning Research* 12 (2011), p. 2825-2830.

[65] Reinhard Pekrun. « The Control-Value Theory of Achievement Emotions ». In : *Educational Psychology Review* 18.4 (2006), p. 315-341.

[66] Leonardo Pepino, Pablo Riera et Luciana Ferrer. « Emotion Recognition from Speech Using wav2vec 2.0 Embeddings ». In : *Proc. Interspeech*. 2021, p. 3400-3404.

[67] Rosalind W. Picard. *Affective Computing*. Cambridge, MA : MIT Press, 1997.

[68] Justin Reich et José A. Ruipérez-Valiente. « The MOOC Pivot ». In : *Science* 363.6423 (2019), p. 130-131.

[69] Nazmus Sakeef, M. Ali Akber Dewan, Fuhua Lin et Dharamjit Parmar. « Detecting Cognitive Engagement in Online Course Forums : A Review of Frameworks and Methodologies ». In : *Natural Language Processing Journal* 11 (2025), p. 100146.

[70] Kshitij Sharma et Michail Giannakos. « Multimodal data capabilities for learning : What can multimodal data tell us about learning ? » In : *British Journal of Educational Technology* 51.5 (2020), p. 1450-1484.

[71] John Sweller. « Cognitive Load During Problem Solving : Effects on Learning ». In : *Cognitive Science* 12.4 (1988), p. 257-285.

[72] John Sweller, Jeroen J. G. van Merriënboer et Fred Paas. « Cognitive Architecture and Instructional Design : 20 Years Later ». In : *Educational Psychology Review* 31 (2019), p. 261-292.

[73] Ahmed Tlili, Boulus Shehata, Michael Agyemang Adarkwah, Aras Bozkurt, David T. Hickey, Ronghuai Huang et Brighter Agyemang. « What if the devil is my guardian angel : ChatGPT as a case study of using chatbots in education ». In : *Smart Learning Environments* 10 (2023), p. 15.

[74] Hugo Touvron, Thibaut Lavril, Gautier Izacard et al. « LLaMA : Open and Efficient Foundation Language Models ». In : *arXiv preprint arXiv :2302.13971* (2023).

[75] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale et al. « Llama 2 : Open Foundation and Fine-Tuned Chat Models ». In : *arXiv preprint arXiv :2307.09288* (2023).

[76] UNESCO. *Guidance for generative AI in education and research*. Rapp. tech. Paris : UNESCO, 2023.

[77] Kurt VanLehn. « The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems ». In : *Educational Psychologist* 46.4 (2011), p. 197-221.

[78] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser et Illia Polosukhin. « Attention Is All You Need ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 30. 2017, p. 5998-6008.

[79] Johannes Wagner, Andreas Triantafyllopoulos, Hagen Wierstorf, Maximilian Schmitt, Felix Burkhardt, Florian Eyben et Björn W. Schuller. « Dawn of the Transformer Era in Speech Emotion Recognition : Closing the Valence Gap ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 45.9 (2023), p. 10745-10759.

[80] Shen Wang, Tianze Xu, Hang Li, Chaoli Zhang, Joleen Liang, Jiliang Tang, Philip S. Yu et Qingsong Wen. « Large Language Models for Education : A Survey and Outlook ». In : *arXiv preprint arXiv :2403.18105* (2024).

[81] Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang et Ming Zhou. « MiniLM : Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33. 2020, p. 5776-5788.

[82] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le et Denny Zhou. « Chain-of-Thought Prompting Elicits Reasoning in Large Language Models ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 35. 2022.

[83] Jules White, Quchen Fu, Sam Hays, Michael Sandborn, Carlos Olea, Henry Gilbert, Ashraf Elnashar, Jesse Spencer-Smith et Douglas C. Schmidt. « A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT ». In : *arXiv preprint arXiv :2302.11382* (2023).

[84] Jacob Whitehill, Zewelanji Serpell, Yi-Ching Lin, Aysha Foster et Javier R. Movellan. « The Faces of Engagement : Automatic Recognition of Student Engagement from Facial Expressions ». In : *IEEE Transactions on Affective Computing* 5.1 (2014), p. 86-98.

[85] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest et Alexander M. Rush. « Transformers : State-of-the-Art Natural Language Processing ». In : *Proceedings of the 2020*

Conference on Empirical Methods in Natural Language Processing : System Demonstrations. 2020, p. 38-45.

[86] Yan Xiong, Xinya Guo et Junjie Xu. « CNN-Transformer : A Deep Learning Method for Automatically Identifying Learning Engagement ». In : *Education and Information Technologies* 29 (2024), p. 9989-10008.

[87] Lixiang Yan, Lele Sha, Linxuan Zhao, Yuheng Li, Roberto Martinez-Maldonado, Guanliang Chen, Xinyu Li, Yueqiao Jin et Dragan Gašević. « Practical and ethical challenges of large language models in education : A systematic scoping review ». In : *British Journal of Educational Technology* 55.1 (2024), p. 90-112.

[88] Shu-wen Yang, Po-Han Chi, Yung-Sung Chuang, Cheng-I Jeff Lai, Kushal Lakhotia, Yist Y. Lin, Andy T. Liu, Jiatong Shi, Xuankai Chang, Guan-Ting Lin, Tzu-Hsien Huang, Wei-Cheng Tseng, Ko-tik Lee, Da-Rong Liu, Zili Huang, Shun-Po Fu, Kuan-Yu Chen, Shane Arora, Chien-Feng Huang, Wei-Cheng Lin, Chia-Hua Tsai, Chieh-Chi Chen, Chuxin Liu, Hung-yi Lee et Lin-shan Lee. « SUPERB : Speech processing Universal PERformance Benchmark ». In : *Proc. Interspeech*. 2021, p. 1194-1198.

[89] Ce Zheng, Matias Mendieta et Chen Chen. « POSTER : A Pyramid Cross-Fusion Transformer Network for Facial Expression Recognition ». In : *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*. 2023, p. 3146-3155.

Annexe A

Templates de prompts

La bibliothèque complète des vingt patrons est détaillée au tableau 3.12 (chapitre 3). Le tableau A.1 reprend les métadonnées implémentées dans `backend/prompts/templates.py`.

TABLE A.1: Métadonnées des 20 patrons (type, longueur cible, objectif).

ID	Type	Longueur	Objectif
A1	A	200 mots	Clarifier
A2	A	150 mots	Clarifier
A3	A+D	200 mots	Débloquer
A4	A	250 mots	Clarifier
A5	A	200 mots	Clarifier
B1	B	200 mots	Stimuler
B2	B	250 mots	Réengager
B3	B	200 mots	Stimuler
B4	B	250 mots	Contextualiser
B5	B	200 mots	Stimuler
C1	C	250 mots	Approfondir
C2	C	200 mots	Consolider
C3	C	200 mots	Stimuler
C4	C	250 mots	Approfondir
C5	C	200 mots	Approfondir
D1	D	150 mots	Encourager
D2	D	180 mots	Encourager
D3	D	200 mots	Réengager
D4	D	150 mots	Renforcer
D5	D	150 mots	Renforcer

Annexe B

Protocoles d'évaluation

Les protocoles détaillés (Delphi mapping, grille experte contenu 60 fiches, banc d'essai $n = 80$, étude pilote $n = 30$) sont documentés dans `docs/PROTOCOLE_EVALUATION.md`. Fichiers de résultats associés :

— `results/fer_classifier_metrics.json`
— `results/iemocap_av_metrics.json`
— `results/balayage_poids_fusion.json`
— `results/sensibilite_mapping.json`
— `results/corpus_metrics.json`
— `results/corpus_audit_summary.json`
— `data/corpus_evaluation_60.csv`

Annexe C

Exemple de contenu généré (extrait)

Exemple de production pour le patron A3 (aide de déblocage — confusion + frustration), concept « algorithmes de tri », avec RAG activé :

> *Ce concept est complexe, c'est normal. [...] Le point de blocage probable concerne la distinction entre complexités $O(n^2)$ et $O(n \log n)$. [...] Micro-exercice guidé : triez à la main la liste [5, 3, 1, 4, 2] avec le tri à bulles en notant chaque permutation.*

Le corpus complet (`data/corpus_200.csv`, 220 entrées) inclut pour chaque ligne l'état détecté, le `template_id`, les sources RAG et le texte intégral.

Annexe D

Résultats détaillés

Matrice de confusion — fusion vote pondéré ($n = 80$).

	Boredom	Co
Boredom (GT)	19	
Confusion (GT)	14	
Engagement (GT)	3	
Frustration (GT)	11	

Sensibilité mapping IEMOCAP ($n = 10\,039$ utterances).

Variante	% état
neutre → Engagement	1
tristesse → Frustration	1
surprise → Engagement	1

Distribution des longueurs par patron (corpus $n = 220$). Les moyennes par patron vont de 131 mots (D4, D5) à 349 mots (C2), conformes aux cibles du tableau A.1. Détail complet : `results/corpus_metrics.json`.