République Tunisienne
Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique
Université de La Manouba
École Supérieure de Commerce de Tunis
Institut Supérieur des Arts Multimédia
de la Manouba

MÉMOIRE DE MASTER DE RECHERCHE

Présenté en vue de l'obtention du

MASTER DE RECHERCHE EN INFORMATIQUE
DÉCISIONNELLE ET INTELLIGENTE APPLIQUÉE À LA GESTION

Parcours : Aide à la Décision

EmoLearn : personnalisation pédagogique adaptative multimodale fondée sur la détection de l'engagement émotionnel et la génération de contenu par IA générative

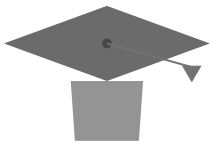
---

Par

Briki Maram

Encadrante académique : Dr. REZGUI Kalthoum, *ISAMM*

Année Universitaire : 2025 – 2026



Dédicace

وَكَانَ فَضْلُ اللَّهِ عَلَيْكَ عَظِيمًا

Je dédie ce travail à tous ceux qui m'ont appris à aimer le savoir
et qui m'ont aidée dans mon apprentissage.

À ma mère, **Radhia**, et à mon père, **Dhahbi**,
pour leur amour, leurs prières et leur soutien constant,

À ma tante, **Jalila**, pour sa bienveillance et ses conseils,

À mes frères, **Hosni** et **Amara**, pour leur solidarité,

À toute ma famille pour leur soutien.

À mon partenaire, **Aymen**, pour sa patience et son appui,

À mes amis, merci pour leur soutien.

Et à tous ceux qui ont aidé, d'une manière ou d'une autre,
à atteindre ce succès,
je vous exprime ma profonde gratitude et mon respect.

Maram Briki

Remerciements

À mon encadrante

Dr. REZGUI Kalthoum

Je tiens à exprimer ma profonde gratitude pour avoir accepté d'encadrer ce travail de recherche.

Je vous remercie sincèrement pour le temps que vous y avez consacré ainsi que pour votre soutien tout au long de ce projet.

Je vous suis reconnaissante pour les ressources mises à ma disposition et pour l'encadrement de qualité dont j'ai bénéficié.

Votre patience, votre professionnalisme, vos conseils et vos remarques constructives ont contribué de manière significative à la réussite de ce travail.

Enfin, j'adresse mes sincères remerciements aux membres du jury pour leur temps et leur évaluation attentive.

Table des matières

Introduction générale **1**

1 Fondements de l'apprentissage adaptatif et de l'engagement **4**
1.1 Introduction 5
1.2 Apprentissage en ligne et MOOC 5
1.2.1 Définition et genèse 5
1.2.2 Rétention et implication pour l'adaptation 5
1.3 Engagement de l'apprenant 6
1.3.1 Définition 6
1.3.2 Dimensions de l'engagement 6
1.3.3 Mesure de l'engagement 6
1.4 Informatique affective et émotions en apprentissage 7
1.4.1 Rôle des émotions dans l'apprentissage 7
1.4.2 États pertinents pour l'adaptation pédagogique 7
1.4.3 Charge cognitive 7
1.5 Détection multimodale de l'engagement 8
1.5.1 Modalités exploitées 8
1.5.2 Corpus de référence 8
1.5.3 Fusion multimodale 9
1.6 IA générative pour l'éducation 9
1.6.1 Grands modèles de langue 9
1.6.2 Guidage par prompts et patrons 10
1.6.3 Récupération augmentée (RAG) 10
1.7 Conclusion 11

2 Synthèse de l'état de l'art **12**
2.1 Introduction 13
2.2 MOOCs et engagement apprenant 13

2.2.1 Défis de rétention et d'engagement 13
2.2.2 Mesure de l'engagement en e-learning 13
2.2.3 Indicateurs émotionnels et cognitifs 14
2.3 Détection automatique de l'engagement 14
2.3.1 Approches multimodales 15
2.3.2 Datasets publics d'engagement 17
2.3.3 État de l'art des performances de détection 17
2.4 Psychologie de l'apprentissage et émotions 18
2.4.1 Impact des émotions sur l'apprentissage 19
2.4.2 Théories de la charge cognitive 19
2.4.3 États d'engagement : ennui, confusion, frustration, flow 19
2.5 IA générative pour l'éducation 20
2.5.1 LLMs et génération de contenu pédagogique 20
2.5.2 Prompt engineering pour applications éducatives 20
2.5.3 Personnalisation et adaptation automatique 21
2.5.4 Évaluation de la qualité pédagogique 21
2.6 Systèmes adaptatifs d'apprentissage 22
2.6.1 Intelligent Tutoring Systems (ITS) 22
2.6.2 Stratégies d'adaptation pédagogique 22
2.6.3 Règles et modèles de décision 23
2.7 Synthèse critique et positionnement 23
2.7.1 Positionnement d'EmoLearn 26
2.8 Conclusion 27

3 Méthodologie proposée et architecture du framework EmoLearn 28
3.1 Introduction 29
3.2 Framework conceptuel proposé 29
3.2.1 Architecture globale du système 29
3.2.2 Workflow de génération adaptative 30
3.3 Données retenues 31
3.3.1 DAiSEE : taxonomie d'engagement 31
3.3.2 IEMOCAP : modalité vocale 31
3.3.3 Articulation des corpus visuel et vocal 32
3.4 Modèle engagement–adaptation 33
3.4.1 Taxonomie des états d'engagement 33
3.4.2 Estimation multimodale de l'état d'engagement 33
3.4.3 Mapping états → besoins pédagogiques 35
3.4.4 Stratégies pédagogiques par état 37
3.4.5 Règles de déclenchement d'adaptation 37

3.5 Système de génération 38
3.5.1 Architecture de prompting contextuel 38
3.5.2 Typologie du contenu adaptatif et patrons de prompts 39
3.6 Conclusion 41

4 Implémentation du prototype 42
4.1 Introduction 44
4.2 Infrastructure technique 44
4.2.1 Stack technologique 44
4.2.2 Choix d'architecture 45
4.3 Traitement et préparation des données 47
4.3.1 Caractérisation de DAiSEE 47
4.3.2 Caractérisation de IEMOCAP 48
4.3.3 Extraction et nettoyage du dataset DAiSEE 49
4.3.4 Extraction et alignement du corpus IEMOCAP 50
4.3.5 Création de scénarios d'apprentissage 51
4.3.6 Segmentation des sessions 52
4.4 Implémentation de la couche de perception 52
4.4.1 Perception faciale 52
4.4.2 Perception vocale 54
4.4.3 Fusion des modalités 56
4.5 Implémentation de la couche de décision 58
4.5.1 Sélection de stratégies 58
4.5.2 Gestion des transitions d'état 59
4.6 Implémentation de la couche de génération 60
4.6.1 Configuration du LLM 60
4.6.2 Bibliothèque de vingt patrons de prompts 61
4.6.3 Pipeline de génération 62
4.6.4 Post-traitement et validation 64
4.7 Algorithme global 65
4.8 Développement du prototype de simulation 66
4.8.1 Interface de visualisation 66
4.8.2 Lecteur de parcours d'apprentissage 68
4.8.3 Affichage des adaptations 68
4.9 Génération du corpus de contenu adaptatif 69
4.9.1 Génération et documentation du corpus 69
4.9.2 Exemples de contenu généré 70
4.10 Conclusion 72

5 Validation et résultats 73

5.1 Introduction 75
5.2 Méthodologie d'évaluation multi-niveaux 75
5.2.1 Approche globale 75
5.2.2 Deux cadres d'évaluation de la fusion 76
5.2.3 Métriques et critères 76
5.3 Validation de la perception et de la fusion 77
5.3.1 Le piège de l'accuracy : classifieur FER déséquilibré 77
5.3.2 Module de décision : Random Forest basé sur FER + AU 77
5.3.3 Fine-tuning SER : WavLM vers DAiSEE 78
5.3.4 Appariement vocal : index acoustique 79
5.3.5 Banc d'essai audiovisuel aligné ($n = 80$) 79
5.3.6 Proxy du pipeline produit 81
5.3.7 Analyse de sensibilité du mapping IEMOCAP $\rightarrow$ DAiSEE 81
5.4 Validation du modèle d'adaptation 81
5.4.1 Analyse de la pertinence du mapping 82
5.4.2 Couverture des états d'engagement 82
5.5 Validation de la qualité du contenu généré 83
5.5.1 Ancrage documentaire (RAG) 83
5.5.2 Évaluation experte (3 enseignants $\times$ 8 exemples) 84
5.5.3 Métriques automatiques (lisibilité, longueur, diversité) 84
5.5.4 Analyse comparative par type de contenu 85
5.6 Validation utilisateur 86
5.6.1 Simulation de parcours adaptatifs 86
5.6.2 Enquête d'acceptabilité de l'idée ($n = 15$) 86
5.7 Synthèse des résultats 87
5.7.1 Retours qualitatifs 88
5.8 Discussion 88
5.8.1 Lecture des mesures 88
5.8.2 Positionnement 89
5.8.3 Portée et limites 89
5.9 Conclusion 89

Conclusion générale **90**

Bibliographie **94**

A Tuteur conversationnel **101**

B Questionnaires et protocoles d'évaluation **102**
B.1 Enquête d'idée (exécutée, $n = 15$) 102

Liste des figures

1.1 Dimensions de l'engagement. 6
1.2 Quatre états d'engagement (DAiSEE). 7
1.3 Détection multimodale. 8
1.4 Architecture d'un LLM (Transformer décodeur). 10
1.5 Architecture du RAG. 11

3.1 Architecture fonctionnelle en couches. 30
3.2 Vocabulaires de décision. 36
3.3 Architecture du prompt. 39

4.1 Architecture technique du prototype. 45
4.2 Distribution des états DAiSEE. 47
4.3 Distribution des émotions IEMOCAP. 49
4.4 Chaîne de préparation des données. 49
4.5 Architecture de la perception faciale. 53
4.6 Architecture de la perception vocale. 55
4.7 Architecture de la fusion multimodale. 57
4.8 Architecture du pipeline de génération. 62
4.9 Interface en mode clip. 67
4.10 Interface en mode séquence. 68
4.11 Écran de résultat. 69

Liste des tableaux

2.1 Performances de détection rapportées. 18
2.2 Synthèse critique de l'état de l'art. 25

3.1 Complémentarité des corpus DAiSEE et IEMOCAP. 32
3.2 Projection IEMOCAP vers DAiSEE. 32
3.3 Taxonomie des états d'engagement. 33
3.4 Mapping FER vers DAiSEE. 34
3.5 Heuristique vocale : de l'indice acoustique à l'état DAiSEE. 35
3.6 Mapping engagement–contenu. 36
3.7 Règles temporelles d'adaptation. 38
3.8 Bibliothèque des vingt patrons. 41

4.1 Pile technologique du prototype. 45
4.2 Commutation des variantes de perception. 46
4.3 Patterns pédagogiques DAiSEE. 48
4.4 Référentiel de scénarios. 51
4.5 Paramètres d'extraction visuelle. 54
4.6 Paramètres d'extraction vocale. 56
4.7 Paramètres de la fusion multimodale. 58
4.8 Paramètres de génération. 61
4.9 Paramètres de la récupération documentaire. 63
4.10 Critères d'audit automatique. 64
4.11 Composants de l'interface. 67
4.12 Artefacts du corpus adaptatif. 70

5.1 Deux cadres d'évaluation. 76
5.2 Effondrement du FER sur la classe majoritaire. 77
5.3 Mapping visage vers DAiSEE. 78
5.4 Matrice de confusion FER+AU (test équilibré $n = 200$). 78

5.5 Fine-tuning SER WavLM. 79
5.6 Appariement vocal ($n = 50$). 79
5.7 Fusion multimodale ($n = 80$), stack déployé. 80
5.8 Matrice de confusion de la fusion ($n = 80$). 80
5.9 Balayage des poids de fusion ($n = 80$). 80
5.10 Sensibilité du mapping IEMOCAP vers DAiSEE ($n = 10\,039$). 81
5.11 Contingence état fusionné × famille ($n = 50$). 82
5.12 Distribution des patrons (50 scénarios). 83
5.13 Récupération RAG. 84
5.14 Grille L2, $n = 3$ enseignants × 8 textes (Likert 1–5). 84
5.15 Comparaison par type de contenu (forme $N = 208$, similarité $N = 189$). 85
5.16 Longueurs par famille de patron. 85
5.17 Similarité interne des contenus. 86
5.18 Enquête d'idée ($n = 15$). SUS ≥ 68 : 3/15. 87
5.19 Synthèse des résultats. 88

A.1 Réglages du tuteur conversationnel. 101

B.1 Enquête d'idée : profil, Likert et questions ouvertes. 103
B.2 Enquête d'idée : SUS imaginé (10 items, 1–5). 103

Liste des acronymes

AU : Action Unit, unité d'action faciale (FACS).

BERT : Bidirectional Encoder Representations from Transformers, encodeur bidirectionnel pré-entraîné pour le texte.

CNN : Convolutional Neural Network, réseau de neurones convolutif.

CoI : Community of Inquiry, communauté d'enquête.

DAiSEE : Dataset for Affective States in E-Environments, corpus public d'états affectifs en environnement d'apprentissage.

FACS : Facial Action Coding System, système de codage des actions faciales.

FER : Facial Expression Recognition, reconnaissance d'expressions faciales.

GPT : Generative Pre-trained Transformer, transformeur génératif pré-entraîné.

ICAP : Interactive, Constructive, Active, Passive.

IEMOCAP : Interactive Emotional Dyadic Motion Capture, corpus de capture de mouvement dyadique émotionnel.

LLM : Large Language Model, grand modèle de langue.

MOOC : Massive Open Online Course, cours en ligne ouvert et massif.

RAG : Retrieval-Augmented Generation, génération augmentée par récupération.

SER : Speech Emotion Recognition, reconnaissance d'émotions de la parole.

TALN : Natural Language Processing, traitement automatique du langage naturel.

ViT : Vision Transformer, transformeur de vision.

WavLM : Wave Language Model, encodeur vocal auto-supervisé.

Introduction générale

Les pratiques d'apprentissage ont été profondément remodelées par la généralisation des outils numériques et l'essor des plateformes éducatives, dont les cours en ligne ouverts et massifs (MOOC, *Massive Open Online Courses*) constituent la forme la plus visible. Ces dispositifs permettent aujourd'hui de collecter, diffuser et personnaliser des contenus pédagogiques à grande échelle, offrant à des millions d'apprenants un accès élargi à la formation, indépendamment des contraintes géographiques (Breslow et al., 2013 ; Daniel, 2012). La crise sanitaire de 2020 a encore accéléré cette dynamique, faisant de l'apprentissage en ligne une composante désormais structurelle des systèmes éducatifs contemporains.

Toutefois, cette évolution s'accompagne d'un constat largement documenté : les MOOC souffrent de taux d'abandon particulièrement élevés. Une part importante des inscrits interrompt son parcours dès les premières semaines, ce qui limite fortement l'efficacité pédagogique réelle de ces dispositifs (Jordan, 2015 ; Onah et al., 2014). Parmi les facteurs explicatifs, la baisse de l'engagement de l'apprenant occupe une place centrale (Hew, 2016 ; Kizilcec et al., 2013). Dans une salle de classe traditionnelle, l'enseignant perçoit en permanence des signaux fins (regard, posture, expression) et adapte spontanément son discours. Cette boucle de régulation disparaît presque entièrement dans les environnements en ligne de masse, où l'apprenant fait face à un contenu figé, identique pour tous et insensible à son état du moment.

Dans ce contexte, plusieurs travaux en informatique affective et en psychologie de l'apprentissage ont établi que les émotions ne sont pas périphériques à la cognition, mais en constituent un rouage essentiel (Pekrun, 2006 ; Picard, 1997). Des états tels que l'ennui, la confusion ou la frustration influencent directement la profondeur du traitement de l'information, la persévérance et la mémorisation (Baker et al., 2010 ; D'Mello et Graesser, 2012). Une détection inefficace de ces états, combinée à l'absence d'adaptation pédagogique, peut entraîner une dégradation de l'expérience d'apprentissage et favoriser le décrochage. L'enjeu est d'intervenir avant que le désengagement ne s'installe.

Le présent travail vise précisément cette articulation : réunir, dans un même cadre logiciel, la perception de l'engagement émotionnel et la génération adaptative de contenu pédagogique.

Le questionnement qui guide ce mémoire peut alors se formuler ainsi :

Comment concevoir un système capable d'inférer automatiquement l'état d'engagement d'un apprenant à partir de signaux multimodaux, puis de générer en réponse un contenu pédagogique adapté à cet état, tout en garantissant la cohérence et la traçabilité de la décision pédagogique sous-jacente ?

Cette question se décompose en quatre sous-questions opérationnelles :

— Comment estimer de manière fiable l'état d'engagement à partir de signaux multimodaux hétérogènes (expressions faciales issues de DAiSEE, signal vocal issu de IEMOCAP), et quel gain la fusion apporte-t-elle par rapport à une modalité unique ?
— Comment formaliser une correspondance pédagogiquement justifiable entre les états d'engagement détectés et les stratégies d'intervention, c'est-à-dire un modèle *engagement* → *adaptation* ?
— Dans quelle mesure un grand modèle de langue, guidé par des patrons de prompts structurés et ancré par un mécanisme de récupération augmentée (RAG), peut-il produire un contenu pédagogique pertinent et adapté à l'état d'engagement visé ?
— Selon quel protocole peut-on évaluer, de façon rigoureuse et multi-niveaux, la qualité de la perception, la pertinence de la décision et la qualité du contenu généré ?

Or la littérature progresse rapidement sur deux fronts qui communiquent peu. Du côté de la perception, les modèles multimodaux estiment l'état affectif d'un apprenant avec une fiabilité croissante (D'Mello, 2013 ; Gupta et al., 2016 ; Whitehill et al., 2014). Du côté de la production de contenu, les grands modèles de langue rendent envisageable une personnalisation pédagogique à grande échelle (Brown et al., 2020 ; Kasneci et al., 2023). Entre ces deux lignes de travaux, la détection débouche rarement sur une décision pédagogique explicite, et la génération est rarement conditionnée par un état d'engagement effectivement mesuré. Il en résulte des approches incapables de reconstituer la boucle de régulation perdue en ligne.

Le système hybride EmoLearn est conçu pour relier ces deux fronts. Il s'articule autour de trois couches : perception de l'état (visage et voix), décision pédagogique explicite (*engagement* → *adaptation*), génération d'un contenu ancré.

La perception s'applique au signal des clips (vidéo, forme d'onde), les annotations des corpus servent d'étiquettes d'entraînement et de validation. Les corpus se limitent à DAiSEE et IEMOCAP.

Les contributions se répartissent comme suit.

Contributions scientifiques.

1. Formalisation d'un modèle *engagement* → *adaptation* assorti d'une bibliothèque de vingt patrons de génération structurés.
2. Conception d'un ancrage documentaire (RAG) conditionnant la génération par l'état d'engagement détecté.
3. Protocole d'évaluation multi-niveaux, incluant une analyse instrumentée de la fusion (compromis entre exactitude globale et sensibilité aux états critiques).

Contributions techniques.

4. Perception faciale (FER+AU, ViT en filtre / mode dégradé) et fine-tuning de la tête WavLM vers les quatre états DAiSEE.
5. Prototype logiciel reproductible, de type client–serveur, matérialisant le cadre proposé.

Structure du mémoire

Le présent mémoire s'ouvre par cette introduction générale, puis s'organise en cinq chapitres numérotés, suivis d'une conclusion générale.

Le chapitre 1 pose les fondements conceptuels de l'apprentissage adaptatif et de l'engagement (MOOC, émotions, détection multimodale, IA générative).

Le chapitre 2 propose une synthèse de l'état de l'art et positionne EmoLearn par rapport aux travaux existants.

Le chapitre 3 est consacré à la conception du système : architecture globale, modèle *engagement* → *adaptation*, patrons de génération et module RAG.

Le chapitre 4 décrit l'implémentation du prototype.

Le chapitre 5 expose la validation et les résultats selon un protocole multi-niveaux.

La conclusion générale synthétise les contributions, expose les limites et trace des perspectives.

Le mémoire se termine par la bibliographie et des annexes : tuteur conversationnel (annexe A) et questionnaires (annexe B).

Chapitre 1

Fondements de l'apprentissage adaptatif et de l'engagement

Sommaire

1.1 Introduction **5**

1.2 Apprentissage en ligne et MOOC **5**

1.2.1 Définition et genèse 5

1.2.2 Rétention et implication pour l'adaptation 5

1.3 Engagement de l'apprenant **6**

1.3.1 Définition 6

1.3.2 Dimensions de l'engagement 6

1.3.3 Mesure de l'engagement 6

1.4 Informatique affective et émotions en apprentissage **7**

1.4.1 Rôle des émotions dans l'apprentissage 7

1.4.2 États pertinents pour l'adaptation pédagogique 7

1.4.3 Charge cognitive 7

1.5 Détection multimodale de l'engagement **8**

1.5.1 Modalités exploitées 8

1.5.2 Corpus de référence 8

1.5.3 Fusion multimodale 9

1.6 IA générative pour l'éducation **9**

1.6.1 Grands modèles de langue 9

1.6.2 Guidage par prompts et patrons 10

1.6.3 Récupération augmentée (RAG) 10

1.7 Conclusion **11**

1.1 Introduction

La conception d'un système d'apprentissage adaptatif fondé sur l'engagement émotionnel mobilise un ensemble de notions issues de domaines distincts : sciences de l'éducation, informatique affective, apprentissage multimodal et intelligence artificielle générative. Ces notions sont souvent présentées séparément, les rassembler permet d'établir un vocabulaire partagé et d'expliciter les hypothèses sur lesquelles repose le pipeline EmoLearn.

Le présent chapitre construit progressivement ce socle. Il part de l'apprentissage en ligne et des MOOC, précise ce que recouvre l'engagement de l'apprenant, puis introduit les apports de l'informatique affective. Il présente ensuite les principes de la détection multimodale avant d'aborder l'intelligence artificielle générative appliquée à l'éducation, à travers les grands modèles de langue, le guidage par prompts et la récupération augmentée. Outre ce cadrage conceptuel, le chapitre assume une vocation de rappel technique général : les notions de Transformer, de prompts et de RAG y sont exposées de manière introductive, afin de préparer la lecture des chapitres de conception et d'implémentation.

1.2 Apprentissage en ligne et MOOC

1.2.1 Définition et genèse

Les cours en ligne ouverts et massifs (MOOC, *Massive Open Online Courses*) désignent des dispositifs de formation accessibles à distance, le plus souvent sans prérequis d'inscription stricts, et destinés à un public potentiellement très large (Daniel, 2012). Ils reposent typiquement sur des vidéos pédagogiques, des quiz, des forums et un parcours de progression asynchrone.

Le sigle s'est imposé au tournant des années 2010, lorsque des universités ont ouvert des cours à une audience mondiale via des plateformes telles que Coursera ou edX. L'un des cas les plus documentés demeure Circuits and Electronics (6.002x), premier MOOC d'edX, qui a rassemblé plus de cent cinquante mille inscrits (Breslow et al., 2013). Daniel (2012) en a dégagé très tôt la tension constitutive : une promesse d'accès élargi, associée à des difficultés persistantes de suivi et d'achèvement.

1.2.2 Rétention et implication pour l'adaptation

Les études de cohortes confirment que les taux d'achèvement restent structurellement bas, souvent de l'ordre de 10 %, une part importante des inscrits quittant le parcours dès les premières semaines (Jordan, 2015 ; Onah et al., 2014 ; Reich et Ruipérez-

Valiente, 2019). Dans ce modèle, le contenu est principalement diffusé de manière uniforme. Toute forme d'adaptation automatique suppose donc, en amont, de disposer d'une mesure d'engagement plus fine que les simples proxies de présence (connexion, clics), point développé dans la section suivante.

1.3 Engagement de l'apprenant

1.3.1 Définition

Fredricks et al. (2004) définissent l'engagement comme la mobilisation cognitive, comportementale et émotionnelle de l'apprenant vis-à-vis de la tâche. Dans les MOOC, Kizilcec et al. (2013) ainsi que Hew (2016) montrent que cette implication ne se réduit pas à la simple présence en ligne (connexion, clics), mais renvoie à une participation active dans le traitement de l'information.

1.3.2 Dimensions de l'engagement

Le cadre théorique dominant, formulé par Fredricks et al. (2004), distingue trois dimensions complémentaires : une dimension cognitive, une dimension comportementale et une dimension émotionnelle.

La figure 1.1 présente les trois dimensions de l'engagement.

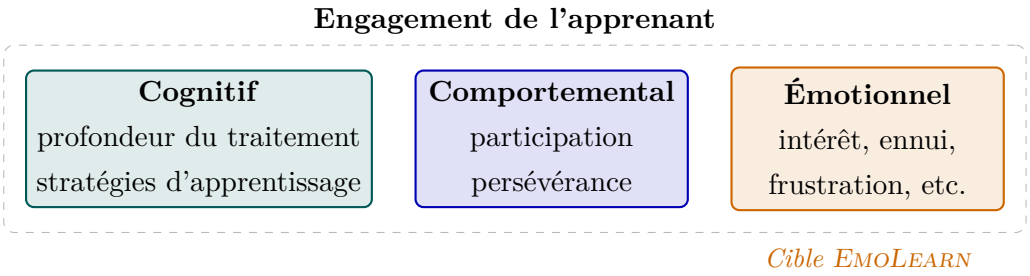


Figure 1.1 – Dimensions de l'engagement.

EmoLearn se concentre principalement sur la dimension émotionnelle, ou affective, tout en visant un effet sur la persévérance globale.

1.3.3 Mesure de l'engagement

Les indicateurs usuels en e-learning (durée de session, progression, scores) fournissent des proxies utiles mais incomplets. Les approches plus récentes mobilisent des signaux multimodaux (visage, voix, posture) pour estimer l'état affectif de manière plus directe (D'Mello, 2013 ; Goldberg et al., 2021 ; Sharma et Giannakos, 2020).

1.4 Informatique affective et émotions en apprentissage

1.4.1 Rôle des émotions dans l'apprentissage

Picard (1997) a posé le cadre de l'informatique affective. En psychologie de l'apprentissage, Pekrun (2006) montre que les émotions de réussite modulent l'attention et la persévérance. D'Mello et Graesser (2012), ainsi que Baker et al. (2010), précisent le rôle de l'ennui, de la confusion et de la frustration dans la profondeur du traitement et la mémorisation (Graesser, 2020 ; Loderer et al., 2020). Les émotions ne sont donc pas périphériques à la cognition, mais constitutives du processus d'apprentissage.

1.4.2 États pertinents pour l'adaptation pédagogique

Il faut distinguer deux emplois du mot engagement. Au sens large, il désigne le construit théorique de la section précédente (mobilisation cognitive, comportementale et émotionnelle). Dans la taxonomie DAiSEE, « Engagement » désigne en revanche un état ponctuel annoté, aux côtés de l'ennui, de la confusion et de la frustration : c'est une étiquette d'observation, et non le concept général. Dans ce mémoire, ces quatre états issus du corpus (Gupta et al., 2016) structurent la taxonomie opérationnelle, chacun annoté sur une échelle d'intensité à quatre niveaux.

La figure 1.2 présente les quatre états d'engagement retenus.

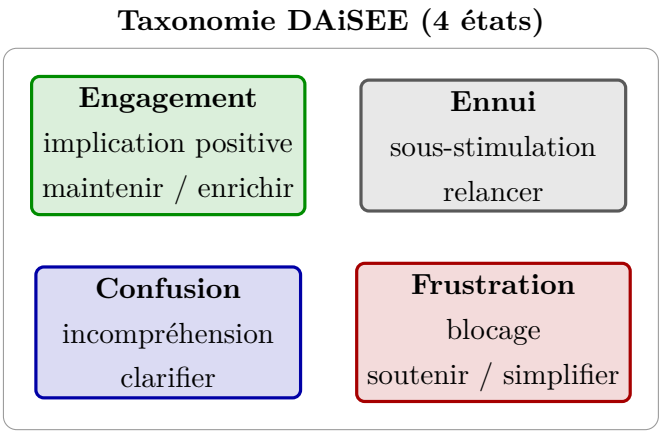


Figure 1.2 – Quatre états d'engagement (DAiSEE).

Chacun de ces états appelle une stratégie pédagogique distincte.

1.4.3 Charge cognitive

Sweller (1988) et Sweller et al. (2019) rappelle qu'un contenu trop dense ou mal séquencé favorise la confusion et l'abandon. Mayer (2021) complète ce cadre par

la théorie de l'apprentissage multimédia : la conception des messages (texte, image, rythme) conditionne la charge utile. L'adaptation du niveau d'explication, du rythme et du type d'exemple constitue dès lors un levier central des systèmes d'apprentissage adaptatifs.

1.5 Détection multimodale de l'engagement

1.5.1 Modalités exploitées

La détection automatique de l'engagement peut s'appuyer sur plusieurs familles de signaux (D'Mello, 2013 ; Sharma et Giannakos, 2020) :

— le visage (expressions faciales, regard) (Gupta et al., 2016 ; Whitehill et al., 2014) ,

— la voix (prosodie, intensité, variations émotionnelles) (Busso et al., 2008) ,

— éventuellement la posture ou des signaux physiologiques (Goldberg et al., 2021).

EmoLearn combine les deux premières modalités, à partir de clips vidéo et audio annotés (hors temps réel), plutôt que de traces textuelles de forums ou de capteurs physiologiques.

La figure 1.3 présente la boucle de détection multimodale.

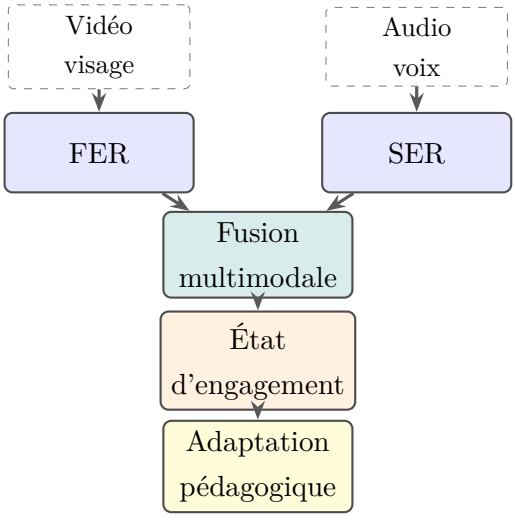


Figure 1.3 – Détection multimodale.

1.5.2 Corpus de référence

Deux corpus publics fondent la chaîne de perception :

— DAiSEE (Gupta et al., 2016) pour l'engagement facial annoté ,

— IEMOCAP (Busso et al., 2008) pour l'émotion vocale et, via un sous-corpus audiovisuel, la validation de la fusion alignée.

Comme ces deux corpus proviennent de populations distinctes, l'alignement des modalités est une contrainte méthodologique assumée, discutée lors de la conception et de la validation.

1.5.3 Fusion multimodale

La fusion vise à combiner des sources hétérogènes pour obtenir une décision plus robuste qu'une modalité seule (Gandhi et al., 2023 ; Liang et al., 2024). Elle soulève toutefois des questions de pondération, de désaccord inter-modalités et de déséquilibre des classes, qui seront traités dans la conception et la validation du système.

1.6 IA générative pour l'éducation

1.6.1 Grands modèles de langue

Les grands modèles de langue (LLM, *Large Language Models*) sont des réseaux entraînés à prédire le token suivant d'une séquence (Brown et al., 2020). Leur architecture repose sur le Transformer (Vaswani et al., 2017) : tokenisation, plongements (embeddings) et attention, puis génération auto-régressive. Ce rappel, volontairement général, sert de socle à la génération pédagogique d'EmoLearn, sans préempter les choix d'implémentation.

La figure 1.4 présente l'architecture d'un grand modèle de langue.

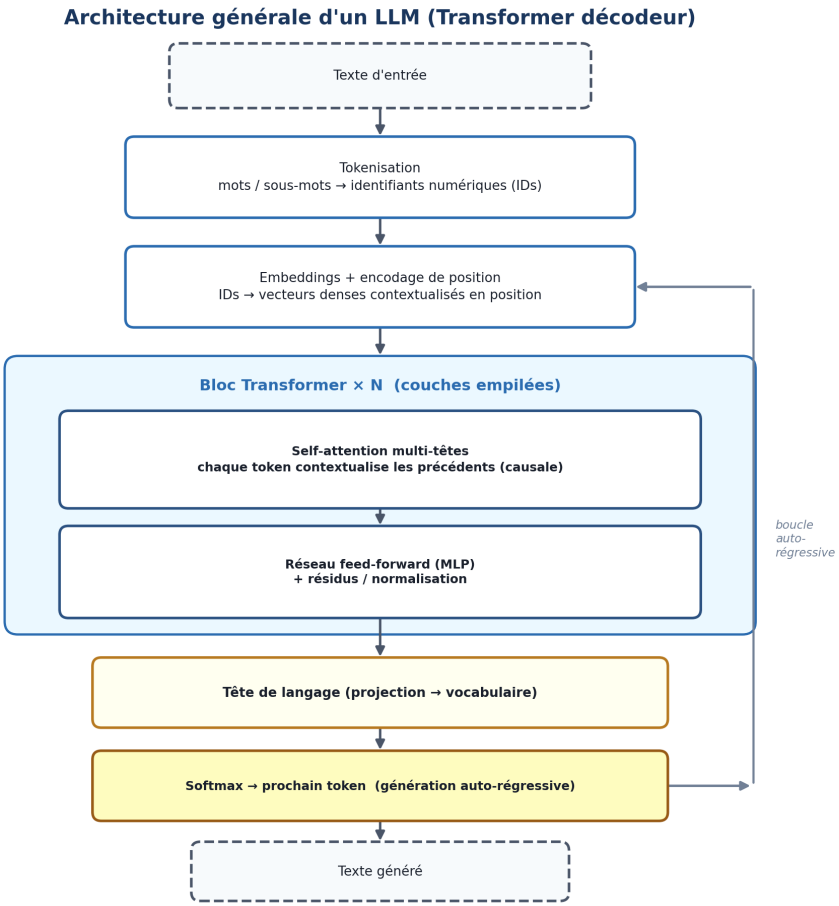


Figure 1.4 – Architecture d'un LLM (Transformer décodeur).

En éducation, Kasneci et al. (2023) et Lo (2023) montrent que ces modèles peuvent produire, à la demande, des explications, reformulations ou encouragements (Wang et al., 2024 ; Yan et al., 2024). Ils offrent ainsi une voie crédible pour personnaliser des contenus pédagogiques à grande échelle.

1.6.2 Guidage par prompts et patrons

Liu et al. (2023a), White et al. (2023) et Wei et al. (2022) soulignent que la qualité du contenu généré dépend fortement du guidage. Une bibliothèque de patrons de prompts structurés permet ainsi de conditionner la génération selon l'état d'engagement détecté et le type d'intervention pédagogique souhaité.

1.6.3 Récupération augmentée (RAG)

Le mécanisme de récupération augmentée (*Retrieval-Augmented Generation*, RAG), introduit par Lewis et al. (2020) et synthétisé par Gao et al. (2023) et Fan et al. (2024), ancre la génération sur des documents de référence indexés dans une base vectorielle. Les documents sont d'abord découpés et vectorisés (indexation hors ligne). À

l'exécution, la requête est à son tour vectorisée puis confrontée à l'index pour récupérer les passages les plus pertinents, ces passages enrichissent le prompt transmis au LLM, qui produit une réponse ancrée. Ce dispositif réduit le risque d'hallucinations factuelles et renforce la cohérence pédagogique des contenus produits.

La figure 1.5 présente l'architecture du RAG.

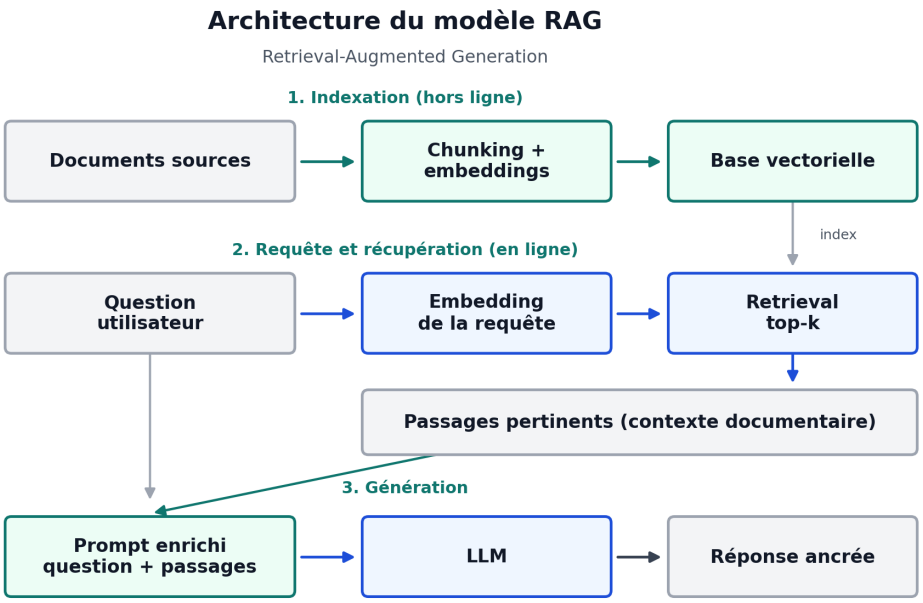


Figure 1.5 – Architecture du RAG.

1.7 Conclusion

Ce chapitre a rappelé le socle conceptuel sur lequel s'appuie EmoLearn : la définition des MOOC et l'enjeu d'adaptation, la centralité de l'engagement émotionnel, les bases de la détection multimodale et le potentiel de l'IA générative guidée et ancrée documentairement. Ces briques étant définies, il devient possible de confronter EmoLearn aux travaux existants, ce à quoi s'attache le chapitre 2.

Chapitre 2

Synthèse de l'état de l'art

Sommaire

2.1 Introduction **13**

2.2 MOOCs et engagement apprenant **13**

2.2.1 Défis de rétention et d'engagement 13

2.2.2 Mesure de l'engagement en e-learning 13

2.2.3 Indicateurs émotionnels et cognitifs 14

2.3 Détection automatique de l'engagement **14**

2.3.1 Approches multimodales 15

2.3.2 Datasets publics d'engagement 17

2.3.3 État de l'art des performances de détection 17

2.4 Psychologie de l'apprentissage et émotions **18**

2.4.1 Impact des émotions sur l'apprentissage 19

2.4.2 Théories de la charge cognitive 19

2.4.3 États d'engagement : ennui, confusion, frustration, flow 19

2.5 IA générative pour l'éducation **20**

2.5.1 LLMs et génération de contenu pédagogique 20

2.5.2 Prompt engineering pour applications éducatives 20

2.5.3 Personnalisation et adaptation automatique 21

2.5.4 Évaluation de la qualité pédagogique 21

2.6 Systèmes adaptatifs d'apprentissage **22**

2.6.1 Intelligent Tutoring Systems (ITS) 22

2.6.2 Stratégies d'adaptation pédagogique 22

2.6.3 Règles et modèles de décision 23

2.7 Synthèse critique et positionnement **23**

2.7.1 Positionnement d'EmoLearn 26

2.8 Conclusion **27**

2.1 Introduction

Le chapitre 1 a fixé le vocabulaire. Il reste à examiner ce que la littérature établit déjà, et ce qu'elle laisse ouvert, lorsqu'il s'agit de réguler un apprenant isolé devant une vidéo de cours.

Deux familles de travaux se croisent sans se rejoindre pleinement. D'un côté, on détecte l'engagement : parfois dans les messages de forum (présence cognitive, émotions épistémiques), parfois sur le visage, la voix ou la posture. De l'autre, on intervient : tuteurs intelligents, règles d'adaptation, puis, depuis peu, texte généré par un grand modèle de langue. Peu de prototypes enchaînent les deux : estimer un état, choisir une stratégie, produire un contenu. C'est cet enchaînement que vise EmoLearn.

Le chapitre s'organise en six sections : MOOC et engagement apprenant, détection automatique, psychologie des émotions, IA générative, systèmes adaptatifs, puis synthèse critique et positionnement. Ce parcours prépare les choix du chapitre 3.

2.2 MOOCs et engagement apprenant

Trois questions structurent cette section : les défis de rétention, la mesure de l'engagement en e-learning, puis les indicateurs émotionnels et cognitifs.

2.2.1 Défis de rétention et d'engagement

Daniel (2012) et Breslow et al. (2013) ont d'abord décrit le MOOC comme un phénomène d'accès ouvert à grande échelle. Les chiffres de rétention sont connus depuis longtemps : une grande partie des inscrits part dans les premières semaines, et le taux moyen d'achèvement stagne près de 10 % (Jordan, 2015 ; Onah et al., 2014 ; Reich et Ruipérez-Valiente, 2019). Onah, Jordan et Reich établissent ce constat. Kizilcec et Hew montrent que le manque de temps n'explique pas à lui seul les départs : la baisse d'engagement y contribue également (Hew, 2016 ; Kizilcec et al., 2013). Le défi de rétention porte donc aussi sur ce que les inscrits vivent pendant le cours, au-delà du calendrier et du volume de travail déclaré.

2.2.2 Mesure de l'engagement en e-learning

L'engagement désigne la mobilisation cognitive, comportementale et émotionnelle de l'apprenant sur une tâche (Fredricks et al., 2004). La définition aujourd'hui la plus partagée distingue trois composantes :

— l'engagement comportemental (participation, persévérance, effort observable) ,

— l'engagement cognitif (profondeur du traitement, stratégies d'apprentissage, présence cognitive) ,
— l'engagement émotionnel (intérêt, ennui, confusion, frustration, sentiment d'affiliation).

En e-learning, on mesure surtout des proxies : connexion, clics, durée de session, progression, notes. Ils sont utiles, mais incomplets : un étudiant peut rester connecté et être déjà ailleurs. Les journaux de plateforme voient le comportement. Les forums donnent un aperçu de la cognition, à condition que l'étudiant écrive. Compter les clics ne suffit donc plus : il faut une mesure plus proche de ce que l'apprenant est en train de vivre (D'Mello, 2013 ; Kizilcec et al., 2013).

2.2.3 Indicateurs émotionnels et cognitifs

L'émotion, pourtant liée à la persévérance (D'Mello et Graesser, 2012 ; Pekrun, 2006), n'apparaît pas dans les logs. EmoLearn s'appuie sur ces indicateurs, dans l'hypothèse qu'une régulation plus précoce agit sur la suite du parcours. L'étude de Liu *et al.* sur le forum d'*Introduction to Psychology* (8 867 inscrits) va dans ce sens : émotion et cognition bougent ensemble, et prédisent mieux la réussite lorsqu'on les lit conjointement (Liu et al., 2022). Un seul score d'« engagement » efface ces nuances.

Dès que l'on dispose de texte, la revue de Sakeef *et al.* montre que trois grilles reviennent pour coder l'engagement cognitif des forums (Sakeef et al., 2025). La plus citée est le modèle de Community of Inquiry (Garrison et al., 1999) : présence sociale, enseignante et cognitive, cette dernière en quatre phases (déclenchement, exploration, intégration, résolution). Hu *et al.* et Liu *et al.* s'en servent pour entraîner des classifieurs (Hu et al., 2021 ; Liu et al., 2023b). ICAP, proposé par Chi et Wylie, classe plutôt le mode d'activité : passif, actif, constructif, interactif (Chi et Wylie, 2014). Plus on construit ou on interagit, plus le traitement est censé être profond.

Ces indicateurs cognitifs aident à relire un fil de discussion après coup. Ils disent peu d'un visionnage sans contribution écrite. Dans ce cas, les indicateurs émotionnels visibles, taxonomie DAiSEE : engagement, ennui, confusion, frustration sont plus directs : un état, un besoin pédagogique (Gupta et al., 2016).

2.3 Détection automatique de l'engagement

On ne peut pas demander à un enseignant de coder des milliers de messages, ni d'observer chaque visage. D'où l'intérêt d'un estimateur automatique. Cette section examine trois axes : les approches multimodales (visuelle, comportementale, physiologique), les corpus publics (DAiSEE, EmotiW, et les ressources complémentaires), puis les performances rapportées dans la littérature. Les scores d'EmoLearn lui-même (FER+AU,

WavLM, fusion) sont ceux du chapitre 5, ils ne constituent pas un palmarès de l'état de l'art.

2.3.1 Approches multimodales

D'Mello, dans sa méta-analyse, insiste sur un point pratique : ennui, confusion, frustration et engagement reviennent souvent, et mélanger les modalités aide, à condition de calibrer (D'Mello, 2013). Trois familles de signaux structurent cet axe.

Voie visuelle : En l'absence de production écrite, le signal disponible est celui que l'on peut filmer. Whitehill *et al.* ont montré, dès 2014, qu'un classifieur de visage peut approcher le jugement humain sur l'engagement (Whitehill et al., 2014). Depuis, les réseaux profonds et les Transformers ont relevé le niveau (Dosovitskiy et al., 2021 ; Li et Deng, 2022). En classe, d'autres travaux suivent le regard ou le décrochage attentionnel (Goldberg et al., 2021 ; Hutt et al., 2021). Sur DAiSEE, plusieurs architectures hybrides spatio-temporelles ont été testées (Abedi et Khan, 2021 ; Gupta et al., 2023).

Xiong, Guo et Xu proposent un CNN-Transformer qui combine l'information fine des expressions faciales (CNN) et l'information plus grossière de la posture (Transformer), en réduisant l'encombrement visuel du fond (Xiong et al., 2024). Sur un jeu de données de classe réelle, annoté par crowdsourcing puis validation experte, le modèle atteint 92,9 % d'accuracy et surpasse plusieurs architectures de deep learning. Ce travail est le plus proche d'EmoLearn du point de vue du signal (vision en situation d'apprentissage). Il s'en distingue toutefois sur deux points décisifs : il ne fusionne pas la voix, et il ne relie pas la détection à une génération de contenu. L'identification s'arrête au diagnostic.

Côté voix : souvent traitée à part, mais bien une modalité perceptive, le passage des descripteurs acoustiques classiques aux représentations auto-supervisées (WavLM), évaluées notamment via le benchmark SUPERB, a transformé la reconnaissance d'émotions vocales (Chen et al., 2022 ; Latif et al., 2023 ; Pepino et al., 2021 ; Yang et al., 2021). Le fine-tuning de ces encodeurs (Chen et Rudnicky, 2023) et les architectures Transformer réduisent notamment l'écart de performance sur la valence, longtemps le point faible du SER (Wagner et al., 2023). Ces avancées justifient le choix actuel d'EmoLearn : un encodeur WavLM fine-tuné vers les quatre états DAiSEE, complété par une ancre émotionnelle IEMOCAP, plutôt que des seuils acoustiques ou un simple mapping émotion → engagement. Côté visage, le runtime retient un Random Forest FER+AU (sept scores d'un ViT pré-entraîné, plus Action Units) comme juge produit, un ViT fine-tuné vers les quatre états filtre les images peu confiantes et sert de mode dégradé, sans choisir l'état transmis à la fusion.

Voie comportementale : On rassemble ici les traces d'activité : clics, durée de session, progression dans un MOOC, souris, posture, et le texte laissé sur un forum. Kizilcec et al. montrent que ces proxies séparent des sous-populations d'inscrits, sans dire ce que l'étudiant est en train de vivre (Kizilcec et al., 2013). La posture, chez Xiong, est déjà un signal comportemental filmé (Xiong et al., 2024). Dans les MOOC, le matériau comportemental le plus riche reste le texte des forums.

Sakeef *et al.* proposent une revue des cadres (CoI, ICAP, KCSA) et des méthodes de TALN / apprentissage profond utilisées pour détecter l'engagement cognitif dans ces messages (Sakeef et al., 2025). Ils soulignent que l'annotation manuelle est trop coûteuse pour un suivi en continu, et que l'automatisation devient indispensable. Ils rappellent aussi une limite structurelle : l'absence d'indices visuels et auditifs dans le texte rend l'inférence de l'état interne partielle. Cette limite motive, pour EmoLearn, le recours aux modalités visage et voix (corpus annotés) plutôt qu'au seul forum.

Hu, Ferreira Mello et Gašević comparent un CNN à des Random Forests fondés sur des traits linguistiques pour classer la présence cognitive selon le CoI (Hu et al., 2021). Le CNN atteint un κ de Cohen de 0,528, comparable aux approches classiques, avec une généralisabilité inter-cours similaire. L'apport principal est l'explicabilité (XAI) au niveau des mots. Le travail reste une tâche de catégorisation de messages, sans lien avec une intervention pédagogique automatique.

Liu *et al.* (2022) introduisent BERT-CNN pour détecter conjointement l'engagement émotionnel et cognitif dans le forum du MOOC *Introduction to Psychology* (Liu et al., 2022). Par rapport aux modèles antérieurs, le F1 s'améliore d'environ 10 % (émotion) et 8 % (cognition). Méthodologiquement, le papier établit qu'un détecteur robuste est un prérequis à toute régulation, opérationnellement, il s'arrête à la prédiction de la réussite, sans générer de contenu adaptatif.

MOOC-BERT pousse plus loin le pré-entraînement : le modèle est pré-entraîné sur le MOOC-Corpus (icourse163.org : 800 cours, cinq disciplines, 3,76 Go), puis fine-tuné pour identifier la présence cognitive (Liu et al., 2023b). Il surpasse les algorithmes représentatifs, y compris en généralisation inter-cours. La boucle s'arrête à l'aide à l'enseignant : fournir un diagnostic, non produire l'intervention.

Liu *et al.* (2021) articulent analyse de réseaux sociaux et analyse de réseaux épistémiques sur 3 925 participants d'un forum MOOC (Liu et al., 2021). Les groupes à haute et basse réussite diffèrent en centralité, les connexions cognitives sont plus fortes chez les apprenants performants. Ce résultat concerne une dynamique collective (forum), distincte du scénario individuel visé par EmoLearn.

Voie physiologique : Une troisième famille EEG, réponse électrodermale, rythme cardiaque, parfois ECG existe surtout en laboratoire (Abedi et Khan, 2021 ; D'Mello,

2013 ; Picard, 1997). Elle sort du périmètre d'EmoLearn : le scénario visé est une vidéo de cours, avec webcam et microphone, sans capteur médical.

2.3.2 Datasets publics d'engagement

Les corpus visuels publics d'engagement restent rares. On en retient ici ce qui structure la détection.

DAiSEE fournit des vidéos d'apprenants annotées en quatre états (engagement, ennui, confusion, frustration), chacun sur une intensité de 0 à 3, en conditions naturelles (« dans la nature ») (Gupta et al., 2016). La classe Engagement y domine largement, ce qui rend l'exactitude globale insuffisante comme seule métrique. C'est la taxonomie retenue par EmoLearn, parce que chaque état appelle une réponse pédagogique distincte.

Le défi EmotiW propose aussi des pistes « dans la nature », dont une tâche d'engagement étudiant (Dhall et al., 2018). Les étiquettes y sont surtout des niveaux d'engagement, pas les quatre états pédagogiques de DAiSEE. Les scores des éditions successives ne se lisent donc pas comme un classement sur le même problème.

IEMOCAP offre un signal vocal riche et, dans sa version audiovisuelle, un cadre où visage et voix proviennent du même locuteur (Busso et al., 2008). Les étiquettes y décrivent l'émotion dyadique, et non l'engagement d'un apprenant en MOOC. EmoLearn s'appuie explicitement sur ces deux ressources complémentaires : DAiSEE pour la taxonomie d'engagement facial, IEMOCAP pour l'émotion vocale.

D'autres jeux restent propriétaires : Whitehill *et al.* annotent leurs propres vidéos d'étudiants (Whitehill et al., 2014), Xiong *et al.* collectent des images de classe faute de dataset ouvert alliant visage et posture (Xiong et al., 2024). Les travaux sur forums (icourse163.org, bancs CoI) et les essais PAGE ou Kong n'offrent pas un dataset public d'engagement visuel.

2.3.3 État de l'art des performances de détection

Comparer un κ sur du texte CoI, une accuracy sur quatre niveaux DAiSEE et 92,9 % sur un corpus de classe privé n'a de sens que si l'on rappelle que la tâche n'est pas la même. Le tableau 2.1 présente les chiffres effectivement rapportés par les articles déjà discutés. Il ne prétend pas couronner un vainqueur unique.

Référence	**Tâche / signal**	**Corpus**	Résultat clé
Whitehill et al. (2014)	Visage, 4 niveaux d'engagement	Corpus propre (non public)	Accord proche des annotateurs humains, Gupta et al. (2016) rappellent ≈ 69 % pour SVM + Gabor
Gupta et al. (2016)	Vidéo, 4 niveaux d'engagement	DAiSEE (public)	Baselines des auteurs : InceptionNet 46,4 %, C3D 56,1 %, LRCN 57,9 %
Abedi et Khan (2021)	Vidéo spatio-temporelle, 4 niveaux	DAiSEE	ResNet+TCN : 63,9 % d'accuracy (mieux que les baselines DAiSEE et plusieurs hybrides)
Xiong et al. (2024)	Visage + posture, 4 niveaux	Images de classe (propre)	Accuracy 92,9 %, pas de voix, corpus non public
Hu et al. (2021)	Texte, phases CoI	Deux cours annotés	κ de Cohen = 0,528 (CNN ≈ Random Forests)
Liu et al. (2022)	Forum, émotion + cognition	icourse163.org ($n = 8\,867$)	F1 +10 % (émotion) et +8 % (cognition) vs modèles antérieurs
EmotiW (Dhall et al., 2018)	Engagement « dans la nature »	Pistes du défi (public)	Scores d'édition en édition, niveaux d'engagement, non comparables à la taxonomie DAiSEE

Table 2.1 – Performances de détection rapportées.

Deux lectures s'imposent. Premièrement, sur DAiSEE, même les meilleures architectures citées ici restent dans une fourchette d'accuracy modérée (57,9 % à 63,9 % pour quatre niveaux d'engagement), parce que la classe haute domine : un classifieur naïf « toujours engagé » paraît déjà fort. C'est pourquoi EmoLearn retient, au chapitre 5, le F1 macro et le rappel des états urgents plutôt que l'accuracy seule. Deuxièmement, un score élevé sur un corpus privé (Xiong) ou un κ sur du CoI ne se substitue pas à une évaluation visage–voix vers les quatre états DAiSEE.

Identifier un état ne suffit pas à justifier son importance pédagogique, ni à en déduire une intervention. La section suivante rappelle les fondements psychologiques, les deux suivantes traitent de la génération et des systèmes adaptatifs.

2.4 Psychologie de l'apprentissage et émotions

Les cadres sur les MOOC et l'engagement indiquent quoi mesurer. Ils disent moins *pourquoi* un état change la suite du parcours. Trois points sont examinés : l'impact des émotions, les théories de la charge cognitive, puis les états d'engagement (ennui, confusion, frustration, flow).

2.4.1 Impact des émotions sur l'apprentissage

Picard et Pekrun ont, chacun de leur côté, rappelé que l'émotion n'est pas un bruit autour de la cognition : elle oriente l'attention et la persévérance (Pekrun, 2006 ; Picard, 1997). Les revues récentes sur les environnements technologiques aboutissent au même constat (Graesser, 2020 ; Loderer et al., 2020). Une émotion n'est donc pas un à-côté du cours : elle décide, en partie, si l'étudiant reste ou part.

2.4.2 Théories de la charge cognitive

Sweller décrit le couple sous l'angle de la charge : trop de matière à la fois, et l'étudiant se perd (surcharge, confusion), trop peu, et il décroche (sous-stimulation, ennui) (Sweller, 1988 ; Sweller et al., 2019). Les développements ultérieurs distinguent charge intrinsèque (difficulté de la matière), charge extrinsèque (présentation maladroite) et charge germane (effort utile). Mayer, pour le multimédia, montre que le rythme, le texte et l'image pèsent sur cette charge utile (Mayer, 2021). Un parcours unique, calé sur un « étudiant moyen », rate ces bascules : c'est précisément ce qu'une adaptation par état cherche à éviter.

2.4.3 États d'engagement : ennui, confusion, frustration, flow

Quatre états, issus de DAiSEE, structurent la suite du mémoire (Gupta et al., 2016) :

— L'engagement : implication positive, traitement en cours. on maintient ou on enrichit.

— L'ennui : sous-stimulation, amorce de retrait, on relance.

— La confusion : incompréhension encore active, on clarifie.

— La frustration : blocage, on soutient et on simplifie.

Chacun est annoté sur une intensité de 0 à 3. Distinguer ces états n'est pas un luxe de taxonomie : chacun appelle une réponse différente.

Le flow de Csikszentmihalyi désigne le pôle productif : un engagement soutenu quand le défi et les compétences s'équilibrent (Csikszentmihalyi, 1990). DAiSEE ne l'annote pas à part, l'état Engagement en est le proxy opératoire. On retient donc le flow comme cadre théorique, et les quatre labels DAiSEE comme taxonomie de détection.

D'Mello et Graesser suivent une séquence souvent observée en EIAH (environnements informatiques pour l'apprentissage humain) : la confusion, si elle se résout, aide (et peut ramener vers le flow), si elle s'enlise, elle glisse vers la frustration, puis vers l'ennui (D'Mello et Graesser, 2012). Baker *et al.* en concluent que la frustration reste préférable à l'ennui, car la première suppose un effort, le second un retrait (Baker et al., 2010). Cette réserve de contexte compte : l'observation a été formulée dans des

tuteurs intelligents, plutôt que lors d'un visionnage isolé de cours en ligne. Elle indique qu'un désengagement sans expression est, pédagogiquement, plus grave qu'un blocage encore actif.

2.5 IA générative pour l'éducation

Les tuteurs intelligents adaptent souvent un contenu déjà écrit. Les grands modèles de langue rendent possible de le produire à la demande. Quatre axes sont examinés : génération pédagogique, ingénierie de prompts, personnalisation, puis évaluation de la qualité.

2.5.1 LLMs et génération de contenu pédagogique

Depuis GPT-3 et les modèles de la famille Llama, un grand modèle de langue peut rédiger une explication, une analogie, un exercice ou un encouragement en quelques secondes (Brown et al., 2020 ; Touvron et al., 2023). Kasneci et al. (2023) ont très tôt listé ce que cela change pour l'école : personnalisation possible, mais aussi erreurs factuelles, biais, et décisions difficiles à retracer. Les revues qui ont suivi (Lo, Yan, Bond, entre autres) ne contredisent pas ce constat (Bond et al., 2024 ; Lo, 2023 ; Yan et al., 2024). Laissé libre, le modèle écrit « comme un cours » sans garantir que le cours soit juste.

Un garde-fou fréquent, distinct du prompt, est le RAG : on récupère d'abord des extraits d'une base documentaire, puis on les fournit au modèle (Lewis et al., 2020). C'est ce mécanisme qu'EmoLearn retient pour coller le texte généré à des fiches de cours, plutôt que de le laisser inventer une définition. Le LLM n'est donc pas, ici, un enseignant autonome : c'est un rédacteur conditionné par une décision déjà prise et par des documents vérifiés.

2.5.2 Prompt engineering pour applications éducatives

La qualité du texte dépend fortement du guidage : rôle, format, longueur, exemples (Liu et al., 2023a ; Wei et al., 2022 ; White et al., 2023). En éducation, un prompt trop vague produit un cours générique, un prompt trop serré peut brider l'utilité. Les patrons structurés permettent de conditionner la génération selon l'état visé et le type d'intervention (clarifier, exemplifier, exercer, soutenir).

Liu *et al.* (2025) poussent le prompt dans une autre direction : non pour écrire un cours, mais pour étiqueter un message (comportement, émotion, cognition) (Liu et al., 2025). Leur méthode AGKA ajoute au prompt les définitions du guide d'annotation et quelques exemples. GPT-4 et Llama 3 70B s'en sortent alors aussi bien que BERT sur

des tâches binaires, dès que les classes se ressemblent (émotions épistémiques, phases CoI), l'écart se creuse. On en retient surtout ceci : un LLM guidé peut aider à classer du texte, il ne remplace pas un détecteur visage–voix. EmoLearn fait l'inverse : le modèle n'étiquette pas l'état, il rédige le contenu après que la couche de perception a décidé, via une bibliothèque de vingt patrons.

2.5.3 Personnalisation et adaptation automatique

Hu et Shao proposent PAGE (*Psychologically-Aware Generative Education*), un système GenAI qui adapte le style, la difficulté et les mécanismes de soutien au profil Big Five et au feedback émotionnel en temps réel (Hu et Shao, 2025). Sur 200 étudiants, PAGE améliore la satisfaction émotionnelle (4,4/5 contre 3,6/5), le taux de complétion des tâches (87,6 % contre 72,3 %) et la durée d'étude (+34 %) par rapport à un système adaptatif classique, le bénéfice est particulièrement marqué pour les étudiants à neuroticisme élevé (baisse de 48 % du décrochage). PAGE est le travail le plus proche d'EmoLearn du point de vue de la génération : il relie un signal affectif à un contenu produit par LLM. L'écart se joue sur le quand et le comment. PAGE s'appuie sur un profil Big Five (assez stable) et sur un retour émotionnel souvent déclaré. Le présent travail vise l'état de ce clip : confusion maintenant, ennui après trois minutes. PAGE ne décrit pas non plus un moteur de règles nommé, ni un RAG sur fiches de cours : le style change, mais on ne peut pas retracer « tel état → tel patron ».

Kong *et al.* évaluent un autre mode d'adaptation : un outil de représentation des discussions assisté par IA (représentations comportementales, cognitives, ou mixtes) auprès de 122 étudiants (Kong et al., 2025). L'outil n'améliore pas significativement la motivation, mais augmente la présence cognitive de haut niveau et la performance. Il s'agit d'une médiation sur le forum, non d'une génération de contenu de cours conditionnée par l'état d'un apprenant isolé. Le résultat confirme qu'une personnalisation IA peut élever le niveau cognitif, à condition d'en changer le canal (vidéo de cours plutôt que fil de discussion).

2.5.4 Évaluation de la qualité pédagogique

La qualité du contenu généré se juge sur des critères humains (pertinence, clarté, adéquation à l'état) complétés par des métriques automatiques de forme (longueur, lisibilité, respect du patron). Aucune métrique automatique ne se substitue à une validation experte ou utilisateur (Hu et Shao, 2025 ; Kasneci et al., 2023). Les travaux de détection rapportent surtout des F1 et des κ, les travaux génératifs rapportent des scores de satisfaction. Un protocole multi-niveaux (perception, décision, génération) reste rare. C'est l'un des choix méthodologiques d'EmoLearn.

2.6 Systèmes adaptatifs d'apprentissage

Identifier un état ne suffit pas à en déduire une intervention. Les tuteurs intelligents en sont le précédent le plus net : un modèle de l'apprenant, une stratégie, un contenu. Trois étages sont distingués ici : ce que sont les ITS, quelles stratégies pédagogiques ils mobilisent, puis comment la décision est formalisée (règles et modèles).

2.6.1 Intelligent Tutoring Systems (ITS)

Les systèmes de tutorat intelligent (ITS) combinent historiquement un modèle de l'apprenant, un modèle pédagogique et une interface adaptative (VanLehn, 2011). VanLehn montre que les meilleurs ITS approchent l'efficacité d'un tuteur humain, à condition que le domaine soit bien modélisé (VanLehn, 2011). Le contenu est le plus souvent pré-écrit : chaque rétroaction a été rédigée à l'avance pour un état de connaissances prévu.

Deux familles d'exemples illustrent ce schéma sans en changer la logique. Les tuteurs cognitifs, dont la revue de VanLehn rend compte, adaptent surtout la prochaine étape d'un parcours : l'item suivant, un indice, une remédiation calée sur ce que l'apprenant maîtrise encore mal. Les tuteurs affectifs, dont AutoTutor et les dynamiques décrites par D'Mello et Graesser sont les références les plus citées, observent aussi la confusion ou la frustration pendant le dialogue, puis ajustent l'étayage (D'Mello et Graesser, 2012 ; Graesser, 2020). Dans les deux cas, l'intervention reste choisie dans un répertoire d'auteurs, pas rédigée à la demande.

Leur limite, dans un MOOC aux contenus ouverts et aux états affectifs fluctuants, est double. D'une part, on ne peut pas pré-écrire un texte pour chaque combinaison d'état et de concept. D'autre part, le modèle de l'apprenant est surtout cognitif (ce qu'il sait), rarement émotionnel (s'il s'ennuie ou s'il est bloqué), même si des travaux récents visent une explication personnalisée des décisions de tuteurs (Conati et al., 2021). C'est cette limite que les modèles de langue visent à lever : générer le contenu, tout en gardant une décision lisible.

2.6.2 Stratégies d'adaptation pédagogique

Les stratégies d'adaptation classiques ne portent pas sur quel algorithme détecte l'état, mais sur l'action à entreprendre une fois l'état connu. On distingue notamment la simplification (réduire la charge, Sweller), l'enrichissement (approfondir lorsque l'apprenant est déjà engagé), la remédiation (revenir sur un point mal compris) et l'encouragement (soutenir un effort qui s'enlise) (Sweller, 1988 ; VanLehn, 2011).

Ces familles se recoupent avec les quatre états DAiSEE : la confusion appelle plutôt

une clarification, la frustration un soutien et une simplification, l'ennui une relance, l'engagement un maintien ou un enrichissement. PAGE adapte plutôt le style et la difficulté à un profil de personnalité (Hu et Shao, 2025), les ITS adaptent surtout la prochaine étape d'un parcours cognitif. Dans les deux cas, une stratégie sans contenu à produire (ou sans règle pour la choisir) reste un principe, pas un système.

2.6.3 Règles et modèles de décision

Deux grandes manières de décider coexistent. Les modèles cognitifs (traçage bayésien des connaissances, théorie des espaces de connaissances) estiment ce que l'apprenant maîtrise, puis sélectionnent un item (VanLehn, 2011). Les règles explicites relient un état observé à une action nommée, au prix d'une rigidité, mais avec une traçabilité que Conati *et al.* jugent utile pour expliquer un tuteur (Conati et al., 2021).

EmoLearn se place délibérément du côté des règles. Une matrice *état* → *type de contenu* (explication, exemple, exercice, encouragement) fixe le quoi, des règles temporelles sur les séquences de clips fixent le quand (un épisode isolé n'a pas le même poids qu'une frustration qui dure). Le moteur reste interprétable : chaque adaptation doit être justifiable par l'état détecté, la stratégie retenue et le patron mobilisé. Le détail de cette matrice appartient au chapitre 3, l'état de l'art retient surtout le principe : sans règle nommée, la génération n'est plus une décision pédagogique, c'est une improvisation.

2.7 Synthèse critique et positionnement

Cette section clôt l'état de l'art par une lecture critique des travaux (ce qu'ils établissent, ce qu'ils laissent ouvert), puis par le positionnement d'EmoLearn. Le tableau 2.2 en est l'instrument : référence, approche / modèle, contexte, forces, limites, résultats clés. Ce tableau compare des méthodes. Il se lit par blocs (cadres et corpus, puis détection, ITS et génération), plutôt que comme un classement unique.

Le tableau 2.2 présente la synthèse critique des travaux retenus.

Référence	**Approche / modèle**	**Contexte**	**Forces**	Limites	Résultats clés
Cadres théoriques, enjeux MOOC et corpus					
Kizilcec et al. (2013), Hew (2016)	Clustering de trajectoires, études de cas	Engagement dans les MOOC	Identification de sous-populations et de leviers	Proxies comportementaux (clics, progression)	L'engagement explique une part majeure du décrochage
Fredricks et al. (2004)	Synthèse conceptuelle	Psychologie de l'éducation	Trois dimensions (comportement, cognition, émotion)	Pas d'estimateur automatique	Cadre de référence encore dominant

Référence	**Approche / modèle**	**Contexte**	**Forces**	Limites	Résultats clés
Garrison et al. (1999)	Community of Inquiry (CoI)	Discussions en ligne	Quatre phases de présence cognitive	Conçu pour les forums, pas pour la vidéo	Schéma d'annotation largement repris
Chi et Wylie (2014)	Taxonomie ICAP	Engagement cognitif	Lien mode d'activité → apprentissage	Codage d'activités, pas d'affect facial/vocal	Plus l'activité est constructive, plus le traitement est profond
Picard (1997)	Informatique affective	Reconnaissance d'émotions	Fondement théorique de la détection	Socle, sans pipeline pédagogique	L'affect est mesurable et actionnable
Pekrun (2006)	Théorie contrôle–valeur	Émotions d'accomplissement	Lien valence / activation / performance	Pas d'opérationnalisation logicielle	Les émotions modulent attention et persévérance
D'Mello et Graesser (2012), Baker et al. (2010)	Dynamique d'états affectifs	Apprentissage complexe médiatisé	Séquence confusion–frustration–ennui	Pas de génération de contenu	Mieux vaut être frustré qu'ennuyé
D'Mello (2013)	Méta-analyse	États affectifs en EIAH	Incidence relative des états, fusion multimodale	Synthèse, pas de système	Ennui, confusion, engagement et frustration sont les états clés
Sweller (1988)	Théorie de la charge cognitive	Conception pédagogique	Explique surcharge et sous-stimulation	Théorie, sans détecteur	Ajuster la complexité au profil de l'apprenant
DAiSEE (Gupta et al., 2016)	Corpus vidéo annoté	Engagement « dans la nature »	Quatre états, intensité 0–3	Fort déséquilibre de classes	Taxonomie opératoire pour la détection faciale
EmotiW (Dhall et al., 2018)	Défi d'affect « dans la nature »	Engagement étudiant, vidéo	Conditions peu contrôlées, piste engagement	Niveaux d'engagement, pas les 4 états DAiSEE	Référence de challenge, non retenue comme taxonomie
IEMOCAP (Busso et al., 2008)	Corpus audiovisuel	Émotion conversationnelle	Voix riche, visage et voix alignés	Taxonomie émotionnelle, pas d'engagement MOOC	Référence SER, cadre de fusion alignée
Détection de l'engagement, ITS et génération adaptative					
Sakeef et al. (2025)	Revue CoI / ICAP / KCSA + TALN	Forums de cours en ligne	Cartographie des cadres et des méthodes IA	Texte seul, pas de webcam/micro	L'automatisation du codage est indispensable au suivi continu
Hu et al. (2021)	CNN + XAI	Présence cognitive (CoI)	Explicabilité au niveau des mots	Texte seul, généralisabilité limitée	κ de Cohen = 0,528, comparable aux Random Forests
Liu et al. (2021)	SNA + ENA	Forum MOOC (3 925 apprenants)	Lien réseau social / traitement cognitif / réussite	Analyse collective, hors temps réel	Centralité et connexions cognitives plus fortes chez les performants

Référence	**Approche / modèle**	**Contexte**	**Forces**	Limites	Résultats clés
Liu et al. (2022)	BERT-CNN	Forums MOOC (8 867 apprenants)	Détection conjointe émotion + cognition	Pas d'intervention générée	F1 +10 % (émotion) et +8 % (cognition), effet combiné sur la réussite
Liu et al. (2023b)	MOOC-BERT (pré-entraînement multi-cours)	Présence cognitive dans les MOOC	Généralisation inter-cours, sans ingénierie de traits	Diagnostic enseignant, sans contenu adaptatif	Surpasse ML et DL représentatifs, analyse longitudinale des phases
Liu et al. (2025)	LLM + AGKA (guides d'annotation)	Classification d'engagement textuel	GPT-4 / Llama 3 rivalisent avec BERT en binaire	LLM comme détecteur, pas comme générateur ancré	Retrait sur les taxonomies multi-classes sémantiquement proches
Whitehill et al. (2014)	Classifieur d'expressions faciales	Engagement en classe / e-learning	Fiabilité comparable à l'annotation humaine	Pas de voix, pas de génération	L'engagement facial est mesurable automatiquement
Xiong et al. (2024)	CNN-Transformer (visage + posture)	Classe réelle annotée	Combine grain fin (visage) et grain large (posture)	Pas de voix, pas de boucle pédagogique	Accuracy 92,9 %, supérieure aux baselines DL
Baevski et al. (2020)	wav2vec 2.0	Représentations de parole	Encodeur auto-supervisé réutilisable (SER)	Générique, pas d'engagement pédagogique	Socle de fine-tuning vocal largement adopté
Chen et al. (2022)	WavLM	Parole auto-supervisée	Représentations plus riches que wav2vec 2.0 (benchmark SUPERB)	Pas d'engagement pédagogique natif	Encodeur retenu par EmoLearn pour le SER
VanLehn (2011)	ITS, contenu pré-écrit	Tutorat cognitif	Efficacité proche d'un tuteur humain	Peu d'affect, contenu figé	Les meilleurs ITS approchent le tutorat humain
Brown et al. (2020), Touvron et al. (2023)	LLM (GPT-3, Llama)	Génération de texte	Production à la demande, few-shot	Hallucinations, pas d'état d'engagement	Faisabilité d'un contenu pédagogique généré
Kasneci et al. (2023)	Revue LLM pour l'éducation	Enseignement et apprentissage	Cartographie opportunités / risques	Pas de prototype multimodal	Fiabilité, biais et traçabilité restent ouverts
Lewis et al. (2020)	RAG (index + générateur)	Tâches NLP intensives en connaissances	Ancrage documentaire, moins d'hallucinations	Non couplé à l'engagement	Le contexte récupéré conditionne la génération
Kong et al. (2025)	Outil de représentation IA	Apprentissage collaboratif en ligne ($n = 122$)	Hausse de la présence cognitive de haut niveau	Canal forum, pas de contenu de cours	Performance améliorée, motivation non significativement accrue
Hu et Shao (2025)	GenAI PAGE (Big Five + émotion)	Contenu pédagogique personnalisé ($n = 200$)	Adaptation du style, de la difficulté et du soutien	Pas de fusion visage–voix, ni RAG, ni règles explicites	Satisfaction 4,4/5 vs 3,6, complétion 87,6 % vs 72,3 %

Table 2.2 – Synthèse critique de l'état de l'art.

Aucun des travaux du tableau ne ferme à lui seul la boucle qui intéresse ce mémoire.

Lecture critique : cinq lacunes

Cinq limites se recoupent.

1. **Signal :** Les détecteurs récents lisent surtout des forums (Liu et al., 2022 ; Liu et al., 2023b). Ils laissent de côté l'apprenant qui visionne sans poster.
2. **Décision :** Quand une intervention apparaît, elle règle le style d'un LLM (PAGE) ou rend visible un forum (Kong), rarement une règle nommée « état → type de contenu ».
3. **Génération :** Le RAG ancre des faits (Lewis et al., 2020) sans connaître l'ennui ou la confusion du moment, la génération conditionnée par un état facial et vocal reste rare.
4. **Évaluation :** On mesure soit un F1, soit une satisfaction : presque jamais perception, décision et texte généré sur le même banc.
5. **Modalités :** Les approches visuelles (Whitehill et al., 2014 ; Xiong et al., 2024) estiment l'engagement sur le visage, sans intégrer, le plus souvent, le signal vocal.

2.7.1 Positionnement d'EmoLearn

Le positionnement d'EmoLearn répond à ces cinq lacunes. L'objet du mémoire est une chaîne unique : percevoir un état à partir du visage et de la voix, décider explicitement s'il faut intervenir et avec quel type de contenu, puis produire un texte ancré documentairement (chapitre 3). Cette chaîne vise l'apprenant qui visionne une vidéo sans contribution écrite, le signal exploité est donc facial et vocal.

Par rapport aux détecteurs textuels (BERT-CNN, MOOC-BERT, AGKA), le changement porte sur le canal, et non sur une amélioration de F1. Par rapport aux classifieurs visuels (Whitehill et al., 2014 ; Xiong et al., 2024), trois maillons supplémentaires sont introduits : une voie vocale, une fusion dont le désaccord reste lisible, et une décision qui déclenche une génération. Les ITS de VanLehn (2011) montrent qu'une médiation peut approcher le tutorat humain, avec toutefois un contenu figé et une prise en compte limitée de l'affect. Dans EmoLearn, l'état détecté conditionne un contenu produit à la demande. PAGE (Hu et Shao, 2025) adapte style et difficulté à partir d'un profil et d'une émotion, sans fusion visage–voix ni règle nommée. Kong et al. (2025) améliore la présence cognitive sur un forum, et non le contenu de cours. Le mémoire se situe entre ces deux familles, avec vingt patrons A1–D5, une cascade inspectable « état → type », un RAG puis un LLM.

Ces choix s'accompagnent de limites, énoncées avant la conception. La chaîne est éprouvée en simulation sur corpus, et non déployée dans un MOOC réel. En production, le visage DAiSEE et la voix IEMOCAP ne proviennent pas du même locuteur, seul un sous-ensemble aligné sert à mesurer la fusion. Le mapping émotion → engagement constitue une hypothèse de construit, distincte d'une équivalence psychologique. L'évaluation du chapitre 5 porte sur la perception, la décision et le texte généré, sans étude longitudinale d'apprenants.

La contribution consiste à relier l'informatique affective, les tuteurs intelligents et les LLM ancrés sur le cas d'un visionnage individuel, de manière assez explicite pour reconstruire chaque étape.

2.8 Conclusion

La littérature documente un décrochage massif des MOOC, dans lequel l'engagement occupe une place centrale. Les cadres CoI et ICAP éclairent l'analyse des forums, ils s'appliquent peu à un visionnage sans message. Pekrun, D'Mello et Sweller relient émotion et charge cognitive à la suite du parcours, Baker précise que cette observation provient surtout de tuteurs intelligents. Les détecteurs de texte (BERT-CNN, MOOC-BERT, AGKA) et les détecteurs de visage (Whitehill, Xiong, DAiSEE) atteignent des performances utiles, sous réserve des biais de corpus. ITS, PAGE et l'outil de Kong montrent qu'une médiation par IA peut modifier l'expérience d'apprentissage, rarement toutefois à partir d'un visage et d'une voix, avec une décision relisible.

Ces travaux laissent ouverte la conception d'une chaîne dont chaque étape peut être reconstruite. Le chapitre suivant en propose la formalisation.

Chapitre 3

Méthodologie proposée et architecture du framework EmoLearn

Sommaire

3.1 Introduction **29**

3.2 Framework conceptuel proposé **29**

3.2.1 Architecture globale du système 29

3.2.2 Workflow de génération adaptative 30

3.3 Données retenues **31**

3.3.1 DAiSEE : taxonomie d'engagement 31

3.3.2 IEMOCAP : modalité vocale 31

3.3.3 Articulation des corpus visuel et vocal 32

3.4 Modèle engagement–adaptation **33**

3.4.1 Taxonomie des états d'engagement 33

3.4.2 Estimation multimodale de l'état d'engagement 33

3.4.3 Mapping états → besoins pédagogiques 35

3.4.4 Stratégies pédagogiques par état 37

3.4.5 Règles de déclenchement d'adaptation 37

3.5 Système de génération **38**

3.5.1 Architecture de prompting contextuel 38

3.5.2 Typologie du contenu adaptatif et patrons de prompts 39

3.6 Conclusion **41**

3.1 Introduction

Le chapitre précédent a montré que détection d'un état affectif et génération pédagogique restent rarement articulées : le signal est surtout textuel, la décision opaque, la génération peu ancrée et peu conditionnée par l'état. Dans une démarche de recherche orientée conception (Hevner et al., 2004), le présent chapitre propose une architecture qui relie ces trois fonctions. Le décrochage associé à la baisse d'engagement dans les MOOC oriente la construction de l'artefact EmoLearn.

Le chapitre fixe d'abord les exigences et le framework, puis justifie les données (DAiSEE, IEMOCAP) et leur articulation. Viennent ensuite le modèle engagement–adaptation (taxonomie, estimation, mapping, stratégies, règles temporelles) et le système de génération (prompt contextuel, bibliothèque A1–D5).

3.2 Framework conceptuel proposé

Cette section décrit le framework conceptuel d'EmoLearn : les exigences dérivées des lacunes, l'architecture en trois couches, puis le workflow de génération adaptative.

3.2.1 Architecture globale du système

L'artefact est orienté par trois principes. Perception, décision et génération forment une seule chaîne. Chaque adaptation est justifiée par un état, une règle et un patron A1–D5, puis journalisée. Fusion et décision restent les mêmes fonctions en production et sur le banc d'essai. Ces principes se traduisent en cinq exigences, qui rendent l'orientation vérifiable.

1. **Signal hors forum :** Percevoir l'engagement sur le visage et la voix d'un apprenant qui visionne sans poster.
2. **Décision nommée :** Traduire l'état en un type de contenu par une règle inspectable, et journaliser le motif (état, urgence, patron).
3. **Génération conditionnée et ancrée :** Produire un texte dont le patron dépend de l'état, et dont les faits viennent d'un contexte documentaire.
4. **Droit à la non-intervention :** S'abstenir lorsque l'engagement se maintient, et traiter cette abstention comme une décision.
5. **Même moteur, deux usages :** Servir la simulation et le banc d'essai par les mêmes fonctions de fusion et de décision, afin d'évaluer perception, choix pédagogique et texte sur une chaîne unique.

De ces exigences suit une architecture à trois couches. La couche de perception réalise le signal hors forum : elle estime l'état d'engagement et son intensité sur le visage

(FER+AU, clips DAiSEE) et sur la voix (WavLM, IEMOCAP), puis fusionne les deux modalités. La couche de décision réalise la décision nommée et le droit à la non-intervention : sur l'état fusionné et l'historique des clips, les règles retiennent un type (A, B, C, D, A+D, D+A, ou abstention), un patron et une urgence. La couche de génération réalise le texte conditionné et ancré : un prompt structuré, éventuellement enrichi par le RAG, est soumis au grand modèle de langue. La cinquième exigence traverse ces couches : simulation et évaluation appellent les mêmes fonctions.

La figure 3.1 présente cette architecture fonctionnelle.

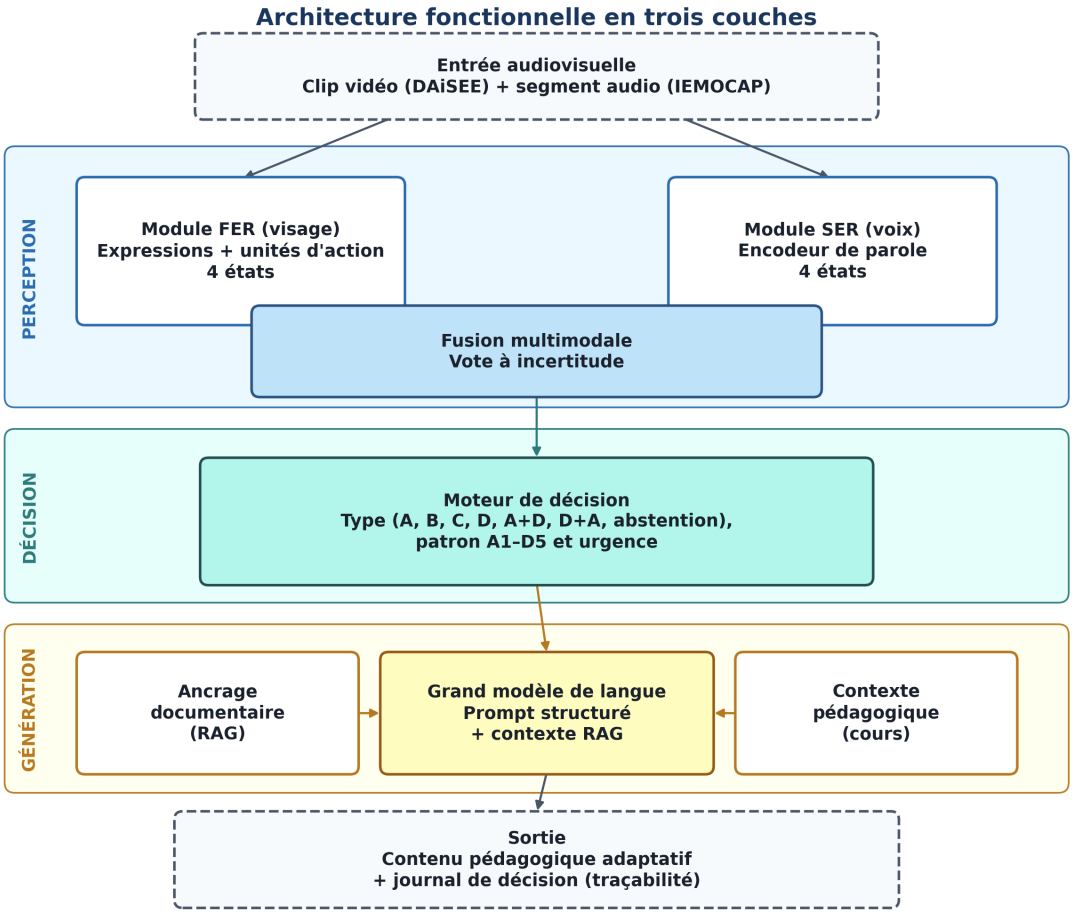


Figure 3.1 – Architecture fonctionnelle en couches.

3.2.2 Workflow de génération adaptative

Le traitement d'un clip suit six étapes.

1. **Acquisition :** Le clip vidéo DAiSEE est associé au segment audio apparié. Le contexte pédagogique (concept, module, niveau, moment du cours) est joint pour la génération.
2. **Perception par modalité :** Le FER (visage) et le SER (voix) estiment chacun une distribution sur les quatre états.

3. **Fusion :** Les deux distributions sont combinées.
4. **Décision :** L'état fusionné et l'historique récent produisent ensemble un type (A, B, C, D, A+D, D+A, ou abstention), un patron A1–D5 et une urgence.
5. **Génération :** Un prompt structuré assemble le contexte pédagogique et, le cas échéant, le RAG, puis est soumis au LLM.
6. **Restitution et traçabilité :** Le contenu est renvoyé à l'interface, l'état, le type, le patron, l'urgence et les paramètres de fusion sont journalisés.

3.3 Données retenues

Cette section justifie le choix des données et la manière dont elles sont reliées.

3.3.1 DAiSEE : taxonomie d'engagement

Le corpus DAiSEE (*Dataset for Affective States in E-Environments*) est retenu comme vocabulaire de décision. Il annote des étudiants filmés en apprentissage en ligne, dans des conditions naturelles. Chaque clip porte quatre scores ordinaux (0 : très faible à 3 : très élevé) pour l'ennui, la confusion, l'engagement et la frustration. Cette grille est plus opératoire, pour un apprenant silencieux devant une vidéo, que les cadres CoI ou ICAP du chapitre 2.

Chaque enregistrement est associé à un quadruplet $s = (s_{\mathrm{B}}, s_{\mathrm{C}}, s_{\mathrm{E}}, s_{\mathrm{F}}) \in \{0,1,2,3\}^4$. L'état dominant d'un clip est :

$$e^{\star} \;=\; \arg\max_{e \in E} s_e, \tag{3.1}$$

où $E = \{\text{Ennui}, \text{Confusion}, \text{Engagement}, \text{Frustration}\}$. En cas d'égalité, un départage pédagogique s'applique une fois pour toutes : Frustration > Confusion > Ennui > Engagement.

3.3.2 IEMOCAP : modalité vocale

Le corpus IEMOCAP (*Interactive Emotional Dyadic Motion Capture*) (Busso et al., 2008) est retenu pour la voix, non comme socle pédagogique. Il annote des énoncés de dialogues actés : une émotion discrète et un triplet valence–activation–dominance. Cette grille décrit une émotion de parole, pas un engagement d'apprenant silencieux. Elle fournit la modalité vocale en production et, hors ligne, un banc audiovisuel aligné (même locuteur, même instant).

3.3.3 Articulation des corpus visuel et vocal

Les deux corpus convergent vers la même taxonomie à quatre états, ce qui permet de fusionner visage et voix.

Le tableau 3.1 présente la complémentarité des corpus DAiSEE et IEMOCAP.

Aspect	DAiSEE	IEMOCAP
Contexte	Apprenants en e-learning (conditions naturelles)	Dialogues actés, dyades (sessions 1–5)
Modalité principale	Visage / engagement annoté	Voix (+ vidéo pour le banc d'essai)
Étiquettes natives	4 états × niveaux 0–3	Émotions discrètes + dimensions VAD
Rôle	Socle : scénarios, patterns, décision	Voix en production, validation AV alignée

Table 3.1 – Complémentarité des corpus DAiSEE et IEMOCAP.

Projection vers la taxonomie DAiSEE : Les émotions conversationnelles d'IEMOCAP ne coïncident pas naturellement avec les états d'engagement de DAiSEE. La conception retient une table de projection : c'est une hypothèse de construit. Elle rend le pipeline cohérent (visage et voix dans un espace commun) et doit être mesurée.

Ainsi appliquée aux 10 039 énoncés, cette projection inverse le déséquilibre observé sur DAiSEE : l'ennui devient l'état majoritaire (5 302 énoncés, soit 53 %), et la confusion n'en représente plus que 147 (1,5 %).

Le tableau 3.2 présente la projection des étiquettes IEMOCAP vers DAiSEE.

Code IEMOCAP	État DAiSEE	Niv.	Justification pédagogique
hap, exc	Engagement	3	Valence positive, activation forte
neu	Ennui	1	Neutre prolongé ≈ faible stimulation
sad	Ennui	2	Pas d'ennui natif dans IEMOCAP, valence basse ≈ sous-stimulation (hypothèse)
ang, fru	Frustration	3	Blocage, tension
dis	Frustration	2	Rejet, gêne modérée
sur, fea	Confusion	2–3	Incertitude, surprise cognitive
xxx	Ennui	1	Non classifié → défaut prudent

Table 3.2 – Projection IEMOCAP vers DAiSEE.

Appariement en production et sous-corpus aligné : Dans la production (simulation sur clips DAiSEE), visage et voix ne proviennent pas du même individu : le FER analyse le clip, le SER sélectionne une utterance IEMOCAP émotionnellement cohérente. La règle calcule l'état dominant du scénario, filtre les utterances projetées sur le même état, puis retient le meilleur appariement par similarité cosinus (profil à douze dimensions : scores B/C/E/F, VAD Baker/Russell (Baker et al., 2010), durée, descripteurs acoustiques). Le segment audio réel est ensuite analysé sur l'intervalle annoté.

3.4 Modèle engagement–adaptation

Le modèle transforme l'état perçu $(\hat{e}, \hat{n})$ et l'historique H en une décision traçable (type, patron, déclenchement). Il fixe d'abord le vocabulaire des quatre états, puis la perception qui les estime, puis le mapping et les stratégies, puis les règles temporelles qui en décident le déclenchement.

3.4.1 Taxonomie des états d'engagement

Le modèle n'introduit pas une grille nouvelle : il adopte les quatre états DAiSEE comme vocabulaire unique de la décision. Chaque état est porté par un niveau ordinal $\hat{n} \in \{0, 1, 2, 3\}$. La section 3.3 a fixé ce vocabulaire côté corpus, il s'agit ici de sa signification pédagogique, celle qui oriente la perception et le mapping.

Le tableau 3.3 présente la taxonomie des quatre états d'engagement.

État	Signification dans le contexte d'apprentissage
Engagement	Attention active et implication dans la tâche d'apprentissage.
Ennui	Désengagement passif, baisse de la stimulation.
Confusion	Incompréhension d'un concept, difficulté de traitement.
Frustration	Blocage émotionnel, tension liée à une difficulté persistante.

Table 3.3 – Taxonomie des états d'engagement.

Cette taxonomie est opératoire pour la régulation : un engagement soutenu n'appelle pas la même intervention qu'une confusion élevée ou qu'un blocage frustré.

3.4.2 Estimation multimodale de l'état d'engagement

La perception transforme un couple (vidéo, audio) en $(\hat{e}, \hat{n})$, où $\hat{e} \in E$ est l'état d'engagement estimé (ennui, confusion, engagement ou frustration) et $\hat{n} \in \{0, 1, 2, 3\}$ son niveau d'intensité.

Perception faciale : Une table fixe projette les sept émotions du détecteur vers DAiSEE. En production, un Random Forest FER+AU (sept scores d'émotion concaténés à dix Action Units MediaPipe) est le juge, un ViT fine-tuné vers les quatre états DAiSEE sert de filtre de frames, sans choisir l'état fusionné.

Le tableau 3.4 présente le mapping des émotions faciales vers DAiSEE.

Émotion faciale	État DAiSEE	Niveau associé
happy	Engagement	3
neutral	Ennui	1
sad	Ennui	2
angry	Frustration	3
fear	Confusion	3
surprise	Confusion	2
disgust	Frustration	2

Table 3.4 – Mapping FER vers DAiSEE.

Cette correspondance aligne les sept émotions du détecteur facial sur la taxonomie pédagogique à quatre états. Le choix s'appuie sur la valence et l'activation, ainsi que sur le geste pédagogique que chaque état autorise. La joie, à valence positive et activation élevée, est associée à l'engagement. Le neutre, à faible stimulation, et la tristesse, à valence négative sans confrontation, sont associés à l'ennui, à des intensités distinctes. La colère, signal de tension et de blocage, est associée à la frustration. La peur et la surprise, qui marquent une incertitude ou une rupture d'attente, sont associées à la confusion. Le dégoût, marqueur de rejet, est associé à une frustration d'intensité moindre.

Perception vocale : En production, un encodeur WavLM, dont la tête est fine-tunée vers les quatre états DAiSEE, est le juge vocal. Lorsque ce modèle est indisponible, une heuristique acoustique estime un triplet valence–activation–dominance à partir de l'énergie, du taux de passages par zéro, du centroïde spectral et de la fréquence fondamentale (Baker et al., 2010). Une émotion discrète au vocabulaire IEMOCAP en est dérivée, puis projetée vers DAiSEE.

Le tableau 3.5 présente cette dérivation.

Condition acoustique	Code IEMOCAP	État DAiSEE
Valence élevée, énergie moyenne à forte	hap, exc	Engagement
Énergie élevée, valence basse	ang, fru	Frustration
Énergie faible	sad, neu	Ennui
Taux de passages par zéro élevé	sur, fea	Confusion
Autres cas	neu	Ennui

Table 3.5 – Heuristique vocale : de l'indice acoustique à l'état DAiSEE.

Fusion multimodale : Visage et voix fournissent chacun une distribution, $P_v(e)$ et $P_a(e)$, alors que la décision n'admet qu'un couple $(\hat{e}, \hat{n})$. La fusion les compose par un vote pondéré à incertitude. Le poids du visage $\tilde{w}_v$ vaut 0,6 par défaut ($\tilde{w}_a = 1 - \tilde{w}_v$), parce que le visage est le signal natif du visionnage silencieux, celui que DAiSEE annote, alors que la voix en production est un énoncé IEMOCAP apparié. Les confiances c_v et c_a modulent ce rapport : un visage illisible abaisse c_v et bascule le poids effectif vers la voix.

Le poids effectif, la distribution fusionnée et l'état s'écrivent :

$$w_v^{\text{eff}} \;=\; \frac{\tilde{w}_v\, c_v}{\tilde{w}_v\, c_v + \tilde{w}_a\, c_a}, \qquad \hat{P}(e) \;=\; w_v^{\text{eff}}\, P_v(e) + (1 - w_v^{\text{eff}})\, P_a(e), \qquad \hat{e} \;=\; \arg\max_{e \in E} \hat{P}(e). \tag{3.2}$$

Le niveau suit la même pondération, arrondi à l'échelle ordinale de DAiSEE :

$$\hat{n} \;=\; \text{round}\Big(w_v^{\text{eff}}\, n_v + (1 - w_v^{\text{eff}})\, n_a\Big). \tag{3.3}$$

Lorsque les deux confiances sont nulles, le vote n'est plus défini. L'état retenu est alors celui de priorité pédagogique maximale, afin de ne pas laisser sans aide un apprenant potentiellement bloqué :

$$\pi(\text{Frustration}) > \pi(\text{Confusion}) > \pi(\text{Ennui}) > \pi(\text{Engagement}). \tag{3.4}$$

3.4.3 Mapping états → besoins pédagogiques

Le mapping traduit le couple $(\hat{e}, \hat{n})$ en une intention pédagogique : un type de contenu τ et une stratégie d'intervention. Les scores $s^{(t)}$ du clip courant, dérivés de la fusion par $s_e = \text{round}(3\,\hat{P}(e))$ lorsque $\hat{P}$ est disponible, servent de conditions. Le patron γ précise ensuite le type dans la bibliothèque A1–D5. L'urgence u et l'historique H fixent le déclenchement.

La figure 3.2 présente les vocabulaires de la décision.

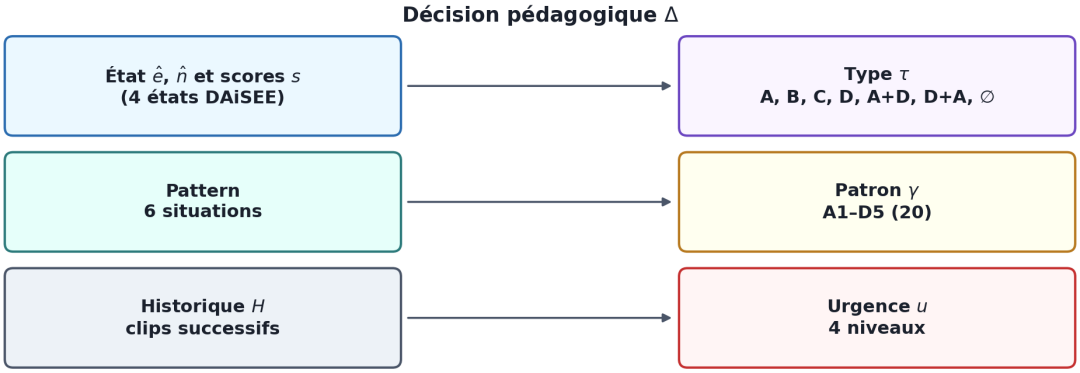


Figure 3.2 – Vocabulaires de décision.

Le tableau 3.6 présente la correspondance engagement–contenu.

Ordre	Condition (scores DAiSEE)	**Type**	Stratégie
1	Confusion ≥ 3 et Frustration ≥ 2	**A+D**	Aide de déblocage immédiate
2	Engagement $= 0$	**B**	Réengagement urgent
3	Frustration ≥ 2	**D+A**	Encouragement + simplification
4	Confusion ≥ 2	**A**	Explication alternative
5	Ennui ≥ 2	**C**	Exercice avancé
6	Engagement ≤ 1	**B**	Exemple concret stimulant
7	Ennui $= 1$	**B**	Application pratique
8	Engagement ≥ 2	**D**	Renforcement positif
9	Sinon	–	Pas d'adaptation

Table 3.6 – Mapping engagement–contenu.

Les scores DAiSEE étant des échelles indépendantes, un même clip peut cumuler Ennui $= 1$ et Engagement ≥ 2. La cascade évalue alors la règle 7 avant la règle 8 : un soupçon d'ennui déclenche une application pratique (B) plutôt qu'un seul renforcement positif (D). Cet ordre traduit un choix pédagogique : un apprenant encore engagé mais déjà sous-stimulé n'est pas traité comme une situation satisfaisante.

Cette cascade se formalise par

$$\big(\tau,\, \gamma,\, u\big) \;=\; \Delta\big(\hat{e},\, \hat{n},\, s^{(t)},\, H\big), \tag{3.5}$$

où $\tau \in \{A, B, C, D, A{+}D, D{+}A, \varnothing\}$ est le type, $\gamma \in \{A1, \ldots, D5\}$ le patron et $u \in \{\text{immédiate}, \text{rapide}, \text{différée}, \text{aucune}\}$ l'urgence. Δ parcourt les règles dans l'ordre et retient la première condition vraie.

3.4.4 Stratégies pédagogiques par état

La stratégie désigne le geste (clarifier, contextualiser, approfondir, soutenir), le patron γ dans A1–D5 en fixe le format. Trois régulations l'organisent : simplifier une charge excessive, relancer une sous-stimulation, soutenir un blocage avant toute nouvelle tâche.

La confusion, au sens de Sweller (1988), indique une charge qui dépasse la capacité de traitement. La famille A reformule, décompose ou change d'analogie, sans ajouter d'exercice. Lorsque cette confusion maximale coexiste avec une frustration notable, le type A+D normalise d'abord la difficulté, puis propose une autre prise sur le concept.

L'ennui et l'engagement faible relèvent d'une sous-stimulation. D'Mello et Graesser (2012) et Baker et al. (2010) montrent qu'un apprenant ennuyé décroche plus rapidement qu'un apprenant encore impliqué dans un échec. Un ennui élevé oriente vers la famille C (exercice plus exigeant), sous l'hypothèse que le concept est déjà assez clair. Un engagement qui s'effondre, ou un ennui encore léger, oriente vers la famille B, qui replace le concept dans une situation concrète.

La frustration est un état affectif (Pekrun, 2006) : une nouvelle explication ou un exercice plus dur augmenterait encore la charge. La famille D précède donc toute relance cognitive, D+A n'ajoute une simplification qu'après ce geste. Un engagement élevé appelle un renforcement (D4, D5), l'urgence u peut valoir *aucune* lorsque cet engagement se tient sur deux clips.

3.4.5 Règles de déclenchement d'adaptation

La décision d'intervenir repose aussi sur la dynamique H, afin de ne réagir ni à un clip isolé, ni trop tard face à un état négatif qui s'installe. Si $u =$ aucune, alors $\tau = \varnothing$: pas d'appel au LLM. Quatre niveaux d'urgence fixent le délai : l'urgence immédiate exige une réponse sur le clip courant : l'état est déjà critique (blocage fort, ou désengagement total). L'urgence rapide signale un état négatif qui s'installe ou qui dépasse déjà un seuil notable : l'intervention ne peut pas attendre plusieurs clips. L'urgence différée concerne une baisse légère mais durable : on observe encore, puis on agit si le signal se confirme. L'urgence aucune constate un engagement stable : le système s'abstient, pour ne pas interrompre un apprenant qui n'en a pas besoin.

Le tableau 3.7 présente les règles temporelles d'adaptation.

Urgence	Règle de déclenchement
Immédiate	Confusion ≥ 3 et Frustration ≥ 2 sur le clip courant, ou Engagement $= 0$.
Rapide	Ennui, Confusion ou Frustration ≥ 2 sur 2 clips consécutifs, ou seuils instantanés du clip courant (confusion, frustration ou ennui ≥ 2, ou engagement ≤ 1) si aucune règle plus spécifique ne s'applique.
Différée	Engagement ≤ 1 (ou Ennui $= 1$) stable sur 4 clips.
Aucune	Engagement ≥ 2 stable sur 2 clips $\rightarrow$ pas d'intervention.

Table 3.7 – Règles temporelles d'adaptation.

Les longueurs d'historique de deux et quatre clips suivent la durée typique d'un extrait DAiSEE (environ dix secondes). Deux clips ($\approx$ 20 s) suffisent à confirmer qu'un état négatif s'installe, ou qu'un engagement tient, sans attendre une minute entière. Quatre clips ($\approx$ 40 s) sont réservés à une baisse légère : on refuse d'interrompre trop tôt un apprenant seulement un peu moins engagé. Ces durées sont des choix de conception.

3.5 Système de génération

Cette section décrit la génération : le prompt qui assemble le contexte, puis la bibliothèque des vingt patrons.

3.5.1 Architecture de prompting contextuel

Une fois le patron γ sélectionné, la génération s'appuie sur un prompt structuré, assemblé toujours dans le même ordre. Cette composition impose au modèle de lire d'abord les faits documentaires, puis la situation de cours, puis l'état de l'apprenant, avant d'exécuter la tâche.

Le message système assigne au modèle un rôle d'expert en pédagogie et restreint la génération aux faits fournis dans le contexte. Le contexte de référence, issu du RAG, n'est injecté que lorsque le seuil de similarité est atteint : il ancre le texte sur les documents du cours. Le contexte pédagogique situe ensuite le concept (module, niveau, objectif). Le bloc état transmet l'état d'engagement estimé, son intensité, sa durée et le pattern pédagogique, afin que le contenu reste conditionné par $\hat{e}$. La tâche nomme le patron γ dans A1–D5 et fixe le format, le ton et la longueur.

Le prompt ainsi assemblé est soumis au grand modèle de langue par une API, à température basse, afin de limiter la variance entre appels comparables.

La figure 3.3 présente le message système et le prompt utilisateur, soumis ensemble au modèle, le journal est assemblé après l'appel.

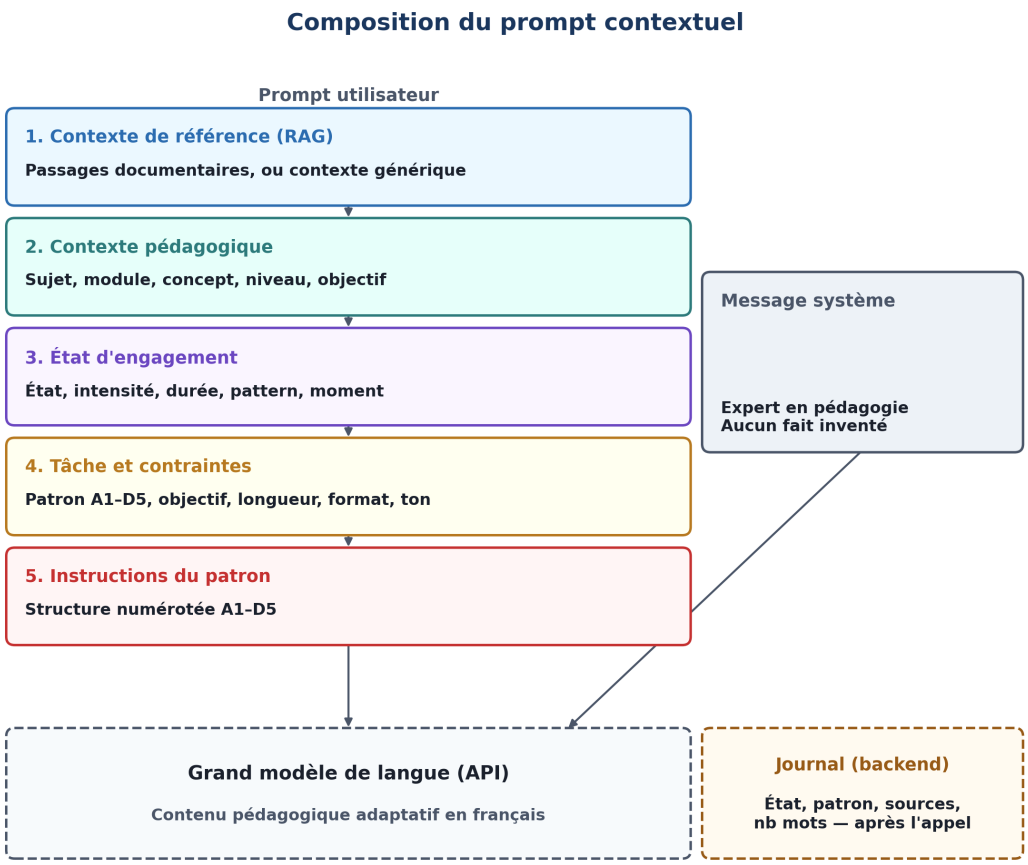


Figure 3.3 – Architecture du prompt.

3.5.2 Typologie du contenu adaptatif et patrons de prompts

La famille A clarifie, B stimule, C approfondit, D encourage. Vingt patrons conditionnent la génération par l'état, pas par un simple réglage de style. Le tableau 3.8 présente, pour chaque patron, le geste pédagogique, les quatre consignes imposées au modèle, le format, le ton et la longueur cible.

ID	Geste et consignes (1–4)	Format / ton	Long.
A1	Explication alternative (confusion modérée) : reformuler plus simplement, analogie quotidienne, trois étapes, question de vérification.	Étapes / rassurant	200
A2	Micro-explication (confusion intense) : partir d'un exemple très simple, monter vers l'abstrait, métaphore visuelle, schéma textuel.	Décomposé / patient	150
A3	Aide de déblocage (confusion + frustration) : normaliser la difficulté, nommer le point de blocage, autre approche, mini-exercice guidé.	Déblocage / empathique	200

ID	Geste et consignes (1–4)	Format / ton	Long.
A4	Explication de fond (confusion récurrente) : concept sous-jacent, ponts avec l'acquis, représentation unificatrice, stratégie d'apprentissage.	Fond / stratégique	250
A5	Explication narrative (concept abstrait) : analogie tangible, mini-scénario, alternance concret / abstrait, reformulation finale.	Narratif / créatif	200
B1	Exemple concret (ennui modéré) : situation actuelle, C résout un problème, données si le RAG le permet, ouverture sur le quotidien.	Engageant / dynamique	200
B2	Cas pratique (engagement faible) : fait surprenant, usage inattendu, enjeux, mini-investigation.	Cas / curiosité	250
B3	Mise en pratique (ennui après théorie) : passage à l'action, mini-projet par étapes, résultat attendu, variation.	Action / pratique	200
B4	Application réelle (contextualisation) : domaine actuel, rôle de C, projet réel si le RAG le permet, compétences associées.	Pro / carrière	250
B5	Exemple interdisciplinaire : autre domaine, transversalité, comparaison inattendue, ouvertures.	Transversal / créatif	200
C1	Exercice avancé (ennui élevé) : problème plus dur, contrainte supplémentaire, justification, extension.	Structuré / challengeant	250
C2	Exercice de consolidation : lier C à un concept déjà vu, trois paliers, indices, auto-évaluation.	Progressif / encourageant	200
C3	Exercice créatif : situation ouverte, contexte original, plusieurs solutions, valorisation.	Ouvert / valorisant	200
C4	Mini-projet : objectif concret, quatre à cinq étapes, concepts à mobiliser, livrable.	Projet / ambitieux	250
C5	Exercice comparatif : deux ou trois approches, forces et faiblesses, choix justifié, pensée critique.	Analytique / critique	200
D1	Encouragement (frustration modérée) : valider la difficulté, rappeler les progrès, perspective, phrase motivante.	Motivant / empathique	150
D2	Soutien (frustration élevée) : autoriser la pause, normaliser, stratégie de déblocage, persévérance.	Soutien / déstressant	180
D3	Remotivation (découragement) : reconnexion au motif initial, objectifs personnels, chemin parcouru, micro-objectif.	Remotivant / recentrant	200

ID	Geste et consignes (1–4)	Format / ton	Long.
D4	Renforcement (bon engagement) : féliciter, souligner un acquis, anticiper la suite, maintenir la dynamique.	Positif / valorisant	150
D5	Félicitation (après déblocage) : célébrer, expliciter la compétence, lien avec la suite, renforcer la confiance.	Félicitation / confiant	150

Table 3.8 – Bibliothèque des vingt patrons.

3.6 Conclusion

Ce chapitre a fixé l'architecture d'EmoLearn : cinq exigences (R1–R5), une perception multimodale, une décision explicite (type, patron, urgence) et une génération ancrée (LLM et RAG), conditionnée par vingt patrons. Les données retenues (DAiSEE, IEMOCAP) justifient le vocabulaire à quatre états. Le chapitre suivant traduit ces choix en prototype exécutable : infrastructure, moteurs de perception et de décision, génération et contrôle de qualité, l'algorithme qui relie ces couches, puis l'interface de simulation.

Chapitre 4

Implémentation du prototype

Sommaire

4.1 Introduction **44**

4.2 Infrastructure technique **44**

4.2.1 Stack technologique 44

4.2.2 Choix d'architecture 45

4.3 Traitement et préparation des données **47**

4.3.1 Caractérisation de DAiSEE 47

4.3.2 Caractérisation de IEMOCAP 48

4.3.3 Extraction et nettoyage du dataset DAiSEE 49

4.3.4 Extraction et alignement du corpus IEMOCAP 50

4.3.5 Création de scénarios d'apprentissage 51

4.3.6 Segmentation des sessions 52

4.4 Implémentation de la couche de perception **52**

4.4.1 Perception faciale 52

4.4.2 Perception vocale 54

4.4.3 Fusion des modalités 56

4.5 Implémentation de la couche de décision **58**

4.5.1 Sélection de stratégies 58

4.5.2 Gestion des transitions d'état 59

4.6 Implémentation de la couche de génération **60**

4.6.1 Configuration du LLM 60

4.6.2 Bibliothèque de vingt patrons de prompts 61

4.6.3 Pipeline de génération 62

4.6.4 Post-traitement et validation 64

4.7 Algorithme global **65**

4.8 Développement du prototype de simulation **66**
4.8.1 Interface de visualisation 66
4.8.2 Lecteur de parcours d'apprentissage 68
4.8.3 Affichage des adaptations 68
4.9 Génération du corpus de contenu adaptatif **69**
4.9.1 Génération et documentation du corpus 69
4.9.2 Exemples de contenu généré 70
4.10 Conclusion **72**

4.1 Introduction

Le chapitre précédent a spécifié les fonctions du système : percevoir un état d'engagement à partir du visage et de la voix, décider d'une éventuelle intervention, puis générer un contenu pédagogique adapté. Le présent chapitre en décrit la réalisation logicielle.

Après l'infrastructure et la préparation des données (DAiSEE, IEMOCAP, cinquante scénarios, dix séquences), les trois couches — perception, décision, génération — sont implémentées et reliées par l'algorithme 1. L'interface de simulation rend cette chaîne observable. Un corpus de 220 contenus, audité et documenté, clôt le chapitre. Conformément à la recherche orientée conception (Hevner et al., 2004), l'artefact logiciel constitue l'objet d'étude.

4.2 Infrastructure technique

Cette section décrit la pile logicielle et l'organisation du prototype.

4.2.1 Stack technologique

Le serveur et les scripts hors ligne (entraînement, évaluation, construction de corpus) sont écrits en Python 3.11. L'interface et la validation appellent les mêmes modules de perception, de fusion et de décision. L'interface cliente est en JavaScript (React). Le tableau 4.1 présente la pile retenue, couche par couche.

Couche	Technologies	Rôle dans le prototype
Exécution	Python 3.11	Langage unique du serveur et des scripts hors ligne.
Service web	FastAPI, Uvicorn, Pydantic	Exposition de l'API REST/JSON et validation des requêtes.
Vision	OpenCV, MediaPipe, Transformers, PyTorch	Décodage des clips, détection BlazeFace, FER (ViT) et Action Units.
Audio	librosa, soundfile, Transformers (WavLM)	Lecture du signal, index acoustique, reconnaissance vocale.
Apprentissage	scikit-learn (Pedregosa et al., 2011), joblib, PyTorch	Classifieur FER+AU, fine-tuning WavLM et sérialisation des modèles.
Génération	SDK Groq, GPT-OSS 20B	Production du contenu pédagogique adaptatif.

Couche	Technologies	Rôle dans le prototype
Récupération	ChromaDB, sentence-transformers (MiniLM) (Wang et al., 2020)	Base vectorielle et encodage des documents pour le RAG (Gao et al., 2023 ; Lewis et al., 2020).
Persistance	SQLite, fichiers JSONL et CSV	Sessions, journal des décisions, référentiels de scénarios.
Client et tests	React 19, jsPDF, pytest, React Testing Library	Interface clip / séquence, lecteurs multimédias, export PDF, tests.

Table 4.1 – Pile technologique du prototype.

Les modèles de perception sont publics, seule la dernière articulation, qui relie leurs sorties à la taxonomie DAiSEE, est apprise localement. L'analyse faciale d'un clip porte sur cinq images réparties sur sa durée, compromis de coût sur processeur. La voix s'appuie sur un encodeur WavLM dont la tête est fine-tunée vers les quatre états. La génération est confiée à un modèle distant, chargé à la première sollicitation, à température basse et budget de sortie borné.

Les dépendances sont figées dans un fichier de spécification unique. La clé d'accès au service de génération est lue depuis un fichier d'environnement non versionné.

4.2.2 Choix d'architecture

L'architecture fonctionnelle du chapitre 3 se réalise ici en un processus d'exécution, un découpage de modules et des modes dégradés. La figure 4.1 présente l'architecture technique du prototype.

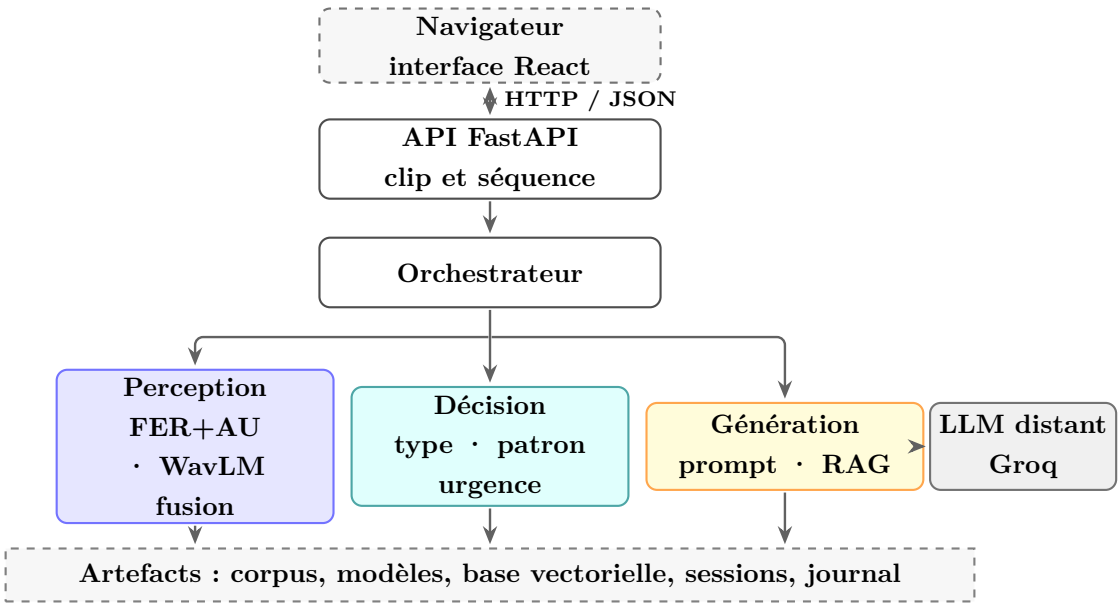


Figure 4.1 – Architecture technique du prototype.

Le client et le serveur sont deux applications distinctes, reliées par des échanges JSON sur HTTP. L'API est sans état : chaque requête porte le contexte pédagogique (scénario, concept, module, niveau, moment du cours), et l'historique des règles temporelles est relu depuis la persistance. Un redémarrage conserve les parcours, un script rejoue une analyse sans passer par l'interface. Deux points d'entrée sont exposés : le clip isolé et la séquence.

De cette séparation suit un découpage par responsabilité scientifique. Perception, fusion, décision, génération et orchestration occupent chacune un module. La chaîne d'un clip est écrite une seule fois dans l'orchestrateur, l'API valide la requête et met en forme la réponse. Les scripts hors ligne (évaluation faciale, sous-corpus aligné, sensibilité) importent les mêmes modules : l'interface et le banc d'essai exécutent donc la même chaîne.

Pour chaque modalité, une référence explicable et une variante apprise sont retenues. Ces alternatives restent comparables parce qu'elles sont sélectionnées par variables d'environnement. La fusion est unique : le vote pondéré par incertitude. La priorité pédagogique n'intervient que lorsque les deux confiances sont nulles. Le tableau 4.2 présente la commutation des variantes de perception.

Réglage	**Valeurs**	**Défaut**
Mapping facial	auto, appris, heuristique	auto
Mode facial	fine-tuné, pré-entraîné, auto	fine-tuné
Méthode vocale	apprise, heuristique	apprise
Hybride vocal	actif (WavLM DAiSEE + ancre IEMOCAP), inactif	actif

Table 4.2 – Commutation des variantes de perception.

Lorsqu'une ressource manque, le traitement se poursuit en mode dégradé : mapping heuristique si le modèle appris est absent, génération sans ancrage si le RAG échoue, tentatives espacées si le service distant est limité, décision unimodale si la voix manque. Chaque dégradation est déclarée dans la réponse et le journal, afin que la configuration mesurée soit celle réellement exécutée.

Deux stocks persistent. Le journal de décision, en ajout seul, conserve pour chaque clip l'état fusionné, le type de conflit, le patron et les indicateurs de génération : c'est la matière du chapitre 5. La base de sessions conserve le déroulé pédagogique de l'interface. Les modèles sont produits hors serveur par des scripts d'apprentissage, puis chargés depuis le disque.

Cette organisation reste celle d'un prototype de simulation, au périmètre fixé au cha-

pitre : utilisateur unique, persistance mono-fichier, service de génération distant. L'exigence retenue est la reproductibilité et la traçabilité de la chaîne scientifique.

4.3 Traitement et préparation des données

Cette section décrit la préparation des deux corpus : leur caractérisation, l'extraction, le référentiel de scénarios, l'index d'énoncés et le découpage temporel.

4.3.1 Caractérisation de DAiSEE

L'analyse des annotations révèle un déséquilibre de classes marqué, caractéristique documentée de DAiSEE. L'engagement est largement dominant (niveaux 2 ou 3), tandis que la confusion et la frustration intenses sont rares. Deux conséquences en découlent : les états critiques, pourtant les plus importants pédagogiquement, sont sous-représentés, maximiser l'exactitude globale tendrait à privilégier la classe majoritaire. La figure 4.2 présente la distribution des états DAiSEE sur les 8 571 clips annotés.

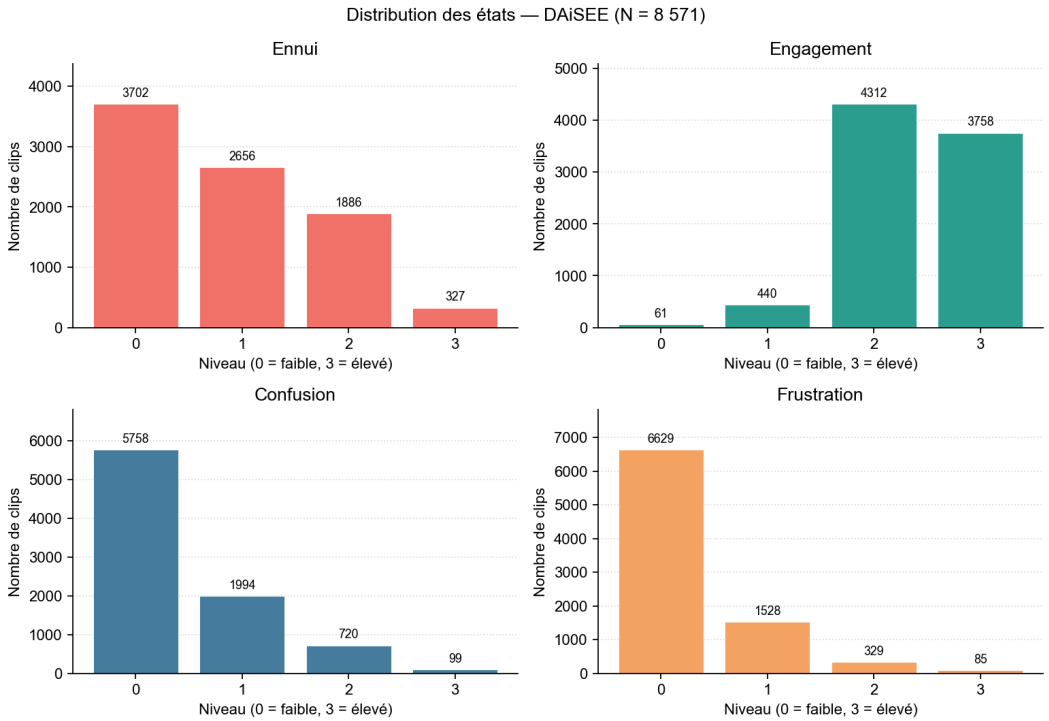


Figure 4.2 – Distribution des états DAiSEE.

L'engagement varie en sens inverse de l'ennui : un clip très engagé est rarement très ennuyé. Confusion et frustration tendent à coexister : un blocage s'accompagne souvent d'une désorientation. Cette co-occurrence motive les types composites A+D et D+A. L'état dominant classe ensuite les extraits.

Un sous-ensemble de scénarios (clip isolé) et de parcours (plusieurs clips) couvre les situations fréquentes et les situations rares mais critiques. Il alimente le prototype.

Un pattern qualifie la situation globale d'un clip ou d'une séquence et oriente le patron de génération. Le tableau 4.3 présente les patterns pédagogiques DAiSEE.

Pattern	Condition (scores DAiSEE)
critique	Au moins trois états simultanément ≥ 2 (situation cumulée).
engagement_faible	Engagement ≤ 1, sans confusion ni frustration marquées.
confusion	État dominant = Confusion.
ennui_eleve	État dominant = Ennui.
frustration	État dominant = Frustration.
stable	Engagement dominant, situation acceptable.

Table 4.3 – Patterns pédagogiques DAiSEE.

4.3.2 Caractérisation de IEMOCAP

Le corpus parsé comprend 10 039 énoncés, répartis en 151 dialogues (4 784 improvisés, 5 255 scriptés), chacun associé à un fichier audio. La durée moyenne d'un énoncé est de 4,46 s (médiane 3,52 s, maximum 34 s), plus courte et plus variable que les clips DAiSEE, calibrés à dix secondes.

L'étiquette la plus fréquente est la classe indéterminée `xxx` (2 507 énoncés, un quart du corpus). Suivent la frustration (`fru`, 1 849) et le neutre (`neu`, 1 708). Colère, tristesse et excitation occupent chacune environ 1 100 énoncés, la joie en compte 595. Surprise, peur, dégoût et résidu `oth` sont marginaux (`dis` : deux occurrences). Les classes rares (`sur`, `fea`) sont trop peu nombreuses pour porter seules un état pédagogique, la masse de `xxx` oriente le défaut de la table de projection.

La figure 4.3 présente la distribution des émotions IEMOCAP.

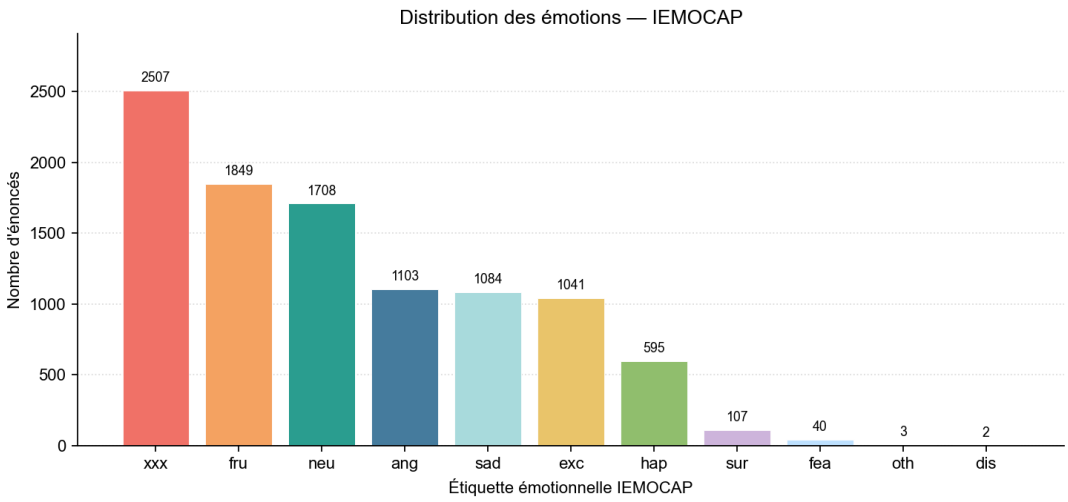


Figure 4.3 – Distribution des émotions IEMOCAP.

Les cinq sessions sont comparables en volume (1 811 à 2 170 énoncés), de même que les tours féminins et masculins (4 800 / 5 239). Les énoncés relèvent d'une parole de laboratoire, filmée en dyade.

Les moyennes VAD valent 2,78 (valence), 3,09 (activation) et 3,19 (dominance). L'activation distingue trois régimes : faible stimulation (`neu`, `xxx`, `sad` : 2,84 une fois regroupées), joie ou excitation (3,41), colère ou frustration (3,35). L'appariement vocal retient donc l'étiquette discrète et ce profil dimensionnel.

Le vocabulaire natif ignore l'ennui, dégoût, surprise et peur y restent marginaux. La projection déjà posée relie ces étiquettes aux quatre états DAiSEE.

Ces observations orientent les traitements qui suivent. La figure 4.4 présente la chaîne de préparation des données.

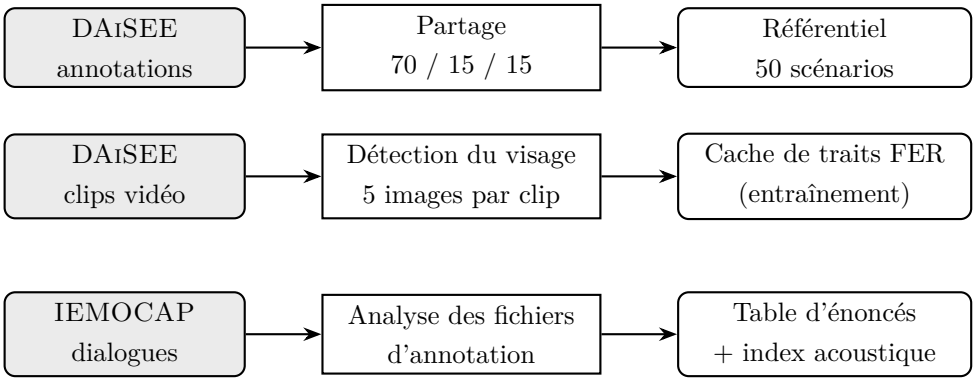


Figure 4.4 – Chaîne de préparation des données.

4.3.3 Extraction et nettoyage du dataset DAiSEE

Cette sous-section décrit le partage des annotations et la résolution des clips vidéo.

Les trois fichiers officiels (5 358 / 1 429 / 1 784, soit 8 571 clips) sont concaténés, puis redécoupés selon un partage 70 / 15 / 15 : 5 999 clips de conception, 1 285 de validation et 1 287 de test. Les noms de colonnes sont normalisés à la lecture.

L'arborescence vidéo (partition, sujet, clip) mélange deux formats de conteneur. Un index en mémoire associe chaque nom de fichier à son chemin absolu, l'identifiant sans extension est résolu en essayant les deux formats. Un clip annoté dont la vidéo est absente produit un code d'erreur nommé.

L'extraction du visage, le cache FER et le classifieur FER+AU appartiennent à la couche de perception.

Un clip est écarté du jeu d'entraînement dans quatre cas, chacun portant un code distinct : vidéo introuvable, illisible, sans image décodable, ou échec du classifieur. Les clips étant calibrés à dix secondes, ni suppression de doublons ni filtrage sur la durée n'ont été appliqués. Le déséquilibre des classes, déjà observé, est traité en aval par une pondération inverse et une métrique moyennée par classe.

4.3.4 Extraction et alignement du corpus IEMOCAP

Les fichiers d'annotation sont lus par une expression régulière qui retient, pour chaque énoncé, les bornes temporelles, l'identifiant, l'étiquette et les coordonnées VAD. Le résultat est une table unique de 10 039 lignes. La projection vers les quatre états suit le tableau 3.2 : elle est isolée dans un dictionnaire, substituable pour l'analyse de sensibilité.

Le signal audio est stocké par dialogue. Le chemin du fichier est reconstruit à partir de l'identifiant de l'énoncé, après retrait du suffixe de locuteur, le segment annoté est ensuite chargé à la position et pour la durée indiquées, en monophonie et à 16 kHz, fréquence attendue par l'encodeur vocal. Une étape d'enrichissement ajoute à la table le chemin résolu et un indicateur d'existence. Cette couverture se vérifie en une lecture, avant tout entraînement.

L'appariement en production applique le filtre d'état, le profil à douze dimensions et la similarité cosinus. Les descripteurs acoustiques des 10 039 énoncés sont précalculés, côté scénario, le profil est approximé à partir des scores, le clip n'ayant pas de piste audio. Les ex-æquo sont départagés par l'identifiant du scénario. La réponse expose la méthode, la similarité et la taille du pool.

Un sous-corpus audiovisuel aligné est construit pour la validation : 80 paires, même locuteur. Seule la session 1 fournit la vidéo, les deux locuteurs y apparaissent côte à côte en 720×480. Le côté retenu compare le genre de l'identifiant à celui du nom de dialogue. La détection de visage est la même que pour DAiSEE. Les énoncés trop

courts et les étiquettes indéterminées sont écartés, vingt énoncés sont retenus par état. Les métriques correspondantes figurent au chapitre 5.

L'apprentissage de la tête WavLM et le mode hybride de production sont décrits avec la couche de perception.

4.3.5 Création de scénarios d'apprentissage

Cette sous-section décrit la constitution du référentiel de cinquante scénarios.

Deux fonctions successives attribuent à chaque clip un état dominant, avec son départage, puis un pattern (cas composites d'abord, puis état dominant, tableau 4.3). Le clip devient un scénario lorsqu'un contexte de cours (concept, module, niveau) lui est joint.

Cinquante clips sont tirés du seul sous-ensemble de conception, par tirages indépendants et reproductibles pour chaque patron. Les effectifs privilégient les états problématiques : un tirage proportionnel à la fréquence du corpus aurait surtout retenu des clips engagés, peu informatifs pour la décision. Le sur-échantillonnage de la frustration, de la confusion et de l'état critique rend l'échantillon utile pour évaluer la chaîne. Les taux mesurés sur ces cinquante lignes caractérisent le référentiel construit.

Le tableau 4.4 présente la composition du référentiel de scénarios.

Patron	**Critère de tirage**	**Effectif**
Stable	engagement ≥ 2	15
Ennui élevé	ennui ≥ 2	10
Frustration	frustration ≥ 2	8
Confusion	confusion ≥ 2	7
Engagement faible	engagement ≤ 1	6
État critique	confusion ≥ 2 *et* frustration ≥ 2	4
Total		50

Table 4.4 – Référentiel de scénarios.

Le fichier conserve l'identifiant du clip, ses quatre scores et le patron obtenu au tirage. Ce patron est recalculé au chargement à partir des scores, afin qu'une révision des règles se propage au référentiel. Un jeu de tests vérifie, pour chacune des cinquante lignes, la cohérence entre le patron stocké et l'état dominant. Un second fichier dérivé associe à chaque scénario la stratégie et le type de contenu retenus : c'est une table de référence pour la discussion des résultats.

4.3.6 Segmentation des sessions

Le clip de dix secondes est l'unité de perception et de décision : c'est le grain du mode isolé. La fenêtre glissante est celle des règles d'urgence : un clip pour l'urgence immédiate, deux clips consécutifs pour l'urgence rapide, quatre clips pour l'urgence différée. La séquence est l'unité de parcours.

Dix séquences de cinq clips ont été assemblées hors ligne, chacune portant sur un même sujet DAiSEE. Les patrons dominants couvrent les six situations : deux parcours stables, deux d'ennui, deux de frustration, deux de confusion, un critique et un d'engagement faible. Lorsque le référentiel de cinquante clips ne suffit pas à remplir une trajectoire, des extraits complémentaires du même sujet la complètent. Le référentiel de parcours est exposé par l'API et analysé d'un bloc.

Chaque adaptation produite est enregistrée dans une table de sessions : identifiant du scénario, état, intensité, stratégie, type de contenu, texte et horodatage. Cette table est plate, sans identifiant de parcours : une trajectoire se relit par ordre chronologique, ce qui suffit au prototype. Le journal de décision ajoute, pour chaque clip, l'état fusionné, le type de conflit, le patron et les indicateurs de génération, en écriture seule.

4.4 Implémentation de la couche de perception

Cette section décrit la perception faciale, la perception vocale et leur fusion.

4.4.1 Perception faciale

Cette sous-section décrit comment un clip DAiSEE devient un état facial : état, intensité et distribution sur les quatre classes.

L'identifiant du clip est résolu vers le fichier vidéo. Cinq images sont lues à intervalles réguliers, hors bords. Sur chacune, MediaPipe Face Detector (BlazeFace) cherche le visage en trois passes, dans cet ordre. La courte portée correspond au plan webcam de DAiSEE, où le visage occupe une grande part de l'image. La longue portée correspond au plan plus large, typique d'IEMOCAP, où deux locuteurs apparaissent côte à côte. L'image miroir reprend ensuite ces deux détecteurs sur le retournement horizontal, afin de rattraper une tête tournée. Au sein d'une passe, la boîte de plus grande aire, d'au moins 40×40 pixels, est retenue. La première passe qui réussit arrête la cascade. La méthode employée (courte, longue ou miroir) est écrite dans la trace. Une marge de 30 % conserve le front et le menton. Si aucune boîte n'est valide, l'image entière est transmise. La figure 4.5 présente l'architecture de la perception faciale.

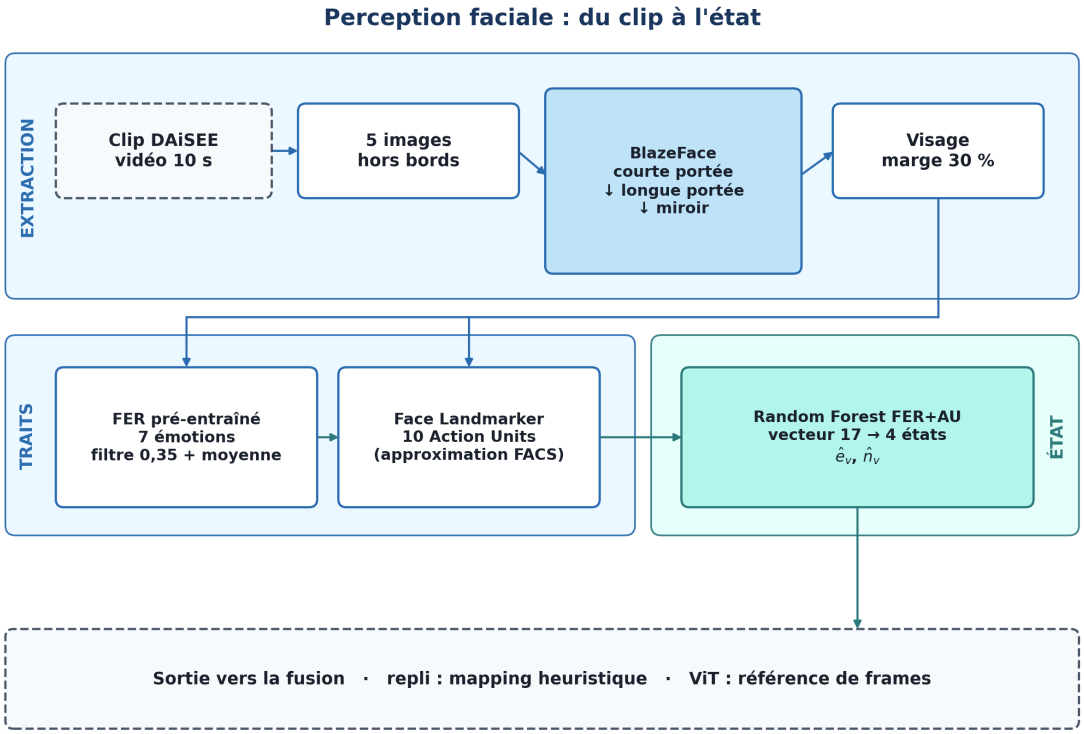


Figure 4.5 – Architecture de la perception faciale.

Le tableau 4.5 présente les paramètres d'extraction visuelle.

Opération	**Valeur**	**Motif du réglage**
Images analysées par clip	5	Compromis entre robustesse et coût sur processeur.
Position des images	régulière, hors bords	Évite les premières et dernières images, souvent floues ou en transition.
Égalisation d'histogramme	non (MediaPipe)	BlazeFace opère sur l'image RGB.
Modèle court / long	BlazeFace	Court : webcam proche (DAiSEE), long : plan plus large (IEMOCAP).
Confiance minimale (détection)	0,5	Filtre les détections trop incertaines.
Confiance minimale (frame FER)	0,35	Rejette les images trop hésitantes avant moyenne des probabilités.

Opération	**Valeur**	**Motif du réglage**
Taille minimale de visage	40 × 40 pixels	Écarte les régions trop petites pour porter une expression exploitable.
Marge autour de la boîte	30 %	Conserve le front et le menton, informatifs pour l'ennui et la confusion.

Table 4.5 – Paramètres d'extraction visuelle.

Chaque visage recadré passe par un classifieur d'images pré-entraîné à sept émotions (colère, dégoût, peur, joie, neutre, tristesse, surprise). Une image dont la probabilité maximale reste sous 0,35 est écartée. Les distributions restantes sont moyennées, si toutes tombent sous le seuil, la moyenne est reprise sans filtre.

En parallèle, MediaPipe Face Landmarker lit dix proxies d'Action Units (sourcils, paupières, nez, sourire, commissures, mâchoire), puis les moyenne sur les mêmes images retenues. Les sept scores et ces dix unités forment un vecteur de dix-sept composantes. Un Random Forest appris sur ce vecteur produit l'état DAiSEE, une distribution sur les quatre classes, et une intensité $\hat{n}_v = \text{round}(3 \max_e \hat{P}_v(e))$, bornée à $\{1, 2, 3\}$. C'est cet état qui est transmis à la fusion.

Si le modèle FER+AU est absent, le tableau 3.4 projette l'émotion dominante vers un état et un niveau. Le ViT fine-tuné vers les quatre états reste une variante commutable, en production, il sert de référence de frames, sans choisir l'état fusionné.

Les vecteurs FER, et le cas échéant les Action Units, sont mis en cache afin de relancer l'apprentissage sans redécoder les vidéos. Le cache FER compte 1 200 clips, 300 par état, le cache FER+AU en compte 800, 200 par état. La réponse expose l'état, l'intensité, les sept scores, les Action Units, le nombre d'images retenues et le code de la méthode effectivement employée.

4.4.2 Perception vocale

Cette sous-section décrit comment l'énoncé IEMOCAP apparié au scénario devient un état vocal : état, intensité et distribution sur les quatre classes.

L'appariement de la section 4.3.4 retient un énoncé d'après le filtre d'état, le profil à douze dimensions et la similarité cosinus. Le fichier audio est celui du dialogue. Le segment annoté en est lu, en monophonie, à 16 kHz, entre les bornes temporelles de l'énoncé. En l'absence de fichier, ou lorsque le signal est trop court, l'état renvoyé est l'ennui, d'intensité 1, accompagné d'un code d'erreur. La figure 4.6 présente l'architecture de la perception vocale.

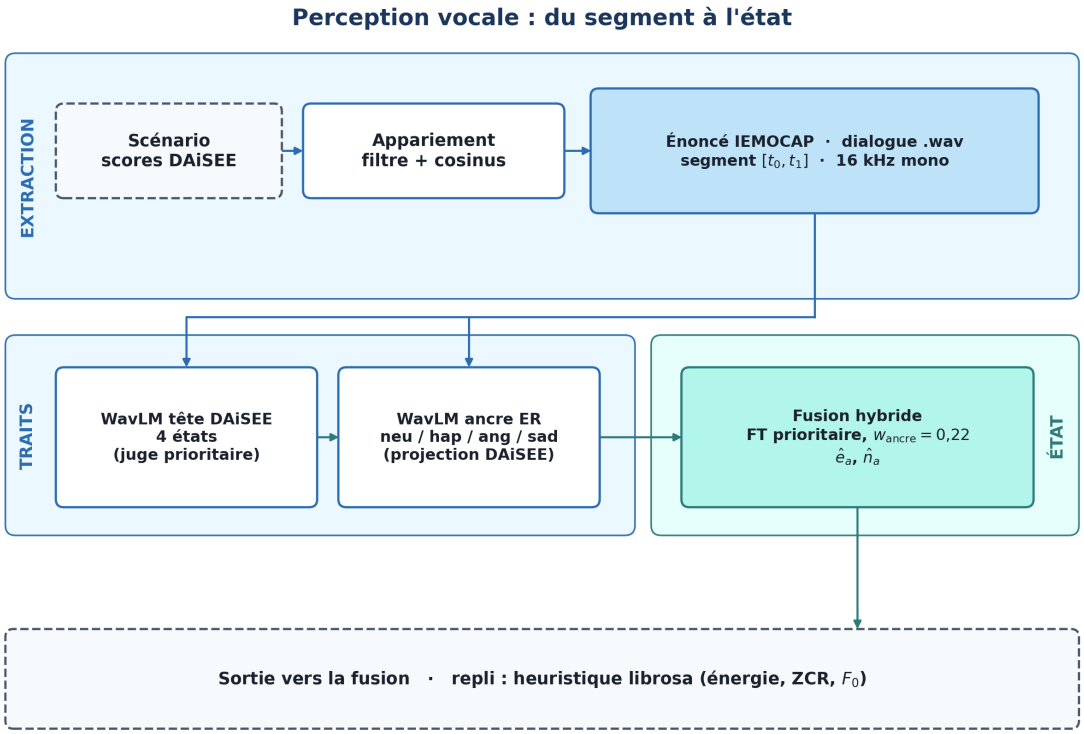


Figure 4.6 – Architecture de la perception vocale.

Le tableau 4.6 présente les paramètres d'extraction vocale.

Opération	**Valeur**	**Motif du réglage**
Échantillonnage	16 kHz, mono	Fréquence attendue par l'encodeur WavLM.
Bornes du segment	`start_time`, `end_time`	Lecture de l'énoncé annoté dans le dialogue.
Durée minimale (apprentissage)	1 s	Écarte les énoncés trop courts pour porter une prosodie exploitable.
Étiquettes exclues	`xxx`, `oth`	Retire les annotations indéterminées.
Fichier audio	obligatoire	L'apprentissage ne retient que les énoncés dont le fichier existe.
Encodeur retenu	WavLM, tête seule, 800 extraits	F-score macro de validation 0,434, graine 42.
Ancre émotionnelle	WavLM IEMOCAP ER, $w = 0{,}22$	Corrige la confusion du juge prioritaire.

Opération	**Valeur**	**Motif du réglage**
Heuristique acoustique	énergie, ZCR, centroïde, F_0	Mélange léger, ou juge unique si le modèle appris est absent.

Table 4.6 – Paramètres d'extraction vocale.

Le segment passe par un encodeur WavLM (Chen et al., 2022). Seule la tête est optimisée vers les quatre états DAiSEE. Le corpus d'apprentissage reprend la table parsée plus haut, après exclusion des étiquettes indéterminées, des énoncés trop courts et des fichiers audio absents. Une variante qui dégèle l'ensemble du réseau, mesurée sur 1 200 extraits, obtient un F-score macro de 0,396. La configuration exécutée retient la tête seule (0,434 sur 800 extraits).

En parallèle, une ancre WavLM, entraînée sur les quatre classes IEMOCAP `neu`, `hap`, `ang` et `sad`, relit le même segment, puis projette ses scores vers DAiSEE. Une heuristique acoustique estime, sur l'énergie, le taux de passages par zéro, le centroïde spectral et la fréquence fondamentale, une émotion du vocabulaire IEMOCAP, projetée ensuite selon le tableau 3.5.

Le mode hybride compose ces trois distributions. Le modèle fine-tuné reçoit le poids dominant. L'ancre reçoit un poids de 0,22, porté plus haut lorsque ce modèle conclut à la confusion et que l'ancre est confiante sur l'engagement ou la frustration. Ce poids vaut zéro lorsque le modèle fine-tuné retient l'engagement et que l'ancre conclut à la frustration. L'heuristique contribue un mélange léger. En l'absence de modèle appris, elle fournit seule l'état.

L'état $\hat{e}_a$ est la classe de probabilité maximale de la distribution fusionnée. L'intensité $\hat{n}_a = \mathrm{round}(3 \max_e \hat{P}_a(e))$ est bornée à $\{1, 2, 3\}$. C'est ce couple qui est transmis à la fusion multimodale. La réponse expose l'état, l'intensité, les quatre scores, l'identifiant de l'énoncé, la méthode (apprise ou heuristique) et l'annotation de référence du corpus.

4.4.3 Fusion des modalités

Cette sous-section décrit comment les deux distributions, faciale et vocale, deviennent le couple $(\hat{e}, \hat{n})$ et les scores $s^{(t)}$ transmis à la décision.

L'orchestrateur reçoit les deux dictionnaires renvoyés par les modules facial et vocal. Chacun porte un état, une intensité, un score lu comme confiance dans $[0, 1]$, et, lorsqu'elle est disponible, une distribution sur les quatre classes. Une modalité absente, ou marquée en erreur, a une confiance nulle. Une distribution manquante est remplacée par un pic sur l'état déclaré, de hauteur égale à cette confiance. Les deux classifieurs

opèrent séparément, leurs sorties sont composées après l'observation. La figure 4.7 présente l'architecture de la fusion multimodale.

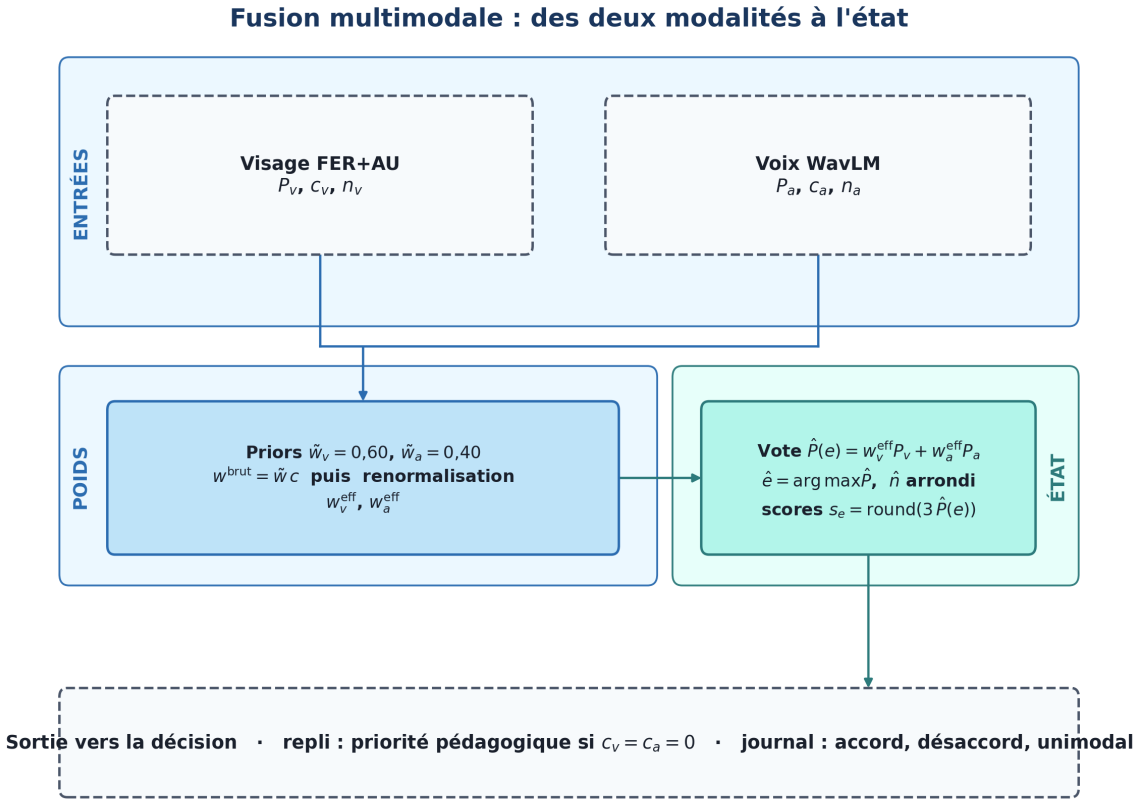


Figure 4.7 – Architecture de la fusion multimodale.

Le prior du visage $\tilde{w}_v$ vaut 0,60, le visage étant le signal annoté par DAiSEE. Celui de la voix vaut $\tilde{w}_a = 1 - \tilde{w}_v$, la piste audio de production étant un énoncé IEMOCAP apparié. Le tableau 4.7 présente les paramètres de la fusion.

Opération	**Valeur**	**Motif du réglage**
Prior visage $\tilde{w}_v$	0,60	Signal natif du visionnage, annoté par DAiSEE.
Prior voix $\tilde{w}_a$	0,40	Énoncé IEMOCAP apparié, hors piste native du clip.
Confiance c_v, c_a	score de la modalité, $[0, 1]$	Une confiance nulle ramène le poids effectif à zéro.
Niveau fusionné $\hat{n}$	arrondi du mélange des intensités	Même pondération que l'état, bornée à $\{1, 2, 3\}$.
Repli (confiances nulles)	frustration, confusion, ennui, engagement	Ordre de l'équation 3.4, dénominateur nul.

Opération	**Valeur**	**Motif du réglage**
Scores transmis s_e	$\text{round}(3\,\hat{P}(e))$	Échelle 0–3 lue par la cascade de décision.

Table 4.7 – Paramètres de la fusion multimodale.

Le poids brut de chaque modalité est le produit du prior et de la confiance. Une distribution absente annule ce produit. Si la somme des poids bruts est strictement positive, elle est ramenée à l'unité : c'est le poids effectif w_v^{eff} de l'équation 3.2. La distribution fusionnée s'écrit alors $\hat{P}(e) = w_v^{\text{eff}}\, P_v(e) + (1 - w_v^{\text{eff}})\, P_a(e)$. L'état $\hat{e}$ est la classe de masse maximale. L'intensité suit la même pondération, équation 3.3, puis l'arrondi à $\{1, 2, 3\}$.

Lorsqu'un seul poids brut est non nul, le vote se réduit à cette modalité : état, intensité et distribution sont ceux du visage, ou ceux de la voix. Lorsque les deux poids bruts valent zéro, le dénominateur du vote est nul. Parmi les états déclarés encore lisibles, l'état retenu est celui de priorité pédagogique maximale, équation 3.4 : frustration, confusion, ennui, engagement. En l'absence de tout état déclaré, l'engagement d'intensité 1 est renvoyé, avec un indicateur d'indétermination.

Le journal conserve le type de désaccord (accord des états, désaccord, modalité unique, abstention), les poids effectifs et la modalité dominante, visage si $w_v^{\text{eff}} \geq w_a^{\text{eff}}$. L'état fusionné reste celui du vote. Les quatre probabilités $\hat{P}(e)$ sont projetées en scores $s_e = \text{round}(3\,\hat{P}(e))$, lus ensuite par le moteur de décision. La comparaison entre ce vote et une fusion par résolution de conflit figure au chapitre 5, sur le sous-corpus audiovisuel aligné.

4.5 Implémentation de la couche de décision

Le modèle d'adaptation transforme un état perçu en une intention pédagogique. Sa formulation conceptuelle occupe le chapitre 3, il s'agit ici d'exposer sa traduction en code, c'est-à-dire l'ordre exact d'évaluation des règles, les seuils effectivement programmés et le traitement des cas où deux règles pourraient s'appliquer. Deux composants sont concernés : la sélection de la stratégie et du patron, et la dynamique temporelle. La fusion appartient à la couche de perception.

4.5.1 Sélection de stratégies

Le type de contenu issu de la cascade ne suffit pas à lancer une génération : il désigne une famille d'intervention, non un patron de prompt. Un second étage traduit le couple formé par ce type et le contexte du clip en l'un des vingt patrons de la bibliothèque

(tableau 3.8). Ce découplage a une raison précise : il permet de faire évoluer la bibliothèque de patrons en ajouter, en reformuler sans toucher aux règles pédagogiques, et réciproquement de modifier un seuil de décision sans réécrire de prompt. L'algorithme complet se déroule ainsi :

1. Les quatre scores sont lus dans l'état fusionné.
2. La cascade du tableau 3.6 désigne un type de contenu et une stratégie.
3. Si la dynamique temporelle conclut à l'absence de besoin d'intervention, la décision est court-circuitée.
4. Sinon, le type est raffiné en un patron précis à l'aide de l'intensité de l'état, du patron du clip et des scores individuels.
5. Les métadonnées du patron, objectif, longueur cible, format, ton sont lues dans la bibliothèque et jointes à la décision.
6. L'objet de décision, qui porte à la fois le résultat et ses déterminants, est transmis au module de génération.

La chaîne entière est l'algorithme 1. Ici, seul le raffinement du type en patron est détaillé.

Le second étage (après le test temporel) décline chaque type en un patron. Les composites ont un seul geste : $A{+}D$ vers l'aide au déblocage (A3), $D{+}A$ vers D2 ou D1 selon l'intensité. Les types simples se séparent par niveau et pattern (micro-explication A2 si la confusion est maximale, réengagement B2 si l'engagement est nul, exercice avancé C1 si l'ennui est élevé). Un cas par défaut garantit qu'aucune combinaison de scores ne reste sans patron.

Sur les cinquante scénarios du référentiel, onze des vingt patrons sont déclenchés. Les effectifs les plus élevés sont le patron D1 (encouragement, frustration d'intensité modérée, $n = 11$) et le patron C1 (exercice avancé, ennui élevé, $n = 9$). La famille D totalise 21 passages, la famille C 11. Le tableau 5.12 présente cette distribution. Elle suit la composition du référentiel, qui sur-représente les profils problématiques, et l'ordre de la cascade, qui oriente ces profils vers D1 et C1. Les neuf patrons restants (A4, B3–B5, C3–C5, D3, D5) exigent des combinaisons de scores absentes de ce passage.

4.5.2 Gestion des transitions d'état

Cette sous-section décrit le branchement du module temporel, en particulier la non-intervention.

Les règles du tableau 3.7 sont évaluées dans l'ordre d'urgence. Le module reçoit l'histo-

rique et retourne le déclenchement, le degré, la règle nommée et la durée de persistance. Les séquences de la section 4.3.6 ont cinq clips : elles couvrent les trois fenêtres.

Lorsque l'engagement se maintient à un niveau satisfaisant sur les deux derniers clips, le type de contenu devient « aucune », la stratégie une continuation normale, la décision non déclenchée. L'orchestrateur n'appelle pas le service de génération. Un objet de saut prend la place du texte. Ni le journal ni la base de sessions ne reçoivent d'enregistrement. La non-intervention se distingue, dans les traces, d'une génération qui aurait échoué.

Chaque clip d'une séquence est analysé avec l'historique cumulé des états détectés. Le mode clip isolé n'a qu'une entrée : seules les règles instantanées s'appliquent.

Hystérésis, délai de garde et filtrage des patrons répétés restent hors du moteur. Un usage longitudinal reste exposé à l'oscillation et à la saturation. Cette limite est reprise dans la conclusion générale.

4.6 Implémentation de la couche de génération

Cette section décrit la configuration du service de génération, la bibliothèque de patrons qui structure les demandes, l'assemblage du prompt effectivement envoyé, et les dispositifs de contrôle appliqués aux textes obtenus.

4.6.1 Configuration du LLM

Cette sous-section décrit le service de génération et ses paramètres.

La génération est confiée à un modèle GPT-OSS de vingt milliards de paramètres, interrogé à distance via Groq. Le coût et la latence conviennent à un corpus de plusieurs centaines de textes. Toute l'adaptation passe par le prompt : chaque contenu reste explicable par l'état, le patron et le contexte documentaire, et le dispositif est transposable à un autre fournisseur. Le tableau 4.8 présente les paramètres de génération.

Paramètre	**Valeur**	**Effet recherché**
Modèle	`openai/gpt-oss-20b`	Génération distante, coût et latence compatibles avec le corpus.
Température (contenu)	0,3	Contenus reproductibles à contexte constant.
Température (tuteur)	0,25 à 0,55	Basse en confusion, plus haute en ennui.

Paramètre	**Valeur**	**Effet recherché**
Budget de sortie (contenu)	600 (cible) / $\geq 2\,048$ (`max_tokens`)	Longueur visée des patrons, plafond relevé pour le raisonnement interne.
Budget de sortie (tuteur)	400 à 650 (cible) / $\geq 2\,048$	Cible selon la demande, même plafond.
Tentatives	4, espacées de 2, 5 puis 8 s	Absorbe les limitations de débit du service gratuit.
Fenêtre de dialogue	10 derniers messages	Borne le contexte conversationnel.
Clé d'accès	variable d'environnement	Aucun secret dans le dépôt.

Table 4.8 – Paramètres de génération.

Les dépassements de quota sont rattrapés par les tentatives du tableau. Les autres erreurs de service remontent jusqu'à l'API, qui répond par un message explicite.

4.6.2 Bibliothèque de vingt patrons de prompts

La bibliothèque des vingt patrons introduite au chapitre 3 (tableau 3.8) est implémentée en deux structures distinctes. La première est une table de métadonnées : pour chaque patron, sa famille, sa longueur cible en mots, son format attendu, son ton et son objectif pédagogique. Ces attributs sont injectés dans la section des contraintes du prompt, exposés par l'API et réutilisés par l'audit automatique comme référence de longueur. La seconde est une table de constructeurs d'instructions, une fonction par patron, qui produit le corps de la demande en y insérant les variables de contexte : concept visé, intensité de l'état, intensité spécifique de la frustration, durée de persistance et module en cours. Un patron inconnu retombe sur un patron de référence, de sorte qu'une faute de frappe dans un identifiant ne provoque jamais d'interruption. Le catalogue A1–D5 reste celui du tableau 3.8, au runtime, ces champs sont lus dans la bibliothèque et injectés dans les contraintes du prompt.

Les instructions ne demandent pas un texte libre mais une structure. Le patron d'aide au déblocage, mobilisé lorsque confusion et frustration se combinent, demande ainsi quatre éléments dans un ordre imposé : une phrase rassurante qui normalise la difficulté, l'identification du point de blocage probable, une approche radicalement différente de l'explication initiale, puis un micro-exercice guidé très simple, le tout sur environ deux cents mots et sur un ton déculpabilisant. Le patron de félicitation, à l'autre extrémité de la bibliothèque, demande de célébrer la réussite, d'expliciter la compétence acquise, de faire le lien avec la suite du parcours et de renforcer la confiance, en cent cinquante mots.

Cette forme numérotée rend le contenu généré vérifiable : un auditeur automatique ou humain peut constater la présence ou l'absence de chaque élément attendu.

4.6.3 Pipeline de génération

Cette sous-section décrit comment l'intention pédagogique (τ, γ) et le contexte de cours deviennent un texte.

Un contexte de référence est constitué, avant l'appel, par récupération augmentée (*Retrieval-Augmented Generation*, RAG) (Gao et al., 2023 ; Lewis et al., 2020). Vingt fiches — définitions, exemples, exercices et cartes de méthode — couvrent les algorithmes de tri, les réseaux de neurones, les structures de données, la complexité, la récursion et l'encouragement pédagogique. Elles sont distinctes des vingt patrons A1–D5. Un encodeur de phrases multilingue MiniLM (Wang et al., 2020) les projette, ChromaDB les indexe en similarité cosinus. Les fiches, courtes, sont indexées en entier. La figure 4.8 présente l'architecture du pipeline de génération.

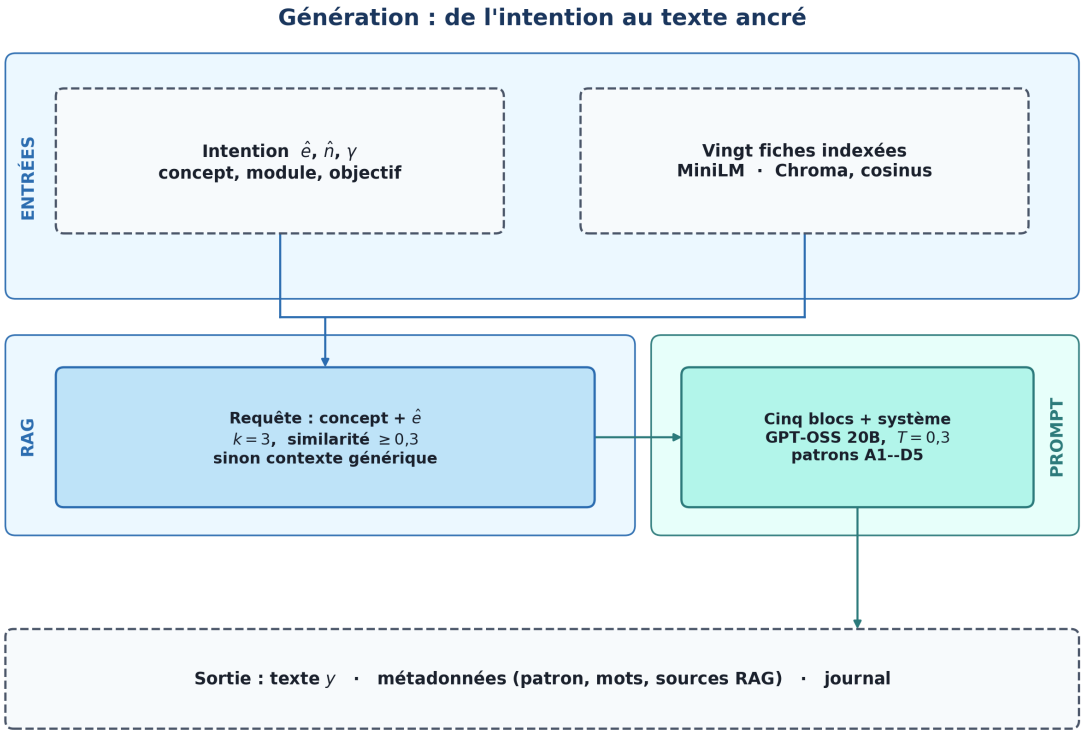


Figure 4.8 – Architecture du pipeline de génération.

Le tableau 4.9 présente les paramètres de la récupération.

Opération	**Valeur**	**Motif du réglage**
Fiches indexées	20	Corpus de démonstration, distinct des patrons A1–D5.
Encodeur	`paraphrase-multilingual-MiniLM-L12-v2`	Phrases françaises et anglaises sur un même espace.
Index	ChromaDB, espace cosinus	Persistance locale, similarité directe.
Requête	concept et état $\hat{e}$	L'appui documentaire dépend de la situation affective.
Voisins retenus k	3	Compromis entre couverture et longueur du prompt.
Seuil de similarité	0,3	Complément de la distance cosinus, écarte les fiches trop éloignées.
Repli	contexte générique (concept, état)	Conserve un appel lorsque aucun voisin ne franchit le seuil.

Table 4.9 – Paramètres de la récupération documentaire.

La requête combine le concept et l'état $\hat{e}$. Les trois plus proches sont retenus si leur similarité atteint 0,3. En deçà, un contexte générique nomme le concept et l'état.

Le prompt utilisateur suit l'ordre des cinq blocs de la figure 3.3 : contexte de référence, situation de cours, état d'engagement, tâche (identifiant γ et objectif), contraintes du patron, puis instructions spécifiques. Le message système assigne un rôle d'expert en pédagogie et restreint la génération aux faits du contexte. La durée d'état est convertie en secondes avant insertion. L'appel distant reprend les paramètres du tableau 4.8.

La réponse du module porte le texte, l'état et l'intensité qui l'ont motivé, le patron, l'objectif, le nombre de mots, l'usage effectif du RAG, le nombre et les sources des documents injectés, et le cas échéant l'erreur de récupération. L'interface les expose, le journal en conserve les principaux.

Le tuteur conversationnel réutilise ce pipeline. L'état module le ton, la consigne et la température (0,25 en confusion, 0,55 en ennui). Le budget de tokens s'étend de 400 à 650 selon la demande. Les dix derniers tours sont conservés. Le contenu adaptatif initial est réinjecté comme premier tour assistant, de sorte que le dialogue prolonge l'adaptation.

4.6.4 Post-traitement et validation

Le module de génération n'applique aucune transformation au texte reçu, hormis le comptage des mots : ni troncature, ni réécriture, ni nouvelle tentative en cas de sortie jugée insatisfaisante. Ce choix est méthodologique. Un post-traitement corrigeant silencieusement les productions rendrait impossible la mesure de la qualité intrinsèque du dispositif : on n'évaluerait plus la génération adaptative, mais la génération augmentée d'un correcteur. Le contrôle est donc reporté sur un audit hors ligne appliqué à l'ensemble du corpus, dont les verdicts alimentent une régénération ciblée.

L'audit vérifie trois familles de propriétés (tableau 4.10) : la conformité de longueur, évaluée par rapport à une plage tolérée autour de la cible du patron, la cohérence émotion–famille, et des marqueurs lexicaux attendus (explication pour A, consigne d'exercice pour C, soutien pour la frustration). Chaque anomalie porte un code et retire vingt-cinq points à un score initialisé à cent. Ce taux mesure la conformité de forme, il ne dit rien de l'exactitude factuelle ni de la pertinence pédagogique (chapitre 5). Le rapport identifie le critère enfreint.

Le tableau 4.10 présente les critères de l'audit automatique.

Code d'anomalie	**Propriété vérifiée**
`trop_court` · `trop_long`	Longueur du contenu au regard de la cible déclarée par le patron.
`emotion_template_suspect`	Compatibilité entre l'émotion enregistrée et la famille du patron.
`manque_marqueurs_explication`	Présence de marqueurs de reformulation dans un contenu de famille A.
`manque_marqueurs_exercice`	Présence d'une consigne d'exercice dans un contenu de famille C.
`ton_trop_positif_pour_frustration`	Absence de registre de félicitation dans un contenu de soutien.
`confusion_sans_ton_rassurant`	Présence d'un registre rassurant dans un contenu de déblocage.
`template_inconnu`	Existence du patron déclaré dans la bibliothèque.

Table 4.10 – Critères d'audit automatique.

En parallèle de l'audit, un script calcule des indicateurs de forme sur le corpus exporté ($N = 208$) : nombre de mots et de phrases, mots par phrase, indice de Kandel–Moles approché par comptage syllabique, et taux de répétition $1 - |V|/|T|$, où V est le voca-

bulaire et T les tokens. Ces grandeurs caractérisent la forme du corpus au chapitre 5, à côté de l'appréciation enseignante.

4.7 Algorithme global

Cette section relie les trois couches en un unique parcours d'exécution.

L'orchestrateur reçoit un clip vidéo v, un segment audio a, le contexte pédagogique c et l'historique H des scores détectés. Il produit un texte y, ou l'objet de saut $\varnothing$ lorsque l'urgence vaut « aucune ». Le journal J accompagne y. L'algorithme 1 présente cette chaîne.

Algorithme 1 Chaîne complète EmoLearn : perception, décision, génération

Entrée : clip vidéo v, segment audio a, contexte pédagogique c, historique H
Sortie : contenu y ou $\varnothing$, journal J si génération

$(P_v, n_v, c_v) \leftarrow \mathrm{FER}(v)$
$(P_a, n_a, c_a) \leftarrow \mathrm{SER}(a)$
si $c_v = c_a = 0$ **alors**
    $\hat{e} \leftarrow \arg\max_{e \in E} \pi(e)$, $\hat{n}$ du candidat retenu ▷ repli
sinon
    $(w_v^{\mathrm{eff}}, \hat{P}, \hat{e}, \hat{n}) \leftarrow$ vote pondéré
fin si
$s_e \leftarrow \mathrm{round}(3\,\hat{P}(e))$ pour tout $e \in E$
$H \leftarrow H \cup \{s\}$
$u \leftarrow \mathrm{urgence}(H)$ ▷ tableau 3.7
si $u =$ aucune **alors**
    retourner $\varnothing$
fin si
$(\tau, \gamma) \leftarrow \Delta(\hat{e}, \hat{n}, s, H)$ ▷ tableau 3.6
$r \leftarrow \mathrm{RAG}(c, \hat{e})$
$y \leftarrow \mathrm{LLM}\big(\mathrm{prompt}(c, s, \gamma, r)\big)$
journaliser $(\hat{e}, \tau, \gamma, u)$ dans J
retourner $(y,\ J)$

Les étapes de perception correspondent aux sections 4.4.1 à 4.4.3. Les scores s alimentent H avant l'urgence, y compris en mode clip isolé, où H ne contient alors que le vecteur courant. Lorsque u vaut « aucune », l'orchestrateur retourne l'objet de saut, sans appel au modèle. Dans les autres cas, Δ fixe (τ, γ), le RAG ancre le prompt et le LLM produit y.

4.8 Développement du prototype de simulation

Cette section décrit l'interface de simulation. Le prototype rend observable la chaîne de l'algorithme 1 : état de chaque modalité, fusion, patron retenu et sources documentaires.

4.8.1 Interface de visualisation

Cette sous-section décrit l'application cliente et l'agencement des vues.

L'interface est une application React en page unique. La configuration, l'attente et les résultats occupent des sections successives de la même vue. Deux modes d'entrée coexistent : un clip isolé, parmi les cinquante scénarios, et une séquence de cinq extraits du même apprenant DAiSEE. L'adresse du serveur est lue dans `REACT_APP_API_URL`, à défaut `http://localhost:8000`. Un indicateur interroge l'API toutes les 30 s et sépare l'indisponibilité du service d'une analyse sans contenu.

Le tableau 4.11 présente les composants de l'interface.

Composant	**Rôle dans l'observation de la chaîne**
Sélecteur de scénario	Liste filtrable des cinquante scénarios, avec repère coloré de l'état dominant.
Bascule clip / séquence	Passage du mode isolé au parcours multi-clips (cinq extraits du même apprenant DAiSEE).
Lecteur vidéo DAiSEE	Lecture du clip source, distincte de l'analyse FER.
Lecteur audio IEMOCAP	Voix appariée, annotation corpus vs aperçu SER WavLM.
Vignettes de séquence	Cinq images du même sujet, dans l'ordre du parcours.
Diagramme en barres / radial	Profil des quatre dimensions du scénario.
Flux de pipeline	Engagement, décision, récupération documentaire, contenu.
Panneau d'attente	Messages d'étape pendant l'analyse.
Pastille d'état	Codage couleur constant dans tout l'écran.
Tuteur conversationnel	Dialogue prolongeant l'adaptation, RAG activé par défaut.
Étapes de parcours	États clip par clip, règle temporelle, non-intervention.

Composant	**Rôle dans l'observation de la chaîne**
Historique latéral	Dix dernières adaptations, rechargées au démarrage.

Table 4.11 – Composants de l'interface.

En mode clip, l'utilisateur sélectionne l'un des cinquante scénarios, des raccourcis regroupent les profils par état dominant. Les lecteurs prévisualisent le clip DAiSEE et l'énoncé IEMOCAP apparié. Le contexte pédagogique (niveau, moment, concept, module) est optionnel et alimente le prompt. La figure 4.9 présente la configuration d'un clip isolé.

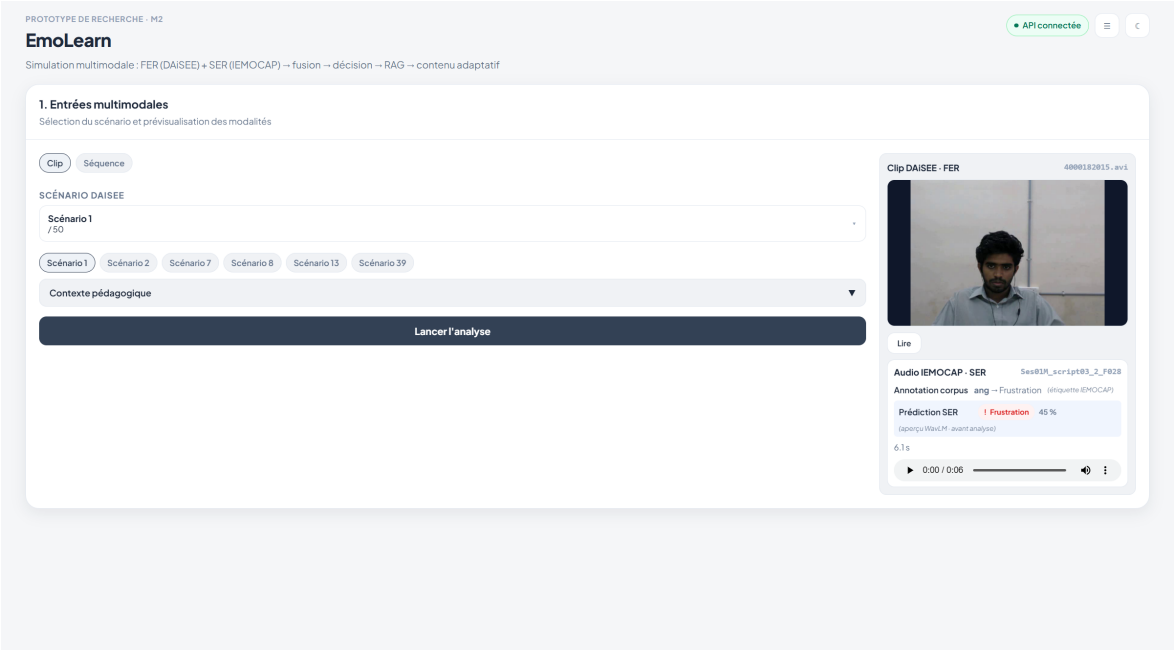


Figure 4.9 – Interface en mode clip.

En mode séquence, un parcours de cinq extraits du même apprenant DAiSEE remplace le scénario unique. Une grille de vignettes ordonne les clips, une seule requête enchaîne les analyses avec l'historique cumulé, décrit à la section 4.8.2. La figure 4.10 présente l'interface en mode séquence.

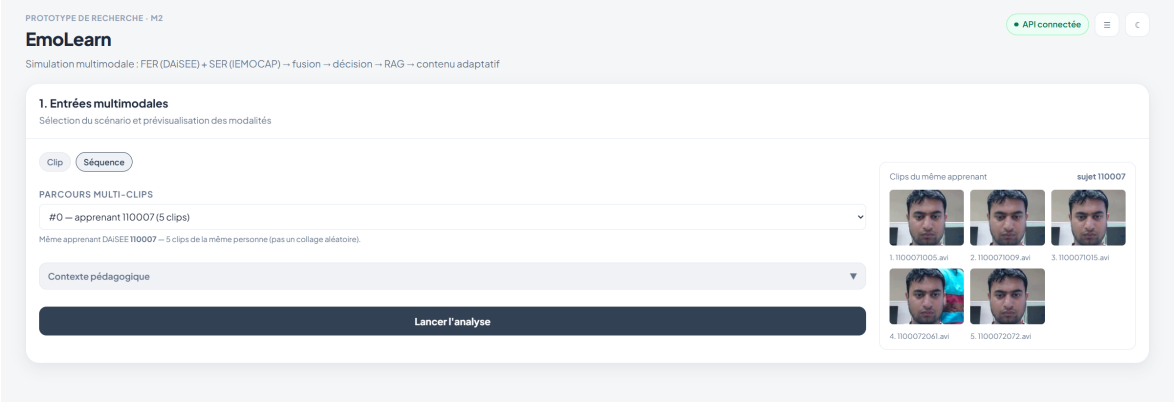


Figure 4.10 – Interface en mode séquence.

Le diagramme en barres est construit en éléments de mise en page, le diagramme radial est un dessin vectoriel. Les quatre états partagent le même codage couleur sur les pastilles, les graphiques et les cartes de fusion.

4.8.2 Lecteur de parcours d'apprentissage

Cette sous-section décrit l'exécution d'un parcours multi-clips.

Un parcours est une suite ordonnée de cinq clips d'un même sujet DAiSEE, parmi les dix séquences de la section 4.3.6. L'utilisateur en sélectionne une. Une requête unique enchaîne les analyses : chaque extrait emprunte le pipeline du mode clip (FER+AU, voix appariée, fusion), avec l'historique H des scores déjà produits.

Par défaut, le service de génération est sollicité pour le dernier clip, afin de borner le coût d'API. Les étapes intermédiaires conservent l'état détecté, le patron et la règle temporelle. Seule la dernière génération est écrite dans le journal et la table des sessions.

Après l'analyse, une liste d'étapes reprend, pour chaque clip, l'état détecté, le patron, la règle temporelle et le déclenchement. Les trois fenêtres d'urgence — un clip, deux clips consécutifs, quatre clips — deviennent lisibles à mesure que H s'allonge. L'historique latéral recharge les dix dernières sessions au démarrage.

4.8.3 Affichage des adaptations

Cette sous-section décrit l'écran de résultat.

L'écran place la décision avant le texte. Un bandeau affiche l'état détecté et son intensité. Les métadonnées indiquent le patron γ, sa famille τ et le nombre de documents RAG. Une carte reprend la description renvoyée par Δ. Le journal d'étapes suit ces indicateurs : visage, voix, fusion, scores, règle temporelle et patron.

Lorsque les deux modalités sont actives, trois cartes juxtaposent l'état facial, l'état vocal et l'état fusionné. Les sources documentaires apparaissent sous le texte généré.

Le contenu porte le patron, l'objectif et le nombre de mots. La copie vers le presse-papiers et l'export PDF (concept, état, intensité, patron) ont servi aux fiches soumises aux évaluateurs du chapitre 5. Un tuteur conversationnel optionnel prolonge l'adaptation, avec le contenu initial comme premier tour.

La section « Perception et décision » occupe le haut de l'écran, le contenu généré, le patron et les sources RAG occupent le bas. La figure 4.11 présente l'écran de résultat.

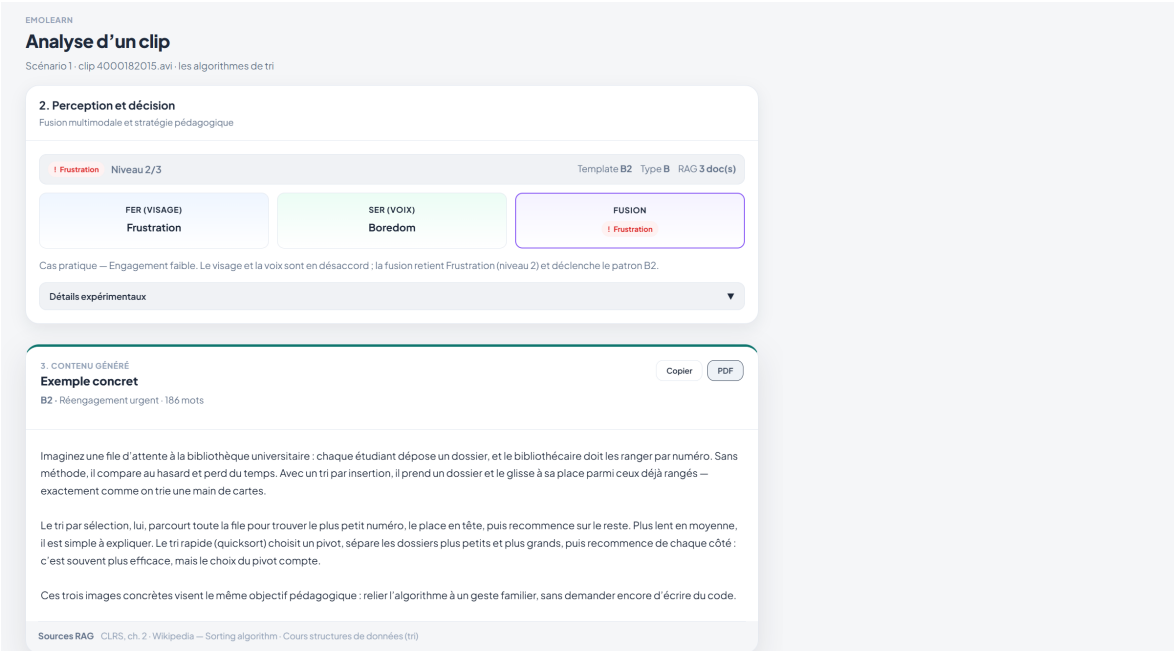


Figure 4.11 – Écran de résultat.

4.9 Génération du corpus de contenu adaptatif

Cette section décrit la production du corpus adaptatif, ses artefacts et des extraits.

4.9.1 Génération et documentation du corpus

Cette sous-section décrit la production, l'audit et les fichiers livrés.

Le corpus est produit sur les cinquante scénarios du référentiel. La chaîne complète est appliquée à chaque scénario, pour plusieurs patrons compatibles avec son état. Le passage automatique déclenche onze patrons, le corpus en documente dix-neuf. Le patron C5 (exercice comparatif) reste sans ligne.

L'audit porte sur 220 contenus. Chaque ligne enregistre l'identifiant du clip, le patron, l'émotion, l'intensité, le texte et le nombre de mots. L'export des métriques de forme en retient 208 : douze lignes étaient absentes ou incomplètes au moment du calcul.

Le corpus a été obtenu en plusieurs passes. Un audit initial a signalé surtout des associations émotion–famille. Une correction des métadonnées, par recalcul de la décision,

a relevé la conformité de forme. Une régénération sélective des lignes restantes, précédée d'une sauvegarde et séparée par un délai entre appels, a porté cette proportion à 97,7 % (215/220 : longueur, famille, marqueurs lexicaux). Cinq contenus restent hors critère. L'état initial, la correction et l'état final font partie du livrable.

Le tableau 4.12 présente les artefacts du corpus adaptatif.

Artefact	**Contenu**	**Volume**
Corpus de contenus	Texte généré, patron, émotion, intensité, nombre de mots (208 lignes exportées)	220 générés / 208 exportés
Rapport d'audit	Anomalies détectées et score de qualité par contenu	220
Indicateurs de forme	Longueur, phrases, lisibilité approchée, répétition	208
Échantillon d'évaluation	Tirage stratifié par famille de patron	58
Fiches d'évaluation	Extrait de contenu et grille de notation à remplir	58
Table de décisions	État, stratégie et patron retenus par scénario	50

Table 4.12 – Artefacts du corpus adaptatif.

Les fiches d'évaluation sont générées par script, à partir d'un tirage stratifié initialisé par une graine fixe. L'effectif visé était de soixante contenus, quinze par famille, cinquante-huit fiches ont été obtenues, du fait de la couverture inégale des familles. Ces effectifs, et le protocole enseignant, sont ceux du chapitre 5.

4.9.2 Exemples de contenu généré

Les extraits ci-dessous proviennent du corpus et portent sur le même concept, « les algorithmes de tri ». Ils relèvent des familles A, B, C et D. Le texte intégral et les métadonnées (clip, patron, sources RAG) restent dans l'export.

A3 — aide de déblocage (confusion et frustration, 195 mots) :

> « Ce concept est complexe, c'est normal. La plupart des gens ont du mal à comprendre les algorithmes de tri au début. Alors, ne vous inquiétez pas si vous avez du mal à les mettre en pratique. »

> Il semble que vous ayez du mal à comprendre pourquoi certains algorithmes de tri fonctionnent mieux que d'autres. C'est peut-être en raison de la complexité des étapes impliquées. Pour simplifier les choses, imaginez que vous devez organiser des livres sur une étagère. Vous voulez les organiser par ordre alphabétique, mais vous n'avez pas de tableau de bord pour montrer la progression.
>
> Essayez de visualiser les algorithmes de tri comme des processus de tri des livres. Pensez à la manière dont vous pouvez utiliser des étiquettes ou des cartes pour les organiser de manière logique. [...]
>
> Exercice guidé : imaginez que [...]

Le marqueur d'ouverture imposé par A3 (« Ce concept est complexe, c'est normal ») est présent. L'analogie des livres et le mini-exercice suivent les quatre consignes du patron.

B1 — application concrète (ennui, 199 mots) :

> L'exemple de l'application de l'algorithme de tri dans le monde de la musique. Imaginez que vous êtes le coordonnateur d'une grande fête de musique. Vous avez reçu plusieurs centaines de CD que vous souhaitez classer par ordre alphabétique pour les présenter à vos invités. [...] Vous pouvez utiliser l'algorithme de tri rapide (*quick sort*) qui a une complexité en temps de $O(n \log n)$. [...] Vous choisissez une piste aléatoire et vous la considérez comme la « pièce maîtresse » de votre ordre. [...]

Le texte part d'une situation concrète et nomme une complexité. L'exactitude de ce chiffre relève du chapitre 5.

C2 — exercice progressif (336 mots) :

> Exercice de consolidation : algorithmes de tri et structures de données. Vous avez bien compris les algorithmes de tri, mais maintenant il est temps de les appliquer à des scénarios plus complexes. [...]
>
> Étape 1 — tri simple. Un magasin a une liste de produits avec leurs prix. Triez cette liste par ordre croissant de prix. [...]
>
> Étape 2 — tri avec structure de données. Une université a une liste d'étudiants (noms, dates de naissance, notes). Triez par nom puis par date de naissance, en choisissant une structure adaptée. [...]

La longueur (336 mots) dépasse la cible nominale de 200 mots du patron C2, elle reste dans la fourchette de famille C retenue pour l'audit de forme (200–360 mots).

D2 — message de soutien (frustration, 168 mots) :

> Je vois que les algorithmes de tri te rendent un peu perdu(e) en ce moment. C'est tout à fait normal ! [...] Prenez une pause si nécessaire. [...] Une stratégie qui

> a aidé de nombreux apprenants est de commencer par comprendre les principes de base du tri et d'identifier les différents types d'algorithmes (tri par insertion, tri à bulles, etc.). [...] Rappelle-toi que la persévérance est plus importante que la vitesse.

Les quatre consignes de D2 (pause, normalisation, stratégie, persévérance) sont présentes. Le même enregistrement contenait une statistique (« 85 % des apprenants ») absente des fiches RAG. Ce cas d'hallucination chiffrée est repris au chapitre 5.

4.10 Conclusion

Le prototype exécute la chaîne spécifiée. La perception faciale repose sur FER+AU, la perception vocale sur WavLM et un énoncé IEMOCAP apparié, la fusion sur des priors 0,60/0,40. La décision Δ retient onze patrons sur le référentiel et court-circuite la génération lorsque l'urgence vaut « aucune ». La génération est ancrée par vingt fiches RAG et vingt patrons, via GPT-OSS. L'algorithme 1 relie ces étages. L'interface expose l'état, la fusion, le patron et les sources, en clip isolé et en parcours de cinq extraits.

Le corpus livré compte 220 contenus ($N = 208$ pour les métriques de forme), dix-neuf patrons, un audit de forme à 97,7 %. Hystérésis et session identifiée restent hors du moteur. Le chapitre 5 évalue la perception, la décision et la qualité pédagogique de ce corpus.

Chapitre 5

Validation et résultats

Sommaire

5.1 Introduction **75**

5.2 Méthodologie d'évaluation multi-niveaux **75**

5.2.1 Approche globale 75

5.2.2 Deux cadres d'évaluation de la fusion 76

5.2.3 Métriques et critères 76

5.3 Validation de la perception et de la fusion **77**

5.3.1 Le piège de l'accuracy : classifieur FER déséquilibré 77

5.3.2 Module de décision : Random Forest basé sur FER + AU 77

5.3.3 Fine-tuning SER : WavLM vers DAiSEE 78

5.3.4 Appariement vocal : index acoustique 79

5.3.5 Banc d'essai audiovisuel aligné ($n = 80$) 79

5.3.6 Proxy du pipeline produit 81

5.3.7 Analyse de sensibilité du mapping IEMOCAP $\rightarrow$ DAiSEE 81

5.4 Validation du modèle d'adaptation **81**

5.4.1 Analyse de la pertinence du mapping 82

5.4.2 Couverture des états d'engagement 82

5.5 Validation de la qualité du contenu généré **83**

5.5.1 Ancrage documentaire (RAG) 83

5.5.2 Évaluation experte (3 enseignants $\times$ 8 exemples) 84

5.5.3 Métriques automatiques (lisibilité, longueur, diversité) 84

5.5.4 Analyse comparative par type de contenu 85

5.6 Validation utilisateur **86**

5.6.1 Simulation de parcours adaptatifs 86

5.6.2 Enquête d'acceptabilité de l'idée ($n = 15$) 86

5.7 Synthèse des résultats **87**

5.7.1 Retours qualitatifs 88
5.8 Discussion 88
5.8.1 Lecture des mesures 88
5.8.2 Positionnement 89
5.8.3 Portée et limites 89
5.9 Conclusion 89

5.1 Introduction

Le chapitre précédent a livré le prototype : perception faciale et vocale, fusion, décision Δ, génération ancrée, interface de simulation, et un corpus de 220 contenus. Le présent chapitre évalue cet artefact selon quatre niveaux : la perception et la fusion, la cohérence du mapping état $\rightarrow$ stratégie, la qualité pédagogique du corpus, et l'acceptabilité de l'idée ($n = 15$).

Deux cadres portent les mesures de fusion. Ils partagent le moteur de décision, le régime de vérité terrain diffère. Le pipeline produit associe un clip DAiSEE à une voix IEMOCAP appariée : visage et voix appartiennent à des locuteurs distincts. Le banc d'essai isole, dans IEMOCAP, des paires audiovisuelles synchronisées (même locuteur, même instant). Chaque métrique est lue dans le cadre qui la rend interprétable.

Les mesures collectées portent sur la classification visage et voix, le banc aligné ($n = 80$), les correspondances du référentiel ($n = 50$), la forme du corpus, une grille enseignante L2 ($n = 3$, huit extraits) et l'enquête d'idée. L'évaluation Likert experte L1 et le pilote C1/C2 sont reportés en perspective.

5.2 Méthodologie d'évaluation multi-niveaux

5.2.1 Approche globale

L'évaluation s'organise en quatre niveaux complémentaires :

1. **Niveau technique — perception :** Exactitude des modules visage (FER+AU, juge produit), voix (WavLM fine-tuné vers DAiSEE, hybride avec ancre IEMOCAP) et fusion multimodale, sur des jeux de test documentés. Deux cadres coexistent : le banc audiovisuel aligné ($n = 80$) et un proxy du pipeline produit (journal de décisions du référentiel).
2. **Niveau décision — correspondances :** Cohérence du mapping engagement $\rightarrow$ stratégie sur le référentiel ($n = 50$ clips joints), tables de contingence état fusionné $\times$ famille A/B/C/D, V de Cramér, et comportement des règles temporelles sur les parcours multi-clips.
3. **Niveau contenu :** Métriques automatiques de forme (longueur, lisibilité, audit heuristique) et de cohérence interne (BLEU / ROUGE) sur le corpus généré, évaluation enseignante L2 ($n = 3$, 8 textes).
4. **Niveau utilisateur :** Enquête d'acceptabilité de l'idée ($n = 15$) hors prototype.

5.2.2 Deux cadres d'évaluation de la fusion

Le tableau 5.1 présente les deux cadres : ils partagent le moteur de fusion, pas le régime de vérité terrain. Il rappelle ce que chaque cadre permet et interdit d'affirmer.

	Pipeline produit	**Banc d'essai aligné**
Visage	Clip DAiSEE réel, FER+AU	Vidéo IEMOCAP (Session 1)
Voix	Audio IEMOCAP apparié (filtre d'état + profil acoustique)	Même locuteur, même segment
Vérité terrain	État dominant DAiSEE du clip (proxy, pas d'or multimodal)	Émotion IEMOCAP projetée vers DAiSEE
Ce que l'on mesure	Comportement du runtime tel qu'il est servi par l'API	Apport de la fusion *sans* biais d'appariement

Table 5.1 – Deux cadres d'évaluation.

Le banc d'essai ($n = 80$) est chiffré avec le stack produit (FER+AU, WavLM hybride, vote à incertitude).

5.2.3 Métriques et critères

Les métriques varient selon le niveau :

— **Classification** : accuracy, F1 macro, rappels par classe — en particulier Frustration et Confusion, les états pédagogiquement urgents. L'accuracy seule est trompeuse sur DAiSEE (≈75 % d'Engagement).

— **Fusion** : accuracy versus rappel des états urgents (Confusion ∪ Frustration), sensibilité aux poids visage/voix, cas synthétiques de pondération par incertitude.

— **Appariement vocal** : similarité cosinus du profil, proportion de voix changées, alignement sur l'état cible.

— **Corpus généré** : longueur, indice Kandel–Moles, taux de répétition, conformité à l'audit automatique, BLEU-4 et ROUGE-1/2/L (référence interne par patron, pas d'or expert).

— **Correspondances** : concordance famille (cascade sur labels DAiSEE versus type journalisé), admissibilité du type au regard de l'état fusionné, V de Cramér sur la table état × famille.

— **Évaluation experte** : L2 $n = 3$ enseignants, 8 extraits (Q1–Q6).

— **Acceptabilité** : enquête d'idée $n = 15$ (Likert 1–7, SUS imaginé).

5.3 Validation de la perception et de la fusion

5.3.1 Le piège de l'accuracy : classifieur FER déséquilibré

Un premier Random Forest a été entraîné sur 1 200 clips DAiSEE en respectant la distribution naturelle (≈74 % Engagement). Sur le jeu de test ($n = 300$), le modèle appris atteint une accuracy de 0,723 contre 0,193 pour le mapping heuristique $7 \to 4$, soit un gain absolu de +0,530. Ce gain d'exactitude masque un effondrement sur la classe majoritaire.

Le tableau 5.2 présente l'effondrement du FER sur la classe majoritaire.

Approche	**Accuracy**	**F1 macro**	Rappel Fru./Conf.
Mapping heuristique	0,193	0,141	≈ 0
RF déséquilibré (1 200 clips)	0,723	0,264	0 % / 0 %
Gain	+0,530	+0,123	—

Table 5.2 – Effondrement du FER sur la classe majoritaire.

Ce chiffre, s'il était isolé, donnerait une image fausse du module. Le rappel est nul sur Confusion et Frustration : le classifieur prédit presque exclusivement Engagement. Or ce sont précisément les états qui doivent déclencher une intervention. L'accuracy élevée n'est donc pas un succès pédagogique, elle justifie le passage à un protocole stratifié et à des descripteurs plus riches (Action Units).

5.3.2 Module de décision : Random Forest basé sur FER + AU

Architecture du juge (ViT-émotions + AU + Random Forest) : chapitre 4. Ici, le protocole stratifié (800 clips, 200 par état, test $n = 200$ équilibré) se compare à l'heuristique et au RF sans AU (tableau 5.3, l'astérisque désigne un test équilibré).

Le tableau 5.3 présente les scores du juge FER+AU.

Variante	**Acc.**	**F1**	**Rapp. Fru.**	Rapp. Conf.
Heuristique (même split FER+AU)	0,26	0,19	4 %	8 %
RF 7 scores, stratifié 300/état	0,28*	0,27	20 %	41 %
FER+AU (retenu)	0,37	0,37	**34 %**	34 %

Table 5.3 – Mapping visage vers DAiSEE.

Le F1 macro passe de 0,19 (heuristique) à 0,37 (+0,18). Les AU aident à séparer Frustration et Confusion. L'accuracy (0,37) est inférieure au 0,72 du modèle déséquilibré : c'est le prix d'un test équitable et d'un rappel non nul sur les classes rares.

La matrice de confusion du juge retenu (tableau 5.4) détaille cette répartition.

Le tableau 5.4 présente la matrice de confusion FER+AU.

	Bor.	**Conf.**	**Eng.**	**Fru.**
Ennui (GT)	18	7	17	8
Confusion (GT)	3	17	14	16
Engagement (GT)	5	14	22	9
Frustration (GT)	5	15	13	17

Table 5.4 – Matrice de confusion FER+AU (test équilibré $n = 200$).

Les rappels par état s'établissent à 36 % pour l'ennui, 34 % pour la confusion, 44 % pour l'engagement et 34 % pour la frustration. Un ViT fine-tuné vers les quatre états, sur le même protocole équilibré (800 extraits), atteint un F1 de 0,39 et un rappel Frustration de 48 % (+14 points par rapport à FER+AU). Les ablations (2 ou 4 couches) restent à 0,36–0,37 de F1, un cache élargi ($\approx$ 1 566 clips) laisse le F1 inchangé. Le ViT est conservé comme filtre de frames et recours, FER+AU reste le juge transmis à la fusion.

5.3.3 Fine-tuning SER : WavLM vers DAiSEE

Le protocole d'apprentissage (tête WavLM, ablation complète, ancre hybride, mode dégradé librosa) est au chapitre 4. Le tableau 5.5 présente les scores du fine-tuning SER.

Modèle	**Éch.**	**Acc.**	**F1**	Rôle
WavLM DAiSEE tête	800	0,453	0,434	Défaut runtime
WavLM DAiSEE complet	1 200	0,457	0,396	Ablation (F1 inférieur)
WavLM ancre IEMOCAP ER	1 200	0,533	0,512	Hybride (`neu/hap/ang/sad`)

Table 5.5 – Fine-tuning SER WavLM.

Le checkpoint retenu est l'époque 2 (F1 0,434), les époques 3 à 5 ne l'améliorent pas. Confusion reste la classe la plus difficile (146 exemples contre 200, rappel 27 %), Frustration est bien rappelée (82 %). Le hybride priorise WavLM DAiSEE ($w_{\text{ancre}} = 0{,}22$ par défaut, soit ≈78 % au fine-tune) et n'appelle l'ancre que si le fine-tune dit Confusion alors que l'ancre est confiante sur Engagement ou Frustration.

5.3.4 Appariement vocal : index acoustique

La règle d'appariement (filtre d'état, profil à 12 dimensions, index 10 039 énoncés) est aux chapitres 3 et 4. L'évaluation A/B sur les 50 scénarios (tableau 5.6) compare le profil VAD seul à l'ajout de l'acoustique : similarité 0,739 contre 0,759 (Δ+0,020), 80 % des voix changées, alignement d'état inchangé (100 %). L'index change donc le choix dans le pool, pas l'état. La limite demeure : les descripteurs acoustiques du scénario DAiSEE sont un *proxy* (pas d'audio natif). On mesure une similarité de profil, pas un jugement « bonne voix ».

Le tableau 5.6 présente les résultats de l'appariement vocal.

Métrique	**VAD seul (A)**	**+ acoustique (B)**
Similarité moyenne	0,739	0,759
Δ similarité moyen	—	+0,020
Voix changée	—	40/50 (80 %)
Alignement état cible	100 %	100 %

Table 5.6 – Appariement vocal ($n = 50$).

5.3.5 Banc d'essai audiovisuel aligné ($n = 80$)

Construction du sous-corpus (Session 1, même locuteur, 20 segments par état) : chapitre 4. Les deux cadres d'évaluation sont au tableau 5.1. Le tableau 5.7 présente le banc aligné avec le stack produit (FER+AU, WavLM hybride, vote à incertitude, visages à 98,8 %).

Variante (stack produit)	**Accuracy**	**Rappel urgents**
Visage — FER+AU (5 images)	0,312	0,750
Voix — SER heuristique	0,263	0,150
Voix — SER WavLM hybride	0,425	0,225
Fusion — perception faible	0,275	0,225
Fusion — vote à incertitude	0,487	0,350

Table 5.7 – Fusion multimodale ($n = 80$), stack déployé.

Lecture : Le vote à incertitude atteint 0,487 d'accuracy et 0,350 de rappel urgent. Il dépasse WavLM (0,425) et le visage FER+AU (0,312). Confusion est reconnue 5 fois sur 20, comme le détaille la matrice de confusion (tableau 5.8).

Le tableau 5.8 présente la matrice de confusion de la fusion.

	Bor.	**Conf.**	**Eng.**	**Fru.**
Ennui (GT)	15	3	0	2
Confusion (GT)	13	5	1	1
Engagement (GT)	4	1	11	4
Frustration (GT)	10	0	2	8

Table 5.8 – Matrice de confusion de la fusion ($n = 80$).

Le runtime retient le vote à incertitude (prior 60 %/40 %, chapitre 3). Le balayage (tableau 5.9) retient le couple 0,6/0,4, qui y maximise le rappel urgent (0,425).

Le tableau 5.9 présente le balayage des poids de fusion.

Poids visage / voix	**Accuracy**	**Rappel urgents**
0,5 / 0,5	0,287	0,375
0,6 / 0,4 (retenu)	0,300	0,425
0,7 / 0,3	0,338	0,400
0,8 / 0,2	0,325	0,350

Table 5.9 – Balayage des poids de fusion ($n = 80$).

Le couple 0,6/0,4 maximise le rappel urgent, 0,7/0,3 maximise l'accuracy sur cette grille. Les poids effectifs s'écrivent $w = \text{prior} \times \text{confiance}$. Six cas synthétiques (modalité bruitée, incertitude totale, accord, prior visage) vérifient ce mécanisme : la pondération continue obtient 6/6. Une voix bruitée est sous-pondérée, le repli pédagogique n'intervient que lorsque les deux confiances sont nulles.

5.3.6 Proxy du pipeline produit

Sur le journal de décisions des cinquante scénarios du référentiel, le fichier proxy compte $n = 50$ lignes (un clip unique chacun). L'accuracy versus l'état dominant DAiSEE (priorité pédagogique en cas d'égalité, pas une étiquette audiovisuelle conjointe) s'établit à 0,46 (23/50). Le rappel des états urgents vaut 0,625 : une part des clips annotés Confusion ou Frustration est bien classée urgente, tandis que Frustration est encore trop souvent prédite (vingt-trois fois pour seize clips annotés). Quelques urgents annotés échappent donc encore à la fusion. Ces scores mesurent la cohérence du runtime avec l'état dominant DAiSEE sous appariement, non une exactitude multimodale sur un or visage–voix conjoint.

5.3.7 Analyse de sensibilité du mapping IEMOCAP → DAiSEE

Sur 10 039 utterances IEMOCAP, des variantes plausibles du mapping émotion → engagement modifient jusqu'à 17 % des étiquettes. La correspondance neutre → Ennui, en particulier, n'est pas anodine : la reclasser en Engagement déplacerait 1 708 énoncés. Cette sensibilité confirme que le mapping est une hypothèse de construit, pas une équivalence psychologique, et justifie une validation experte prioritaire.

Le mapping de référence associe neutre et tristesse à l'ennui, colère, frustration et dégoût à la frustration, joie et excitation à l'engagement, surprise et peur à la confusion. Le tableau 5.10 chiffre l'effet de quatre variantes plausibles.

Le tableau 5.10 présente la sensibilité du mapping IEMOCAP vers DAiSEE.

Variante	**Énoncés modifiés**	**%**
neutre → Engagement	1 708	17,0
tristesse → Frustration	1 084	10,8
surprise → Engagement	107	1,1
dégoût → Ennui	2	≈ 0

Table 5.10 – Sensibilité du mapping IEMOCAP vers DAiSEE ($n = 10\,039$).

5.4 Validation du modèle d'adaptation

Cette section mesure le mapping engagement → stratégie sur deux axes : pertinence (le type servi est-il celui que l'état justifie ?) et couverture des quatre états.

5.4.1 Analyse de la pertinence du mapping

La pertinence se lit à deux niveaux. Sur les labels annotés, la cascade est-elle fidèle à elle-même ? Sur l'état fusionné servi à l'apprenant, le type journalisé est-il encore celui que justifie cet état ? Le journal des décisions a été joint aux scores DAiSEE ($n = 50$).

Cohérence du moteur sur les scores annotés : La cascade A/B/C/D appliquée aux quatre scores DAiSEE du scénario reproduit 98 % des familles journalisées et 82 % des patrons exacts (un clip live hors famille attendue sur labels, le reste, écarts de sous-type). Le V de Cramér famille annotée × famille journalisée vaut 0,965. Le mapping reste très fidèle dès que l'état d'entrée est le label.

Écart perception / décision journalisée : Dès que l'entrée est l'état détecté, la pertinence chute. L'état fusionné ne coïncide avec l'état dominant annoté que dans 46 % des cas ($V = 0{,}437$). Conditionnellement à l'état détecté, le type journalisé n'est la famille canonique (Confusion → A, Ennui → C, Frustration → D, Engagement → D) que dans 44 % des cas (22/50). Sur les 56 % restants, seuls 6 cas (12 % du total) relèvent encore d'un voisin pédagogique admissible prévu par le modèle de décision (chapitre 3), les 22 autres (44 % du total) sortent de cet ensemble. L'ensemble admissible — canonique inclus — couvre donc 56 % des clips. Le V de Cramér état fusionné × famille observée (tableau 5.11) vaut 0,412 : association modérée, loin d'une fonction déterministe. La pertinence telle que l'apprenant la verrait n'est garantie que si la perception est juste.

Le tableau 5.11 présente la contingence état fusionné × famille.

État fusionné	**A**	**B**	**C**	**D**
Ennui	5	2	2	3
Confusion	4	0	0	2
Engagement	0	3	0	6
Frustration	1	3	9	10

Table 5.11 – Contingence état fusionné × famille ($n = 50$).

Cette analyse quantifie la correspondance observée, sans juger si elle est pédagogiquement souhaitable au-delà des familles retenues.

5.4.2 Couverture des états d'engagement

La cascade a été appliquée aux cinquante scénarios. Le tirage sur-représente les états problématiques (confusion, frustration, état critique), les quatre états DAiSEE et les

quatre familles A–D sont néanmoins atteints (tableau 5.12 : onze patrons distincts). Les taux de ce tableau ne sont pas des taux attendus en population. Onze patrons sur vingt sont déclenchés, les absents (A4, B3–B5, C3–C5, D3, D5) sont surtout des sous-types rares, pas des familles manquantes.

Le tableau 5.12 présente la distribution des patrons sur les cinquante scénarios.

Type	**Patrons observés**	n
A — explication	A1 (4), A2 (2), A3 (2), A5 (2)	10
B — exemple	B1 (4), B2 (4)	8
C — exercice	C1 (9), C2 (2)	11
D — encouragement	D1 (11), D2 (5), D4 (5)	21

Table 5.12 – Distribution des patrons (50 scénarios).

Les patrons absents de ce tableau ne sont pas déclenchés par cet échantillon de scénarios statiques, plusieurs n'apparaissent que sur parcours multi-clips ou dans le corpus généré.

Couverture temporelle : Les règles d'urgence ne s'observent pas sur un clip isolé. Dix séquences de cinq extraits du même apprenant DAiSEE (engagement stable, ennui progressif, frustration montante, confusion, état critique) font parcourir toutes les fenêtres (immédiate, rapide, différée). Chaque extrait traverse le pipeline produit, l'historique des scores détectés alimente les règles. Validation fonctionnelle, pas une étude longitudinale.

5.5 Validation de la qualité du contenu généré

La chaîne (perception simulée, décision, LLM + RAG) a produit environ 220 contenus. Cette section rapporte l'ancrage documentaire, l'évaluation enseignante ($n = 3 \times 8$), les métriques automatiques et la comparaison par type A/B/C/D.

5.5.1 Ancrage documentaire (RAG)

L'index de vingt fiches a été évalué sur 19 questions ($k = 3$). Le MRR global vaut 1,0 et le score top-1 moyen 0,661. Le tableau 5.13 présente le Hit@k et la précision $P@k$ par concept.

Concept	n	**Hit@k**	**P@k**
Algorithmes de tri	4	1,00	0,917
Réseaux de neurones	3	1,00	1,000
Encouragement	3	1,00	1,000
Structures de données	3	1,00	0,667
Complexité algorithmique	3	1,00	0,556
Récursion	3	1,00	0,333
Global	19	1,00	0,754

Table 5.13 – Récupération RAG.

Le MRR de 1,0 indique que le premier document renvoyé appartient au concept visé. La précision $P@k$ plus faible sur la récursion (0,333) traduit des collisions avec d'autres fiches (tri, encouragement).

5.5.2 Évaluation experte (3 enseignants × 8 exemples)

Trois enseignants d'informatique ont noté 8 textes (deux extraits par famille A/B/C/D, Likert Q1–Q6), sans utiliser le prototype (24 grilles).

Le tableau 5.14 présente la grille L2 renseignée par les enseignants.

Critère	**M**	**ET**
Q1 Pertinence	3,83	0,76
Q2 Clarté	3,92	0,83
Q3 Adéquation à l'état	3,83	0,70
Q4 Qualité pédagogique	4,12	0,90
Q5 Utilisable en ligne	4,08	0,72
Q6 Factualité	3,62	0,71

Table 5.14 – Grille L2, $n = 3$ enseignants × 8 textes (Likert 1–5).

Moyenne globale ≈ 3,9/5. Q4 et Q5 sont les plus hauts, Q6 (erreurs factuelles) est le plus bas.

5.5.3 Métriques automatiques (lisibilité, longueur, diversité)

Sur $N = 208$ contenus (12 lignes de l'audit 220 n'ont pas d'export de forme) :

— **Longueur** : 222 mots en moyenne (min. 113, max. 410, médiane 216), 83 % dans la cible du patron.
— **Lisibilité** (Kandel–Moles) : 95,0 (textes accessibles).
— **Diversité / régularité** : taux de répétition moyen 0,479, BLEU-4 interne 0,139 et ROUGE-1 0,449 ($N = 189$, référence = contenu médian du même patron, sans étiquette experte).
— **Audit heuristique** : 97,7 % conformes (215/220), après régénération sélective (chapitre 4).

Ces indicateurs contrôlent la forme et la stéréotypie interne. Ils ne remplacent pas Q1–Q6, ils les complètent (forme vs jugement enseignant sur 8 extraits).

5.5.4 Analyse comparative par type de contenu

Les quatre familles se distinguent comme prévu par les patrons (tableau 5.15) : D le plus court et le plus stéréotypé, C le plus long et le plus variable, A et B intermédiaires. Les cibles de longueur sont respectées en moyenne. C5 n'a aucune entrée dans le corpus.

Le tableau 5.15 présente la comparaison des contenus par type.

Type	n	**Mots**	**BLEU-4**	ROUGE-1
A — explication	51	230	0,119	0,426
B — exemple	43	250	0,127	0,432
C — exercice	48	286	0,099	0,418
D — encouragement	66	151	0,190	0,498

Table 5.15 – Comparaison par type de contenu (forme $N = 208$, similarité $N = 189$).

Le tableau 5.16 présente ces longueurs rapportées aux cibles déclarées par chaque famille de patron.

Famille	n	**Mots (moy.)**	**Cible (mots)**
A	51	230,0	150–280
B	43	250,1	180–320
C	48	286,2	200–360
D	66	151,3	100–220

Table 5.16 – Longueurs par famille de patron.

Quelques patrons s'écartent de la moyenne de leur famille. A4 (310 mots) dépasse la cible A (150–280), C3 (190) reste sous la cible C (200–360), C2 (356) atteint le plafond de cette cible. Les encouragements D1, D4 et D5 se situent autour de 130 mots.

Le tableau 5.17 présente la similarité interne, mesurée par rapport au contenu médian du même patron ($N = 189$, dix-neuf patrons).

	Global	**Type A**	**Type C**	**Type D**
BLEU-4	0,139	0,119	0,099	0,190
ROUGE-1 F1	0,449	0,426	0,418	0,498
ROUGE-2 F1	0,176	0,146	0,140	0,230
ROUGE-L F1	0,272	0,248	0,240	0,324

Table 5.17 – Similarité interne des contenus.

Le type D présente la plus faible diversité lexicale interne, le type C la plus élevée. Ces scores mesurent une similarité de forme, distincte d'une qualité pédagogique.

5.6 Validation utilisateur

Cette section rapporte l'enquête d'idée ($n = 15$) et une simulation qui documente l'observabilité du prototype.

5.6.1 Simulation de parcours adaptatifs

Le parcours est simulé sur les dix séquences déjà décrites (couverture temporelle) : chaque extrait alimente l'historique des scores détectés. Le protocole reste une simulation de parcours.

Le prototype React rend la chaîne observable comme le ferait une session pilote : clip (vidéo DAiSEE + voix IEMOCAP appariée), parcours multi-clips, état détecté, décision, contenu (sources RAG), tuteur dont le ton dépend de l'état, aperçu SER WavLM distinct de l'annotation corpus, export PDF et journal SQLite. Cette simulation montre que le parcours adaptatif est exécutable, elle ne mesure pas l'acceptabilité.

5.6.2 Enquête d'acceptabilité de l'idée ($n = 15$)

Quinze étudiants ont renseigné un formulaire autonome, sans ouvrir le prototype. Les items Likert (utilité perçue, maintien dans le cours, satisfaction, acceptation d'une captation) et le SUS (Brooke, 1996) portent sur l'idée décrite, formulée au conditionnel. Le pilote C1/C2 et un SUS après usage restent en perspective.

Les répondants se situent du niveau L1 au master ou cycle d'ingénieur, la familiarité déclarée avec les MOOC vaut $M = 3{,}33$ sur une échelle 1–5. Les libellés et la formule du SUS imaginé figurent aux tableaux B.1 et B.2.

Le tableau 5.18 présente les moyennes et écarts-types de l'enquête.

Mesure	**Échelle**	**M**	**ET**
Utilité perçue de l'adaptation	1–7	4,60	1,40
Rester dans le cours	1–7	4,80	1,37
Satisfaction	1–7	5,07	1,16
Acceptation webcam / micro	1–7	4,87	1,06
SUS imaginé	0–100	61,0	9,1

Table 5.18 – Enquête d'idée ($n = 15$). SUS ≥ 68 : 3/15.

Les moyennes Likert se situent autour de 5/7. Le SUS moyen (61) demeure sous le seuil 68 retenu pour un usage réel, trois participants l'atteignent (80, 70, 77,5). Deux copies peu différenciées (presque tout à 1, tout à 3 sur le SUS) sont conservées, avec mention. Les champs ouverts sont repris à la section 5.7.

5.7 Synthèse des résultats

Le tableau 5.19 présente les métriques retenues aux quatre niveaux. Les lignes du banc aligné reprennent le tableau 5.7. Le V de Cramér de l'association état × famille vaut 0,965 lorsque l'entrée est le label annoté, et 0,412 lorsque l'entrée est l'état fusionné. L2 ($n = 3 \times 8$) et l'enquête ($n = 15$) sont rapportées par des moyennes et des écarts-types.

Composant	**Métrique clé**	**Valeur**
FER+AU (juge produit, test éq.)	F1 macro	0,37
FER+AU — rappel Fru. / Conf.	Rappel	34 % / 34 %
ViT fine-tuné complet (filtre)	F1 macro	0,39
WavLM DAiSEE tête (retenu)	F1 val.	0,434
WavLM DAiSEE complet (ablation)	F1 val.	0,396
Banc aligné — vote (stack produit)	Accuracy / rappel urgents	0,487 / 0,350
Proxy produit (50 scénarios)	Acc. vs état dominant	0,46
Correspondances ($n = 50$)	Famille GT / patron exact	98 % / 82 %
Correspondances	État GT vs fusion / type admissible	46 % / 56 %
Correspondances	V de Cramér état fusionné × famille	0,412

Composant	**Métrique clé**	**Valeur**
Appariement + acoustique	Δ similarité / voix changées	+0,020 / 80 %
Corpus généré (LLM + RAG)	Audit OK	97,7 %
Forme du corpus ($N = 208$)	Longueur moy. / Kandel–Moles	222 mots / 95,0
Similarité interne ($N = 189$)	BLEU-4 / ROUGE-1	0,139 / 0,449
Enquête d'idée ($n = 15$)	SUS imaginé (moy.)	61,0
L2 enseignants ($n = 3$, 8 textes)	Likert Q1–Q6 (moy.)	3,9/5

Table 5.19 – Synthèse des résultats.

5.7.1 Retours qualitatifs

Les champs ouverts de l'enquête ($n = 15$) sont rarement renseignés. Les verbatims disponibles portent sur l'utilité perçue d'un contenu qui suivrait l'engagement, sur la captation (opt-in, explication des données) et sur le besoin d'une authentification. Une mention « Erreur de contenu » reste sans précision. Un enseignant ($n = 3$) signale, sur l'extrait A4, un parallèle abusif tri / recherche et une métaphore peu claire, en ligne avec Q6 comme critère le plus bas.

5.8 Discussion

5.8.1 Lecture des mesures

Sur DAiSEE, l'engagement domine la distribution (Gupta et al., 2016). Une accuracy élevée sur un test non stratifié peut masquer un rappel nul des états qui justifient une intervention. Les métriques retenues sont le F1 macro et le rappel de la confusion et de la frustration. L'accuracy 0,72 du Random Forest déséquilibré décrit la classe majoritaire.

La cascade engagement $\rightarrow$ stratégie est presque déterministe dès que l'état d'entrée est le label annoté : 98 % des familles et 82 % des patrons exacts sur le référentiel ($n = 50$). Lorsque l'entrée est l'état fusionné, l'accord d'état tombe à 46 % et le type admissible à 56 %. L'adaptation servie à l'apprenant dépend d'abord de la perception.

La forme du corpus est contrainte par les patrons, le RAG et l'audit (97,7 %). Les enseignants notent plus haut la qualité pédagogique et l'utilisabilité en ligne (Q4–Q5, vers 4,1/5) que la factuelité (Q6). Le vote à incertitude, l'index acoustique et l'ancrage documentaire encodent ces arbitrages.

5.8.2 Positionnement

Les scores de perception restent inférieurs aux benchmarks FER et SER rapportés pour des taxonomies émotionnelles plus larges (Busso et al., 2008 ; Chen et al., 2022). La tâche visée est une projection vers quatre états pédagogiques, à partir de corpus hétérogènes. En production, visage et voix n'appartiennent pas au même locuteur, le banc aligné isole l'apport de la fusion hors de ce biais. Conformément à la recherche orientée conception (Hevner et al., 2004), la contribution retenue est une architecture reproductible, deux cadres d'évaluation distincts, et l'explicitation des compromis.

5.8.3 Portée et limites

Le prototype exécute la chaîne spécifiée et en journalise les maillons : état, sources RAG, aperçu SER distinct de l'annotation. Le banc aligné ($n = 80$) compare les fusions sur des paires synchronisées. L'appariement vocal est évalué en A/B, les ablations du ViT et de WavLM documentent le juge retenu.

Le protocole reste une simulation sur corpus. L'appariement visage–voix du pipeline produit est hétérogène. Le mapping IEMOCAP → DAiSEE déplace jusqu'à 17 % des énoncés selon la variante. Le F1 facial du juge s'établit à 0,37. Le proxy produit se réfère à l'état dominant DAiSEE. La grille L2 porte sur huit extraits, l'enquête ($n = 15$) porte sur l'idée. L'index RAG compte vingt fiches. L1, le pilote C1/C2 et les 58 fiches L2 sont reportés en perspective.

5.9 Conclusion

La validation porte sur la perception et la fusion, le mapping état → stratégie, la forme du corpus et l'acceptabilité de l'idée. Le juge FER+AU atteint un F1 macro de 0,37, la tête WavLM un F1 de 0,434. Le vote à incertitude obtient, sur le banc aligné ($n = 80$), une accuracy de 0,487 et un rappel urgent de 0,350. Sur le référentiel ($n = 50$), la famille concorde avec le label annoté à 98 % et l'état fusionné à 46 %.

Le corpus ($N = 208$ pour la forme) passe l'audit à 97,7 %. Trois enseignants notent huit extraits à 3,9/5 en moyenne. Quinze étudiants évaluent l'idée : le SUS imaginé vaut 61. Chaque score de fusion se lit dans son cadre, produit apparié ou banc synchronisé. L1 et le pilote C1/C2 sont reportés en perspective. La conclusion générale dresse le bilan de ces mesures.

Conclusion générale

Le mémoire a conçu, implémenté et évalué le prototype EmoLearn : une chaîne unique qui relie la perception multimodale de l'engagement, une décision pédagogique explicite et une génération de contenu ancrée dans des sources documentaires. La validation a été conduite en simulation sur corpus (DAiSEE, IEMOCAP). Elle ne mesure pas une réduction du décrochage sur une plateforme réelle, elle documente ce que la chaîne fait, et où elle échoue (chapitre 5).

Les résultats se lisent sur trois plans. En perception, le juge FER+AU atteint un F1 macro de 0,37 (contre 0,19 pour le mapping heuristique), la tête de classification WavLM se situe à 0,434. Sur le banc audiovisuel aligné, le vote à incertitude obtient 0,487 d'accuracy et 0,350 de rappel des états urgents : la fusion améliore ce rappel par rapport à une modalité seule, sans établir une exactitude élevée. En décision, la cascade engagement $\rightarrow$ adaptation est exécutable et journalisée, sur le référentiel ($n = 50$), la famille de contenu suit l'état de vérité à 98 %, tandis que l'état fusionné ne concorde qu'à 46 %. En génération, environ 220 textes passent l'audit de forme à 97,7 %, le fond pédagogique n'est étayé que par la grille L2 ($n = 3$ enseignants, 8 extraits).

Ces constats bornent la réponse aux questions de recherche. Une telle chaîne est réalisable et évaluable. Les scores de perception restent modestes. Les validations enseignantes et usagers sont encore incomplètes. La contribution retenue n'est donc pas un gain de performance isolé, mais une architecture dont chaque maillon laisse une trace inspectable.

Synthèse des contributions

La chaîne, conçue au chapitre 3 et implémentée au chapitre 4, relie un juge FER+AU, un SER WavLM hybride, une fusion 60/40 à incertitude, vingt patrons et un LLM ancré par RAG. Deux pipelines partagent ce moteur (produit et banc d'essai). Les livrables se déclinent en cinq axes (C1–C5).

— **C1 — Architecture de bout en bout.** Le prototype relie une API FastAPI et une interface React (modes clip, séquence, tuteur et RAG). La décision pédagogique est produite par le runtime, et non par un script hors ligne.

— **C2 — Modèle engagement → adaptation.** L'adaptation combine une cascade A/B/C/D, vingt patrons, des règles temporelles et la possibilité d'une non-intervention lorsque l'intervention n'est pas justifiée. Les familles A à D sont toutes représentées sur le référentiel (D1, C1, D2/D4, A1 et B1 étant les plus fréquents). Le dispositif ne constitue pas un tuteur intelligent complet.

— **C3 — Perception apprise, avec ablations.** Le juge FER+AU atteint un F1 macro de 0,37, contre 0,19 pour le mapping heuristique, le ViT fine-tuné (F1 0,39) sert de filtre. La tête WavLM obtient un F1 de 0,434, supérieur à celui du backbone complet (0,396). L'index acoustique améliore le score de $\Delta + 0{,}020$: 80 % des voix sont substituées, avec un alignement d'état de 100 %.

— **C4 — Génération guidée et ancrée.** Environ 220 contenus passent l'audit de forme à 97,7 % (208 textes retenus pour les métriques). La forme est stable (222 mots en moyenne, indice de Kandel–Moles 95,0). Les scores BLEU et ROUGE mesurent une cohérence interne, en l'absence d'une référence rédigée par des enseignants. Le RAG s'appuie sur vingt fiches, une hallucination résiduelle, encore mesurable, est illustrée sur l'extrait D2.

— **C5 — Évaluation instrumentée, avec limites explicites.** L'évaluation comprend quatre niveaux. Sur les correspondances ($n = 50$), la famille suit la vérité terrain à 98 %, l'état fusionné à 46 % et le type admissible à 56 %. Le niveau L1 n'est pas scoré, L2 porte sur huit extraits notés par trois enseignants, L4 est une enquête d'idée ($n = 15$), le pilote C1/C2 n'ayant pas été administré. Sur le banc aligné rejoué (FER+AU, WavLM), l'accuracy vaut 0,487 et le rappel des états urgents 0,350. L'accuracy 0,72 du premier classifieur facial, obtenue sur un corpus déséquilibré, n'est pas le résultat retenu.

Limites de l'étude

Ces limites conditionnent la lecture des contributions (chapitre 5).

— **Cadre.** L'étude ne porte ni sur un apprenant réel, ni sur une captation en conditions vives, ni sur une mesure d'apprentissage. Toute extrapolation vers un tuteur MOOC en production serait abusive.

— **Données.** En production, l'appariement visage–voix reste hétérogène. Le mapping IEMOCAP → DAiSEE est sensible jusqu'à 17 % des énoncés. Le corpus DAiSEE est déséquilibré.

— **Modèles.** Les unités d'action faciale sont des descripteurs proxy, le SER est hybride et empirique, le LLM n'est pas fine-tuné, le RAG se limite à vingt fiches.
— **Évaluation.** Aucune vérité terrain multimodale n'a été produite. Le niveau L1 n'a pas été exécuté. L2 se limite à trois enseignants et huit extraits, et non aux 58 fiches. Le pilote C1/C2 ($n = 30$ visé) n'a pas été administré, l'enquête d'idée ($n = 15$) fournit un score SUS de 61, obtenu sur un usage hypothétique. BLEU et ROUGE sont calculés sans référence enseignante sur l'ensemble du corpus.
— **Éthique.** Les questions de consentement, de biais et de profilage affectif demeurent. L'absence de captation en conditions vives réduit une partie du risque, mais ôte aussi la validité écologique.

En particulier, le prototype n'établit pas qu'une fusion multimodale en production surpasse une modalité unique sous une vérité terrain conjointe. Il n'établit pas davantage que le contenu généré améliore l'apprentissage, ni qu'il réduise le décrochage dans un MOOC, ni qu'un alignement visage–voix sur la même personne vaille hors du banc d'essai.

Perspectives de recherche

Les perspectives sont ordonnées par le gain de preuve, et non par l'attrait technologique. Aucune ne devrait précéder la collecte L1/L2 : un meilleur F1 facial, obtenu sur un mapping non validé par des enseignants, n'améliorerait que la cohérence interne du prototype.

— **À court terme.** Une validation par experts pédagogiques (L1) reste prioritaire : Delphi simplifié, deux tours, trois experts (sciences de l'éducation, ingénierie pédagogique, e-learning). Le matériel comprend la matrice engagement–adaptation, vingt fiches de patrons et quinze cas tests stratifiés, avec des items Likert 1–5 (C1 à C4, instruments : annexe Niveau 1). Il convient ensuite de compléter L2 sur les 58 fiches et de recaler le seuil d'intervention du pipeline produit (rappel urgent 1,00 au proxy).
— **À moyen terme.** Un réentraînement de FER et de SER n'est justifié que si le F1 des classes rares progresse sans que les prédictions ne se concentrent à nouveau sur la classe majoritaire (Engagement). Une fusion apprise n'est recevable qu'à condition de préserver le journal. Un corpus audiovisuel d'apprentissage aligné et un RAG étendu au matériau d'un vrai cours constitueraient ensuite des gains de validité.
— **À plus long terme.** Un pilote utilisateurs C1/C2 (intra-sujet, $n = 30$ visé) comparerait un contenu statique (C1) au contenu EmoLearn (C2), avec des items Likert 1–7 puis un SUS après usage réel (seuil visé 68). Une captation en conditions vives

ne serait envisageable que dans un cadre éthique strict, un fine-tuning d'un modèle open-weight francophone, sous contrainte de patrons, resterait optionnel.

Sur le plan pratique, l'usage réaliste d'EmoLearn est une couche additionnelle pendant une vidéo : estimer un état, décider d'intervenir ou non, proposer un contenu court ancré dans le cours. Les approches fondées sur les forums restent complémentaires. Le journal (état, patron, sources RAG) rend la décision relisible. Un usage responsable suppose un consentement granulaire, une non-intervention fréquente, et un RAG dont les sources coïncident avec les documents du cours.

— **Poursuite du prototype.** Les niveaux L1 et L2 doivent précéder tout nouvel entraînement. La séparation des deux pipelines doit être conservée dans toute publication. Le RAG doit être étendu au cours cible avant d'élargir les disciplines.

— **Recherche en EIAH et informatique affective.** Les publications devraient documenter la chaîne complète, et non les seuls scores F1. Les mappings doivent être présentés comme des hypothèses de construit, et non comme des équivalences psychologiques. Le contenu généré doit être évalué avec des grilles enseignantes. Le mot « multimodal » ne devrait désigner que les protocoles qui précisent si les modalités sont alignées ou appariées.

— **Praticiens de la formation en ligne.** Il n'est pas raisonnable d'attendre un détecteur parfait. Toute captation affective doit être traitée comme une donnée sensible. L'IA générative peut rédiger sous contrainte, elle ne doit pas décider seule de l'intervention pédagogique.

Bibliographie

[Abedi et Khan, 2021] Abedi, A. et S. S. Khan (2021). Improving state-of-the-art in Detecting Student Engagement with ResNet and TCN Hybrid Network. In : *18th Conference on Robots and Vision (CRV)*, p. 151-157.

[Baevski et al., 2020] Baevski, A., Y. Zhou, A. Mohamed et M. Auli (2020). wav2vec 2.0 : A Framework for Self-Supervised Learning of Speech Representations. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33, p. 12449-12460.

[Baker et al., 2010] Baker, R. S. J. d., S. K. D'Mello, M. M. T. Rodrigo et A. C. Graesser (2010). Better to Be Frustrated than Bored. *International Journal of Human-Computer Studies* 68.4, p. 223-241.

[Bond et al., 2024] Bond, M., H. Khosravi, M. De Laat, N. Bergdahl, V. Negrea, E. Oxley, P. Pham, S. W. Chong et G. Siemens (2024). A meta systematic review of artificial intelligence in higher education : a call for increased collaboration, equality, and research. *International Journal of Educational Technology in Higher Education* 21, p. 4.

[Breslow et al., 2013] Breslow, L., D. E. Pritchard, J. DeBoer, G. S. Stump, A. D. Ho et D. T. Seaton (2013). Studying Learning in the Worldwide Classroom : Research into edX's First MOOC. *Research & Practice in Assessment* 8, p. 13-25.

[Brooke, 1996] Brooke, J. (1996). SUS : A Quick and Dirty Usability Scale. In : *Usability Evaluation in Industry*. Sous la dir. de P. W. Jordan, B. Thomas, B. A. Weerdmeester et I. L. McClelland. London : Taylor & Francis, p. 189-194.

[Brown et al., 2020] Brown, T. B., B. Mann, N. Ryder, M. Subbiah et al. (2020). Language Models are Few-Shot Learners. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33, p. 1877-1901.

[Busso et al., 2008] Busso, C., M. Bulut, C.-C. Lee, A. Kazemzadeh, E. Mower, S. Kim, J. N. Chang, S. Lee et S. S. Narayanan (2008). IEMOCAP : Interactive Emotional Dyadic Motion Capture Database. *Language Resources and Evaluation* 42.4, p. 335-359.

[Chen et al., 2022] Chen, S., C. Wang, Z. Chen, Y. Wu, S. Liu et al. (2022). WavLM : Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing. *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 30, p. 2398-2413.

[Chen et Rudnicky, 2023] Chen, L.-W. et A. Rudnicky (2023). Exploring Wav2vec 2.0 Fine Tuning for Improved Speech Emotion Recognition. In : *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*.

[Chi et Wylie, 2014] Chi, M. T. H. et R. Wylie (2014). The ICAP Framework : Linking Cognitive Engagement to Active Learning Outcomes. *Educational Psychologist* 49.4, p. 219-243.

[Conati et al., 2021] Conati, C., O. Barral, V. Putnam et L. Rieger (2021). Toward personalized XAI : A case study in intelligent tutoring systems. *Artificial Intelligence* 298, p. 103503.

[Csikszentmihalyi, 1990] Csikszentmihalyi, M. (1990). *Flow : The Psychology of Optimal Experience*. New York : Harper & Row.

[D'Mello et Graesser, 2012] D'Mello, S. et A. Graesser (2012). Dynamics of Affective States during Complex Learning. *Learning and Instruction* 22.2, p. 145-157.

[D'Mello, 2013] D'Mello, S. K. (2013). A Selective Meta-Analysis on the Relative Incidence of Discrete Affective States during Learning with Technology. *Journal of Educational Psychology* 105.4, p. 1082-1099.

[Daniel, 2012] Daniel, J. (2012). Making Sense of MOOCs : Musings in a Maze of Myth, Paradox and Possibility. *Journal of Interactive Media in Education* 2012.3, p. 18.

[Dhall et al., 2018] Dhall, A., A. Kaur, R. Goecke et T. Gedeon (2018). EmotiW 2018 : Audio-Video, Student Engagement and Group-Level Affect Prediction. In : *Proceedings of the 20th ACM International Conference on Multimodal Interaction*, p. 653-656.

[Dosovitskiy et al., 2021] Dosovitskiy, A., L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit et N. Houlsby (2021). An Image is Worth 16x16 Words : Transformers for Image Recognition at Scale. In : *International Conference on Learning Representations (ICLR)*.

[Dubey et al., 2024] Dubey, A., A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Yang, A. Fan et al. (2024). The Llama 3 Herd of Models. *arXiv preprint arXiv :2407.21783*.

[Fan et al., 2024] Fan, W., Y. Ding, L. Ning, S. Wang, H. Li, D. Yin, T.-S. Chua et Q. Li (2024). A Survey on RAG Meeting LLMs : Towards Retrieval-Augmented Large Language Models. In : *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, p. 6491-6501.

[Fredricks et al., 2004] Fredricks, J. A., P. C. Blumenfeld et A. H. Paris (2004). School Engagement : Potential of the Concept, State of the Evidence. *Review of Educational Research* 74.1, p. 59-109.

[Gandhi et al., 2023] Gandhi, A., K. Adhvaryu, S. Poria, E. Cambria et A. Hussain (2023). Multimodal sentiment analysis : A systematic review of history, datasets, fusion methods, applications, challenges and opportunities. *Information Fusion* 91, p. 424-444.

[Gao et al., 2023] Gao, Y., Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, M. Wang et H. Wang (2023). Retrieval-Augmented Generation for Large Language Models : A Survey. *arXiv preprint arXiv :2312.10997*.

[Garrison et al., 1999] Garrison, D. R., T. Anderson et W. Archer (1999). Critical Inquiry in a Text-Based Environment : Computer Conferencing in Higher Education. *The Internet and Higher Education* 2.2–3, p. 87-105.

[Goldberg et al., 2021] Goldberg, P., Ö. Sümer, K. Stürmer, W. Wagner, R. Göllner, P. Gerjets, E. Kasneci et U. Trautwein (2021). Attentive or Not ? Toward a Machine Learning Approach to Assessing Students' Visible Engagement in Classroom Instruction. *Educational Psychology Review* 33, p. 27-49.

[Graesser, 2020] Graesser, A. C. (2020). Emotions are the experiential glue of learning environments in the 21st century. *Learning and Instruction* 70, p. 101212.

[Gupta et al., 2016] Gupta, A., A. D'Cunha, K. Awasthi et V. Balasubramanian (2016). DAiSEE : Towards User Engagement Recognition in the Wild. *arXiv preprint arXiv :1609.01885*.

[Gupta et al., 2023] Gupta, S., P. Kumar et R. Tekchandani (2023). A multimodal facial cues based engagement detection system in e-learning context using deep learning model. *Multimedia Tools and Applications* 82, p. 28545-28574.

[Hevner et al., 2004] Hevner, A. R., S. T. March, J. Park et S. Ram (2004). Design Science in Information Systems Research. *MIS Quarterly* 28.1, p. 75-105.

[Hew, 2016] Hew, K. F. (2016). Promoting Engagement in Online Courses : What Strategies Can We Learn from Three Highly Rated MOOCs. *British Journal of Educational Technology* 47.2, p. 320-341.

[Holmes et Tuomi, 2022] Holmes, W. et I. Tuomi (2022). State of the art and practice in AI in education. *European Journal of Education* 57.4, p. 542-570.

[Hu et Shao, 2025] Hu, W. et Z. Shao (2025). Design and Evaluation of a GenAI-based Personalized Educational Content System Tailored to Personality Traits and Emotional Responses for Adaptive Learning. *Computers in Human Behavior Reports* 19, p. 100735.

[Hu et al., 2021] Hu, Y., R. Ferreira Mello et D. Gašević (2021). Automatic Analysis of Cognitive Presence in Online Discussions : An Approach Using Deep

Learning and Explainable Artificial Intelligence. *Computers and Education : Artificial Intelligence* 2, p. 100037.

[Hutt et al., 2021] Hutt, S., K. Krasich, C. Mills, N. Bosch, S. White, J. R. Brockmole et S. K. D'Mello (2021). Automated gaze-based mind wandering detection during computerized learning in classrooms. *User Modeling and User-Adapted Interaction* 31, p. 821-877.

[Jordan, 2015] Jordan, K. (2015). Massive Open Online Course Completion Rates Revisited : Assessment, Length and Attrition. *The International Review of Research in Open and Distributed Learning* 16.3, p. 341-358.

[Kasneci et al., 2023] Kasneci, E., K. Sessler, S. Küchemann, M. Bannert et al. (2023). ChatGPT for Good ? On Opportunities and Challenges of Large Language Models for Education. *Learning and Individual Differences* 103, p. 102274.

[Kizilcec et al., 2013] Kizilcec, R. F., C. Piech et E. Schneider (2013). Deconstructing Disengagement : Analyzing Learner Subpopulations in Massive Open Online Courses. In : *Proceedings of LAK '13*, p. 170-179.

[Kong et al., 2025] Kong, X., Z. Liu, C. Chen, S. Liu, Z. Xu et Q. Tang (2025). Exploratory Study of an AI-supported Discussion Representational Tool for Online Collaborative Learning in a Chinese University. *The Internet and Higher Education* 64, p. 100973.

[Latif et al., 2023] Latif, S., R. Rana, S. Khalifa, R. Jurdak, J. Qadir et B. W. Schuller (2023). Survey of Deep Representation Learning for Speech Emotion Recognition. *IEEE Transactions on Affective Computing* 14.2, p. 1634-1654.

[Lewis et al., 2020] Lewis, P., E. Perez, A. Piktus et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33, p. 9459-9474.

[Li et Deng, 2022] Li, S. et W. Deng (2022). Deep Facial Expression Recognition : A Survey. *IEEE Transactions on Affective Computing* 13.3, p. 1195-1215.

[Liang et al., 2024] Liang, P. P., A. Zadeh et L.-P. Morency (2024). Foundations and Trends in Multimodal Machine Learning : Principles, Challenges, and Open Questions. *ACM Computing Surveys* 56.10, p. 1-42.

[Liu et al., 2023a] Liu, P., W. Yuan, J. Fu, Z. Jiang, H. Hayashi et G. Neubig (2023a). Pre-train, Prompt, and Predict : A Systematic Survey of Prompting Methods in Natural Language Processing. *ACM Computing Surveys* 55.9, p. 1-35.

[Liu et al., 2022] Liu, S., S. Liu, Z. Liu, X. Peng et Z. Yang (2022). Automated Detection of Emotional and Cognitive Engagement in MOOC Discussions to Predict Learning Achievement. *Computers & Education* 181, p. 104461.

[Liu et al., 2025] Liu, S., S. Liu, L. Sha, Z. Zeng, D. Gašević et Z. Liu (2025). Annotation Guideline-Based Knowledge Augmentation : Toward Enhancing Large

Language Models for Educational Text Classification. *IEEE Transactions on Learning Technologies* 18, p. 619-634. DOI : 10.1109/TLT.2025.3570775.

[Liu et al., 2023b] Liu, Z., X. Kong, H. Chen, S. Liu et Z. Yang (2023b). MOOC-BERT : Automatically Identifying Learner Cognitive Presence From MOOC Discussion Data. *IEEE Transactions on Learning Technologies* 16.4, p. 528-541.

[Liu et al., 2021] Liu, Z., N. Zhang, X. Peng, S. Liu, Z. Yang, J. Peng, Z. Su et J. Chen (2021). Exploring the Relationship Between Social Interaction, Cognitive Processing and Learning Achievements in a MOOC Discussion Forum. *Journal of Educational Computing Research*. DOI : 10.1177/07356331211027300.

[Lo, 2023] Lo, C. K. (2023). What Is the Impact of ChatGPT on Education ? A Rapid Review of the Literature. *Education Sciences* 13.4, p. 410.

[Loderer et al., 2020] Loderer, K., R. Pekrun et J. C. Lester (2020). Beyond cold technology : A systematic review and meta-analysis on emotions in technology-based learning environments. *Learning and Instruction* 70, p. 101162.

[Mayer, 2021] Mayer, R. E. (2021). *Multimedia Learning*. 3e éd. Cambridge : Cambridge University Press.

[Onah et al., 2014] Onah, D. F. O., J. Sinclair et R. Boyatt (2014). Dropout Rates of Massive Open Online Courses : Behavioural Patterns. In : *EDULEARN14 Proceedings*, p. 5825-5834.

[Ouyang et al., 2022] Ouyang, L., J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. Schulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askell, P. Welinder, P. Christiano, J. Leike et R. Lowe (2022). Training language models to follow instructions with human feedback. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 35.

[Pedregosa et al., 2011] Pedregosa, F., G. Varoquaux, A. Gramfort, V. Michel et al. (2011). Scikit-learn : Machine Learning in Python. *Journal of Machine Learning Research* 12, p. 2825-2830.

[Pekrun, 2006] Pekrun, R. (2006). The Control-Value Theory of Achievement Emotions. *Educational Psychology Review* 18.4, p. 315-341.

[Pepino et al., 2021] Pepino, L., P. Riera et L. Ferrer (2021). Emotion Recognition from Speech Using wav2vec 2.0 Embeddings. In : *Proc. Interspeech*, p. 3400-3404.

[Picard, 1997] Picard, R. W. (1997). *Affective Computing*. Cambridge, MA : MIT Press.

[Reich et Ruipérez-Valiente, 2019] Reich, J. et J. A. Ruipérez-Valiente (2019). The MOOC Pivot. *Science* 363.6423, p. 130-131.

[Sakeef et al., 2025] Sakeef, N., M. A. A. Dewan, F. Lin et D. Parmar (2025). Detecting Cognitive Engagement in Online Course Forums : A Review of Frameworks and Methodologies. *Natural Language Processing Journal* 11, p. 100146.

[Sharma et Giannakos, 2020] Sharma, K. et M. Giannakos (2020). Multimodal data capabilities for learning : What can multimodal data tell us about learning ? *British Journal of Educational Technology* 51.5, p. 1450-1484.

[Sweller, 1988] Sweller, J. (1988). Cognitive Load During Problem Solving : Effects on Learning. *Cognitive Science* 12.4, p. 257-285.

[Sweller et al., 2019] Sweller, J., J. J. G. van Merriënboer et F. Paas (2019). Cognitive Architecture and Instructional Design : 20 Years Later. *Educational Psychology Review* 31, p. 261-292.

[Touvron et al., 2023] Touvron, H., T. Lavril, G. Izacard et al. (2023). LLaMA : Open and Efficient Foundation Language Models. *arXiv preprint arXiv :2302.13971*.

[UNESCO, 2023] UNESCO (2023). *Guidance for generative AI in education and research*. Rapp. tech. Paris : UNESCO.

[VanLehn, 2011] VanLehn, K. (2011). The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems. *Educational Psychologist* 46.4, p. 197-221.

[Vaswani et al., 2017] Vaswani, A., N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser et I. Polosukhin (2017). Attention Is All You Need. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 30, p. 5998-6008.

[Wagner et al., 2023] Wagner, J., A. Triantafyllopoulos, H. Wierstorf, M. Schmitt, F. Burkhardt, F. Eyben et B. W. Schuller (2023). Dawn of the Transformer Era in Speech Emotion Recognition : Closing the Valence Gap. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 45.9, p. 10745-10759.

[Wang et al., 2024] Wang, S., T. Xu, H. Li, C. Zhang, J. Liang, J. Tang, P. S. Yu et Q. Wen (2024). Large Language Models for Education : A Survey and Outlook. *arXiv preprint arXiv :2403.18105*.

[Wang et al., 2020] Wang, W., F. Wei, L. Dong, H. Bao, N. Yang et M. Zhou (2020). MiniLM : Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33, p. 5776-5788.

[Wei et al., 2022] Wei, J., X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. V. Le et D. Zhou (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 35.

[White et al., 2023] White, J., Q. Fu, S. Hays, M. Sandborn, C. Olea, H. Gilbert, A. Elnashar, J. Spencer-Smith et D. C. Schmidt (2023). A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT. *arXiv preprint arXiv :2302.11382*.

[Whitehill et al., 2014] Whitehill, J., Z. Serpell, Y.-C. Lin, A. Foster et J. R. Movellan (2014). The Faces of Engagement : Automatic Recognition of Student Engagement from Facial Expressions. *IEEE Transactions on Affective Computing* 5.1, p. 86-98.

[Xiong et al., 2024] Xiong, Y., X. Guo et J. Xu (2024). CNN-Transformer : A Deep Learning Method for Automatically Identifying Learning Engagement. *Education and Information Technologies* 29, p. 9989-10008.

[Yan et al., 2024] Yan, L., L. Sha, L. Zhao, Y. Li, R. Martinez-Maldonado, G. Chen, X. Li, Y. Jin et D. Gašević (2024). Practical and ethical challenges of large language models in education : A systematic scoping review. *British Journal of Educational Technology* 55.1, p. 90-112.

[Yang et al., 2021] Yang, S.-w., P.-H. Chi, Y.-S. Chuang, C.-I. J. Lai, K. Lakhotia, Y. Y. Lin, A. T. Liu, J. Shi, X. Chang, G.-T. Lin, T.-H. Huang, W.-C. Tseng, K.-t. Lee, D.-R. Liu, Z. Huang, S.-P. Fu, K.-Y. Chen, S. Arora, C.-F. Huang, W.-C. Lin, C.-H. Tsai, C.-C. Chen, C. Liu, H.-y. Lee et L.-s. Lee (2021). SUPERB : Speech processing Universal PERformance Benchmark. In : *Proc. Interspeech*, p. 1194-1198.

Annexe A

Tuteur conversationnel

Les vingt patrons A1–D5, y compris leurs consignes, figurent au tableau 3.8 du chapitre 3. Cette annexe ne conserve que le réglage du tuteur, distinct de la cascade de génération.

Le tuteur reprend le même identifiant de patron que la génération, mais avec un prompt système distinct, une température *par état* et un historique borné aux dix derniers tours. Le contenu adaptatif déjà affiché est injecté comme premier message, afin d'éviter la recopie mot à mot.

Températures par état. Le tableau A.1 présente le protocole du tuteur conversationnel.

État	T	**Consigne émotionnelle (extrait)**
Confusion	0,25	Décomposer en 2–3 micro-étapes, question de vérification.
Frustration	0,35	Valider l'effort, une seule action de déblocage.
Engagement	0,45	Approfondir, mini-défi, pensée critique.
Ennui	0,55	Cas réel, anecdote, éviter les longues définitions.

Table A.1 – Réglages du tuteur conversationnel.

Règles absolues du message système (extrait). Réponses uniquement en français, 3 à 8 phrases par défaut (jusqu'à 12 si l'apprenant demande un exemple ou un exercice), s'appuyer sur le RAG lorsqu'il est fourni, ne pas inventer de faits techniques, rester focalisé sur le concept en cours.

Annexe B

Questionnaires et protocoles d'évaluation

B.1 Enquête d'idée (exécutée, $n = 15$)

Quinze étudiants ont répondu (`https://questionnaire-etudiants.netlify.app`, source : `questionnaires/etudiants.html`) sans ouvrir le prototype. La page décrit EmoLearn en trois couches, puis pose les items au conditionnel. Résultats : tableau 5.18, fichier `results/forms/l4_enquete_idee_reponses.csv`.

Consignes (extrait). « Vous n'utilisez pas le prototype. Répondez seulement d'après la description, comme si cette idée existait dans un cours en ligne. » Consentement obligatoire, la page ne filme pas et n'enregistre ni webcam ni micro.

Le tableau B.1 présente les items de l'enquête d'idée.

Code	Item (libellé du formulaire)	Éch.
Profil	Niveau d'études (texte libre).	—
Familiarité	Familiarité avec les cours en ligne / MOOC (ancres : pas du tout — beaucoup).	1–5
Utilité	D'après la description (sans avoir testé le logiciel) : un contenu qui s'adapte à l'engagement me semblerait utile.	1–7
Rester dans le cours	D'après la description : un tel contenu m'aiderait à rester dans le cours.	1–7
Satisfaction	D'après la description : je serais satisfait(e) de recevoir ce type de texte pendant un module.	1–7
Acceptation captation	D'après la description : j'accepterais qu'une webcam / un micro estime mon engagement pendant un cours (données non stockées à des fins commerciales).	1–7

Code	Item (libellé du formulaire)	Éch.
Ouvertes	Qu'est-ce qui aiderait ? Qu'est-ce qui gênerait ? Une suggestion.	texte

Table B.1 – Enquête d'idée : profil, Likert et questions ouvertes.

Ancrage des Likert 1–7 : 1 = pas d'accord, 7 = tout à fait d'accord.

SUS imaginé. Dix items Brooke (1996), Likert 1–5, reformulés au conditionnel (titre du bloc : « Facilité d'usage imaginée »). Consignes : « Ces 10 questions ne portent pas sur un essai réel. Imaginez seulement le système décrit plus haut. » Score : items impairs ($v - 1$), items pairs ($5 - v$), somme $\times 2{,}5$ (intervalle 0–100). Ce n'est pas un SUS après usage.

Le tableau B.2 présente les items du questionnaire SUS.

Item	Libellé du formulaire
SUS 1	Je voudrais utiliser ce type de système fréquemment.
SUS 2	Je le trouverais inutilement complexe.
SUS 3	Je le trouverais facile à utiliser.
SUS 4	J'aurais besoin d'un support technique pour l'utiliser.
SUS 5	Les fonctions me sembleraient bien intégrées.
SUS 6	Il y aurait trop d'incohérences.
SUS 7	La plupart des gens l'apprendraient très rapidement.
SUS 8	Je le trouverais lourd à utiliser.
SUS 9	Je me sentirais en confiance en l'utilisant.
SUS 10	Il me faudrait apprendre beaucoup de choses avant de m'en servir.

Table B.2 – Enquête d'idée : SUS imaginé (10 items, 1–5).